Ecole supérieure d'agro-développement international
istom

Examen de statistiques et analyse de données

Mercredi 30 avril 2025

Promotion 115

Antoine Géré

Document(s) autorisé(s) : ☐ Oui ☒ Non Calculatrice autorisée : ☒ Oui ☐ Non

Remarques :

- Les exercices sont indépendants.
- Il sera tenu compte de la propreté de votre copie, ainsi que de la clarté et de la qualité de la rédaction et du raisonnement.
- **Ne pas écrire avec un crayon papier**, sauf pour dessiner et/ou annoter des croquis, le cas échéant.
- Utiliser les **notations** indiquées dans le texte et **justifier toutes vos réponses**.
- Le sujet est à conserver par l'étudiant-e.

Exercice 1

On dispose des résultats d'une enquête concernant l'âge et les loisirs d'une population de 20 personnes :

Age	12	14	40	35	26	30	30	50	75	50	30	45	25	55	28	25	50	40	25	35
Loisir	S	S	C	C	S	T	T	L	L	L	T	C	C	C	S	L	L	C	T	T

Codification :

- S : Sport
- C : Cinéma
- T : Théâtre
- L : Lecture

1. Dans cette question on étudiera la variable «âge», que l'on notera X.
   (a) Préciser la nature de la variable «âge».
   (b) Construire le tableau statistique (effectifs, effectifs cumulés, fréquences, fréquences cumulées).
   (c) Calculer le mode, la médiane M, la moyenne $\overline{X}$, le 1er quartile Q_1 et le 3eme quartile Q_3.
   (d) Calculer la variance σ^2, et l'étendue e.
   (e) (BONUS) Tracez le diagramme boxplot, ou plus communément appelé "boite à moustaches" de cette distribution.
2. Dans cette question on étudiera la variable «Loisir», que l'on notera Y.
   (a) Préciser la nature de la variable «Loisir».
   (b) Construire le tableau statistique (effectifs, effectifs cumulés, fréquences, fréquences cumulées).
   (c) Tracer le diagramme en bâtons en fréquence.
   (d) Déterminer le mode.

Tournez la page S.V.P.

Indication ▼ Correction ▼ [stat-0007]

Exercice 2

Une coopérative agricole recueille la production de canne à sucre de 600 exploitants au Brésil. Les surfaces cultivées de ces 600 producteurs sont données par le tableau suivant :

Surface (ha)	$[25;50[$	$[50;60[$	$[60;80[$	$[80;100[$	$[100;120[$	$[120;145[$
fréquence	0,02	0,15	0,13	0,22	0,28	0,20

1. Préciser la nature de la variable étudiée : «la surface cultivée», que l'on notera X.
2. Construire le tableau statistique (effectifs, effectifs cumulés, fréquences, fréquences cumulées, centres, étendues).
3. Calculer la moyenne $\overline{X}$, la classe modale C, la variance σ^2, le 1er quartile Q_1, la mediane M et le 3eme quartile Q_3.
4. (BONUS) Tracer le diagramme boxplot, ou plus communément appelé "boite à moustaches" de cette série statistique.
5. Tracer l'histogramme en fréquence de cette série statistique.
6. (BONUS) Tracer la courbe cumulative des fréquences.

Indication ▼ Correction ▼ [stat-0008]

Exercice 3

Une étude est menée sur des ingénieur-es, istomiens et non istomiens, afin de savoir si un lien existe entre «être istomiens» et le fait de «travailler à l'étranger une fois diplômé».

L'étude porte sur 375 personnes, 197 non istomiens et 178 istomiens. Parmi les istomiens 23 ont travaillé à l'étranger une fois diplômé, et parmis les non istomiens 185 sont restés en France une fois diplômé.

On adoptera les conventions suivantes :

- I : Istomien
- $\overline{I}$: Non Istomien
- E : à l'étranger une fois diplômé
- $\overline{E}$: en France une fois diplômé

1. Construire le tableau de contingence. Préciser les effectifs marginaux.
2. Parmi les istomiens, quelle proportion est restée en France travailler ?
3. Calculer χ^2. Detailler les calculs et la démarche.
4. Calculer le coefficient de Cramer et conclure sur le lien entre «être istomiens» et le fait de «travailler à l'étranger une fois diplômé».

Indication ▼ Correction ▼ [stat-0009]

Indication pour l'exercice 1 ▲

Commencer par ranger les 20 âges par ordre croissant. Avec $N = 20$: Q_1 est la 5e valeur, la médiane est la moyenne des 10e et 11e valeurs, Q_3 est la 15e valeur. Une série peut avoir plusieurs modes.

Indication pour l'exercice 2 ▲

Les effectifs s'obtiennent par $n_i = 600 \times f_i$. Les classes n'ont pas toutes la même amplitude : pour l'histogramme et la classe modale, il faut raisonner sur les *densités* f_i / a_i (fréquence divisée par l'amplitude). Les quartiles se calculent par interpolation linéaire dans la classe où la fréquence cumulée atteint 0,25, 0,50 ou 0,75.

Indication pour l'exercice 3 ▲

Compléter le tableau 2×2 à partir des marges (178 istomiens, 197 non istomiens). Le coefficient de Cramer vaut $V = \sqrt{\dfrac{\chi^2}{N \times \min(L-1, C-1)}}$; il est compris entre 0 (aucun lien) et 1 (lien parfait).

Tournez la page S.V.P.

Correction de l'exercice 1 ▲

1. (a) L'âge est une variable **quantitative discrète** (âge en années entières).

   (b) Série ordonnée : 12 ; 14 ; 25 ; 25 ; 25 ; 26 ; 28 ; 30 ; 30 ; 30 ; 35 ; 35 ; 40 ; 40 ; 45 ; 50 ; 50 ; 50 ; 55 ; 75.

Âge x_i	n_i	N_i (cumulés)	f_i	F_i
12	1	1	0,05	0,05
14	1	2	0,05	0,10
25	3	5	0,15	0,25
26	1	6	0,05	0,30
28	1	7	0,05	0,35
30	3	10	0,15	0,50
35	2	12	0,10	0,60
40	2	14	0,10	0,70
45	1	15	0,05	0,75
50	3	18	0,15	0,90
55	1	19	0,05	0,95
75	1	20	0,05	1,00
Total	20		1	

   (c) **Mode** : trois valeurs ont l'effectif maximal 3 : 25, 30 et 50 ans (série trimodale).

   Médiane : $N = 20$ est pair, $M = \dfrac{x_{(10)} + x_{(11)}}{2} = \dfrac{30 + 35}{2} = \mathbf{32{,}5}$ ans.

   Moyenne : $\overline{X} = \dfrac{720}{20} = \mathbf{36}$ ans.

   Quartiles : $N/4 = 5$, donc $Q_1 = x_{(5)} = \mathbf{25}$ ans ; $3N/4 = 15$, donc $Q_3 = x_{(15)} = \mathbf{45}$ ans.

   (d) $\sum x_i^2 = 30\,200$, d'où $\sigma^2 = \dfrac{30\,200}{20} - 36^2 = 1\,510 - 1\,296 = \mathbf{214}$ (soit $\sigma \approx 14{,}6$ ans). Étendue : $e = 75 - 12 = \mathbf{63}$ ans.

   (e) Boîte à moustaches : boîte de $Q_1 = 25$ à $Q_3 = 45$, trait de la médiane à 32,5, moustaches de 12 à 75 (la valeur 75 est exactement à la limite $Q_3 + 1{,}5\,(Q_3 - Q_1) = 75$: elle n'est pas considérée comme atypique).

2. (a) Le loisir est une variable **qualitative nominale**.

   (b) Les effectifs cumulés n'ont de sens que si l'on fixe un ordre arbitraire des modalités (ici S, C, T, L) :

Loisir	n_i	N_i	f_i	F_i
Sport (S)	4	4	0,20	0,20
Cinéma (C)	6	10	0,30	0,50
Théâtre (T)	5	15	0,25	0,75
Lecture (L)	5	20	0,25	1,00

   (c) Diagramme en bâtons (ou en barres) : une barre par loisir, de hauteurs 0,20 ; 0,30 ; 0,25 ; 0,25.

   (d) Mode : le **cinéma** (effectif 6).

Correction de l'exercice 2 ▲

1. La surface cultivée est une variable **quantitative continue**, ici regroupée en classes d'amplitudes inégales.

2. Tableau statistique ($n_i = 600\,f_i$, c_i centre, a_i amplitude) :

Classe	a_i	c_i	f_i	n_i	N_i	F_i	densité f_i/a_i
$[25;50[$	25	37,5	0,02	12	12	0,02	0,0008
$[50;60[$	10	55	0,15	90	102	0,17	0,0150
$[60;80[$	20	70	0,13	78	180	0,30	0,0065
$[80;100[$	20	90	0,22	132	312	0,52	0,0110
$[100;120[$	20	110	0,28	168	480	0,80	0,0140
$[120;145[$	25	132,5	0,20	120	600	1,00	0,0080

3. **Moyenne** : $\overline{X} = \sum f_i c_i = 0{,}75 + 8{,}25 + 9{,}1 + 19{,}8 + 30{,}8 + 26{,}5 = \mathbf{95{,}2}$ ha.

   Classe modale : les amplitudes étant inégales, on compare les densités : la plus forte est celle de $[50;60[$ (0,015). La classe modale est donc $C = [50;60[$ (et non $[100;120[$, qui a seulement la plus forte fréquence).

   Variance : $\sum f_i c_i^2 \approx 9\,800{,}1$, d'où $\sigma^2 = 9\,800{,}1 - 95{,}2^2 \approx \mathbf{737{,}1}$ ha^2 ($\sigma \approx 27{,}1$ ha).

   Quartiles (interpolation linéaire) :

$$Q_1 = 60 + \frac{0{,}25 - 0{,}17}{0{,}13} \times 20 \approx \mathbf{72{,}3} \text{ ha}, \qquad M = 80 + \frac{0{,}50 - 0{,}30}{0{,}22} \times 20 \approx \mathbf{98{,}2} \text{ ha},$$

$$Q_3 = 100 + \frac{0{,}75 - 0{,}52}{0{,}28} \times 20 \approx \mathbf{116{,}4} \text{ ha}.$$

4. Boîte de 72,3 à 116,4, médiane à 98,2, moustaches de 25 à 145 ha.

5. Histogramme : rectangles de base $[a\,;b[$ et de *hauteur égale à la densité* f_i/a_i (l'aire de chaque rectangle est alors proportionnelle à la fréquence).

6. Courbe cumulative : on relie les points $(25\,;0)$, $(50\,;0{,}02)$, $(60\,;0{,}17)$, $(80\,;0{,}30)$, $(100\,;0{,}52)$, $(120\,;0{,}80)$, $(145\,;1)$. Les quartiles se lisent aux ordonnées 0,25, 0,5 et 0,75.

Correction de l'exercice 3 ▲

1. Tableau de contingence :

	E (étranger)	$\overline{E}$ (France)	Total
I (istomiens)	23	155	178
$\overline{I}$ (non istomiens)	12	185	197
Total	35	340	375

2. $\dfrac{155}{178} \approx \mathbf{0{,}871}$: environ 87 % des istomiens sont restés travailler en France.

3. Effectifs théoriques sous l'hypothèse d'indépendance :

$$n_{11}^\star = \frac{178 \times 35}{375} \approx 16{,}61, \qquad n_{12}^\star = \frac{178 \times 340}{375} \approx 161{,}39,$$
$$n_{21}^\star = \frac{197 \times 35}{375} \approx 18{,}39, \quad n_{22}^\star = \frac{197 \times 340}{375} \approx 178{,}61.$$

$$\chi^2 = \frac{(23-16{,}61)^2}{16{,}61} + \frac{(155-161{,}39)^2}{161{,}39} + \frac{(12-18{,}39)^2}{18{,}39} + \frac{(185-178{,}61)^2}{178{,}61}$$
$$\approx 2{,}46 + 0{,}25 + 2{,}22 + 0{,}23 = \mathbf{5{,}15}.$$

4. $V = \sqrt{\dfrac{\chi^2}{N \times \min(L-1, C-1)}} = \sqrt{\dfrac{5{,}15}{375 \times 1}} \approx \mathbf{0{,}12}$.

   Le lien est **faible** : être istomien augmente un peu la probabilité de travailler à l'étranger (13 % contre 6 %), mais la grande majorité des deux groupes travaille en France. (À titre de test, $\chi^2 = 5{,}15 > 3{,}84$: ce lien faible est néanmoins statistiquement significatif au seuil de 5 %.)
