

# Examen de statistiques et analyse de données

Antoine Géré

10 décembre 2025

## Table des matières

|                                                |    |
|------------------------------------------------|----|
| Exercice 1 - L'énigme des oeufs de coucou..... | 1  |
| Exercice 2 - Décrypter le transcriptome .....  | 17 |

- 
- Document(s) autorisé(s) : **Non**
  - Calculatrice autorisée : **Oui**
  - Remarques :
    - Les exercices sont indépendants.
    - Il sera tenu compte de la propreté de votre copie, ainsi que de la clarté et de la qualité de la rédaction et du raisonnement.
    - Ne pas écrire avec un crayon papier, sauf pour dessiner et/ou annoter des croquis, le cas échéant.
    - Utiliser les notations indiquées dans le texte et justifier toutes vos réponses.

## Exercice 1 - L'énigme des oeufs de coucou

Les packages qui seront utiles pour cet exercice.

Le coucou européen ne couve pas ses propres oeufs, mais les dépose dans les nids d'oiseaux d'autres espèces. Des études antérieures ont montré que les coucous ont parfois évolué pour pondre des oeufs dont la couleur est similaire à celle des oeufs de l'espèce hôte.

Est-ce également le cas pour la taille des oeufs ? Les coucous pondent-ils des oeufs de taille similaire à ceux de leurs hôtes ?



Le fichier de données est `cuckooeggs.csv`

```
cuckooeggs = read.csv("data_raw/cuckooeggs.csv")  
head(cuckooeggs)
```

```
  host_species egg_length  
1 Hedge Sparrow    20.85  
2 Hedge Sparrow    21.65  
3 Hedge Sparrow    22.05  
4 Hedge Sparrow    22.85  
5 Hedge Sparrow    23.05  
6 Hedge Sparrow    23.05
```

```
summary(cuckooeggs)
```

```
host_species      egg_length  
Length:120      Min.   :19.65  
Class :character 1st Qu.:21.85  
Mode  :character Median :22.35  
                        Mean  :22.46  
                        3rd Qu.:23.25  
                        Max.   :25.05
```

### 1. Le fichier de données

Présentez le fichier de données en indiquant le nombre de variables, leur type ainsi que leurs principales caractéristiques.

## 1. Solution

Le jeu de données cuckooeggs contient :

- 120 observations (lignes)
- 2 variables :


| Variable     | Type                  | Description                      |
|--------------|-----------------------|----------------------------------|
| host_species | qualitative (facteur) | Espèce hôte où le coucou a pondu |
| egg_length   | quantitative continue | Longueur de l'œuf (en mm)        |

- Caractéristiques principales de `host_species` :
  - 6 modalités :
    - Hedge Sparrow
    - Meadow Pipit
    - Pied Wagtail
    - Robin
    - Tree Pipit
    - Wren
- Caractéristiques principales de `egg_length` :
  - minimum : 19.65 mm
  - maximum : 25.05 mm
  - moyenne : 22.46 mm
  - médiane : 22.35 mm

Les données sont adaptées à une analyse comparative de moyennes entre groupes.

Nous traçons quelques graphiques ci-dessous.

```
library(ggplot2)
ggplot(cuckooeggs, aes(x = egg_length)) +
  geom_histogram(bins = 10, fill = "lightblue", color = "black") +
  facet_wrap(~ host_species, scales = "free_y") +
  labs(
    title = "",
    x = "Longueur (mm)", y = "Fréquence"
  )
```



## 2. Interprétation des graphes ci-dessus

- Comment se nomme ce type de graphe ?
- Décrivez les différences visibles entre les distributions des longueurs d'oeufs selon les espèces hôtes.
- Les variances semblent-elles comparables ?
- Les distributions paraissent-elles approximativement normales ?
- Les moyennes semblent-elles clairement différentes ?

## 2. Solution

Il s'agit d'un ensemble d'histogrammes, un pour chaque espèce hôte.

- L'axe des abscisses représente des classes de valeurs de la longueur des œufs (en millimètres)
- L'axe des ordonnées représente la fréquence (nombre d'observations par classe)
- Contrairement à un diagramme en baton, les classes sont continues, ce qui est caractéristique des histogrammes

- 
- Différences de position (centre de la distribution)
    - On observe que les histogrammes ne sont pas centrés au même endroit.
    - Les distributions associées à Hedge Sparrow et Tree Pipit sont centrées autour de valeurs relativement élevées (autour de 23 mm).
    - À l'inverse, la distribution correspondant à Wren est clairement décalée vers la gauche, avec des valeurs majoritairement comprises entre 20 et 22 mm.
    - Les espèces Meadow Pipit, Pied Wagtail et Robin occupent une position intermédiaire.
    - Cela suggère que la taille moyenne des œufs varie selon l'espèce hôte.
  - Différences de dispersion (étalement des distributions)
    - Certaines espèces présentent une distribution plus concentrée (barres regroupées sur un intervalle étroit). D'autres montrent un étalement légèrement plus large, traduisant une plus grande variabilité.
    - Aucun histogramme ne montre cependant une dispersion extrêmement plus grande ou plus petite que les autres. Les largeurs des distributions restent globalement comparables. Cela suggère que les variances entre groupes sont relativement proches, sans hétérogénéité flagrante.
  - Différences de forme
    - Toutes les distributions semblent unimodales (un seul pic principal).
    - Les formes sont globalement symétriques, ou très légèrement asymétriques.
    - Aucune distribution ne présente de bimodalité (deux pics), ou de valeurs "aberrantes" clairement visibles.
  - On observe que Hedge Sparrow et Tree Pipit présentent des plages de valeurs très proches. En revanche, la distribution de Wren chevauche moins celles des autres espèces. Cela suggère que toutes les différences ne seront pas nécessairement significatives, mais que certaines espèces (notamment Wren) pourraient se distinguer nettement.

On demande à **R** de nous donner les moyennes et les écarts types de la longueur des oeufs pour chacune des espèces hôtes.

```
stats <- cuckooeggs %>%
group_by(host_species) %>%
summarise(
Moyenne = mean(egg_length),
Ecart_type = sd(egg_length),
n = n()
)
stats
```

# A tibble: 6 × 4

|   | host_species<br><chr> | Moyenne<br><dbl> | Ecart_type<br><dbl> | n<br><int> |
|---|-----------------------|------------------|---------------------|------------|
| 1 | Hedge Sparrow         | 23.1             | 1.07                | 14         |
| 2 | Meadow Pipit          | 22.3             | 0.921               | 45         |
| 3 | Pied Wagtail          | 22.9             | 1.07                | 15         |
| 4 | Robin                 | 22.6             | 0.685               | 16         |
| 5 | Tree Pipit            | 23.1             | 0.901               | 15         |
| 6 | Wren                  | 21.1             | 0.744               | 15         |

### 3. Interprétation du tableau descriptif

- Quelle espèce hôte présente les œufs les plus grands en moyenne ?
- Quelle espèce présente les œufs les plus petits en moyenne ?
- Les différences de moyennes vous semblent-elles importantes ?
- Les écarts-types semblent-ils homogènes ?

### 3. Solution

Le tableau présenté résume, pour chaque espèce hôte, des statistiques descriptives essentielles de la longueur des œufs de coucou (la moyenne, l'écart-type et la taille d'échantillon). Ces statistiques permettent de :

- comparer la tendance centrale entre groupes,
- évaluer la variabilité intra-groupe,
- apprécier la fiabilité des estimations (via les tailles d'échantillon).

Les espèces qui présentent les plus grandes longueurs moyennes d'œufs sont Hedge Sparrow et Tree Pipit avec en moyenne des longueurs de 23,1 mm.

L'espèce qui présentent les œufs les plus petits en moyenne est Wren avec en moyenne des longueurs de 21,1 mm. Cette moyenne est nettement inférieure à celle de toutes les autres espèces. L'écart avec les espèces aux plus grandes moyennes est d'environ 2 mm, ce qui est substantiel à l'échelle de la longueur totale d'un œuf (10 %). Cela indique que les œufs pondus dans les nids de Wren sont significativement plus petits.

L'écart maximal observé entre espèces est

$$23,1 \text{ mm} - 21,1 \text{ mm} = 2,0 \text{ mm}$$

Cet écart représente environ 9 % de la longueur moyenne d'un œuf, ce qui n'est pas négligeable. Les écarts-types sont de l'ordre de 0,7 à 1,1 mm. Un écart de 2 mm correspond donc à environ 2 à 3 écarts-types. Une différence de cette importance est potentiellement statistiquement significative.

Les valeurs observées sont :

| Espèce        | Écart-type |
|---------------|------------|
| Hedge Sparrow | 1,07       |
| Meadow Pipit  | 0,92       |
| Pied Wagtail  | 1,07       |
| Robin         | 0,69       |
| Tree Pipit    | 0,90       |
| Wren          | 0,74       |

Tous les écarts-types sont compris entre 0,69 et 1,07 mm. Le rapport entre le plus grand et le plus petit écart-type est :

$$\frac{1,07}{0,69} \approx 1,55$$

On se propose, afin de savoir si les coucous pondent des oeufs de tailles différentes selon l'espèce hôte, de réaliser un **T-test**.

```
t.test(egg_length ~ host_species, data = cuckooeggs)
```

#### 4. Interprétation d'une erreur

Expliquez la raison pour laquelle ce `t.test` ne fonctionne pas dans ce cas précis.

#### 4. Solution

Le t-test de Student est un test paramétrique destiné à comparer la moyenne d'une variable quantitative entre deux groupes. Il existe plusieurs variantes :

- `t.test` à un échantillon
- `t.test` pour échantillons indépendants (2 groupes)
- `t.test` apparié

Dans tous les cas, le t-test est conçu pour comparer exactement deux groupes. Or dans notre étude :

- Variable dépendante : `egg_length` (quantitative continue) → possède 6 modalités distinctes !
- Variable explicative : `host_species` (qualitative nominale)

Le modèle demandé par `egg_length ~ host_species` implique donc une comparaison entre 6 groupes !

Le `t-test` calcule une statistique `t` basée sur la différence entre deux moyennes et compare cette différence à la variabilité intra-groupe. Avec plus de deux groupes il n'existe pas de différence unique à tester. Il faudrait comparer toutes les paires possibles. Dans notre cas :

$$\binom{6}{2} = 15 \text{ comparaisons}$$

Ce n'est pratique, de plus en multipliant les `t-test` on multiplie également l'erreur toujours commise lors d'un test statistique. Chaque t-test est réalisé avec un risque  $\alpha$  (souvent pris à 5 %). Avec 15 tests indépendants la probabilité de faire au moins une erreur de type I augmente fortement. Le risque global devient largement supérieur à 5 %.

On tente alors de réaliser une ANOVA.

#### 5. Conditions d'application de l'ANOVA

- Rappelez les conditions nécessaires à l'ANOVA à un facteur.
- En vous appuyant sur les histogrammes et le tableau des moyennes et écarts types, indiquez si elles sont raisonnablement satisfaites.
- Rappelez l'hypothèse nulle pour l'ANOVA



## 5. Solution

L'ANOVA repose sur un certain nombre d'hypothèses, dont la validité est nécessaire pour que le test statistique soit fiable :

- **Indépendance** des observations. Chaque observation (ici chaque œuf de coucou) doit être indépendante des autres. Si deux œufs dans le même nid sont dépendants, les résultats pourraient être biaisés. En pratique s'assurer que les mesures proviennent de différents nids ou individus.
- **Normalité des résidus**. Les résidus du modèle (différence entre chaque observation et la moyenne du groupe) doivent suivre une loi normale.
- **Homogénéité des variances**. Les variances des groupes doivent être approximativement égales.

- 
- **Indépendance**. Chaque observation représente la longueur d'un œuf de coucou dans un nid donné. Les données semblent provenir de différents nids et espèces, donc on peut raisonnablement supposer l'indépendance.
  - **Normalité des résidus**. Les histogrammes par espèce montrent des distributions unimodales et symétriques, sans valeurs aberrantes extrêmes. La normalité exacte sera testée plus tard par Shapiro-Wilk, mais visuellement, les conditions de normalité semblent raisonnablement respectées.
  - **Homogénéité des variances**. Les écarts-types par groupe varient entre 0,685 et 1,07 mm. Les variances (écart-type au carré) sont donc proches les unes des autres. Comme déjà vu le rapport entre la plus grande et la plus petite variance est d'environ 1,55 (inférieur à 2), ce qui est généralement acceptable. Les histogrammes montrent des étalements similaires pour tous les groupes. Visuellement la condition d'homogénéité des variances semble respectée.
- 

L'hypothèse nulle pour l'ANOVA est :

**Toutes les espèces hôtes reçoivent des oeufs de coucou de même longueur en moyenne.**

Sur conseil d'un collaborateur on réalise un `leveneTest`.

```
leveneTest(egg_length ~ host_species, data = cuckooeggs)
```

```
Warning in leveneTest.default(y = y, group = group, ...): group coerced to factor.
```

```
Levene's Test for Homogeneity of Variance (center = median)  
Df F value Pr(>F)
```

```
group    5    0.6397 0.6698
      114
```

## 6. Levene test

- Donner l'hypothèse nulle pour ce test.
- Interpréter ce test, que pouvez vous en conclure ?

## 6. Solution

Le Levene Test est un test paramétrique destiné à vérifier l'égalité des variances entre plusieurs groupes. L'hypothèse nulle pour ce test est :

**Toutes les variances des groupes sont égales.**

Ou encore les variances de longueurs d'oeufs sont égales. Le test donne  $p = 0,6698$ . Comme la p-value est largement supérieure à 0,05, nous acceptons l'hypothèse nulle  $H_0$ . Les variances sont donc considérées comme homogènes.

Ce collaborateur nous recommande vivement d'effectuer un `shapiro.test`. Nous en réalisons donc plusieurs.

```
by(cuckooeggs$egg_length, cuckooeggs$host_species, shapiro.test)
```

```
cuckooeggs$host_species: Hedge Sparrow
```

```
Shapiro-Wilk normality test
```

```
data: dd[x, ]
```

```
W = 0.94843, p-value = 0.5366
```

```
-----
cuckooeggs$host_species: Meadow Pipit
```

```
Shapiro-Wilk normality test
```

```
data: dd[x, ]
```

```
W = 0.93006, p-value = 0.009424
```

```
-----
cuckooeggs$host_species: Pied Wagtail
```

```
Shapiro-Wilk normality test
```

```
data: dd[x, ]
```

```
W = 0.96471, p-value = 0.7736
```

```
-----
cuckooeggs$host_species: Robin
```

```
Shapiro-Wilk normality test
```

```
data: dd[x, ]
W = 0.95212, p-value = 0.5239

-----

cuckooeggs$host_species: Tree Pipit

      Shapiro-Wilk normality test

data: dd[x, ]
W = 0.89772, p-value = 0.08786

-----

cuckooeggs$host_species: Wren

      Shapiro-Wilk normality test

data: dd[x, ]
W = 0.93295, p-value = 0.3019

anova_res <- aov(egg_length ~ host_species, data = cuckooeggs)
shapiro.test(residuals(anova_res))

      Shapiro-Wilk normality test

data: residuals(anova_res)
W = 0.9804, p-value = 0.07761
```

## 7. Shapiro test

- Donnez l'hypothèse nulle pour le `shapiro.test`.
- Interprétez chacun de ces `shapiro.test`.
- Étaient ils tous nécessaire ?
- Que pouvez vous en conclure pour l'ANOVA ?

## 7. Solution

L'hypothèse nulle du Shapiro-Wilk test est :

**Les données suivent une distribution normale.**

En pratique :

- si la p-value  $> 0,05$ , on considère que l'hypothèse nulle est acceptée et que la normalité donc est acceptée
- si la p-value  $< 0,05$ , on considère que l'hypothèse nulle est rejetée et que la normalité est rejetée

| Espèce        | p-value | Interprétation                                                       |
|---------------|---------|----------------------------------------------------------------------|
| Hedge Sparrow | 0,537   | $p > 0,05 \rightarrow H_0$ acceptée $\rightarrow$ normalité acceptée |
| Meadow Pipit  | 0,009   | $p < 0,05 \rightarrow H_0$ rejetée $\rightarrow$ normalité rejetée   |
| Pied Wagtail  | 0,774   | $p > 0,05 \rightarrow H_0$ acceptée $\rightarrow$ normalité acceptée |
| Robin         | 0,524   | $p > 0,05 \rightarrow H_0$ acceptée $\rightarrow$ normalité acceptée |
| Tree Pipit    | 0,088   | $p > 0,05 \rightarrow H_0$ acceptée $\rightarrow$ normalité acceptée |
| Wren          | 0,302   | $p > 0,05 \rightarrow H_0$ acceptée $\rightarrow$ normalité acceptée |

Meadow Pipit présente une p-value  $< 0,05$ , donc la distribution sera considérée comme non normale. Les autres espèces n'indiquent aucune violation significative de normalité.

Shapiro-Wilk sur les résidus de l'ANOVA

```
shapiro.test(residuals(anova_res))
```

Shapiro-Wilk normality test

```
data: residuals(anova_res)
W = 0.9804, p-value = 0.07761
```


On obtient p-value = 0,078  $> 0.05$ . L'hypothèse nulle est acceptée, donc la normalité est acceptée.

L'ANOVA repose sur la normalité des résidus, pas nécessairement des groupes pris séparément. Un groupe peut être légèrement non normal (ex : Meadow Pipit), mais si les résidus globaux sont normaux, l'ANOVA reste valide. Tester chaque groupe séparément est utile pour l'inspection exploratoire, mais ce n'est pas la condition clé pour l'ANOVA.

Si les résidus ne sont pas normaux, les p-values de l'ANOVA peuvent être inexactes, le risque d'erreur de type I (faux positif) peut augmenter. Cependant, l'ANOVA est robuste aux violations légères, surtout avec des échantillons de taille raisonnable (ici entre 15 et 50 individus par groupe).

Une fois nos `shapiro.test` réalisés, un autre collaborateur examine notre travail et nous indique qu'il aurait été pertinent de produire un `qqplot`. Nous tentons alors de tracer ce graphique.

```
qqnorm(residuals(anova_res))  
qqline(residuals(anova_res))
```



### 8. Q-Q plot

- Rappelez la définition d'un q-q plot et expliquez en quoi l'observation de ce collaborateur était pertinente.
- Analysez et interprétez ce graphique.
- Ces résultats concordent-ils avec le test de Shapiro précédemment effectué ?

## 8. Solution

Un Q-Q plot est un graphique permettant de comparer les quantiles observés des données (des résidus ici) et les quantiles théoriques d'une loi normale.

- Sur l'axe X : quantiles théoriques d'une loi normale
- Sur l'axe Y : quantiles observés des résidus
- Si les points se rapprochent d'une droite diagonale, cela indique que les données suivent approximativement une loi normale
- Les écarts significatifs par rapport à la droite indiquent des déviations à la normalité (asymétrie, queues longues, outliers)
- Il permet de compléter le Shapiro-Wilk test par une inspection visuelle
- Le Q-Q plot est particulièrement utile car il permet de détecter des déviations légères ou des outliers que les tests statistiques seuls pourraient ne pas révéler
- Les tests de normalité (Shapiro-Wilk) sont sensibles au nombre d'observations, pour de grands échantillons des écarts mineurs peuvent rendre le test significatif, pour de petits échantillons des écarts importants peuvent ne pas être détectés. Le Q-Q plot fournit une inspection visuelle complémentaire.

Ici les points suivent assez bien la droite diagonale. Quelques écarts peuvent apparaître aux extrémités, ce qui est courant dans les données biologiques. Les écarts légers aux extrémités correspondent aux queues de distribution (valeurs extrêmes légèrement plus petites ou plus grandes que prévu). Aucune déviation majeure n'est visible.

Le Shapiro-Wilk test sur les résidus avait permis d'accepter l'hypothèse de normalité. Le Q-Q plot confirme visuellement cette conclusion.

```
summary(anova_res)
```

|              | Df  | Sum Sq | Mean Sq | F value | Pr(>F)       |
|--------------|-----|--------|---------|---------|--------------|
| host_species | 5   | 42.94  | 8.588   | 10.39   | 3.15e-08 *** |
| Residuals    | 114 | 94.25  | 0.827   |         |              |

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

## 9. Résultat de l'ANOVA

- D'après les résultats de l'ANOVA, peut-on conclure que l'effet de l'espèce hôte sur la taille des œufs est statistiquement significatif ?
- L'ANOVA permet-elle de déterminer exactement quelles espèces présentent des effets différents ?

## 9. Solution

On obtient une p-value égale à  $3,15 \times 10^{-8}$ . Cette valeur est extrêmement inférieure aux seuils usuels de 0,05. On rejette très fortement l'hypothèse nulle. Oui, l'effet de l'espèce hôte sur la taille des œufs de coucou est hautement statistiquement significatif. Autrement dit il est extrêmement improbable que les différences observées de longueur d'œufs soient dues uniquement au hasard. L'espèce hôte explique une partie significative de la variabilité observée.

L'ANOVA met en évidence un effet global significatif de l'espèce hôte sur la longueur des œufs de coucou. Cependant, elle ne permet pas d'identifier quelles espèces diffèrent entre elles. Un test post-hoc est donc nécessaire pour comparer les moyennes deux à deux.

Toujours le même collaborateur nous parle de tester un test post hoc. On le réalise sans trop savoir ce que l'on est en train de tester.

```
tukey <- TukeyHSD(anova_res)
tukey

Tukey multiple comparisons of means
 95% family-wise confidence level

Fit: aov(formula = egg_length ~ host_species, data = cuckooeggs)

$host_species
              diff          lwr          upr      p adj
Meadow Pipit-Hedge Sparrow -0.82253968 -1.629133605 -0.01594576 0.0428621
Pied Wagtail-Hedge Sparrow -0.21809524 -1.197559436  0.76136896 0.9872190
Robin-Hedge Sparrow        -0.54642857 -1.511003196  0.41814605 0.5726153
Tree Pipit-Hedge Sparrow   -0.03142857 -1.010892769  0.94803563 0.9999990
Wren-Hedge Sparrow         -1.99142857 -2.970892769 -1.01196437 0.0000006
Pied Wagtail-Meadow Pipit   0.60444444 -0.181375330  1.39026422 0.2324603
Robin-Meadow Pipit         0.27611111 -0.491069969  1.04329219 0.9021876
Tree Pipit-Meadow Pipit     0.79111111  0.005291337  1.57693089 0.0474619
Wren-Meadow Pipit          -1.16888889 -1.954708663 -0.38306911 0.0004861
Robin-Pied Wagtail         -0.32833333 -1.275604766  0.61893810 0.9155004
Tree Pipit-Pied Wagtail     0.18666667 -0.775762072  1.14909541 0.9932186
Wren-Pied Wagtail          -1.77333333 -2.735762072 -0.81090459 0.0000070
Tree Pipit-Robin           0.51500000 -0.432271433  1.46227143 0.6159630
Wren-Robin                 -1.44500000 -2.392271433 -0.49772857 0.0003183
Wren-Tree Pipit            -1.96000000 -2.922428738 -0.99757126 0.0000006
```

## 10. Test post-hoc - Tukey test

- Rappelez l'objectif d'un test post-hoc après une ANOVA.
- D'après les résultats du test de Tukey, quelles paires d'espèces présentent des différences significatives ?
- Quelles conclusions peut-on tirer de ces résultats ?

## 10. Solution

Après avoir mis en évidence, grâce à l'ANOVA, un effet global significatif de l'espèce hôte sur la longueur des œufs de coucou, il est nécessaire d'aller plus loin dans l'analyse afin de comprendre quelles espèces diffèrent réellement entre elles.

C'est précisément le rôle d'un test post-hoc, ici le test de Tukey.

Un test post-hoc permet de comparer toutes les paires de groupes deux à deux, tout en contrôlant le risque global d'erreur de type I (fausse détection de différences). Sans correction post-hoc, multiplier les comparaisons augmenterait artificiellement le risque de conclure à tort.

Le test de Tukey est particulièrement adapté lorsque toutes les comparaisons par paires sont d'intérêt, les tailles d'échantillons sont comparables, et les variances sont homogènes (condition vérifiée par le test de Levene).

Les paires pour lesquelles la différence est statistiquement significative :

| Comparaison                  | Différence de moyennes (mm) | IC 95 %         | p-value ajustée      | Interprétation               |
|------------------------------|-----------------------------|-----------------|----------------------|------------------------------|
| Meadow Pipit – Hedge Sparrow | -0,82                       | [-1,63 ; -0,02] | 0,043                | Hedge Sparrow > Meadow Pipit |
| Tree Pipit – Meadow Pipit    | +0,79                       | [0,01 ; 1,58]   | 0,047                | Tree Pipit > Meadow Pipit    |
| Wren – Hedge Sparrow         | -1,99                       | [-2,97 ; -1,01] | $< 10^{-6}$          | Wren << Hedge Sparrow        |
| Wren – Meadow Pipit          | -1,17                       | [-1,95 ; -0,38] | $4,9 \times 10^{-4}$ | Wren << Meadow Pipit         |
| Wren – Pied Wagtail          | -1,77                       | [-2,74 ; -0,81] | $7 \times 10^{-6}$   | Wren << Pied Wagtail         |
| Wren – Robin                 | -1,45                       | [-2,39 ; -0,50] | $3,2 \times 10^{-4}$ | Wren << Robin                |
| Wren – Tree Pipit            | -1,96                       | [-2,92 ; -1,00] | $< 10^{-6}$          | Wren << Tree Pipit           |

Toutes les comparaisons impliquant Wren sont significatives.

Ci-dessous les paires pour lesquelles la comparaison est non significative.

| Comparaison                  | p-value ajustée | Conclusion        |
|------------------------------|-----------------|-------------------|
| Hedge Sparrow – Tree Pipit   | 1,00            | Pas de différence |
| Hedge Sparrow – Pied Wagtail | 0,99            | Pas de différence |
| Hedge Sparrow – Robin        | 0,57            | Pas de différence |
| Meadow Pipit – Pied Wagtail  | 0,23            | Pas de différence |
| Meadow Pipit – Robin         | 0,90            | Pas de différence |
| Pied Wagtail – Robin         | 0,92            | Pas de différence |
| Pied Wagtail – Tree Pipit    | 0,99            | Pas de différence |
| Robin – Tree Pipit           | 0,62            | Pas de différence |

| Groupe                   | Espèces                    | Interprétation                       |
|--------------------------|----------------------------|--------------------------------------|
| Groupe A (œufs les plus) | Hedge Sparrow, Tree Pipit, | Moyennes élevées, pas de différences |



## Exercice 2 - Décrypter le transcriptome

Les packages qui seront utiles pour cet exercice.

Le jeu de données utilisé dans cet examen est inspiré d'une étude publiée dans la revue Cell, Petropoulos et al. (2016), où des chercheurs ont mesuré l'activité de nombreux gènes dans des cellules provenant d'embryons humains très précoces. Leur objectif était d'observer comment les cellules évoluent au cours du développement et comment elles se différencient en plusieurs types cellulaires.

Pour notre exercice, nous utilisons une version simplifiée de ce type de données. Le fichier contient :

- 300 gènes (chaque ligne correspond à un gène différent)
- 12 échantillons (chaque colonne correspond à une condition biologique), représentant différents jours de développement et différents types de cellules :
  - Exemples : Day\_5\_EPI, Day\_5\_TE, Day\_6\_PE, etc.
- Les variables du fichier sont donc :
  - Gene : nom du gène
  - 12 variables quantitatives (une par condition), correspondant à l'expression du gène dans chaque échantillon (mesure numérique)

L'objectif de l'Analyse en composantes principales est d'identifier les grands axes qui résument les principales différences d'expression entre ces 12 conditions, et de visualiser si certaines conditions se regroupent selon des profils similaires.

Le fichier de données est `mmc3.xlsx`.

```
data = read_excel("data_raw/mmc3.xlsx")
head(data)

# A tibble: 6 × 13
  Gene      Day_3 Day_4 Pre_Day_5 Day_5_EPI Day_5_PE Day_5_TE Day_6_EPI
Day_6__PE
  <chr>    <dbl> <dbl>    <dbl>    <dbl>    <dbl>    <dbl>    <dbl>
<dbl>
1 SEPT6      1.5  0        0.2      2.2      0.6      0.3      9.8
0.7
2 AARS2      2.3 13.8      17.3     44.1     19.5      8.5     21.8
7.5
3 ABCG2      0.2  0.3      7.6      3.3     10.4     35.1     23
4 ABHD12B    5.8 11        16.7     33.3     17      12.3     57.4
18.3
5 ABHD6      0.8  4.2      9.7      7.5     29.2      8.1     11.8
14.8
6 ACE        0.3 17.5     10.3     15.4      6.7      3.9     11.1
1.3
# i 4 more variables: Day_6_TE <dbl>, Day_7_EPI <dbl>, Day_7_PE <dbl>,
#   Day_7_TE <dbl>
```

```

var.quanti = sapply(data, is.numeric)
data.quanti = data[, var.quanti]
head(data.quanti)

# A tibble: 6 × 12
  Day_3 Day_4 Pre_Day_5 Day_5_EPI Day_5_PE Day_5_TE Day_6_EPI Day_6__PE
Day_6_TE
  <dbl> <dbl>      <dbl>      <dbl>      <dbl>      <dbl>      <dbl>      <dbl>
<dbl>
1  1.5    0          0.2        2.2        0.6        0.3        9.8        0.7
0.4
2  2.3  13.8       17.3       44.1       19.5       8.5       21.8       7.5
4.8
3  0.2    0.3        7.6        3.3       10.4      35.1       23        54
71.3
4  5.8   11        16.7       33.3       17        12.3      57.4      18.3
9.8
5  0.8    4.2        9.7        7.5       29.2       8.1       11.8      14.8
8.8
6  0.3   17.5       10.3       15.4       6.7       3.9       11.1       1.3
0.8
# i 3 more variables: Day_7_EPI <dbl>, Day_7_PE <dbl>, Day_7_TE <dbl>

```

### 1. Question théorique

- Combien de gènes et de conditions contient le jeu de données ?
- Quelles sont les variables quantitatives ?
- Pourquoi est-il important de distinguer les variables quantitatives et qualitatives avant l'analyse ?
- Expliquez en quelques phrases l'objectif de l'ACP. Pourquoi cette méthode est-elle utilisée ?

## 1. Solution

Le jeu de données est structuré sous forme de tableau où :

- Chaque ligne correspond à un gène
- Chaque colonne correspond à une variable

À partir de la description et de l'aperçu avec `head(data)`, on observe :

- 300 lignes, ce qui signifie que 300 gènes distincts sont analysés
- 13 colonnes au total, parmi lesquelles :
  - 1 colonne qualitative : Gene (nom du gène)
  - 12 colonnes quantitatives correspondant aux conditions biologiques. Ces 12 conditions représentent :
    - Différents jours de développement embryonnaire (Day 3 à Day 7)
    - Différents types cellulaires :
      - EPI (Epiblaste)
      - PE (Primitive Endoderm)
      - TE (Trophectoderme)

Le jeu de données contient donc 300 gènes (individus statistiques) décrits par 12 conditions biologiques (variables quantitatives).

---

Les variables quantitatives sont celles qui sont de type numérique, qui représentent des mesures continues, et peuvent être comparées par des opérations mathématiques (moyenne, variance, corrélation). Dans ce jeu de données, il s'agit des 12 colonnes évoquées plus haut :

Day\_3, Day\_4, Pre\_Day\_5, Day\_5\_EPI, Day\_5\_PE, Day\_5\_TE, Day\_6\_EPI, Day\_6\_PE, Day\_6\_TE, Day\_7\_EPI, Day\_7\_PE et Day\_7\_TE.

Chaque valeur numérique correspond à un niveau d'expression génique mesuré pour un gène donné dans une condition biologique précise.

---


L'Analyse en Composantes Principales est une méthode algébrique. Elle repose sur :

- Le calcul de variances
- Le calcul de covariances ou de corrélations
- La diagonalisation d'une matrice numérique

Ces concepts mathématiques n'ont de sens que pour des variables quantitatives. Conséquences si cette distinction n'est pas faite, inclure une variable qualitative dans une ACP entraînerait une impossibilité mathématique ! Cette sélection garantit la validité statistique de l'analyse.

```
Matrice.Correlation <- cor(data.quanti, use = "complete.obs")
```

```
corrplot(Matrice.Correlation,
  method = "color",
  type = "upper",
  order = "hclust",
  tl.col = "black",
  tl.srt = 45,
  addCoef.col = "black",
  cl.pos = "n",
  cl.cex = 1.2,
  addCoefasPercent = TRUE,
  number.cex = 0.8)
```



```
data.quanti = data[, var.quanti]
```

## 2. Matrice de corrélation

- Quelles conditions semblent fortement corrélées ? Quelles conditions semblent peu corrélées ?
- Que peut-on déduire de ces corrélations pour l'analyse en composantes principales ?

## 2. Solution

Les conditions qui montrent des valeurs proches de 100 dans la matrice sont fortement corrélées.

| Conditions fortement corrélées                                                                                                                                                                                                                          | Interprétation                                     |
|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------|
| Day_6_EPI et Day_7_EPI                                                                                                                                                                                                                                  | Même type cellulaire (EPI) à des jours consécutifs |
| Day_5_TE et Day_6_TE                                                                                                                                                                                                                                    | Même type cellulaire (EPI) à des jours consécutifs |
| Day_5_PE et Day_6_PE                                                                                                                                                                                                                                    | Même type cellulaire (EPI) à des jours consécutifs |
| <ul style="list-style-type: none"> <li>Ces cellules continuent leur programme de développement spécifique.</li> <li>Les gènes exprimés dans un type cellulaire donné restent actifs à des niveaux comparables au cours des jours successifs.</li> </ul> |                                                    |

Les conditions qui montrent des valeurs proches de 0 dans la matrice sont faiblement corrélées.

| Conditions faiblement corrélées | Interprétation                                                              |
|---------------------------------|-----------------------------------------------------------------------------|
| Day_3 et Day_7_TE               | Gènes exprimés très différemment ; changement de programme de développement |
| Day_3 et Day_5_PE               | Profils biologiques distincts.                                              |
| EPI vs TE ou PE                 | Très différents                                                             |

Les variables fortement corrélées apportent la même information (exemple : Day\_6\_EPI et Day\_7\_EPI). Pour une ACP, cette redondance est utile. L'ACP combine les variables corrélées pour créer un axe principal. Cela permet de résumer l'information avec moins de composantes.

- L'axe 1 de l'ACP capturera probablement la variation commune à ces jours consécutifs pour un type cellulaire.
- Les variables faiblement corrélées ou négativement corrélées introduisent des axes supplémentaires.

| Observation                                                  | Implication pour l'ACP                                            |
|--------------------------------------------------------------|-------------------------------------------------------------------|
| Corrélation forte entre conditions similaires                | Ces variables seront résumées par le même axe principal           |
| Corrélation faible entre types cellulaires ou jours éloignés | Ces différences seront capturées par des axes secondaires         |
| Bloc de corrélations                                         | Permet d'identifier des groupes biologiques cohérents avant l'ACP |

```
data.CR <- scale(data.quanti, center = TRUE, scale=TRUE)
pca.data <- PCA(data.CR, graph = FALSE)
vp = pca.data$eig
vp
```


|         | eigenvalue  | percentage of variance | cumulative percentage of variance |
|---------|-------------|------------------------|-----------------------------------|
| comp 1  | 7.585892122 | 63.21576768            | 63.21577                          |
| comp 2  | 2.217238058 | 18.47698382            | 81.69275                          |
| comp 3  | 0.873147907 | 7.27623255             | 88.96898                          |
| comp 4  | 0.776224795 | 6.46853996             | 95.43752                          |
| comp 5  | 0.293172253 | 2.44310211             | 97.88063                          |
| comp 6  | 0.097438066 | 0.81198388             | 98.69261                          |
| comp 7  | 0.072100242 | 0.60083535             | 99.29345                          |
| comp 8  | 0.046325556 | 0.38604630             | 99.67949                          |
| comp 9  | 0.016444017 | 0.13703347             | 99.81653                          |
| comp 10 | 0.013633402 | 0.11361169             | 99.93014                          |
| comp 11 | 0.005016309 | 0.04180257             | 99.97194                          |
| comp 12 | 0.003367273 | 0.02806061             | 100.00000                         |

```

barplot(vp[, 2],
        names.arg=1:nrow(vp),
        main = "",
        xlab = "Composantes principales",
        ylab = "Pourcentage de variance expliquée",
        col = "steelblue")

lines(x = 1:nrow(vp),
      vp[, 2],
      type="b",
      pch=19,
      col = "black")

```



**3. Variance expliquée**

- a. Que représente la variance expliquée par chaque composante principale ?
- b. Combien de composantes principales retiendriez-vous pour représenter l'essentiel de l'information ? Justifiez votre réponse.
- c. Quelle proportion de variance est expliquée par les deux premières composantes ?

### 3. Solution

Dans une ACP, chaque composante principale est une combinaison linéaire des variables originales.

- La première composante principale (Dim 1) est construite pour maximiser la variance totale des données projetées sur cette dimension.
- La deuxième composante principale (Dim 2) maximise la variance restante sous contrainte d'orthogonalité à la première composante principale.
- Et ainsi de suite pour les axes suivants.

La variance expliquée par une composante principale correspond à :

$$\text{Variance expliquée de Dim } i = \frac{\text{valeur propre (eigenvalue) de Dim } i}{\text{somme des valeurs propres}} \times 100$$

La valeur propre (eigenvalue) mesure la quantité de variance capturée par l'axe. Plus la valeur propre est grande, plus l'axe est informative.

Ici chaque axe représente un profil d'expression génétique combiné :

- Dim 1 : direction qui distingue les conditions les plus différentes
- Dim 2 : direction qui capture le deuxième contraste le plus important

La variance expliquée indique combien de l'information totale (différences d'expression entre conditions) est conservée sur cet axe. Exemple : si Dim 1 explique 63 %, cela signifie que 63 % de la variabilité totale entre conditions est résumée sur ce seul axe.

| Composante | Eigenvalue | % Variance | % Cumulée |
|------------|------------|------------|-----------|
| Dim 1      | 7.586      | 63.2 %     | 63.2 %    |
| Dim 2      | 2.217      | 18.5 %     | 81.7 %    |
| Dim 3      | 0.873      | 7.3 %      | 88.97 %   |
| Dim 4      | 0.776      | 6.47 %     | 95.44 %   |
| Dim 5      | 0.293      | 2.44 %     | 97.88 %   |


- Dim 1 (63 %) : capture la majeure partie de la variation, probablement liée aux différences temporelles globales et aux types cellulaires majeurs
- Dim 2 (18.5 %) : capture les différences secondaires,
- Axes suivants (<10 %) : capturent des variations mineures, bruit ou différences très spécifiques

Seules les composantes avec une valeur propre > 1 sont considérées comme significatives. Ici :

- Dim 1 : 7.586 → OK
- Dim 2 : 2.217 → OK
- Dim 3 : 0.873 < 1 → moins informative



```
fviz_pca_var(pca.data,  
  col.var = "cos2",  
  gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"),  
  repel = TRUE,  
  title = "Cercle de Corrélation des Variables (cos2)")
```



#### 4. Cercle de corrélation

- Identifiez deux variables fortement corrélées et deux variables faiblement corrélées.
- Que signifie la longueur et l'orientation des flèches ?
- Quelles variables ont une contribution importante sur l'axe 2 ?

#### 4. Solution

Le cercle de corrélation est un outil graphique qui permet de visualiser :

- La relation entre variables quantitatives et les axes principaux
- Les corrélations entre variables
- La contribution de chaque variable à chaque axe

Deux variables sont fortement corrélées si leurs flèches sont proches et orientées suivant la même direction. L'angle entre elles est proche de  $0^\circ$ .

Exemples attendus dans ce jeu de données :

| Variables fortement corrélées | Justification                                                             |
|-------------------------------|---------------------------------------------------------------------------|
| Day_6_EPI et Day_7_EPI        | Même type cellulaire, jours consécutifs → profils d'expression similaires |
| Day_5_TE et Day_6_TE          | Même type cellulaire TE → corrélation positive élevée                     |

Deux variables sont faiblement corrélées si leurs flèches sont perpendiculaires (angle  $\approx 90^\circ$ ).

Exemples attendus :

| Variables faiblement corrélées | Justification                                                         |
|--------------------------------|-----------------------------------------------------------------------|
| Day_3 et Day_7_TE              | Jour très éloigné et type cellulaire différent → profils indépendants |
| Day_4 et Day_6_PE              | Flèches orthogonales → absence de corrélation linéaire                |

La longueur des flèches représente la qualité de représentation sur le plan factoriel.

- Longue flèche → la variable est bien représentée, proche du plan choisi (Dim1 × Dim2)
- Courte flèche → variable mal représentée, sa variance est surtout sur d'autres axes

Exemple pratique :

- Day\_6\_EPI : longue flèche → forte contribution aux axes principaux
- Day\_7\_PE : courte flèche → beaucoup de variance sur axes non représentés (Dim3, Dim4...)

L'orientation des flèches, vue par l'angle entre flèches traduit la corrélation entre variables :


- Angle proche de  $0^\circ$  → corrélation positive forte
- Angle proche de  $180^\circ$  → corrélation négative forte

Ici les flèches proches traduisent des types cellulaires avec profils similaires, et des flèches perpendiculaires traduisent des types cellulaires différents ou jours éloignés.

```
head(pca.data$ind$coord)
```

|   | Dim.1      | Dim.2       | Dim.3       | Dim.4         | Dim.5       |
|---|------------|-------------|-------------|---------------|-------------|
| 1 | -0.8860388 | -0.05653948 | -0.05987579 | 0.0326202352  | 0.03833300  |
| 2 | -0.6057873 | 0.10852636  | -0.12243416 | -0.0690008780 | -0.10503767 |
| 3 | -0.3699260 | -0.31957924 | 0.03212768  | 0.1043982993  | 0.31567397  |
| 4 | -0.5063049 | 0.11052344  | -0.11409912 | -0.1403434496 | 0.02666491  |
| 5 | -0.6891486 | -0.07722587 | -0.02877404 | 0.0005839167  | -0.07581851 |
| 6 | -0.7792027 | 0.06145232  | -0.06881027 | 0.0769645114  | -0.05851516 |

```
fviz_pca_ind(pca.data, col.ind="cos2") +
  scale_color_gradient2(low="blue", mid="white", high="red", midpoint=0.50) +
  theme_minimal()
```




```
# Filtrer les individus avec cos² > 50%
ind_cos2 <- apply(pca.data$ind$cos2, 1, max) > 0.5

# Filtrer les variables avec cos² > 50%
var_cos2 <- apply(pca.data$var$cos2, 1, max) > 0.5

# Créer un graphique combiné des individus et des variables
fviz_pca_biplot(pca.data,
  select.ind = list(cos2 = 0.5), # Sélectionner les individus
  avec cos² > 50%
  select.var = list(cos2 = 0.5), # Sélectionner les variables
  avec cos² > 50%
  repel = TRUE, # Éviter le chevauchement des étiquettes
  title = "Biplot des Individus et des Variables (cos² > 50%)",
```

```
col.ind = "blue", # Couleur des individus  
col.var = "red", # Couleur des variables  
geom.ind = "point"  
)
```



### 5. Représentation des individus

Que révèle la position des individus sur le plan des deux premiers axes (proximité, similarité, groupes, outliers) ?

## 5. Solution

Nous analysons la position des individus (gènes) sur le plan des deux premières composantes principales de l'ACP (Dim1 et Dim2) afin de comprendre leur similarité, la formation de groupes et la présence d'outliers.

- Deux gènes **proches** dans le plan ont des **profils d'expression similaires** sur les 12 conditions.
- La **distance euclidienne** dans le plan factoriel reflète la similarité après réduction de dimension.
- Gènes éloignés : expression spécifique ou extrême dans certaines conditions. Peuvent représenter des **marqueurs spécifiques** ou des variations expérimentales.
- Le **cos<sup>2</sup>** mesure la qualité de représentation d'un gène sur le plan Dim1 × Dim2 :
  - $\cos^2 > 0.5$  → bien représenté, interprétation fiable (on a uniquement représenté ces individus)
  - $\cos^2$  faible → beaucoup de variance sur d'autres axes

En conclusion, la projection des gènes sur le plan factoriel permet de **visualiser la structure globale des profils d'expression**, d'identifier des **groupes cohérents**, et de mettre en évidence les **gènes spécifiques ou outliers**, tout en restant justifiée par la variance expliquée et le  $\cos^2$ .

Ici beaucoup de points sont concentrés proche de l'origine, sachant que  $\cos^2 > 0.5$ . La position est bien représentée sur ce plan. Autrement dit, la position à proximité de l'origine est fiable, pas un artefact dû au choix du plan. La plupart des individus (genes) ont donc une expression relativement constante à travers les conditions.

Petropoulos, S., Edsgård, D., Reinius, B., Deng, Q., Panula, S. P., Codeluppi, S., Reyes, A. P., Linnarsson, S., Sandberg, R., et Lanner, F. (2016). Single-cell RNA-seq reveals lineage and X chromosome dynamics in human preimplantation embryos. *Cell* 165: 1012-1026.