Ecole supérieure d'agro-développement international

istom

Examen de statistiques et analyse de données

Jeudi 22 janvier 2026

Promotion 114

Antoine Géré

Document(s) autorisé(s) : ☐ Oui ☒ Non Calculatrice autorisée : ☒ Oui ☐ Non

Remarques :

- Les exercices sont indépendants.
- Il sera tenu compte de la propreté de votre copie, ainsi que de la clarté et de la qualité de la rédaction et du raisonnement.
- **Ne pas écrire avec un crayon papier**, sauf pour dessiner et/ou annoter des croquis, le cas échéant.
- Utiliser les **notations** indiquées dans le texte et **justifier toutes vos réponses**.
- Le sujet est à conserver par l'étudiant-e.

Exercice 1 ANOVA et ACP sous R : maïs et malaria en Éthiopie

Le pollen du maïs (*Zea mays*) constitue une source de nourriture pour les larves de moustiques de l'espèce *Anopheles arabiensis*, principal vecteur de la malaria en Éthiopie. La production de maïs a augmenté de manière substantielle dans certaines régions d'Éthiopie ces dernières années et, sur la même période, la malaria s'est étendue à de nouvelles zones où la maladie était auparavant rare. Cela soulève la question suivante :

L'augmentation de la culture du maïs est-elle en partie responsable de l'augmentation de la malaria en Éthiopie ?



Image : Flickr/CIMMYT

Une approche consiste à rechercher une association entre la production de maïs et l'incidence de la malaria dans différents sites géographiquement dispersés (Kebede et al., 2005). Le fichier `data_stat-0117.csv` contient les variables suivantes :

- `village` : nom du village où les mesures ont été réalisées (ils sont tous différents) ;
- `maize_yield` : niveau de production de maïs (`Low`, `Medium`, `High`) ;
- `mean_elevation_m` : altitude du village (m) ;

- `person.years` : nombre d'habitants recensés dans le village ;
- `number_malaria_cases` : nombre de cas de malaria recensés dans le village ;
- `incidence_rate_per_ten_thousand` : taux d'incidence de la malaria pour 10 000 habitants.

On cherche à déterminer s'il existe une association statistique entre la culture du maïs et le taux d'incidence de la malaria.

Partie A – Analyse descriptive

On importe la base de données sous R afin de réaliser quelques analyses descriptives.

```
library(dplyr); library(ggplot2); library(car); library(FactoMineR); library(factoextra)
data_ethiopia <- read.csv("data_raw/data_stat-0117.csv")
head(data_ethiopia)
str(data_ethiopia)
summary(data_ethiopia)
table(data_ethiopia$maize_yield)
```

R affiche (`head`, puis `summary` des variables numériques, puis `table`) :

	village	maize_yield	mean_elevation_m	person.years	number_malaria_cases	incidence_rate...
1	Gulim	High	2050	23 458	683	291
2	Denbun	High	2050	20 630	88	43
3	Wadra	High	2050	12 805	170	133
4	Zalimashebekuma	High	2050	16 857	370	219
5	Adel Agata	High	2050	12 805	226	176
6	Fetamsantom	High	2050	18 333	552	301

	mean_elevation_m	person.years	number_malaria_cases	incidence_rate...
Min.	2050	10 960	5,0	3,0
1st Qu.	2050	12 975	68,5	39,0
Median	2200	16 857	170,0	83,0
Mean	2155	16 590	224,6	129,4
3rd Qu.	2200	18 359	298,0	197,5
Max.	2450	26 223	857,0	466,0

`table(maize_yield)`

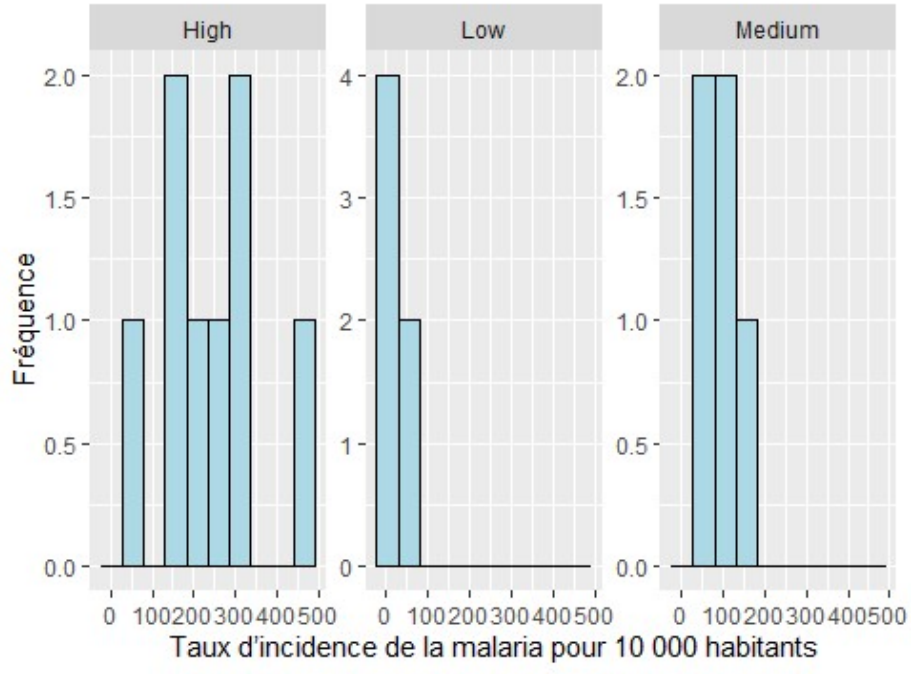
High	Low	Medium
8	6	5

La commande `str` indique `'data.frame': 19 obs. of 6 variables` : `village` et `maize_yield` sont de type `chr` (texte), les quatre autres de type `int` (entiers).

1. **Le fichier de données.** Présenter le fichier de données en indiquant le nombre de variables, leur nom, leur type ainsi que leurs principales caractéristiques.

2. **Interprétation des histogrammes.**

```
ggplot(data_ethiopia, aes(x = incidence_rate_per_ten_thousand)) +
  geom_histogram(bins = 10, fill = "lightblue", color = "black") +
  facet_wrap(~ maize_yield, scales = "free_y") +
  labs(x = "Taux d'incidence de la malaria pour 10 000 habitants", y = "Frequence")
```



a) Les variances semblent-elles comparables ? Justifier.

b) Les distributions paraissent-elles approximativement normales ? Justifier.

c) Les moyennes semblent-elles clairement différentes ? Justifier.

3. Interprétation du tableau descriptif.

```
stats <- data_ethiopia %>%
  group_by(maize_yield) %>%
  summarise(Moyenne = mean(incidence_rate_per_ten_thousand),
            Ecart_type = sd(incidence_rate_per_ten_thousand), n = n())
stats
```

maize_yield	Moyenne	Ecart_type	n
High	234	126	8
Low	17,7	17,1	6
Medium	95,4	41,4	5

a) Quel niveau de production de maïs présente, en moyenne, le plus haut taux d'incidence de la malaria ?

b) Quel niveau présente, en moyenne, le plus bas taux d'incidence ?

c) Les variances semblent-elles comparables ? Justifier.

Partie B – Tests statistiques

On se propose de réaliser des tests statistiques afin de déterminer quel niveau de production a, en moyenne, le plus d'impact sur le taux d'incidence de la malaria.
Avant de se lancer, il est proposé de vérifier « l'indépendance » de la variable `maize_yield`. On réalise pour cela le test du χ^2 suivant :

```
chisq.test(table(data_ethiopia$maize_yield))
```

```
        Chi-squared test for given probabilities
X-squared = 0.73684, df = 2, p-value = 0.6918
```

4. **Le test du χ^2.**
   a) Donner l'hypothèse nulle de ce test du χ^2.
   b) Interpréter son résultat.

5. **Test de Student.** On se propose de réaliser un test de Student afin de déterminer s'il existe une association statistique entre la culture du maïs et le taux d'incidence de la malaria :

```
t.test(incidence_rate_per_ten_thousand ~ maize_yield, data = data_ethiopia)
```

   a) Donner l'hypothèse nulle d'un `t.test`.
   b) Expliquer pourquoi ce `t.test` ne fonctionne pas dans ce cas précis.

6. **ANOVA.** L'ANOVA est un choix logique pour tester les différences de taux moyens de malaria entre des niveaux de production de maïs différents.
   a) Donner l'hypothèse nulle de l'ANOVA.
   b) Donner les conditions d'application de l'ANOVA.

7. **Violation des hypothèses.**

```
leveneTest(incidence_rate_per_ten_thousand ~ maize_yield, data = data_ethiopia)
anova_model <- aov(incidence_rate_per_ten_thousand ~ maize_yield, data_ethiopia)
shapiro.test(residuals(anova_model))
summary(anova_model)
```

Levene's Test for Homogeneity of Variance (center = median)

	Df	F value	Pr(>F)
group	2	3,9662	0,03991 *
	16		

Shapiro-Wilk normality test

```
data: residuals(anova_model)
W = 0.88211, p-value = 0.02337
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
maize_yield	2	168 844	84 422	11,23	0,000898 ***
Residuals	16	120 294	7 518		

   a) Interpréter le test de Levene.
   b) Interpréter le test de Shapiro–Wilk.
   c) Ces données semblent-elles conformes aux hypothèses de l'ANOVA ? Justifier.
   d) Quelle information l'ANOVA donne-t-elle ? Cette information est-elle exploitable ?

8. **Transformation des données.** Afin de pouvoir utiliser l'ANOVA, on calcule le logarithme du taux d'incidence et l'on refait l'analyse sur ces données transformées :

```
data_ethiopia$log_incidence <- log(data_ethiopia$incidence_rate_per_ten_thousand)
leveneTest(log_incidence ~ maize_yield, data = data_ethiopia)
anova_log <- aov(log_incidence ~ maize_yield, data_ethiopia)
shapiro.test(residuals(anova_log))
summary(anova_log)
```

Levene's Test for Homogeneity of Variance (center = median)

	Df	F value	Pr(>F)
group	2	3,4689	0,05604 .
	16		

Shapiro-Wilk normality test

```
data: residuals(anova_log)
W = 0.97606, p-value = 0.8875
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
maize_yield	2	29,49	14,744	22,22	$2{,}41 \times 10^{-5}$ ***
Residuals	16	10,62	0,663		

a) Les données transformées par le logarithme respectent-elles mieux les hypothèses de l'ANOVA que les données non transformées ?

b) Interpréter le résultat de cette ANOVA.

c) L'ANOVA permet-elle de déterminer exactement quels niveaux de production de maïs ont des effets différents sur le taux d'incidence ?

9. Test post-hoc de Tukey.

```
tukey <- TukeyHSD(anova_log)
tukey
```

Tukey multiple comparisons of means – 95% family-wise confidence level

$maize_yield	diff	lwr	upr	p adj
Low – High	−2,8949	−4,0300	−1,7598	0,0000180
Medium – High	−0,7882	−1,9864	0,4101	0,2365763
Medium – Low	2,1068	0,8341	3,3795	0,0016001

a) Rappeler l'objectif d'un test post-hoc après une ANOVA.

b) Quelles conclusions peut-on tirer de ces résultats ?

Partie C – Analyse factorielle

Dans cette partie, on considère l'ensemble des variables quantitatives du jeu de données (y compris le taux d'incidence transformé `log_incidence`).

```
var.quanti  <- sapply(data_ethiopia, is.numeric)
data.quanti <- data_ethiopia[, var.quanti]
```

10. Question théorique.

a) Pourquoi est-il important de distinguer les variables quantitatives et qualitatives avant l'analyse ?

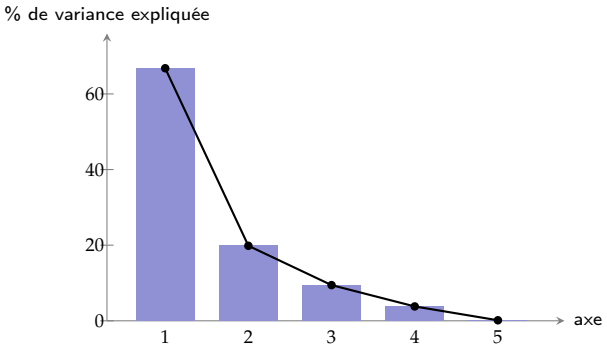
b) Expliquer en quelques phrases l'objectif de l'ACP. Pourquoi cette méthode est-elle utilisée ici ?

11. Variance expliquée.

```
data.CR  <- scale(data.quanti, center = TRUE, scale = TRUE)
pca.data <- PCA(data.CR, graph = FALSE)
vp <- pca.data$eig
vp
barplot(vp[, 2], names.arg = 1:nrow(vp), xlab = "Composantes principales",
        ylab = "Pourcentage de variance expliquee", col = "steelblue")
lines(x = 1:nrow(vp), vp[, 2], type = "b", pch = 19, col = "black")
```

Axe	1	2	3	4	5
Valeur propre	3,339	0,992	0,472	0,190	0,007
% de variance	66,79	19,84	9,44	3,80	0,14
% cumulé	66,79	86,63	96,07	99,86	100

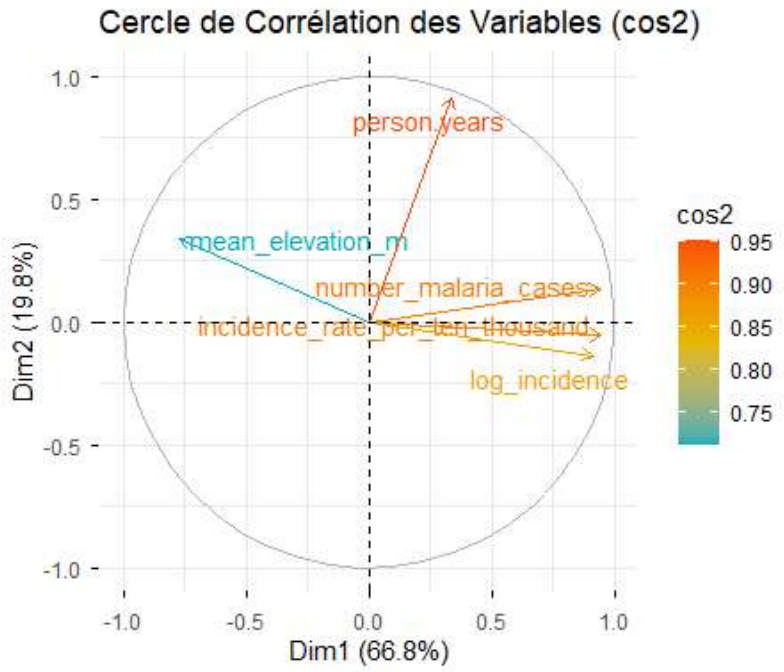
Tournez la page S.V.P.



Combien de composantes principales retiendriez-vous pour représenter l'essentiel de l'information ? Justifier.

12. Cercle des corrélations.

```
fviz_pca_var(pca.data, col.var = "cos2",
             gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"), repel = TRUE,
             title = "Cercle de correlation des variables (cos2)")
```



a) Identifier deux variables fortement corrélées positivement.
b) Identifier deux variables fortement corrélées négativement.
c) Identifier deux variables faiblement corrélées.
d) Que signifient la longueur et l'orientation des flèches ?
e) Quelles variables contribuent fortement à l'axe 1 ?
f) Interpréter ces résultats.

Référence. Kebede A., McCann J. C., Kiszewski A. E., Ye-Ebiyo Y. (2005). New evidence of the effects of agro-ecologic change on malaria transmission. *The American Journal of Tropical Medicine and Hygiene*, 73, 676–680.

Indication ▼ Correction ▼ [stat-0117]

Indication pour l'exercice 1 ▲

1. `19 obs. of 6 variables` : combien d'individus, combien de variables ? Une colonne `chr` est qualitative, une colonne `int` quantitative. Regarder aussi comment se répartissent les villages entre les trois niveaux de production.
2. Attention : avec `scales = "free_y"`, chaque panneau a sa propre échelle verticale. Comparer l'étendue des valeurs sur l'axe horizontal (commun aux trois panneaux), la forme et la position des histogrammes. Combien de valeurs par groupe ?
3. Comparer les moyennes. Pour les variances, calculer le rapport du plus grand au plus petit écart-type (règle pratique : il doit rester inférieur à 2).
4. La sortie indique `Chi-squared test for given probabilities` : on teste si les effectifs observés $(8,\ 6,\ 5)$ sont compatibles avec des probabilités données. Lesquelles, par défaut ? Ce test porte-t-il vraiment sur une indépendance ?
5. Combien de groupes un test de Student compare-t-il ? Combien en a-t-on ici ?
6. Trois conditions : indépendance des observations, normalité (de quoi ?), homogénéité des variances.
7. Comparer chaque p-valeur à $0{,}05$. Une ANOVA dont les conditions ne sont pas remplies donne des p-valeurs peu fiables.
8. Comparer les p-valeurs des tests de Levene et de Shapiro–Wilk avant et après transformation. Le logarithme « resserre » les grandes valeurs. Une différence de moyennes de logarithmes correspond à un *rapport* de moyennes géométriques.
9. Une différence est significative si la p-valeur ajustée est inférieure à $0{,}05$, ou si l'intervalle $[\,\texttt{lwr}\ ;\ \texttt{upr}\,]$ ne contient pas 0. Pour revenir à l'échelle d'origine, calculer $e^{\texttt{diff}}$. Regarder aussi l'altitude des villages de chaque groupe.
10. Une ACP calcule des moyennes, des variances et des corrélations : cela a-t-il un sens pour `village` ou `maize_yield` ? Combien de variables quantitatives contient `data.quanti` ?
11. En ACP normée, la somme des valeurs propres vaut le nombre de variables, ici 5. Critères usuels : valeur propre supérieure à 1 (Kaiser), coude de l'éboulis, pourcentage cumulé d'au moins $80\,\%$.
12. Angle entre deux flèches : proche de $0°$, corrélation positive forte ; proche de $90°$, corrélation faible ; proche de $180°$, corrélation négative. Une flèche n'est interprétable que si elle est longue. Penser au lien entre le nombre de cas, le nombre d'habitants et le taux d'incidence, et au rôle de l'altitude.

Tournez la page S.V.P.

Correction de l'exercice 1 ▲

Partie A – Analyse descriptive

1. **Le fichier de données.** Le tableau contient **19 villages** (les individus) décrits par **6 variables** :

Variable	Type	Principales caractéristiques
`village`	qualitative (identifiant)	19 noms tous différents
`maize_yield`	qualitative ordinale	High 8, Low 6, Medium 5
`mean_elevation_m`	quantitative	de 2 050 à 2 450 m ; seulement 3 valeurs distinctes
`person.years`	quantitative discrète	de 10 960 à 26 223 ; moyenne 16 590
`number_malaria_cases`	quantitative discrète	de 5 à 857 ; médiane 170, moyenne 224,6
`incidence_rate...`	quantitative	de 3 à 466 ; médiane 83, moyenne 129,4

   - Les deux variables qualitatives sont lues comme du texte (`chr`) ; il faudrait déclarer `maize_yield` comme facteur (`as.factor`). R range ses modalités par ordre alphabétique (High, Low, Medium), et non dans l'ordre naturel Low $<$ Medium $<$ High.
   - Pour le nombre de cas et le taux d'incidence, la moyenne est nettement supérieure à la médiane : les distributions sont **étalées vers la droite** (quelques villages très touchés).
   - Le taux d'incidence n'est pas une mesure indépendante : il se déduit des deux colonnes précédentes, $\dfrac{\text{nombre de cas}}{\text{person.years}} \times 10\,000$ (Gulim : $683/23\,458 \times 10\,000 \approx 291$).

2. **Interprétation des histogrammes.** Ce sont trois histogrammes, un par niveau de production ; l'axe horizontal est commun, mais chaque panneau a sa propre échelle verticale (`scales = "free_y"`).

   a) **Non.** Les valeurs s'étalent d'environ 40 à 470 pour High, de 50 à 170 pour Medium, et restent toutes sous 50 pour Low. Les dispersions sont très différentes, et elles augmentent avec le niveau moyen.

   b) **Difficile à dire, et plutôt non.** Chaque groupe ne compte que 5 à 8 villages : un histogramme est alors très grossier. Le groupe Low est concentré contre 0 (un taux ne peut pas être négatif), ce qui donne une distribution dissymétrique ; le groupe High est très dispersé, sans forme en cloche nette.

   c) **Oui, au moins en partie.** Le groupe Low est nettement à gauche (taux proches de 0), le groupe High nettement à droite ; Medium est intermédiaire et chevauche une partie du groupe High.

3. **Interprétation du tableau descriptif.**

   a) La production **High** : 234 cas pour 10 000 habitants en moyenne.

   b) La production **Low** : 17,7 cas pour 10 000 habitants, soit environ 13 fois moins.

   c) **Non.** Les écarts-types vont de 17,1 (Low) à 126 (High) : leur rapport vaut

$$\frac{126}{17{,}1} \approx 7{,}4,$$

   bien au-delà du seuil pratique de 2 (rapport des variances ≈ 55). L'écart-type augmente avec la moyenne : c'est typique de taux ou de comptages, et c'est précisément ce que le logarithme corrigera (question 8).

Partie B – Tests statistiques

4. **Le test du χ^2.** Malgré son nom dans l'énoncé, ce n'est pas un test d'indépendance : un test d'indépendance croise *deux* variables qualitatives. La sortie le dit (`Chi-squared test for given probabilities`) : c'est un test d'**ajustement** à une loi donnée, par défaut la loi uniforme.

   a) H_0 : les trois niveaux de production sont équiprobables, $p_{\text{High}} = p_{\text{Low}} = p_{\text{Medium}} = \frac{1}{3}$. Sous H_0, on attend $19/3 \approx 6{,}33$ villages par niveau.

b) $\chi^2_{\text{obs}} = \dfrac{(8-6{,}33)^2+(6-6{,}33)^2+(5-6{,}33)^2}{6{,}33} \approx 0{,}737$, avec 2 degrés de liberté et $p = 0{,}69 > 0{,}05$: on **ne rejette pas** H_0. Les effectifs des trois groupes sont compatibles avec une répartition équilibrée ; le plan d'observation n'est pas trop déséquilibré.

Ce test ne dit rien de l'*indépendance des observations* exigée par l'ANOVA : celle-ci relève du protocole (villages différents, éloignés les uns des autres) et ne se teste pas ainsi. Un léger déséquilibre des effectifs ne gêne d'ailleurs pas l'ANOVA.

5. Test de Student.

a) Pour deux groupes : H_0 : $\mu_1 = \mu_2$ (les deux moyennes sont égales), contre H_1 : $\mu_1 \neq \mu_2$.

b) Le test de Student compare **deux** moyennes, alors que `maize_yield` a **trois** modalités : R renvoie l'erreur `grouping factor must have exactly 2 levels`. Faire les 3 comparaisons deux à deux ne convient pas non plus : chaque test ayant un risque de 5 %, le risque de conclure à tort au moins une fois monterait à environ $1 - 0{,}95^3 \approx 14\,\%$. Il faut une méthode qui compare les trois moyennes en une fois : l'ANOVA.

6. ANOVA.

a) H_0 : $\mu_{\text{High}} = \mu_{\text{Medium}} = \mu_{\text{Low}}$ (le taux d'incidence moyen est le même quel que soit le niveau de production), contre H_1 : au moins deux moyennes diffèrent.

b)
- **indépendance** des observations (villages distincts) ;
- **normalité des résidus** (test de Shapiro–Wilk, Q-Q plot) ;
- **homogénéité des variances** entre groupes (test de Levene ou de Bartlett).

7. Violation des hypothèses.

a) Test de Levene : H_0 : les variances des trois groupes sont égales. $p = 0{,}040 < 0{,}05$: on **rejette** H_0 ; les variances sont hétérogènes, ce que laissaient prévoir les histogrammes et le rapport des écarts-types (7,4).

b) Test de Shapiro–Wilk sur les résidus : H_0 : les résidus suivent une loi normale. $p = 0{,}023 < 0{,}05$: on **rejette** la normalité des résidus.

c) **Non.** Deux des trois conditions sont violées, sur de petits groupes (5 à 8 villages) : l'ANOVA n'est pas robuste dans ces conditions.

d) L'ANOVA donne $F = \dfrac{84\,422}{7\,518} \approx 11{,}23$ et $p = 0{,}0009$: elle conclurait à une différence très significative entre les taux moyens (le niveau de production expliquerait $R^2 = \frac{168\,844}{289\,138} \approx 58\,\%$ de la variabilité). Mais ses conditions n'étant pas remplies, cette p-valeur n'est **pas fiable** : l'information n'est pas exploitable en l'état. Il faut transformer les données (question suivante) ou utiliser un test non paramétrique (test de Kruskal–Wallis, qui donne ici $p \approx 0{,}001$).

8. Transformation des données.

a) **Oui, nettement mieux.**

	Taux d'incidence	log(taux)
Levene (p)	0,040 : variances inégales	0,056 : non rejeté
Shapiro–Wilk (p)	0,023 : non normal	0,89 : normalité non rejetée
Rapport des écarts-types	7,4	$1{,}13/0{,}39 \approx 2{,}9$

La normalité des résidus est désormais très satisfaisante. Pour les variances, le test de Levene n'est plus significatif, mais de justesse ($p = 0{,}056$) : le groupe Low, avec ses taux très faibles (3 à 40), reste plus dispersé sur l'échelle logarithmique. Les conditions sont acceptables, sans être parfaites.

b) $F = \dfrac{14{,}744}{0{,}663} \approx 22{,}2$ avec 2 et 16 degrés de liberté, $p = 2{,}4 \times 10^{-5}$: on **rejette** H_0. Le logarithme moyen du taux d'incidence diffère selon le niveau de production de maïs, et ce facteur explique $R^2 = \frac{29{,}49}{29{,}49+10{,}62} \approx 74\,\%$ de sa variabilité. Il existe donc une **association statistique** entre production de maïs et incidence de la malaria.

c) **Non.** L'ANOVA dit seulement qu'au moins deux moyennes diffèrent, pas lesquelles : il faut un test post-hoc.

Tournez la page S.V.P.

9. Test post-hoc de Tukey.

a) Un test post-hoc compare toutes les paires de groupes *après* une ANOVA significative, en contrôlant le risque global d'erreur de première espèce (5 % pour l'ensemble des comparaisons, *family-wise confidence level*), ce que ne font pas des tests de Student successifs.

b) Une différence est significative quand la p-valeur ajustée est inférieure à 0,05, c'est-à-dire quand l'intervalle $[\,\texttt{lwr}\ ;\ \texttt{upr}\,]$ ne contient pas 0. Sur l'échelle logarithmique, une différence `diff` correspond à un *rapport* $e^{\texttt{diff}}$ entre moyennes géométriques des taux :

Comparaison	`diff`	p ajustée	$e^{\texttt{diff}}$	Conclusion
Low – High	$-2{,}89$	0,00002	0,055	significative ($\div 18$)
Medium – Low	$+2{,}11$	0,0016	8,2	significative ($\times 8$)
Medium – High	$-0{,}79$	0,24	0,45	non significative

- Les villages à **faible production de maïs** ont un taux d'incidence significativement plus faible que les deux autres groupes (moyennes géométriques : environ 11 cas pour 10 000 habitants, contre 89 pour Medium et 196 pour High).
- Les groupes Medium et High **ne se distinguent pas significativement** : l'intervalle $[-1{,}99\ ;\ 0{,}41]$ contient 0. En lettres : High a, Medium a, Low b.
- **Prudence sur l'interprétation.** Ces données sont *observationnelles* : elles montrent une association, pas une causalité. En particulier, les niveaux de production sont liés à l'**altitude** : les 8 villages High sont tous à 2 050 m, les villages Low entre 2 200 et 2 450 m. Or la transmission de la malaria diminue avec l'altitude (il fait plus froid pour les moustiques). On ne peut donc pas séparer l'effet du maïs de celui de l'altitude avec ces seules données ; il faudrait comparer des villages de même altitude ou intégrer l'altitude au modèle.

Partie C – Analyse factorielle

10. Question théorique.

a) L'ACP calcule des moyennes, des variances et des corrélations, puis diagonalise la matrice des corrélations : cela n'a de sens que pour des variables quantitatives. `village` (un nom) et `maize_yield` (une catégorie) feraient échouer l'analyse ; `sapply(data_ethiopia, is.numeric)` ne garde que les 5 colonnes numériques :

`mean_elevation_m`, `person.years`, `number_malaria_cases`, `incidence_rate_per_ten_thousand`, `log_incidence`.

Une variable qualitative peut ensuite servir à *interpréter* les résultats, comme variable supplémentaire.

b) L'ACP résume l'information de plusieurs variables quantitatives corrélées par un petit nombre de nouvelles variables non corrélées (les composantes principales), qui conservent le plus possible de variance. Elle permet de visualiser sur un plan les liaisons entre variables et les ressemblances entre individus. Ici, elle permet de voir d'un coup d'œil comment l'incidence de la malaria est liée à l'altitude et à la taille des villages. C'est une méthode descriptive et exploratoire : elle ne teste aucune hypothèse.

11. Variance expliquée. On retient **deux composantes** :

- *variance cumulée* : les deux premiers axes restituent $66{,}8 + 19{,}8 \approx 86{,}6\,\%$ de l'inertie, au-delà du seuil usuel de 80 % ;
- *coude* : la grande cassure de l'éboulis est entre les axes 1 et 2, puis les barres décroissent plus lentement ; les axes 3 à 5 apportent peu (13 % à eux trois) ;
- *Kaiser* : seul $\lambda_1 = 3{,}34$ dépasse strictement 1, mais $\lambda_2 = 0{,}99$ en est si proche que l'axe 2 mérite d'être gardé : il résume presque à lui seul une variable (`person.years`, voir question suivante).

Remarque. $\lambda_5 = 0{,}007$ est presque nul : il existe une relation presque exacte entre les variables. C'est logique : le taux d'incidence se calcule à partir du nombre de cas et du nombre d'habitants, et `log_incidence` à partir du taux.

12. Cercle des corrélations. Coordonnées des flèches (corrélations avec les axes) et matrice des corrélations utiles :

Variable	$r(\cdot, F_1)$	$r(\cdot, F_2)$	$\cos^2$ sur le plan	contribution à l'axe 1 (%)
`mean_elevation_m`	$-0{,}77$	$0{,}34$	$0{,}71$	$17{,}9$
`person.years`	$0{,}34$	$0{,}92$	$0{,}95$	$3{,}4$
`number_malaria_cases`	$0{,}94$	$0{,}14$	$0{,}91$	$26{,}5$
`incidence_rate...`	$0{,}95$	$-0{,}06$	$0{,}90$	$26{,}9$
`log_incidence`	$0{,}92$	$-0{,}14$	$0{,}86$	$25{,}2$

a) **Fortement corrélées positivement** : le nombre de cas (`number_malaria_cases`) et le taux d'incidence (flèches presque confondues ; $r = 0{,}97$). On peut citer aussi le taux et son logarithme ($r = 0{,}83$).

b) **Fortement corrélées négativement** : `mean_elevation_m` et `log_incidence` (flèches presque opposées ; $r = -0{,}73$), ou l'altitude et le taux d'incidence ($r = -0{,}61$).

c) **Faiblement corrélées** : `person.years` et `mean_elevation_m` ($r = -0{,}06$), ou `person.years` et le taux d'incidence ($r = 0{,}20$) : flèches presque perpendiculaires.

d) La **longueur** d'une flèche mesure la qualité de représentation de la variable sur le plan ($\cos^2$) : ici toutes les flèches sont longues ($\cos^2$ de $0{,}71$ à $0{,}95$, ce qu'indique aussi l'échelle de couleur), donc toutes s'interprètent. L'**orientation** indique à quels axes la variable est liée (horizontale : axe 1 ; verticale : axe 2) ; l'angle entre deux flèches traduit leur corrélation : proche de $0°$, corrélation positive forte ; proche de $90°$, corrélation faible ; proche de $180°$, corrélation négative forte.

e) Les trois variables de malaria (environ 25 à $27\,\%$ chacune) et l'altitude ($18\,\%$) contribuent fortement à l'axe 1, au-dessus de la contribution moyenne de $100/5 = 20\,\%$ ou proches d'elle ; `person.years` n'y contribue presque pas ($3\,\%$) mais construit à elle seule l'axe 2 ($84\,\%$).

f)
- L'**axe 1** est un *axe malaria–altitude* : à droite les villages où la malaria est fréquente, à gauche les villages d'altitude, peu touchés.
- L'**axe 2** est un *axe taille du village*, indépendant du premier : la taille de la population n'est pas liée au taux d'incidence, ce qui est attendu puisque le taux est justement rapporté au nombre d'habitants.
- Si l'on projette les niveaux de production comme variable qualitative supplémentaire, les villages High se placent du côté droit de l'axe 1 (coordonnée moyenne $\approx 1{,}65$), les villages Low du côté gauche ($\approx -1{,}97$). On retrouve le résultat de l'ANOVA, mais aussi la même limite : sur cet axe, forte production de maïs, basse altitude et malaria vont ensemble, et l'ACP ne permet pas de dire lequel de ces facteurs explique l'autre.
- Enfin, trois des cinq variables mesurent la même chose (la malaria) : elles « pèsent » trois fois dans la construction de l'axe 1. Il serait plus rigoureux de n'en garder qu'une (par exemple `log_incidence`).