

Fiche Mémo Stat. II

Antoine Géré

Année 2026 - 2027¹



Ces notes sont en cours d'élaboration. Si vous avez la moindre question ou remarque ne pas hésiter à contacter par mail : a.gere@istom.fr.

Ces cinq visages incarnent la statistique telle qu'elle se pratique aujourd'hui : non plus une affaire de formules abstraites, mais un outil pour comprendre et transformer le monde réel. **Hans Rosling** a montré, avec Gapminder, comment de simples données de santé et de développement peuvent renverser nos idées reçues sur les pays du Sud. **Esther Duflo**, prix Nobel d'économie, a fait de l'expérimentation rigoureuse, les essais randomisés, une méthode pour savoir ce qui marche vraiment contre la pauvreté. **Hadley Wickham** a bâti les outils (le tidyverse, en R) avec lesquels toute une génération apprend aujourd'hui à explorer et visualiser les données. **Cathy O'Neil** rappelle l'envers du décor : quand les algorithmes décident à notre place, ils peuvent aussi amplifier les injustices, d'où la nécessité d'un regard critique. Enfin, **David Spiegelhalter** s'attache à rendre l'incertitude et le risque compréhensibles, pour que chacun puisse lire un chiffre sans se laisser tromper. Ensemble, ils dessinent une discipline vivante, au service de la santé, de l'environnement et du développement.

Table des matières

1	Probabilités	2
1.1	Événements et dénombrement	2
1.2	Probabilités conditionnelles	2
1.3	Indépendance	3
1.4	Variables aléatoires discrètes	3
1.5	Lois usuelles	3
1.6	Théorème central limite (TCL)	5
2	Échantillonnage	5
2.1	Plans d'échantillonnage et biais	6
2.2	Moyenne et variance d'un échantillon	7
2.3	Fréquence et taille d'échantillon	7
3	Estimation	9
3.1	Estimation ponctuelle	9
3.2	Intervalles de confiance	9


¹version du 5 octobre 2026

1 Probabilités

1.1 Événements et dénombrement

Calculer avec des événements

- $P(\bar{A}) = 1 - P(A)$
- $P(A \cup B) = P(A) + P(B) - P(A \cap B)$ (si A et B sont incompatibles, $P(A \cap B) = 0$).
- « A mais pas B » : $P(A \cap \bar{B}) = P(A) - P(A \cap B)$; « un seul des deux » : $P(A) + P(B) - 2P(A \cap B)$.
- De Morgan : $\overline{A \cup B} = \bar{A} \cap \bar{B}$ et $\overline{A \cap B} = \bar{A} \cup \bar{B}$.
- Probabilité uniforme : $P(A) = \frac{\text{nombre de cas favorables}}{\text{nombre de cas possibles}}$.



$A \cup B$: l'intérieur des deux cercles. Dans $P(A) + P(B)$, la zone orange $A \cap B$ est comptée deux fois : on la retire une fois. Le reste du rectangle est « ni A ni B ».

On choisit k éléments parmi n	L'ordre compte ?	Nombre de choix
On range les n éléments	oui	$n!$
Arrangement	oui	$A_n^k = \frac{n!}{(n-k)!}$
Combinaison	non	$\binom{n}{k} = \frac{n!}{k!(n-k)!}$

Principe multiplicatif : choix successifs indépendants $\Rightarrow$ on *multiplie* les nombres de choix. Ex. : 2 bovins parmi 3 et 1 ovin parmi 5 : $\binom{3}{2} \times \binom{5}{1} = 15$.

1.2 Probabilités conditionnelles

Conditionnement, probabilités totales, Bayes


- $P(A | B) = \frac{P(A \cap B)}{P(B)}$, donc $P(A \cap B) = P(B) P(A | B)$.
- Si $B_1, \dots, B_k$ forment un **système complet**^a (incompatibles, de réunion Ω) :

$$P(A) = \sum_i P(B_i) P(A | B_i)$$

$$P(B_j | A) = \frac{P(B_j) P(A | B_j)}{P(A)} \quad (\text{Bayes}).$$

^aOn appelle système complet d'événements toute famille finie ou dénombrable d'événements 2 à 2 incompatibles, et dont la réunion est égale à l'univers entier Ω .

Méthode : faire un **arbre pondéré**; on multiplie le long d'une branche, on additionne les branches qui mènent au même événement.



On multiplie le long d'une branche. $P(+)$ = somme des deux branches rouges (probabilités totales).

$$VPP = P(M | +) = \frac{\text{branche rouge du haut}}{P(+)}$$

Test de diagnostic. M : « malade », $+$: « test positif ». Prévalence $P(M)$, sensibilité $P(+ | M)$, spécificité $P(- | \bar{M})$. La question utile est la **valeur prédictive positive** $VPP = P(M | +)$, calculée par Bayes; elle dépend fortement de la prévalence. De même, la **valeur prédictive négative** est

$$VPN = P(\bar{M} | -) = \frac{P(\bar{M}) P(- | \bar{M})}{P(-)}$$

1.3 Indépendance

A et B sont **indépendants** si $P(A \cap B) = P(A) P(B)$ (équivalent : $P(A | B) = P(A)$). Pour n épreuves indépendantes de même probabilité de succès p :

$$P(\text{aucun succès}) = (1 - p)^n, \quad P(\text{au moins un succès}) = 1 - (1 - p)^n.$$

1.4 Variables aléatoires discrètes

Loi, espérance, variance

- Loi : la liste des valeurs x_i et des probabilités $p_i = P(X = x_i)$, avec $\sum p_i = 1$.
- Fonction de répartition : $F(x) = P(X \leq x)$ (fonction en escalier).
- $E(X) = \sum x_i p_i$, $V(X) = E(X^2) - E(X)^2 = \sum x_i^2 p_i - E(X)^2$, $\sigma(X) = \sqrt{V(X)}$.
- $E(aX + b) = aE(X) + b$ $V(aX + b) = a^2 V(X)$.
- $E(X + Y) = E(X) + E(Y)$ toujours; $V(X + Y) = V(X) + V(Y)$ si X et Y sont **indépendantes**.

1.5 Lois usuelles


Lois discrètes : on *compte* (valeurs $0, 1, 2, \dots$).

Loi	On la reconnaît quand...	$P(X = k)$	$E(X)$	$V(X)$
Bernoulli $\mathcal{B}(p)$	une seule épreuve à deux issues (succès = 1, échec = 0)	$P(X = 1) = p$	p	$p(1 - p)$
Binomiale $\mathcal{B}(n, p)$	on compte les succès sur n épreuves indépendantes de même probabilité p (ou tirage avec remise)	$\binom{n}{k} p^k (1 - p)^{n-k}$	np	$np(1 - p)$
Hypergéom. $\mathcal{H}(N, K, n)$	on compte les succès parmi n unités tirées sans remise dans une population de N unités dont K succès	$\frac{\binom{K}{k} \binom{N-K}{n-k}}{\binom{N}{n}}$	np avec $p = \frac{K}{N}$	$np(1 - p) \frac{N - n}{N - 1}$
Poisson $\mathcal{P}(\lambda)$	on compte des événements rares , indépendants, à taux constant, dans une unité de temps ou d'espace; λ = nombre moyen	$e^{-\lambda} \frac{\lambda^k}{k!}$	λ	λ


Lois continues : on *mesure* (toutes les valeurs d'un intervalle; $P(X = x) = 0$).

Loi	On la reconnaît quand...	Probabilité utile	$E(X)$	$V(X)$
Uniforme $\mathcal{U}([a, b])$	valeur « au hasard » entre a et b , toutes aussi probables (randomisation, date de semis, ...)	$P(X \leq x) = \frac{x - a}{b - a}$	$\frac{a + b}{2}$	$\frac{(b - a)^2}{12}$
Exponentielle $\mathcal{E}(\lambda)$	durée d'attente avant un événement (panne, levée); λ = taux, $1/\lambda$ = durée moyenne	$P(X > t) = e^{-\lambda t}$ médiane = $\frac{\ln 2}{\lambda}$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
Normale $\mathcal{N}(\mu, \sigma^2)$	grandeur continue résultant de nombreux petits effets (rendement, poids); courbe en cloche	$P(X \leq x) = \Phi\left(\frac{x - \mu}{\sigma}\right)$	μ	σ^2

Remarque : $\mathcal{P}(\lambda_1) + \mathcal{P}(\lambda_2) = \mathcal{P}(\lambda_1 + \lambda_2)$ (comptages indépendants); l'exponentielle est **sans mémoire** : $P(X > s + t \mid X > s) = P(X > t)$.



Quand le calcul exact est trop lourd, on remplace la loi par une loi plus simple, à condition de respecter les conditions écrites sur les flèches.



Loi de Poisson $\mathcal{P}(1,5)$ (chenilles par plant) : $P(X \geq 3) = 1 - P(X = 0) - P(X = 1) - P(X = 2) \approx 0,19$.



Loi normale : tout ramener à $\mathcal{N}(0,1)$

Si $X \sim \mathcal{N}(\mu, \sigma^2)$, alors $Z = \frac{X - \mu}{\sigma} \sim \mathcal{N}(0,1)$, de fonction de répartition Φ (table).

$$P(X \leq x) = \Phi\left(\frac{x - \mu}{\sigma}\right), \quad P(a \leq X \leq b) = \Phi\left(\frac{b - \mu}{\sigma}\right) - \Phi\left(\frac{a - \mu}{\sigma}\right),$$

$$\Phi(-z) = 1 - \Phi(z).$$

Repères : $\mu \pm \sigma$ contient 68 % des valeurs, $\mu \pm 2\sigma$ environ 95 %, et $\mu \pm 3\sigma$ sensiblement 99,7 %.



À gauche : la table donne l'aire à gauche de z . Par symétrie, l'aire à gauche de $-z$ est égale à l'aire à droite de z : $\Phi(-z) = 1 - \Phi(z)$. À droite : 95 % des valeurs sont à moins de 1,96 écart-type de la moyenne ; c'est l'origine du 1,96 des intervalles.


1.6 Théorème central limite (TCL)

Pour n observations indépendantes de même loi (espérance μ , écart-type σ), quelle que soit la loi et dès que $n \geq 30$:

$$\bar{X}_n \approx \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right) \quad \text{et} \quad \sum X_i \approx \mathcal{N}(n\mu, n\sigma^2).$$


2 Échantillonnage

Échantillonnage : la population est *connue* (μ, σ, p) ; on étudie comment varient les échantillons. **Estimation** (section suivante) : la population est *inconnue* ; on la reconstitue à partir d'un échantillon.




2.1 Plans d'échantillonnage et biais

- **Recensement** : on observe toutes les unités (long, coûteux); **sondage** : on n'en observe qu'une partie, moins cher, plus rapide, avec une collecte plus soignée et une précision chiffrable.
- **Unité statistique** : l'élément sur lequel on mesure (une exploitation, un animal, une parcelle...). **Population** : toutes les unités étudiées; **échantillon** : les n unités observées; **base de sondage** : la liste où l'on tire l'échantillon (si elle est incomplète, la population réellement étudiée change).
- **Erreur d'échantillonnage** : aléatoire, diminue quand n augmente. **Biais** : systématique (sélection ou couverture, non-réponse, mesure); augmenter n ne le corrige pas.



Fluctuation seule (sans biais)




Biais (erreur systématique)


Chaque point est l'estimation (par exemple $\bar{x}$) obtenue sur un échantillon; le centre est la vraie valeur. L'écart des points autour de leur propre centre est l'erreur d'échantillonnage : elle diminue quand n augmente. Le décalage de tout le nuage est un biais (sélection, couverture, non-réponse, mesure) : augmenter n resserre les points autour d'une mauvaise valeur, sans les ramener vers le centre.

Plan	Principe
Aléatoire simple	tirage au hasard dans la base de sondage, chaque unité a la même chance.
Systématique	pas $k = N/n$, départ tiré entre 1 et k , puis une unité tous les k rangs (attention si la liste est périodique).
Stratifié	on découpe la population en strates (zones, tailles d'exploitation...) : chaque unité dans une seule strate, homogène à l'intérieur, différente des autres. Tirage aléatoire simple dans chaque strate. Plus précis que l'aléatoire simple si les strates sont bien choisies.
Grappes / degrés	on tire au hasard des groupes d'unités voisines (villages, ...) : grappes si l'on enquête toutes les unités des groupes tirés, plusieurs degrés si l'on en tire seulement une partie. Il suffit de la liste des groupes, et les déplacements sont réduits; mais les unités d'un même groupe se ressemblent : à n égal, la précision est plus faible (effet de grappe).
Non probabilistes	quotas, choix raisonné : rapides, mais précision non calculable et risque de biais.


Deux grandes familles : les plans **probabilistes** (aléatoire simple, systématique, stratifié, grappes : chaque unité a une probabilité connue et non nulle d'être tirée, donc la précision est calculable) et les plans **non probabilistes** (quotas, choix raisonné).




Aléatoire simple



Systématique (pas k)



Stratifié (3 strates)



Par grappes


En rouge, les unités enquêtées. Stratifié : on tire dans chaque strate. Par grappes : on tire des groupes entiers (villages), moins coûteux mais moins précis.

2.2 Moyenne et variance d'un échantillon

Moyenne empirique $\bar{X}_n = \frac{1}{n} \sum X_i$

$$E(\bar{X}_n) = \mu, \quad V(\bar{X}_n) = \frac{\sigma^2}{n}, \quad \sigma(\bar{X}_n) = \frac{\sigma}{\sqrt{n}} \quad (\text{erreur-type}).$$

- Population normale : $\bar{X}_n \sim \mathcal{N}(\mu, \sigma^2/n)$ exactement ; sinon par le TCL si $n \geq 30$.
- Intervalle de fluctuation à 95 % : $\bar{X}_n$ tombe dans $\mu \pm 1,96 \frac{\sigma}{\sqrt{n}}$ avec probabilité 0,95.
- Diviser l'erreur-type par 2 demande 4 fois plus d'unités.
- Population finie (taux $n/N > 10\%$) : $\sigma(\bar{X}_n) = \frac{\sigma}{\sqrt{n}} \sqrt{\frac{N-n}{N-1}}$, où $\frac{N-n}{N-1}$ est le **facteur d'exhaustivité** (tirage sans remise ; proche de 1 si $n \ll N$).



La moyenne d'un échantillon reste centrée sur μ mais fluctue de moins en moins : son écart-type est $\sigma/\sqrt{n}$. Pour diviser cette fluctuation par 2, il faut 4 fois plus d'unités.

Variance empirique et variance corrigée

$$s^2 = \frac{1}{n} \sum (x_i - \bar{x})^2 \quad (\text{biaisée : } E(S^2) = \frac{n-1}{n} \sigma^2), \quad s'^2 = \frac{1}{n-1} \sum (x_i - \bar{x})^2 = \frac{n}{n-1} s^2 \quad (\text{sans biais}).$$


Calcul pratique : $s^2 = \overline{x^2} - \bar{x}^2$ (König-Huygens).

2.3 Fréquence et taille d'échantillon

Fréquence $F = K/n$ d'un caractère de proportion p

$K \sim \mathcal{B}(n, p)$, $E(F) = p$, $\sigma(F) = \sqrt{\frac{p(1-p)}{n}}$. Si $np \geq 5$ et $n(1-p) \geq 5$: $F \approx \mathcal{N}\left(p, \frac{p(1-p)}{n}\right)$ (théorème de **Moivre-Laplace** : le TCL appliqué à une binomiale).

- Intervalle de fluctuation à 95 % : $p \pm 1,96 \sqrt{\frac{p(1-p)}{n}}$; forme simplifiée $p \pm \frac{1}{\sqrt{n}}$ (si $n \geq 25$ et $0,2 < p < 0,8$).
- Si la fréquence observée sort de cet intervalle, on remet en cause la valeur p annoncée (risque 5%).



Semences annoncées à 90 % de germination, $n = 200$ graines testées. Si l'annonce est vraie, F tombe dans la zone verte 95 fois sur 100. La fréquence observée (0,84) est en dehors : on remet en cause l'annonce.


Taille d'échantillon pour une marge d'erreur e (arrondir au-dessus)

On fixe la marge e voulue (demi-largeur de l'intervalle, dans l'unité de la variable).

$$\text{Moyenne : } n \geq \left(\frac{z\sigma}{e} \right)^2 \quad \text{Proportion : } n \geq \frac{z^2 p(1-p)}{e^2}$$

- z : quantile de la loi normale qui fixe le **niveau de confiance** : $z = 1,645$ à 90 %, 1,96 à 95 %, 2,576 à 99 % (cf. tableau).
- σ : écart-type de la population, ou son estimation tirée d'une enquête précédente ou d'un pré-test.
- p inconnu : on prend $p = 0,5$, où $p(1-p)$ est **maximal** (0,25), d'où $n \geq \frac{z^2}{4e^2}$: taille « au pire », toujours suffisante.
- Population finie de taille N : si la taille n_0 obtenue ci-dessus dépasse 10 % de N , on la réduit :
$$n = \frac{n_0}{1 + n_0/N}$$

marge e (en unités de σ)



Marge d'erreur à 95 % : $e = 1,96 \sigma / \sqrt{n}$. Elle diminue vite au début, puis de plus en plus lentement : multiplier n par 4 ne divise la marge que par 2. Gagner en précision coûte cher.

Exemple : chenilles légionnaires sur le maïs au Sénégal

On sait que 30 % des champs de maïs sont infestés ($p = 0,30$, valeur connue). Un agent inspecte $n = 100$ champs tirés au hasard ; F est la proportion de champs infestés qu'il trouvera.

1. **Loi de F .** $np = 30 \geq 5$ et $n(1-p) = 70 \geq 5$, donc $F \approx \mathcal{N}(0,30; 0,046^2)$, avec $\sigma(F) \approx 0,046$.
2. **Probabilité d'un résultat élevé.** $P(F > 0,40) = P\left(Z > \frac{0,40 - 0,30}{0,046}\right) \approx 1 - \Phi(2,18) \approx 0,015$.
3. **Intervalle de fluctuation à 95 %.** $0,30 \pm 1,96 \times 0,046 = [0,21; 0,39]$. Si l'agent trouve 40 % de champs infestés, ce résultat sort de l'intervalle.
4. **Et pour plus de précision ?** Avec ces 100 champs, la marge est de $\pm 9\%$ ($1,96 \times 0,046 \approx 0,09$). Pour réestimer p à $\pm 3\%$ près la saison suivante (l'infestation a pu changer), il faut diviser la marge par 3, donc multiplier n par 9 : avec l'ancienne valeur $p \approx 0,30$ comme ordre de grandeur, $n \geq \frac{1,96^2 \times 0,30 \times 0,70}{0,03^2} \approx 896,4$, soit 897 champs. Sans aucune information ($p = 0,5$) : $n \geq \frac{1,96^2}{4 \times 0,03^2} \approx 1067,1$, soit 1068 champs, taille suffisante quelle que soit la vraie valeur de p .

3 Estimation


3.1 Estimation ponctuelle

Un **estimateur** est une formule appliquée à l'échantillon (variable aléatoire) ; une **estimation** est le nombre obtenu sur les données.

Paramètre	Estimation	Remarque
moyenne μ	$\bar{x}$	sans biais
proportion p	$f = k/n$	sans biais
écart-type σ	$s' = s\sqrt{\frac{n}{n-1}}$	on corrige l'écart-type de l'échantillon


3.2 Intervalles de confiance

Interprétation : si l'on répétait l'échantillonnage, 95 % des intervalles ainsi construits contiendraient la vraie valeur. Une fois calculé, l'intervalle contient ou non cette valeur : c'est la *méthode* qui réussit 95 % du temps.



Dix échantillons, dix intervalles différents (le point est la moyenne observée $\bar{x}$). À 95 %, environ 1 intervalle sur 20 ne contient pas μ : on ne sait jamais si le sien est le bon, mais la méthode réussit 95 % du temps.


Niveau $1 - \alpha$	80 %	85 %	90 %	92 %	95 %	99 %
$z = z_{1-\alpha/2}$	1,282	1,440	1,645	1,751	1,960	2,576



L'intervalle est centré sur la valeur observée $\bar{x}$ (ou f) et s'étend de la marge e de chaque côté, avec $e = z\sigma/\sqrt{n}$ pour une moyenne et $e = z\sqrt{f(1-f)/n}$ pour une proportion.


Les intervalles à connaître

Moyenne, σ connu	$\bar{x} \pm z \frac{\sigma}{\sqrt{n}}$
Moyenne, σ inconnu, population normale, petit n	$\bar{x} \pm t_{n-1; 1-\alpha/2} \frac{s'}{\sqrt{n}}$ (table de Student à $n - 1$ ddl)
Moyenne, σ inconnu, $n \geq 30$	$\bar{x} \pm z \frac{s'}{\sqrt{n}}$
Proportion ($n \geq 30$, $nf \geq 5$, $n(1-f) \geq 5$)	$f \pm z \sqrt{\frac{f(1-f)}{n}}$ (intervalle de Wald)
Différence de deux proportions	$(f_1 - f_2) \pm z \sqrt{\frac{f_1(1-f_1)}{n_1} + \frac{f_2(1-f_2)}{n_2}}$
Différence de moyennes <i>appariées</i>	$\bar{d} \pm t_{n-1; 1-\alpha/2} \frac{s'_d}{\sqrt{n}}$ (sur les différences d_i)



Quand σ est estimé par s' sur peu de données, on utilise la loi de Student, plus étalée : son quantile est plus grand que 1,96, donc l'intervalle est plus large. Pour $n \geq 30$, les deux lois se confondent.

- Student suppose une population normale : on le vérifie avec un histogramme ou une boîte à moustaches (symétrie, pas de valeur aberrante), une droite de Henry (QQ-plot) ou un test de Shapiro-Wilk.
- **Appariement** (mêmes unités mesurées deux fois, ou paires de parcelles voisines) : on travaille sur les différences d_i , ce qui élimine la variabilité *entre* unités ; s'_d est plus petit, donc l'intervalle est plus étroit.
- Grandeur proportionnelle à μ (prix = $a\mu$, total = $N\mu$, gain sur 90 jours = 90μ) : on **multiplie les deux bornes** de l'intervalle par la même constante.
- La marge e (demi-largeur) augmente avec le niveau de confiance et σ , diminue en $1/\sqrt{n}$.
- Une valeur de référence *hors* de l'intervalle n'est pas compatible avec les données ; si l'intervalle d'une *différence* contient 0, on ne peut pas conclure à une différence.



Intervalles de confiance d'une différence : écart de taux d'adoption entre deux villages (en orange) et gain de rendement d'une variété améliorée en parcelles appariées (en vert).



istom

Ecole
supérieure
d'agro-
développement
international





Étudiant(e) (Nom, Prénom) :

Promotion, groupe :

Email :