

Travaux dirigés

Promotion 116

Table des matières

1	Probabilités	1
1.1	Événements et dénombrement	1
1.2	Probabilités conditionnelles et formule de Bayes	2
1.3	Indépendance	3
1.4	Variations aléatoires et lois discrètes	4
1.5	Lois continues	6
2	Échantillonnage	7
2.1	Plans d'échantillonnage et biais	7
2.2	Moyenne et variance d'un échantillon	9
2.3	Théorème central limite, fréquence et taille d'échantillon	11
3	Estimation	12
3.1	Estimation ponctuelle	12
3.2	Intervalle de confiance d'une moyenne	13
3.3	Intervalle de confiance d'une proportion et d'une différence	16
3.4	Synthèse	17
	Indications	19
	Corrections	31

1 Probabilités

1.1 Événements et dénombrement

Exercice 1 Bio-agresseurs du manioc au Togo

Dans une région du Togo, un technicien d'une ONG inspecte les pieds de manioc d'une grande exploitation. Pour un pied choisi au hasard, on note :

- M : « le pied présente des symptômes de la mosaïque du manioc » ;
- C : « le pied est attaqué par la cochenille farineuse ».

Les relevés des campagnes précédentes donnent $P(M) = 0,30$, $P(C) = 0,25$ et $P(M \cap C) = 0,10$.

1. Traduire par une phrase les événements $M \cup C$, $\overline{M} \cap \overline{C}$ et $M \cap \overline{C}$.
2. Les événements M et C sont-ils incompatibles ? Justifier.
3. Calculer la probabilité qu'un pied soit atteint par au moins un des deux bio-agresseurs.
4. À l'aide d'une loi de De Morgan, calculer la probabilité qu'un pied soit indemne des deux bio-agresseurs.
5. Calculer la probabilité qu'un pied soit atteint par *un seul* des deux bio-agresseurs.
6. Calculer $P(M | C)$ et $P(C | M)$. Interpréter chacune de ces valeurs.

7. Les événements M et C sont-ils indépendants ? Que peut-on en dire d'un point de vue agronomique ?

Indication ▼ Correction ▼

[stat-0063]

Exercice 2 Dénombrement et essai variétal de niébé au Burkina Faso

Un institut de recherche agricole du Burkina Faso dispose de 8 variétés de niébé, dont 3 variétés améliorées et 5 variétés locales. Il prépare un essai au champ.

- On choisit 3 variétés parmi les 8 pour l'essai, sans tenir compte de l'ordre.
 - Combien de choix différents sont possibles ?
 - Les 3 variétés retenues doivent ensuite être semées sur 3 parcelles numérotées 1, 2, 3 (une variété par parcelle). Combien de dispositions différentes existe-t-il si l'on part directement des 8 variétés ?
- Un agriculteur doit réaliser 5 opérations culturales distinctes (labour, semis, sarclage, traitement, récolte partielle) dans un ordre quelconque pour un essai de calendrier. Combien d'ordres sont possibles ?
- Les 3 variétés de l'essai sont tirées au hasard parmi les 8 (tous les choix sont équiprobables).
 - Quelle est la probabilité que les 3 variétés tirées soient les 3 variétés améliorées ?
 - Quelle est la probabilité de tirer exactement 2 variétés améliorées ?
 - Quelle est la probabilité de tirer au moins une variété améliorée ?

Indication ▼ Correction ▼

[stat-0064]

1.2 Probabilités conditionnelles et formule de Bayes

Exercice 3 Le striga sur un terroir hétérogène au Mali

Une exploitation de la région de Ségou (Mali) cultive du sorgho sur trois types de sol :

- 50 % des parcelles sont sur sol sableux (S_1) ;
- 30 % sur sol argileux (S_2) ;
- 20 % sur sol hydromorphe de bas-fond (S_3).

Le striga, une plante parasite, infeste 40 % des parcelles sur sol sableux, 15 % des parcelles sur sol argileux et 10 % des parcelles sur sol hydromorphe. On choisit une parcelle au hasard et on note I : « la parcelle est infestée par le striga ».

- Justifier que $\{S_1, S_2, S_3\}$ forme un système complet d'événements, puis construire l'arbre pondéré.
- Calculer $P(I)$.
- Une parcelle est infestée. Quelle est la probabilité qu'elle soit sur sol sableux ? sur sol argileux ? sur sol hydromorphe ? Vérifier que la somme vaut 1.
- Une parcelle n'est pas infestée. Quelle est la probabilité qu'elle soit sur sol sableux ?
- Le technicien dispose d'un traitement pour seulement la moitié des parcelles. Sur quel(s) type(s) de sol conseillez-vous de le concentrer ? Justifier à l'aide des résultats précédents.

Indication ▼ Correction ▼

[stat-0066]

Exercice 4 Dépistage de la peste porcine africaine au Cameroun

Dans les élevages porcins de l'Ouest du Cameroun, les services vétérinaires utilisent un test rapide de dépistage de la peste porcine africaine (PPA). On note M : « le porc est infecté » et $+$: « le test est positif ». Les caractéristiques du test sont :

- sensibilité : $P(+ | M) = 0,95$;
- spécificité : $P(- | \overline{M}) = 0,98$.

Dans la zone étudiée, la prévalence de la maladie est estimée à $P(M) = 0,04$.

1. Construire l'arbre pondéré décrivant la situation.
2. Calculer la probabilité qu'un porc pris au hasard ait un test positif.
3. Un porc a un test positif. Quelle est la probabilité qu'il soit réellement infecté (valeur prédictive positive, VPP) ? Commenter.
4. Un porc a un test négatif. Quelle est la probabilité qu'il soit réellement sain (valeur prédictive négative, VPN) ?
5. Le même test est utilisé dans un élevage où un foyer est déclaré : la prévalence y est de 0,30. Recalculer la VPP. Que constate-t-on ?

Indication ▼ Correction ▼

[stat-0065]

1.3 Indépendance

Exercice 5 Combien de graines par poquet ? (Niger)

Au Niger, le mil est semé en poquets (petits trous dans lesquels on dépose plusieurs graines). Le taux de levée d'une graine du lot utilisé est de 0,7. On suppose que les graines lèvent indépendamment les unes des autres.

1. On sème 2 graines par poquet. Calculer la probabilité :
 - (a) qu'aucune graine ne lève (poquet « vide ») ;
 - (b) qu'au moins une graine lève.
2. On sème 3 graines par poquet.
 - (a) Calculer la probabilité que le poquet soit vide.
 - (b) Calculer la probabilité qu'exactement 2 graines lèvent.
 - (c) Un champ compte 100 poquets semés de cette façon. Combien de poquets vides peut-on s'attendre à devoir ressemer ?
3. On sème k graines par poquet. Exprimer en fonction de k la probabilité qu'au moins une graine lève.
4. Déterminer le nombre minimal de graines à semer par poquet pour que la probabilité d'avoir au moins une levée dépasse 0,99.
5. Pourquoi l'hypothèse d'indépendance peut-elle être discutable sur le terrain ?

Indication ▼ Correction ▼

[stat-0067]

1.4 Variables aléatoires et lois discrètes

Exercice 6 Prolifération des chèvres dans un élevage sénégalais

Dans un élevage de chèvres du Sénégal, on note X le nombre de chevreaux nés vivants lors d'une mise-bas. Les données de l'élevage permettent d'adopter la loi suivante :

k	1	2	3
$P(X = k)$	0,4	0,5	a

1. Déterminer la valeur de a .
2. Déterminer et représenter la fonction de répartition F de X .
3. Calculer l'espérance $E(X)$, la variance $V(X)$ et l'écart-type $\sigma(X)$. Interpréter $E(X)$.
4. Chaque chevreau est vendu 25 000 FCFA et chaque mise-bas entraîne des frais vétérinaires de 10 000 FCFA. On note $R = 25\,000 X - 10\,000$ le revenu net d'une mise-bas. Calculer $E(R)$ et $\sigma(R)$.
5. L'élevage compte 40 chèvres qui mettent bas au cours de la saison, de façon indépendante. On note T le nombre total de chevreaux nés. Calculer $E(T)$, $V(T)$ et $\sigma(T)$.

Indication ▼ Correction ▼

[stat-0068]

Exercice 7 Loi binomiale et germination des semences de maïs au Bénin

Une coopérative du Sud-Bénin achète un lot de semences de maïs dont le taux de germination garanti est de 85 %. Un producteur sème 10 graines prises au hasard dans ce lot. On suppose que les graines germent indépendamment les unes des autres, et on note X le nombre de graines qui germent.

1. Justifier que X suit une loi binomiale dont on précisera les paramètres.
2. Calculer la probabilité que les 10 graines germent.
3. Calculer la probabilité qu'exactly 8 graines germent.
4. Calculer la probabilité qu'au moins 8 graines germent.
5. Calculer $E(X)$ et $V(X)$. Interpréter $E(X)$.
6. Le producteur souhaite obtenir *en moyenne* 50 plants levés sur une ligne. Combien de graines doit-il semer ?

Indication ▼ Correction ▼

[stat-0069]

Exercice 8 Loi hypergéométrique : contrôle de semences certifiées de niébé au Burkina Faso

Une union de producteurs du Burkina Faso reçoit des semences certifiées de niébé.

Partie A – Petit lot. Un lot comprend $N = 50$ sacs, dont $K = 4$ sont non conformes (taux de germination insuffisant). Le contrôleur prélève au hasard, *sans remise*, $n = 5$ sacs et note X le nombre de sacs non conformes parmi eux.

1. Justifier que X suit une loi hypergéométrique dont on précisera les paramètres.
2. Calculer $P(X = 0)$, puis la probabilité que le contrôle détecte au moins un sac non conforme.
3. Calculer $E(X)$ et interpréter.

Partie B – Grand lot. Un second lot comprend $N = 2\,000$ sacs, dont 8 % sont non conformes. On prélève au hasard, sans remise, $n = 20$ sacs. Le lot est accepté si l'on trouve au plus un sac non conforme.

4. Quelle est la loi exacte du nombre Y de sacs non conformes prélevés ? Justifier qu'on peut l'approcher par une loi binomiale dont on précisera les paramètres.
5. À l'aide de cette approximation, calculer $P(Y = 0)$ puis la probabilité que le lot soit accepté.
6. Commenter l'efficacité de cette règle de contrôle pour l'union de producteurs.

Indication ▼ Correction ▼

[stat-0093]

Exercice 9 Loi de Poisson : chenilles légionnaires et mortalité des poussins

Les deux parties sont indépendantes.

Partie A – Chenilles légionnaires au Kenya. Dans un champ de maïs, le nombre X de chenilles légionnaires d'automne présentes sur un plant suit une loi de Poisson de paramètre $\lambda = 1,5$.

1. Rappeler les conditions d'utilisation d'une loi de Poisson et donner $E(X)$ et $V(X)$.
2. Calculer la probabilité qu'un plant soit indemne de chenilles.
3. Calculer la probabilité qu'un plant porte au moins 3 chenilles (seuil d'intervention recommandé).
4. On examine 4 plants voisins, les comptages étant supposés indépendants. Le nombre total Y de chenilles suit une loi de Poisson. Préciser son paramètre puis calculer $P(Y \leq 2)$.

Partie B – Mortalité des poussins en Côte d'Ivoire. Dans un élevage avicole, chaque poussin d'une bande meurt pendant la première semaine avec une probabilité 0,02, indépendamment des autres. Une bande compte 150 poussins ; on note Z le nombre de poussins morts la première semaine.

5. Quelle est la loi exacte de Z ?
6. Justifier qu'on peut approcher cette loi par une loi de Poisson dont on précisera le paramètre.
7. À l'aide de cette approximation, calculer la probabilité que la mortalité ne dépasse pas 2 poussins. Comparer avec la valeur exacte $P(Z \leq 2) \approx 0,421$.

Indication ▼ Correction ▼

[stat-0070]

1.5 Lois continues

Exercice 10 Loi normale : régimes de plantain au Cameroun

Dans une plantation de la région du Mounjo (Cameroun), le poids X (en kg) d'un régime de banane plantain suit la loi normale $\mathcal{N}(12; 2,5^2)$.

1. Donner $E(X)$ et $\sigma(X)$. Exprimer la variable centrée réduite Z associée à X et donner sa loi.
2. Calculer la probabilité qu'un régime pèse moins de 10 kg.
3. Calculer la probabilité qu'un régime pèse entre 10 et 15 kg.
4. À l'aide de la règle des 68–95–99,7, donner sans table un intervalle centré sur 12 kg contenant environ 95 % des régimes.
5. Un grossiste n'achète au prix « premium » que les 10 % des régimes les plus lourds. À partir de quel poids un régime est-il classé « premium » ? (On donne $z_{0,90} = 1,2816$.)
6. Dans une autre plantation, le poids moyen est aussi de 12 kg mais seuls 5 % des régimes pèsent moins de 8 kg. En supposant le poids normal, déterminer l'écart-type σ dans cette plantation. (On donne $z_{0,95} = 1,645$.)

Indication ▼ Correction ▼

[stat-0071]

Exercice 11 Loi exponentielle et théorème central limite : motopompes d'irrigation

Un projet d'irrigation maraîchère au Burkina Faso équipe les producteurs de motopompes. La durée de fonctionnement T (en heures) d'une motopompe avant sa première panne suit une loi exponentielle $\mathcal{E}(\lambda)$, de durée moyenne 400 heures.

1. Déterminer la valeur de λ et l'écart-type de T .
2. Rappeler l'expression de $P(T > t)$ pour $t \geq 0$. Calculer la probabilité qu'une motopompe fonctionne plus de 600 heures sans panne.
3. Déterminer la durée médiane m , c'est-à-dire la valeur telle que $P(T \leq m) = 0,5$. Comparer à la durée moyenne et commenter.
4. Une motopompe a déjà fonctionné 300 heures sans panne. Quelle est la probabilité qu'elle fonctionne encore au moins 200 heures ? Comparer avec $P(T > 200)$. Quelle propriété de la loi exponentielle retrouve-t-on ?
5. Le projet a distribué 50 motopompes fonctionnant indépendamment. On note $\bar{T}$ la durée moyenne avant première panne de ces 50 machines.
 - (a) Donner $E(\bar{T})$ et $\sigma(\bar{T})$.
 - (b) À l'aide du théorème central limite, calculer approximativement la probabilité que $\bar{T}$ soit inférieure à 350 heures.

Indication ▼ Correction ▼

[stat-0072]

2 Échantillonnage

2.1 Plans d'échantillonnage et biais

Exercice 12 Plans d'échantillonnage pour une enquête sur le coton au Bénin

Une ONG souhaite connaître les pratiques de fertilisation des producteurs de coton d'une commune du Nord-Bénin. La commune compte $N = 2\,000$ exploitations cotonnières, réparties en trois zones agro-écologiques :

- zone de plateau : 1 200 exploitations ;
- zone de bas-fond : 600 exploitations ;
- zone de berge : 200 exploitations.

L'ONG dispose de la liste des exploitations membres de l'union communale des producteurs de coton et peut enquêter $n = 150$ exploitations.

1. Préciser la population étudiée, l'unité statistique, l'échantillon et la base de sondage.
2. Environ 15% des producteurs de la commune ne sont pas membres de l'union. Quel problème cela pose-t-il ? Ce problème disparaît-il si l'on enquête 1 000 exploitations au lieu de 150 ?
3. Pourquoi un recensement n'est-il pas envisagé ici ? Donner deux raisons.
4. On choisit un échantillonnage *stratifié* par zone avec allocation proportionnelle. Calculer le nombre d'exploitations à enquêter dans chaque zone. Quel est l'intérêt de stratifier ici ?
5. On envisage plutôt un échantillonnage *systématique* sur la liste des 2 000 exploitations.
 - (a) Calculer le pas de sondage.
 - (b) Le nombre tiré au hasard entre 1 et ce pas est 7. Donner les rangs des 4 premières exploitations enquêtées.
 - (c) La liste est classée par village, et dans chaque village le président de groupement est toujours inscrit en premier, puis viennent 19 autres producteurs. Quel risque présente ce plan ?
6. Pour limiter les déplacements, un collègue propose de tirer au hasard 10 villages et d'enquêter 15 exploitations dans chacun. Comment s'appelle ce plan ? Quel en est l'avantage et quel en est l'inconvénient statistique ?

Indication ▼ Correction ▼

[stat-0073]

Exercice 13 Plan stratifié pour une enquête sur les éleveurs de zébus à Madagascar

Dans la région du Menabe (Madagascar), un projet d'appui à l'élevage veut enquêter sur les pratiques des éleveurs de zébus. Le registre communal des services vétérinaires recense $N = 2\,500$ éleveurs, répartis selon la taille de leur troupeau :

Strate	petits (< 10 têtes)	moyens (10 à 49 têtes)	grands (≥ 50 têtes)
Effectif N_h	1 500	750	250

Le budget permet d'interroger $n = 400$ éleveurs.

1. Préciser l'unité statistique, la population et la base de sondage. Le registre ne contient pas les éleveurs non déclarés, souvent de petits éleveurs transhumants. De quel type d'erreur s'agit-il ? Interroger plus d'éleveurs la corrigerait-il ?
2. Calculer les effectifs à interroger dans chaque strate avec une allocation proportionnelle.
3. Pourquoi un plan stratifié selon la taille du troupeau est-il préférable ici à un tirage aléatoire simple de 400 éleveurs ?

4. Dans la strate des grands éleveurs, la taille des troupeaux a pour moyenne $\mu = 80$ têtes et pour écart-type $\sigma = 30$ têtes. On note $\bar{X}$ la taille moyenne des troupeaux des grands éleveurs interrogés. Calculer $E(\bar{X})$ et l'écart-type $\sigma(\bar{X})$ en tenant compte du facteur d'exhaustivité. Pourquoi faut-il en tenir compte ici ?
5. Calculer la probabilité que $\bar{X}$ s'écarte de μ de plus de 8 têtes. Quel théorème justifie le calcul ?
6. Un collègue propose plutôt de tirer au hasard 20 fokontany (villages) et d'interroger tous les éleveurs de chacun. Comment s'appelle ce plan ? Donner un avantage et un inconvénient.

Indication ▼ Correction ▼

[stat-0101]

Exercice 14 Biais ou fluctuation ? Situations d'enquêtes agricoles

Pour chacune des situations suivantes, dire si l'écart entre le résultat de l'enquête et la valeur réelle relève plutôt d'une *erreur d'échantillonnage* (fluctuation aléatoire) ou d'un *biais*. Dans le cas d'un biais, préciser son type (sélection/couverture, non-réponse, mesure) et dire si augmenter la taille de l'échantillon permettrait de le corriger. Proposer à chaque fois une amélioration.

1. Pour estimer le rendement du riz dans la vallée du fleuve Sénégal, un technicien ne visite que les parcelles situées le long de la route goudronnée.
2. Dans une enquête sur l'usage des pesticides au Vietnam, les producteurs déclarent eux-mêmes les quantités utilisées ; une partie d'entre eux sous-déclarent par crainte d'un contrôle.
3. On tire au hasard 30 ménages sur la liste complète d'un village du Togo pour estimer la surface cultivée moyenne ; un second tirage de 30 ménages donne une moyenne différente de 0,2 ha.
4. Une enquête par SMS sur l'adoption d'un service de conseil agricole est envoyée aux 5 000 producteurs d'une région de Côte d'Ivoire ; seuls 800 répondent, majoritairement les plus jeunes.
5. Les rendements de manioc sont mesurés en pesant les tubercules avec une balance mal tarée qui ajoute systématiquement 2 kg à chaque pesée.
6. Pour estimer la proportion de bétail vacciné dans une région du Tchad, on interroge les éleveurs présents au marché à bétail du chef-lieu.

Indication ▼ Correction ▼

[stat-0074]

2.2 Moyenne et variance d'un échantillon

Exercice 15 Précision d'une moyenne : poids de mille grains de riz à Madagascar

Dans une station de recherche de Madagascar, le poids de mille grains (PMG) d'une variété de riz a une moyenne $\mu = 30$ g et un écart-type $\sigma = 4$ g. On prélève un échantillon i.i.d. de n lots et on note $\bar{X}_n$ le PMG moyen de l'échantillon.

1. Donner $E(\bar{X}_n)$ et $V(\bar{X}_n)$ en fonction de μ , σ et n . Que signifie le fait que $E(\bar{X}_n) = \mu$?
2. Qu'appelle-t-on erreur-type de $\bar{X}_n$? La calculer pour $n = 16$, $n = 64$ et $n = 256$.
3. Par combien faut-il multiplier la taille de l'échantillon pour diviser l'erreur-type par 2 ? par 10 ? Commenter du point de vue du coût de l'expérimentation.
4. On travaille maintenant sur un petit verger de $N = 200$ parcelles dont on mesure $n = 50$ parcelles tirées sans remise.
 - (a) Calculer le taux de sondage. La correction pour population finie est-elle nécessaire ?
 - (b) Calculer l'erreur-type de $\bar{X}_n$ avec et sans le facteur d'exhaustivité (on garde $\sigma = 4$ g). Commenter.

Indication ▼ Correction ▼

[stat-0075]

Exercice 16 Variance empirique et variance corrigée : rendements de cacao en Côte d'Ivoire

Un technicien d'une coopérative de cacao de Côte d'Ivoire mesure le rendement (en t/ha) de 6 parcelles tirées au hasard :

Parcelle	1	2	3	4	5	6
Rendement x_i (t/ha)	2,4	2,8	3,4	2,5	3,0	2,7

1. Calculer la moyenne empirique $\bar{x}$.
2. Calculer la variance empirique s_n^2 (division par n) puis la variance empirique corrigée $s_n'^2$ (division par $n - 1$). En déduire l'écart-type corrigé s_n' .
3. On admet que la variance des rendements dans la population est $\sigma^2 = 0,15$ (t/ha)². Calculer $E(S_n^2)$ et $E(S_n'^2)$ pour $n = 6$. Laquelle des deux statistiques est sans biais ?
4. Expliquer en quelques lignes pourquoi la variance empirique S_n^2 sous-estime en moyenne σ^2 .
5. Que devient l'écart entre S_n^2 et $S_n'^2$ quand n devient grand ? Illustrer avec $n = 100$.

Indication ▼ Correction ▼

[stat-0076]

Exercice 17 Moyenne d'un échantillon gaussien : riz pluvial en Guinée

En Haute-Guinée, le rendement X (en t/ha) du riz pluvial sur une parcelle suit la loi normale $\mathcal{N}(2,4;0,6^2)$. Un projet mesure le rendement de $n = 9$ parcelles tirées au hasard et indépendantes. On note $\bar{X}$ le rendement moyen de l'échantillon.

1. Quelle est la loi exacte de $\bar{X}$? Justifier.
2. Calculer la probabilité que le rendement moyen de l'échantillon dépasse 2,7 t/ha.
3. Comparer avec la probabilité qu'une *seule* parcelle dépasse 2,7 t/ha. Commenter.
4. Déterminer l'intervalle de fluctuation au niveau 95 % de $\bar{X}$, centré sur μ .
5. Le projet a obtenu $\bar{x} = 1,9$ t/ha sur ses 9 parcelles. Ce résultat est-il compatible avec un rendement moyen de 2,4 t/ha dans la région? Que peut-on suspecter?
6. Combien de parcelles faudrait-il mesurer pour que $\bar{X}$ soit à moins de 0,1 t/ha de μ avec une probabilité de 95 %?

Indication ▼ Correction ▼

[stat-0077]

Exercice 18 Production de riz dans la vallée du fleuve Sénégal

Dans la vallée du fleuve Sénégal, le riz irrigué constitue une culture stratégique pour la sécurité alimentaire. Une étude menée par un service agricole régional s'intéresse aux rendements et aux pratiques culturales des exploitations rizicoles.

On admet que le rendement annuel en riz paddy par exploitation suit une loi normale de moyenne 4800 kg/ha et d'écart-type 600 kg/ha.

Un échantillon aléatoire simple de 76 exploitations est sélectionné.

1. *Analyse du rendement moyen*

On note $\bar{X}$ la moyenne des rendements observés dans l'échantillon.

- (a) Calculer l'écart-type de la moyenne $\bar{X}$.
- (b) Calculer la probabilité que la moyenne soit inférieure à 4600 kg/ha.
- (c) Calculer la probabilité que la moyenne soit comprise entre 4700 kg / ha et 4900 kg/ha.

2. *Fiabilité de l'estimation du rendement*

Les autorités agricoles souhaitent disposer d'une estimation fiable du rendement moyen. Déterminer la taille minimale de l'échantillon nécessaire pour que la probabilité que la moyenne soit comprise entre 4750 kg/ha et 4850 kg/ha soit égale à 95%.

3. *Adoption des engrais minéraux* Une enquête antérieure indique que 65% des exploitations rizicoles de la vallée utilisent des engrais minéraux. Calculer alors la probabilité que la proportion observée dans l'échantillon soit supérieure à 75%.

4. *Choix du plan d'échantillonnage*

Pour améliorer la qualité des futures enquêtes agricoles, identifier les deux grandes familles de méthodes d'échantillonnage, et proposer une méthode d'échantillonnage adaptée aux périmètres irrigués, et une méthode adaptée aux villages agricoles dispersés de la vallée.

Indication ▼ Correction ▼

[stat-0031]

2.3 Théorème central limite, fréquence et taille d'échantillon

Exercice 19 Théorème central limite : revenus des ménages et comptages de ravageurs

Les deux parties sont indépendantes.

Partie A – Revenus agricoles au Burkina Faso. Dans une province du Burkina Faso, le revenu agricole annuel d'un ménage a une moyenne $\mu = 350$ milliers de FCFA et un écart-type $\sigma = 200$ milliers de FCFA. Sa distribution est très asymétrique (quelques ménages ont des revenus très élevés). On enquête $n = 100$ ménages tirés au hasard et on note $\bar{X}$ leur revenu moyen.

1. Peut-on calculer la probabilité qu'un ménage ait un revenu supérieur à 390 milliers de FCFA avec la loi normale ? Justifier.
2. Énoncer le théorème central limite et en déduire une loi approchée pour $\bar{X}$.
3. Calculer la probabilité que le revenu moyen de l'échantillon dépasse 390 milliers de FCFA.
4. Calculer la probabilité que $\bar{X}$ soit compris entre 330 et 370 milliers de FCFA.

Partie B – Chenilles sur le maïs au Kenya. Le nombre de chenilles par plant suit une loi de Poisson de paramètre $\lambda = 1,5$. On examine 60 plants indépendants et on note $\bar{Y}$ le nombre moyen de chenilles par plant.

5. Donner $E(\bar{Y})$ et $\sigma(\bar{Y})$.
6. Calculer approximativement la probabilité que $\bar{Y}$ dépasse 1,8.

Indication ▼ Correction ▼

[stat-0079]

Exercice 20 Intervalle de fluctuation : contrôle d'un taux de germination au Sénégal

Un semencier du Sénégal annonce que ses semences d'arachide ont un taux de germination de $p = 90\%$. Un technicien d'une coopérative fait germer $n = 200$ graines tirées au hasard dans un lot et observe 168 graines germées.

1. Calculer la fréquence observée f de graines germées.
2. On note F la fréquence de germination d'un échantillon de 200 graines. Sous l'hypothèse que le semencier dit vrai, donner $E(F)$ et $\sigma(F)$.
3. Vérifier les conditions permettant d'utiliser l'approximation normale (théorème de Moivre–Laplace).
4. Déterminer l'intervalle de fluctuation au niveau 95 % de F .
5. La fréquence observée est-elle compatible avec l'annonce du semencier ? Quelle décision la coopérative peut-elle prendre ? Quel est le risque de se tromper ?
6. Pourquoi ne peut-on pas utiliser ici la règle simplifiée $\left[p - \frac{1}{\sqrt{n}}; p + \frac{1}{\sqrt{n}}\right]$?

Indication ▼ Correction ▼

[stat-0080]

Exercice 21 Dimensionner une enquête agricole en Éthiopie

Le ministère de l'Agriculture éthiopien prépare une enquête dans la région d'Oromia pour estimer :

- la proportion p d'exploitations utilisant des semences améliorées de teff ;
- le rendement moyen μ du teff (en t/ha).

On travaille au niveau de confiance 95 % ($z = 1,96$).

1. On ne dispose d'aucune information sur p . Combien d'exploitations faut-il enquêter pour une marge d'erreur de 3 points ($e = 0,03$) ?
2. Une enquête antérieure suggère $p \approx 0,2$. Recalculer la taille nécessaire. Pourquoi est-elle plus faible ?
3. Quelle taille faudrait-il pour une marge d'erreur de 1,5 point, sans information sur p ? Commenter.
4. Pour le rendement, on estime l'écart-type à $\sigma \approx 0,8$ t/ha. Combien de parcelles faut-il mesurer pour estimer μ à $\pm 0,1$ t/ha près ?
5. Même question au niveau de confiance 99 % ($z = 2,576$).
6. L'enquête sur le rendement se limite finalement à un district comptant $N = 1\,500$ exploitations. Appliquer la correction pour population finie $n = \frac{n_0}{1 + n_0/N}$ au résultat de la question 4.

Indication ▼ Correction ▼

[stat-0082]

3 Estimation

3.1 Estimation ponctuelle

Exercice 22 Estimations ponctuelles : cabosses de cacao au Ghana

Dans une coopérative cacaoyère de la région Ashanti (Ghana), un technicien veut connaître le poids moyen d'une cabosse et la proportion de cabosses atteintes de pourriture brune. Il prélève au hasard 12 cabosses mûres et les pèse (en g) :

540	480	610	550	495	530	575	505	560	540	515	580
-----	-----	-----	-----	-----	-----	-----	-----	-----	-----	-----	-----

Parmi ces 12 cabosses, 3 présentent des symptômes de pourriture brune.

1. Préciser la population, les paramètres d'intérêt et les estimateurs qui leur sont naturellement associés.
2. Expliquer la différence entre un *estimateur* et une *estimation*. Laquelle de ces deux notions est une variable aléatoire ?
3. Donner une estimation ponctuelle du poids moyen μ d'une cabosse.
4. Donner une estimation ponctuelle de la variance σ^2 et de l'écart-type σ du poids. Justifier le choix de la division par $n - 1$.
5. Donner une estimation ponctuelle de la proportion p de cabosses atteintes de pourriture brune.
6. Un second technicien prélève 12 autres cabosses et trouve un poids moyen de 552 g. Les deux techniciens ont-ils fait une erreur ? Quelle information manque à une estimation ponctuelle ?

Indication ▼ Correction ▼

[stat-0083]

Exercice 23 Estimations ponctuelles : production laitière des chèvres au Niger

Dans la région de Maradi (Niger), un agent d'élevage mesure la production de lait (en litres par jour) de 10 chèvres rousses de Maradi, tirées au hasard dans les élevages d'un village :

1,2	0,9	1,5	1,1	0,8	1,3	1,0	1,4	0,9	1,1
-----	-----	-----	-----	-----	-----	-----	-----	-----	-----

On s'intéresse à la production moyenne μ , à la variance σ^2 et à la proportion p de chèvres produisant *plus* de 1 litre par jour, pour l'ensemble des chèvres du village.

1. Donner une estimation ponctuelle de μ .
2. Calculer la variance empirique s^2 puis la variance corrigée s'^2 . Laquelle utilise-t-on pour estimer σ^2 ? Pourquoi ?
3. Donner une estimation ponctuelle de σ et de p .
4. Un second agent mesure 10 autres chèvres du même village. Obtiendra-t-il les mêmes valeurs ? Expliquer à cette occasion la différence entre un *estimateur* et une *estimation*.
5. Estimer l'erreur-type de la moyenne $\bar{X}$. Que mesure-t-elle ?
6. Une coopérative collecte le lait des 120 chèvres en lactation du village et le revend 400 FCFA le litre. Estimer la quantité de lait produite chaque jour par ces 120 chèvres et le chiffre d'affaires journalier correspondant.

Indication ▼ Correction ▼

[stat-0102]

3.2 Intervalle de confiance d'une moyenne

Exercice 24 Intervalle de confiance d'une moyenne, écart-type connu : sacs de noix de cajou

En Guinée-Bissau, les noix de cajou sont exportées en sacs dont le poids nominal est de 80 kg. Une longue série de contrôles a établi que le poids d'un sac suit une loi normale d'écart-type connu $\sigma = 6$ kg. Un acheteur pèse $n = 36$ sacs tirés au hasard dans un lot et obtient un poids moyen $\bar{x} = 78,6$ kg.

1. Donner une estimation ponctuelle du poids moyen μ des sacs du lot.
2. Rappeler la fonction pivot utilisée et sa loi.
3. Construire l'intervalle de confiance de μ au niveau 95 %.
4. Construire l'intervalle de confiance au niveau 99 % (on donne $z_{0,995} = 2,576$). Comparer avec le précédent et expliquer.
5. L'acheteur peut-il affirmer que les sacs du lot sont en moyenne sous-pesés ? Argumenter.
6. Parmi les phrases suivantes, lesquelles sont correctes ?
 - (a) « Il y a 95 % de chances que μ soit dans l'intervalle calculé à la question 3. »
 - (b) « Si l'on répétait l'échantillonnage un grand nombre de fois, environ 95 % des intervalles ainsi construits contiendraient μ . »
 - (c) « 95 % des sacs pèsent entre les deux bornes de l'intervalle. »
7. Combien de sacs faut-il peser pour obtenir, au niveau 95 %, une marge d'erreur de 1,5 kg ?

Indication ▼ Correction ▼

[stat-0087]

Exercice 25 Intervalle de confiance d'une moyenne, écart-type connu : lait au Burkina Faso

Une minilaiterie de Kaya (Burkina Faso) collecte le lait des éleveurs peuls des environs. Le prix payé aux éleveurs comprend une prime si le taux butyreux (TB, teneur en matière grasse) moyen du lait livré atteint au moins 3,5 g pour 100 mL.

Le laboratoire de la laiterie suit le TB depuis plusieurs années : il suit une loi normale dont l'écart-type est stable et connu, $\sigma = 0,5$ g/100 mL. Sa moyenne μ , en revanche, varie selon la saison et l'alimentation des animaux.

En fin de saison sèche, on analyse $n = 16$ bidons tirés au hasard parmi les livraisons de la semaine. On obtient un TB moyen $\bar{x} = 3,8$ g/100 mL.

1. Pourquoi peut-on utiliser ici le quantile de la loi normale (et non celui de Student), bien que l'échantillon soit petit ?
2. Construire l'intervalle de confiance de μ au niveau 95 %.
3. Construire les intervalles de confiance au niveau 90 % et au niveau 99 %. Comment évolue la largeur de l'intervalle avec le niveau de confiance ?
4. Au vu de ces intervalles, la laiterie peut-elle affirmer que le TB moyen de la semaine atteint le seuil de 3,5 g/100 mL ? La réponse dépend-elle du niveau de confiance choisi ?
5. Combien de bidons faudrait-il analyser pour estimer μ à $\pm 0,1$ g/100 mL près au niveau 95 % ?
6. Un nouveau laboratoire, qui ne dispose pas de l'historique, ne connaît pas σ . Sur les mêmes 16 bidons, il trouve un écart-type corrigé $s' = 0,62$ g/100 mL. Quel intervalle de confiance à 95 % obtient-il ? On donne $t_{15;0,975} = 2,131$. Comparer avec la question 2 et expliquer la différence.

Indication ▼ Correction ▼

[stat-0107]

Exercice 26 Intervalle de confiance d'une moyenne, grand échantillon : zébus de l'Adamaoua

Sur le marché à bétail de Ngaoundéré (Cameroun), un projet de suivi des prix pèse au ruban barymétrique $n = 64$ zébus Goudali tirés au hasard parmi les animaux mis en vente. On obtient un poids vif moyen $\bar{x} = 312$ kg et un écart-type corrigé $s' = 48$ kg. L'écart-type σ de la population n'est pas connu.

1. Quelle formule d'intervalle de confiance peut-on utiliser pour le poids vif moyen μ ? Justifier. Faut-il supposer que les poids suivent une loi normale ?
2. Construire l'intervalle de confiance de μ au niveau 95 %.
3. Construire l'intervalle de confiance de μ au niveau 99 %. Comparer les deux intervalles.
4. Un commerçant affirme : « 95 % des zébus du marché pèsent entre les deux bornes de l'intervalle à 95 %. » A-t-il raison ? Donner l'interprétation correcte.
5. Le kilogramme de poids vif se négocie à 1 500 FCFA. En déduire un intervalle de confiance à 95 % du prix moyen d'un zébu sur ce marché.
6. Il y a cinq ans, le poids vif moyen des zébus vendus sur ce marché était de 330 kg. Ce chiffre est-il compatible avec les données actuelles ? Proposer une explication agronomique.
7. Combien de zébus faudrait-il peser pour estimer μ à ± 5 kg près au niveau 95 % (on prendra $\sigma \approx 48$ kg) ?

Indication ▼ Correction ▼

[stat-0103]

Exercice 27 Intervalle de Student : rendement du mil au Niger

Dans la région de Maradi (Niger), un projet mesure le rendement en grain du mil (en t/ha) sur 10 parcelles paysannes tirées au hasard :

0,82	0,95	0,71	1,10	0,88	0,64	0,97	0,79	1,02	0,92
------	------	------	------	------	------	------	------	------	------

On suppose que le rendement suit une loi normale de moyenne μ et d'écart-type σ inconnus.

1. Calculer la moyenne $\bar{x}$ et l'écart-type corrigé s' de l'échantillon (on pourra utiliser la calculatrice).
2. Pourquoi ne peut-on pas utiliser le quantile 1,96 de la loi normale pour construire l'intervalle de confiance de μ ? Quelle loi utilise-t-on ?
3. On donne $t_{9;0,975} = 2,262$. Construire l'intervalle de confiance de μ au niveau 95 %.
4. Quel intervalle aurait-on obtenu en utilisant (à tort) 1,96 ? Commenter.
5. Le rendement moyen régional publié l'an passé était de 0,75 t/ha. Les parcelles du projet semblent-elles avoir un rendement moyen différent ?
6. Quelle hypothèse est indispensable à la validité de cet intervalle ? Comment pourrait-on la vérifier ?

Indication ▼ Correction ▼

[stat-0088]

Exercice 28 Intervalle de Student : embouche ovine au Mali

Avant la Tabaski, des éleveurs de la région de Ségou (Mali) pratiquent l'embouche ovine : des béliers sont engraisés pendant 90 jours avec une ration à base de tourteau de coton et de fanes de niébé. On mesure le gain moyen quotidien (GMQ, en g/jour) de 8 béliers :

152	138	165	147	171	129	158	144
-----	-----	-----	-----	-----	-----	-----	-----

On suppose que le GMQ suit une loi normale de moyenne μ et d'écart-type σ inconnus. On donne $t_{7;0,975} = 2,365$ et $t_{7;0,95} = 1,895$.

1. Calculer la moyenne $\bar{x}$ et l'écart-type corrigé s' de l'échantillon.
2. Pourquoi doit-on utiliser ici la loi de Student et non la loi normale ? À quoi sert l'hypothèse de normalité ? Comment pourrait-on la vérifier ?
3. Construire l'intervalle de confiance de μ au niveau 95 %, puis au niveau 90 %.
4. Le fournisseur de la ration annonce un GMQ moyen de 165 g/jour. Cette annonce est-elle compatible avec les données ?
5. Un étudiant a utilisé 1,96 au lieu de 2,365. Quel intervalle a-t-il obtenu ? Quelle erreur d'interprétation risque-t-il de commettre ?
6. En déduire un intervalle de confiance à 95 % du gain de poids moyen d'un bélier sur les 90 jours d'embouche, puis du supplément de valeur moyen qu'il apporte si le kilogramme vif se vend 2000 FCFA.

Indication ▼ Correction ▼

[stat-0105]

3.3 Intervalle de confiance d'une proportion et d'une différence

Exercice 29 Intervalle de confiance d'une proportion : la pyriculariose du riz à Madagascar

Sur les Hautes Terres de Madagascar, un technicien inspecte $n = 250$ parcelles de riz tirées au hasard et constate que 60 d'entre elles sont atteintes de pyriculariose (maladie fongique).

1. Donner une estimation ponctuelle de la proportion p de parcelles atteintes dans la région.
2. Vérifier les conditions d'utilisation de l'intervalle de confiance classique (de Wald) d'une proportion.
3. Construire l'intervalle de confiance de p au niveau 95 %.
4. Construire l'intervalle de confiance de p au niveau 90 % (on donne $z_{0,95} = 1,645$).
5. Le service de la protection des végétaux déclenche une campagne de traitement si la proportion de parcelles atteintes dépasse 20 %. Que peut-on conclure au vu de l'intervalle à 95 % ?
6. Combien de parcelles faudrait-il inspecter pour estimer p avec une marge d'erreur de 3 points au niveau 95 % ? (On utilisera l'estimation obtenue à la question 1.)
7. Dans un village voisin, on n'a pu inspecter que 20 parcelles, dont 2 atteintes. Pourquoi l'intervalle classique n'est-il pas fiable dans ce cas ?

Indication ▼ Correction ▼

[stat-0089]

Exercice 30 Intervalle de confiance d'une proportion : vaccination des volailles au Sénégal

La maladie de Newcastle décime chaque année les volailles villageoises au Sénégal. Un programme de vaccination a été lancé dans la région de Kaolack. Pour évaluer la couverture vaccinale, on interroge $n = 400$ ménages éleveurs de volailles tirés au hasard : 252 d'entre eux ont fait vacciner leurs volailles.

1. Donner une estimation ponctuelle de la proportion p de ménages ayant vacciné leurs volailles.
2. Vérifier les conditions d'utilisation de l'intervalle de confiance d'une proportion, puis construire l'intervalle de confiance de p au niveau 95 %.
3. L'objectif du programme était une couverture de 70 %. Peut-on considérer qu'il est atteint ?
4. L'année prochaine, on souhaite estimer p avec une marge d'erreur de 3 points au niveau 95 %. Calculer la taille d'échantillon nécessaire :
 - (a) sans aucune information préalable sur p ;
 - (b) en utilisant l'estimation obtenue cette année.

Expliquer pourquoi le premier résultat est plus grand.

5. Dans la région de Kolda, une enquête identique auprès de 300 ménages donne 150 ménages vaccinateurs. Construire l'intervalle de confiance à 95 % de la différence $p_{\text{Kaolack}} - p_{\text{Kolda}}$. Peut-on conclure à une différence de couverture entre les deux régions ?

Indication ▼ Correction ▼

[stat-0104]

Exercice 31 Intervalles de confiance d'une différence : adoption et variétés améliorées en Ouganda

Partie A – Deux villages. En Ouganda, une ONG a promu le compostage dans deux villages. Une enquête indépendante dans chaque village donne :

- village A : 72 ménages pratiquent le compostage sur 180 enquêtés ;
 - village B : 45 ménages pratiquent le compostage sur 150 enquêtés.
1. Calculer les fréquences f_A et f_B , puis la différence $f_A - f_B$.
 2. Construire l'intervalle de confiance au niveau 95 % de la différence $p_A - p_B$ des taux d'adoption.
 3. Peut-on affirmer que les taux d'adoption sont différents dans les deux villages ?

Partie B – Parcelles appariées. Sur 8 exploitations, on a cultivé côte à côte une variété améliorée de haricot (A) et la variété locale (L). Rendements en t/ha :

Exploitation	1	2	3	4	5	6	7	8
Variété A	2,9	3,4	2,6	3,8	3,1	2,7	3,5	3,0
Variété L	2,4	2,8	2,5	3,1	2,6	2,5	2,9	2,4

4. Pourquoi parle-t-on d'échantillons *appariés* ? Quel est l'intérêt de ce dispositif ?
5. Calculer les différences $d_i = a_i - l_i$, leur moyenne $\bar{d}$ et leur écart-type corrigé s'_D .
6. On suppose les différences gaussiennes et on donne $t_{7;0,975} = 2,365$. Construire l'intervalle de confiance au niveau 95 % du gain moyen de rendement.
7. Conclure sur l'intérêt de la variété améliorée.

Indication ▼ Correction ▼

[stat-0091]

3.4 Synthèse

Exercice 32 Synthèse : enquête auprès des productrices de beurre de karité au Burkina Faso

Une union de coopératives de la région des Hauts-Bassins (Burkina Faso) regroupe $N = 1\,200$ productrices de beurre de karité. Pour préparer un plan de commercialisation, elle enquête sur $n = 50$ productrices tirées au hasard dans la liste de ses membres. On obtient :

- quantité de beurre vendue par mois : moyenne $\bar{x} = 42$ kg, écart-type corrigé $s' = 15$ kg ;
 - 18 productrices sur 50 ont accès à un microcrédit.
1. Les productrices sont tirées par un tirage systématique dans la liste des membres. Décrire précisément la procédure. Quel est le risque si la liste est rangée par village, avec la présidente de chaque coopérative en tête ?
 2. Donner des estimations ponctuelles de la quantité moyenne μ vendue par mois, de l'écart-type σ et de la proportion p de productrices ayant accès au microcrédit.
 3. Construire l'intervalle de confiance de μ au niveau 95 %. Faut-il ici tenir compte du facteur d'exhaustivité ?
 4. Le beurre est vendu 1 500 FCFA le kilogramme. En déduire un intervalle de confiance à 95 % du revenu mensuel moyen tiré de la vente de beurre.
 5. Estimer la quantité totale de beurre vendue chaque mois par l'ensemble des 1 200 productrices, et donner un intervalle de confiance à 95 % de ce total.
 6. Construire l'intervalle de confiance de p au niveau 95 %. Que penser de sa largeur ?

7. L'union veut estimer p à ± 5 points près au niveau 95 %, sans se fier à l'estimation précédente. Combien de productrices faut-il interroger ? Corriger ce résultat pour tenir compte de la taille finie de l'union.

Indication ▼ Correction ▼

[stat-0106]

Indications

Indication pour l'exercice 1 ▲

Fiche mémo : § 1.1 « Événements et dénombrement » (encadré « Calculer avec des événements »), § 1.2 et § 1.3.

1. Traduire symbole par symbole : $\cup$ = « ou » (au moins un des deux), $\cap$ = « et », la barre = « ne... pas ».
2. Incompatibles signifie « ne peuvent pas se produire ensemble ». Que vaudrait alors $P(M \cap C)$? Comparer avec la donnée.
3. « Au moins un des deux », c'est $M \cup C$. Dans $P(M) + P(C)$, les pieds atteints des deux maladies sont comptés deux fois : il faut les retirer une fois (voir le diagramme de la fiche).
4. « Indemne des deux », c'est $\overline{M \cap C}$. Par De Morgan, c'est le contraire de $M \cup C$: réutiliser la question 3.
5. « Un seul » = « M mais pas C » ou « C mais pas M » (deux cas incompatibles). La fiche donne $P(M \cap \overline{C}) = P(M) - P(M \cap C)$. Contrôle : le résultat doit valoir $P(M \cup C) - P(M \cap C)$.
6. $P(M | C) = \frac{P(M \cap C)}{P(C)}$ se lit « parmi les pieds atteints par la cochenille, part de ceux qui ont la mosaïque ». Les deux probabilités n'ont pas le même dénominateur : elles n'ont aucune raison d'être égales.
7. Comparer $P(M \cap C)$ et $P(M)P(C)$ (ou $P(M | C)$ et $P(M)$). Si les deux attaques vont plus souvent ensemble que par hasard, se demander pourquoi sur le terrain (pieds affaiblis, parcelles mal entretenues...).

Indication pour l'exercice 2 ▲

Fiche mémo : § 1.1 (tableau du dénombrement et principe multiplicatif).

1. (a) Se poser la question du tableau : l'ordre compte-t-il ? Ici on choisit seulement un groupe de 3 variétés.
(b) Maintenant les parcelles 1, 2, 3 sont distinctes : échanger deux variétés donne une autre disposition, l'ordre compte. Contrôle : le résultat doit valoir celui de la question 1(a) multiplié par 3!.
2. On range tous les éléments (les 5 opérations) : ligne « on range les n éléments » du tableau.
3. Tous les choix de la question 1(a) sont équiprobables : $P = \frac{\text{nombre de cas favorables}}{\text{nombre de cas possibles}}$, avec le résultat de 1(a) au dénominateur.
(a) Combien de groupes contiennent exactement les 3 variétés améliorées ?
(b) Il faut choisir 2 améliorées parmi 3 et 1 locale parmi 5 : principe multiplicatif (on multiplie les deux nombres de choix).
(c) « Au moins une » : passer par le contraire « aucune », c'est-à-dire 3 variétés choisies parmi les 5 locales.

Indication pour l'exercice 3 ▲

Fiche mémo : § 1.2 « Probabilités conditionnelles » (encadré « Conditionnement, probabilités totales, Bayes » et méthode de l'arbre pondéré).

1. Système complet : les trois sols sont incompatibles deux à deux et toutes les parcelles sont sur l'un d'eux (les pourcentages font 100 %). Arbre : 1^{er} niveau S_1, S_2, S_3 ; 2^e niveau I ou $\bar{I}$ avec les pourcentages d'infestation, qui sont des probabilités *conditionnelles* $P(I | S_i)$. À chaque nœud, les branches font 1.
2. Probabilités totales : on multiplie le long de chacune des trois branches qui mènent à I , puis on additionne.
3. Bayes : on « remonte » l'arbre, $P(S_1 | I) = \frac{\text{branche } S_1 \rightarrow I}{P(I)}$. Les trois résultats doivent faire 1 : c'est un bon contrôle.

4. Même méthode avec $\bar{I}$: $P(\bar{I}) = 1 - P(I)$ et $P(\bar{I} | S_1) = 1 - 0,40$.
5. Regarder où se trouve la plus grande part des parcelles infestées (question 3), et pas seulement quel sol a le plus fort taux d'infestation.

Indication pour l'exercice 4 ▲

Fiche mémo : § 1.2 (encadré « Conditionnement, probabilités totales, Bayes » et paragraphe « Test de diagnostic »).

1. 1^{er} niveau : M ou $\bar{M}$ (prévalence). 2^e niveau : $+$ ou $-$. La sensibilité est $P(+ | M)$, la spécificité $P(- | \bar{M})$; on en déduit $P(+ | \bar{M}) = 1 - \text{spécificité}$ (faux positifs).
2. Probabilités totales : additionner les deux branches qui mènent à $+$ (vrais positifs et faux positifs).
3. VPP = $P(M | +)$ par Bayes : branche « M puis $+$ » divisée par $P(+)$. Comparer le résultat à la sensibilité : pourquoi est-il beaucoup plus faible ? (Comparer le nombre de vrais positifs et de faux positifs.)
4. VPN = $P(\bar{M} | -)$: même méthode avec les branches qui mènent à $-$, et $P(-) = 1 - P(+)$.
5. Refaire les questions 2 et 3 avec $P(M) = 0,30$. Que change la prévalence dans le rapport vrais positifs / faux positifs ?

Indication pour l'exercice 5 ▲

Fiche mémo : § 1.3 « Indépendance ».

1. Le poquet est vide si *toutes* les graines échouent ; par indépendance, on multiplie les probabilités d'échec ($1 - 0,7$). « Au moins une lève » est le contraire de « vide ».
2. (a) Même raisonnement avec 3 graines.
(b) « Exactement 2 » : choisir laquelle des 3 graines échoue (3 cas), chaque cas ayant la probabilité $0,7^2 \times 0,3$. C'est déjà la loi binomiale.
(c) Nombre moyen de poquets vides = nombre de poquets $\times$ probabilité qu'un poquet soit vide.
3. Généraliser la question 1 : $P(\text{au moins une levée}) = 1 - P(\text{vide})$ avec k graines.
4. Résoudre $1 - 0,3^k \geq 0,99$: isoler $0,3^k$, puis passer au logarithme comme dans la fiche. Attention, $\ln 0,3 < 0$: diviser par ce nombre change le sens de l'inégalité. k est entier : vérifier la réponse avec k et $k - 1$.
5. Les graines d'un même poquet partagent le même trou : même sol, même humidité, mêmes ravageurs...

Indication pour l'exercice 6 ▲

Fiche mémo : § 1.4 « Variables aléatoires discrètes » (encadré « Loi, espérance, variance »).

1. La somme des probabilités d'une loi vaut 1.
2. $F(x) = P(X \leq x)$: la fonction est en escalier, nulle avant 1, égale à 1 après 3, et saute de $P(X = k)$ en chaque valeur k . Bien regarder ce qui se passe *exactement* en $x = 1, 2, 3$.
3. $E(X) = \sum k P(X = k)$. Pour la variance, calculer d'abord $E(X^2) = \sum k^2 P(X = k)$, puis $V(X) = E(X^2) - E(X)^2$. Interpréter $E(X)$ comme une moyenne sur un grand nombre de mises-bas.
4. $R = aX + b$: $E(R) = aE(X) + b$ et $V(R) = a^2 V(X)$, donc $\sigma(R) = a \sigma(X)$. La constante $-10\,000$ décale le revenu mais ne change pas sa dispersion.
5. T est la somme de 40 variables indépendantes de même loi que X : on additionne les espérances *et les variances* (pas les écarts-types !).

Indication pour l'exercice 7 ▲

Fiche mémo : § 1.5 « Lois usuelles » (tableau des lois discrètes, ligne « Binomiale »).

1. Vérifier les trois points de la colonne « On la reconnaît quand... » : même épreuve répétée, deux issues (germe ou non), indépendance. Donner n et p .
2. C'est $P(X = 10)$: toutes les graines germent.
3. Formule de la binomiale avec $k = 8$; $\binom{10}{8}$ compte le nombre de façons de choisir les 8 graines qui germent.
4. « Au moins 8 » = 8, 9 ou 10 : additionner les trois probabilités (deux sont déjà calculées).
5. $E(X) = np$ et $V(X) = np(1 - p)$. $E(X)$: nombre moyen de graines germées si l'on répète le semis de 10 graines un grand nombre de fois.
6. Ici n est l'inconnue : résoudre $n \times 0,85 = 50$ et arrondir à l'entier supérieur. « En moyenne » : ce n'est pas une garantie d'obtenir 50 plants.

Indication pour l'exercice 8 ▲

Fiche mémo : § 1.5 « Lois usuelles » (ligne « Hypergéométrique » du tableau et schéma des approximations).

1. Tirage *sans remise* dans un lot fini, et on compte des « succès » (sacs non conformes) : $\mathcal{H}(N, K, n)$. Préciser N , K et n .
2. $P(X = 0)$: les 5 sacs sont tirés parmi les 46 conformes, divisé par le nombre total de façons de choisir 5 sacs parmi 50. « Détecter au moins un sac non conforme » est le contraire.
3. $E(X) = n \frac{K}{N}$: nombre moyen de sacs non conformes trouvés par contrôle.
4. La loi exacte est encore hypergéométrique. Schéma de la fiche : si $N \geq 10n$, on l'approche par $\mathcal{B}(n, p)$ avec $p = K/N$.
5. Avec la binomiale : $P(Y = 0) = (1 - p)^{20}$. Le lot est accepté si $Y = 0$ ou $Y = 1$: additionner.
6. Le lot contient pourtant 8% de sacs non conformes : la probabilité de l'accepter est-elle rassurante pour l'union ?

Indication pour l'exercice 9 ▲

Fiche mémo : § 1.5 « Lois usuelles » (ligne « Poisson », remarque sur la somme de lois de Poisson, schéma des approximations).

1. Colonne « On la reconnaît quand... » : événements rares, indépendants, à taux constant, comptés dans une unité de temps ou d'espace. Pour Poisson, $E(X) = V(X) = \lambda$.
2. « Indemne » = $X = 0$: $P(X = 0) = e^{-\lambda}$.
3. « Au moins 3 » : passer par le contraire, $1 - P(X = 0) - P(X = 1) - P(X = 2)$.
4. Une somme de lois de Poisson indépendantes est une loi de Poisson : les paramètres s'additionnent. Puis $P(Y \leq 2) = P(Y = 0) + P(Y = 1) + P(Y = 2)$.
5. On répète 150 fois la même épreuve indépendante (le poussin meurt ou non) et on compte les morts : quelle loi du tableau ?
6. Schéma des approximations : vérifier $n \geq 30$ et $p \leq 0,1$, puis prendre $\lambda = np$.
7. Calculer $P(Z \leq 2)$ avec la loi de Poisson et comparer à 0,421 : l'approximation est-elle bonne ?

Indication pour l'exercice 10 ▲

Fiche mémo : § 1.5, encadré « Loi normale : tout ramener à $\mathcal{N}(0,1)$ » et sa figure.

1. Attention à la notation $\mathcal{N}(12; 2,5^2)$: 2,5 est l'écart-type, $2,5^2$ la variance. $Z = \frac{X - \mu}{\sigma}$ suit $\mathcal{N}(0,1)$.
2. Centrer et réduire 10, puis lire Φ dans la table. La valeur est négative : utiliser $\Phi(-z) = 1 - \Phi(z)$.
3. $P(a \leq X \leq b) = \Phi\left(\frac{b - \mu}{\sigma}\right) - \Phi\left(\frac{a - \mu}{\sigma}\right)$.
4. Repères de la fiche : $\mu \pm 2\sigma$ contient environ 95 % des valeurs.
5. Les 10 % les plus lourds sont au-dessus du seuil x : on cherche x tel que $P(X \leq x) = 0,90$, soit $x = \mu + z_{0,90} \sigma$.
6. Ici l'inconnue est σ . Écrire $P(X < 8) = 0,05$ puis centrer-réduire : $\frac{8 - 12}{\sigma} = z_{0,05}$. Par symétrie de la courbe, $z_{0,05} = -z_{0,95}$.

Indication pour l'exercice 11 ▲

Fiche mémo : § 1.5 (tableau des lois continues, ligne « Exponentielle », et l'exponentielle « sans mémoire »); § 1.6 et § 2.2 pour la question 5.

1. $E(T) = 1/\lambda$ donne λ . Pour une exponentielle, $\sigma(T) = 1/\lambda$: même valeur que la moyenne.
2. Formule de la fiche : $P(T > t) = e^{-\lambda t}$.
3. Résoudre $P(T > m) = e^{-\lambda m} = 0,5$ avec le logarithme. Médiane plus petite que la moyenne : quelques motopompes durent très longtemps et tirent la moyenne vers le haut.
4. $P(T > 500 | T > 300) = \frac{P(T > 500 \text{ et } T > 300)}{P(T > 300)}$, et « $T > 500$ » est inclus dans « $T > 300$ ». Comparer avec $P(T > 200)$: c'est la propriété « sans mémoire » de la fiche.
5. (a) $\bar{T}$ est la moyenne de 50 variables indépendantes de même loi : $E(\bar{T}) = \mu$ et $\sigma(\bar{T}) = \sigma/\sqrt{n}$ (§ 2.2).
(b) $n = 50 \geq 30$: le TCL (§ 1.6) donne $\bar{T} \approx \mathcal{N}(\mu, \sigma^2/n)$, même si T n'est pas normale. Centrer et réduire 350 avec $\sigma/\sqrt{n}$.

Indication pour l'exercice 12 ▲

Fiche mémo : § 2.1 « Plans d'échantillonnage et biais » (définitions, tableau des plans, figure des cibles).

1. Unité statistique : l'élément sur lequel on mesure. Population : toutes les unités visées. Échantillon : les n unités enquêtées. Base de sondage : la liste dans laquelle on tire.
2. Les non-membres ne peuvent jamais être tirés : l'erreur est-elle aléatoire ou systématique ? Un biais diminue-t-il quand n augmente (figure des cibles) ?
3. Penser au coût, au temps et à la qualité de la collecte (définitions de recensement et de sondage dans la fiche).
4. Allocation proportionnelle : $n_h = n \frac{N_h}{N}$; vérifier que la somme fait 150. Intérêt : les zones diffèrent entre elles mais sont assez homogènes à l'intérieur.
5. (a) Pas de sondage : $k = N/n$.
(b) Les rangs sont $d, d + k, d + 2k, d + 3k$ avec $d = 7$.
(c) Comparer le pas k au nombre de lignes par village (20) : piège de la liste périodique (tableau des plans).
6. On tire d'abord des groupes, puis des unités dans chaque groupe : quelle ligne du tableau des plans ? Avantage sur le terrain, inconvénient pour la précision (effet de grappe).

Indication pour l'exercice 13 ▲

Fiche mémo : § 2.1 « Plans d'échantillonnage et biais » ; § 2.2, encadré « Moyenne empirique » (facteur d'exhaustivité) ; § 1.6 pour la question 5.

1. Reprendre les définitions de la fiche. Les éleveurs absents du registre ne peuvent jamais être tirés : erreur aléatoire ou biais ? Que dit la figure des cibles sur l'effet d'une hausse de n ?
2. $n_h = n \frac{N_h}{N}$; vérifier que la somme fait 400.
3. Que gagne-t-on quand les strates sont homogènes à l'intérieur ? Et que pourrait-il arriver aux grands éleveurs, peu nombreux, avec un tirage aléatoire simple ?
4. $E(\bar{X}) = \mu$. Calculer le taux de sondage *dans la strate* (n_h/N_h) : s'il dépasse 10 %, multiplier $\sigma/\sqrt{n}$ par $\sqrt{\frac{N-n}{N-1}}$, avec N et n ceux de la strate.
5. $n = 40 \geq 30$: le TCL permet d'utiliser une loi normale. « S'écarter de plus de 8 » se traduit par $|\bar{X} - \mu| > 8$: deux queues symétriques, soit $2(1 - \Phi(z))$ avec $z = 8/\sigma(\bar{X})$.
6. On tire des villages entiers : quelle ligne du tableau des plans ? Penser à la liste nécessaire et aux déplacements, puis à la ressemblance entre éleveurs d'un même village.

Indication pour l'exercice 14 ▲

Fiche mémo : § 2.1, définitions de l'erreur d'échantillonnage et du biais, figure des cibles.

Méthode. Pour chaque situation, se poser deux questions.

1. Si l'on refaisait l'enquête de la même façon avec un autre échantillon, l'écart changerait-il de sens au hasard (fluctuation) ou irait-il toujours dans le même sens (biais) ?
2. Pour un biais, d'où vient-il : de *qui est tiré* (sélection, couverture), de *qui répond* (non-réponse) ou de *la façon de mesurer* (mesure) ?

Rappel. Augmenter n réduit l'erreur d'échantillonnage, mais ne corrige pas un biais : les points se resserrent autour d'une mauvaise valeur (figure des cibles).

Piste pour les améliorations. Chercher à chaque fois ce qui permettrait à toutes les unités d'avoir une chance connue d'être tirées, de répondre, et d'être mesurées correctement.

Indication pour l'exercice 15 ▲

Fiche mémo : § 2.2, encadré « Moyenne empirique » et figure des courbes en cloche.

1. Formules de l'encadré. $E(\bar{X}_n) = \mu$: la moyenne d'échantillon ne se trompe pas systématiquement, elle « vise juste » en moyenne.
2. L'erreur-type est l'écart-type de $\bar{X}_n$: $\sigma/\sqrt{n}$. Observer ce que devient l'erreur-type quand n est multiplié par 4.
3. Pour diviser $\sigma/\sqrt{n}$ par c , il faut multiplier $\sqrt{n}$ par c , donc n par c^2 .
4. (a) Taux de sondage n/N : le comparer au seuil de 10 % de la fiche.
(b) Avec le facteur : $\frac{\sigma}{\sqrt{n}} \sqrt{\frac{N-n}{N-1}}$. Le tirage sans remise d'une grande partie de la population rend la moyenne plus précise.

Indication pour l'exercice 16 ▲

Fiche mémo : § 2.2, encadré « Variance empirique et variance corrigée ».

1. Moyenne des 6 valeurs.
2. Faire un tableau : écarts $x_i - \bar{x}$, puis leurs carrés, puis leur somme $SCE = \sum (x_i - \bar{x})^2$. Contrôle : la somme des écarts doit valoir 0. Ensuite $s_n^2 = SCE/n$ et $s_n'^2 = SCE/(n-1)$.
3. $E(S_n^2) = \frac{n-1}{n} \sigma^2$ et $E(S_n'^2) = \sigma^2$ (encadré). Un estimateur est sans biais si son espérance vaut exactement le paramètre.
4. Les écarts sont mesurés autour de $\bar{x}$, calculée sur les mêmes données, et non autour de la vraie moyenne μ . Les données sont « au plus près » de leur propre moyenne : la dispersion observée est trop petite.
5. Le rapport $S_n'^2/S_n^2 = \frac{n}{n-1}$: que vaut-il pour $n = 6$? pour $n = 100$?

Indication pour l'exercice 17 ▲

Fiche mémo : § 2.2, encadré « Moyenne empirique » ; § 1.5, encadré « Loi normale » ; § 2.3, encadré « Taille d'échantillon » pour la question 6.

1. La population est normale : $\bar{X}$ est *exactement* normale, pour tout n (pas besoin du TCL, et $n = 9 < 30$ ne pose donc pas de problème). Donner son espérance et sa variance.
2. Centrer et réduire avec l'écart-type de $\bar{X}$, c'est-à-dire $\sigma/\sqrt{n}$, et non σ .
3. Même calcul pour une parcelle, avec σ . Comparer : la moyenne fluctue beaucoup moins qu'une observation isolée.
4. Intervalle de fluctuation : $\mu \pm 1,96 \frac{\sigma}{\sqrt{n}}$.
5. La valeur 1,9 tombe-t-elle dans l'intervalle ? Sinon, deux explications : une malchance rare, ou des parcelles non représentatives (ou une année particulière).
6. Résoudre $1,96 \frac{\sigma}{\sqrt{n}} \leq 0,1$, c'est-à-dire $n \geq \left(\frac{1,96 \sigma}{0,1}\right)^2$, et arrondir au-dessus.

Indication pour l'exercice 18 ▲

Fiche mémo : § 2.2, encadré « Moyenne empirique » ; § 2.3, encadrés « Fréquence » et « Taille d'échantillon » ; § 2.1 pour la question 4.

1. (a) Écart-type de la moyenne : $\sigma/\sqrt{n}$.
(b) Population normale, donc $\bar{X} \sim \mathcal{N}(\mu, \sigma^2/n)$: centrer et réduire 4600 avec $\sigma/\sqrt{n}$.
(c) $P(a \leq \bar{X} \leq b) = \Phi(\cdot) - \Phi(\cdot)$; l'intervalle est symétrique autour de μ .
2. L'intervalle $[4750; 4850]$ est centré sur μ avec une marge $e = 50$ kg/ha. Encadré « Taille d'échantillon » : $n \geq \left(\frac{z \sigma}{e}\right)^2$ avec $z = 1,96$, arrondi au-dessus.
3. $F \approx \mathcal{N}\left(p, \frac{p(1-p)}{n}\right)$ après avoir vérifié $np \geq 5$ et $n(1-p) \geq 5$. Centrer et réduire 0,75.
4. Les deux familles sont dans le paragraphe qui suit le tableau des plans. Périmètres irrigués : zones bien délimitées et différentes entre elles (quel plan en profite ?). Villages dispersés : quel plan limite les déplacements ?

Indication pour l'exercice 19 ▲

Fiche mémo : § 1.6 « Théorème central limite » ; § 2.2, encadré « Moyenne empirique ».

1. La distribution des revenus est très asymétrique : une loi normale (symétrique) décrit-elle bien le revenu d'un ménage ?
 2. Énoncé du TCL dans la fiche. Vérifier les conditions : observations indépendantes, de même loi, $n \geq 30$. Il porte sur la moyenne, pas sur un individu.
 3. Centrer et réduire 390 avec $\sigma(\bar{X}) = \sigma/\sqrt{n}$.
 4. $\Phi(\cdot) - \Phi(\cdot)$; l'intervalle $[330; 370]$ est symétrique autour de μ .
 5. Pour une loi de Poisson, $E(Y) = V(Y) = \lambda$, donc $\sigma(Y) = \sqrt{\lambda}$. Ensuite $\sigma(\bar{Y}) = \sigma(Y)/\sqrt{60}$.
 6. $n = 60 \geq 30$: le TCL s'applique même si les comptages ne sont pas normaux. Centrer et réduire 1,8.
-

Indication pour l'exercice 20 ▲

Fiche mémo : § 2.3, encadré « Fréquence $F = K/n$ » et sa figure (c'est exactement la situation de l'exercice).

1. $f = \frac{\text{nombre de graines germées}}{n}$.
 2. On se place dans l'hypothèse où le semencier dit vrai : utiliser la valeur annoncée $p = 0,9$ (et non f) dans $E(F) = p$ et $\sigma(F) = \sqrt{\frac{p(1-p)}{n}}$.
 3. Conditions de Moivre-Laplace : $np \geq 5$ et $n(1-p) \geq 5$.
 4. $p \pm 1,96\sigma(F)$.
 5. f est-elle dans l'intervalle ? Si non, on remet en cause l'annonce (deuxième puce de l'encadré). Le risque de se tromper est la probabilité qu'une annonce vraie donne une fréquence hors de l'intervalle.
 6. Relire les conditions de la forme simplifiée dans l'encadré et les comparer à $p = 0,9$.
-

Indication pour l'exercice 21 ▲

Fiche mémo : § 2.3, encadré « Taille d'échantillon » et exemple des chenilles légionnaires.

1. Aucune information sur p : prendre $p = 0,5$, cas le plus défavorable, d'où $n \geq \frac{z^2}{4e^2}$ avec $e = 0,03$. Toujours arrondir à l'entier supérieur.
 2. Remplacer $p(1-p)$ par sa valeur pour $p = 0,2$ et la comparer à 0,25.
 3. Diviser la marge par 2 multiplie la taille par 4 : vérifier par le calcul.
 4. Pour une moyenne : $n \geq \left(\frac{z\sigma}{e}\right)^2$ avec $e = 0,1$ t/ha.
 5. Même formule avec $z = 2,576$: plus de confiance coûte plus d'unités.
 6. n_0 est le résultat de la question 4 ; il dépasse 10 % de N , donc $n = \frac{n_0}{1 + n_0/N}$, arrondi au-dessus.
-

Indication pour l'exercice 22 ▲

Fiche mémo : § 3.1 « Estimation ponctuelle » (définitions et tableau) ; § 2.2, encadré « Variance empirique et variance corrigée ».

1. Population : toutes les cabosses mûres de la coopérative. Paramètres : μ , σ^2 (ou σ) et p . Estimateurs : voir le tableau du § 3.1.
2. Définitions du § 3.1 : laquelle des deux notions change d'un échantillon à l'autre ?
3. $\bar{x} = \frac{\sum x_i}{n}$ (le résultat est un nombre rond).
4. Tableau des écarts $x_i - \bar{x}$ et de leurs carrés, puis $SCE = \sum (x_i - \bar{x})^2$ divisée par $n - 1$. On divise par $n - 1$ pour obtenir un estimateur sans biais de σ^2 (encadré du § 2.2).
5. $f = \frac{k}{n}$.
6. Deux échantillons différents donnent deux estimations différentes : c'est la fluctuation d'échantillonnage. Comparer l'écart entre les deux moyennes à l'erreur-type $s' / \sqrt{n}$. Ce qui manque à une estimation ponctuelle, c'est sa précision : c'est le rôle de l'intervalle de confiance (§ 3.2).

Indication pour l'exercice 23 ▲

Fiche mémo : § 3.1 « Estimation ponctuelle » ; § 2.2, encadré « Variance empirique et variance corrigée ».

1. $\bar{x} = \frac{\sum x_i}{n}$.
2. Tableau des écarts et de leurs carrés, $SCE = \sum (x_i - \bar{x})^2$, puis $s^2 = SCE/n$ et $s'^2 = SCE/(n - 1)$. Laquelle est sans biais (encadré du § 2.2) ?
3. $\hat{\sigma} = s'$. Pour p : compter les chèvres qui produisent *strictement* plus de 1 litre (1,0 n'est pas compté).
4. Définitions du § 3.1 : la règle de calcul reste la même, le nombre obtenu change.
5. Erreur-type estimée : $s' / \sqrt{n}$. Elle mesure de combien $\bar{x}$ varie typiquement d'un échantillon à l'autre.
6. Production totale estimée = $120 \times \bar{x}$, puis chiffre d'affaires = quantité $\times$ prix. Ce n'est qu'une estimation ponctuelle : sans intervalle, on ne connaît pas sa précision.

Indication pour l'exercice 24 ▲

Fiche mémo : § 3.2 « Intervalles de confiance » (paragraphe « Interprétation », figure des dix intervalles, tableau des z , encadré « Les intervalles à connaître », ligne « Moyenne, σ connu »).

1. L'estimation ponctuelle de μ est $\bar{x}$ (§ 3.1).
2. La population est normale et σ connu, donc $Z = \frac{\bar{X} - \mu}{\sigma / \sqrt{n}}$ suit exactement $\mathcal{N}(0, 1)$. C'est de cette variable, dont on connaît la loi, qu'on part pour construire l'intervalle.
3. Marge $e = z \frac{\sigma}{\sqrt{n}}$ avec $z = 1,96$, puis $\bar{x} \pm e$.
4. Même calcul avec $z = 2,576$. Plus de confiance $\Rightarrow$ intervalle plus large.
5. Le poids nominal 80 kg est-il dans l'intervalle ? Une valeur de référence dans l'intervalle reste compatible avec les données.
6. Relire « Interprétation » et la figure des dix intervalles : une fois calculé, l'intervalle est fixe et μ aussi ; c'est la *méthode* qui réussit 95 % du temps. L'intervalle porte sur la moyenne μ , pas sur les sacs.

7. Encadré « Taille d'échantillon » du § 2.3 : $n \geq \left(\frac{z\sigma}{e}\right)^2$, arrondi au-dessus.

Indication pour l'exercice 25 ▲

Fiche mémo : § 3.2, encadré « Les intervalles à connaître » (lignes « σ connu » et « Student ») et tableau des z ; § 2.3, encadré « Taille d'échantillon ».

1. Regarder les conditions des lignes du tableau : la loi de Student ne sert que lorsque σ est remplacé par son estimation s' . Ici la population est normale et σ est connu.
2. $e = 1,96 \frac{\sigma}{\sqrt{n}}$, puis $\bar{x} \pm e$.
3. $z = 1,645$ à 90 % et $z = 2,576$ à 99 % (tableau des z).
4. Le seuil est atteint « avec confiance » si 3,5 est *sous la borne inférieure*. Regarder chacun des trois intervalles.
5. $n \geq \left(\frac{z\sigma}{e}\right)^2$ avec $e = 0,1$, arrondi au-dessus.
6. Ligne « Student » : $\bar{x} \pm t_{15;0,975} \frac{s'}{\sqrt{n}}$. Pour expliquer la différence avec la question 2, comparer s' à σ , puis t à 1,96.

Indication pour l'exercice 26 ▲

Fiche mémo : § 3.2, encadré « Les intervalles à connaître » (ligne « Moyenne, σ inconnu, $n \geq 30$ »), paragraphe « Interprétation » et règles de lecture ; § 1.6 pour la normalité.

1. σ inconnu mais $n \geq 30$: quelle ligne de l'encadré ? Pour la normalité, se demander ce que garantit le TCL (§ 1.6).
2. $e = 1,96 \frac{s'}{\sqrt{n}}$, puis $\bar{x} \pm e$.
3. Même calcul avec $z = 2,576$, puis comparer les largeurs.
4. L'intervalle porte sur le poids *moyen*, pas sur les animaux, beaucoup plus dispersés. Reformuler avec le paragraphe « Interprétation ».
5. Prix moyen = 1 500 μ : on multiplie les deux bornes par la même constante (règle de la fiche).
6. 330 kg est-il dans l'intervalle ? Une valeur de référence hors de l'intervalle n'est pas compatible avec les données. Pour l'explication, penser aux pâturages, aux sécheresses ou à l'âge des animaux vendus.
7. $n \geq \left(\frac{z\sigma}{e}\right)^2$ avec $e = 5$ kg, arrondi au-dessus (§ 2.3).

Indication pour l'exercice 27 ▲

Fiche mémo : § 3.2, encadré « Les intervalles à connaître » (ligne « Student »), figure Student / normale et puce sur la normalité.

1. À la calculatrice, en mode statistique, prendre l'écart-type *corrigé* (souvent noté s_x ou σ_{n-1}), et non σ_x ou σ_n .
2. Petit échantillon et σ remplacé par s' : cette estimation ajoute de l'incertitude. Quelle loi en tient compte, avec combien de degrés de liberté ?

3. $\bar{x} \pm t_{9;0,975} \frac{s'}{\sqrt{n}}$.
 4. Remplacer 2,262 par 1,96 : l'intervalle obtenu est-il plus large ou plus étroit ? Sa confiance réelle est-elle encore de 95 % ?
 5. 0,75 t/ha est-il dans l'intervalle ? (règle « valeur de référence hors de l'intervalle »).
 6. Avec $n = 10$, le TCL ne s'applique pas : l'intervalle de Student suppose une population normale. Les moyens de vérification sont donnés dans la fiche.
-

Indication pour l'exercice 28 ▲

Fiche mémo : § 3.2, encadré « Les intervalles à connaître » (ligne « Student »), puces sur la normalité et sur les grandeurs proportionnelles à μ .

1. Tableau des écarts et de leurs carrés (ou calculatrice, écart-type corrigé), puis $s'^2 = \frac{SCE}{n-1}$.
 2. $n = 8$, σ inconnu : ligne « Student ». Le TCL ne s'applique pas avec si peu de données : c'est la normalité qui garantit la loi de Student. Vérification : voir la fiche.
 3. $\bar{x} \pm t \frac{s'}{\sqrt{n}}$ avec $t_{7;0,975}$ à 95 % et $t_{7;0,95}$ à 90 % (on prend le quantile d'ordre $1 - \alpha/2$).
 4. 165 g/jour est-il dans l'intervalle à 95 % ?
 5. Refaire le calcul avec 1,96 : l'intervalle est trop étroit, donc son niveau de confiance réel est inférieur à 95 %.
 6. Gain sur 90 jours = 90μ : multiplier les deux bornes par 90 (attention aux unités : g puis kg), puis par le prix du kilogramme.
-

Indication pour l'exercice 29 ▲

Fiche mémo : § 3.2, encadré « Les intervalles à connaître » (ligne « Proportion » et ses conditions) et tableau des z ; § 2.3, encadré « Taille d'échantillon ».

1. $f = \frac{k}{n}$.
 2. Conditions de la ligne « Proportion » : $n \geq 30$, $nf \geq 5$ et $n(1-f) \geq 5$.
 3. $f \pm 1,96 \sqrt{\frac{f(1-f)}{n}}$.
 4. Même formule avec $z = 1,645$: l'intervalle doit être plus étroit.
 5. Le seuil 0,20 est-il dans l'intervalle ? S'il y est, peut-on affirmer que la proportion dépasse 20 % ?
 6. $n \geq \frac{z^2 p(1-p)}{e^2}$ avec $p \approx f$ et $e = 0,03$, arrondi au-dessus.
 7. Vérifier les conditions avec $n = 20$ et $k = 2$, puis calculer la borne inférieure de l'intervalle classique : que remarque-t-on ?
-

Indication pour l'exercice 30 ▲

Fiche mémo : § 3.2, encadré « Les intervalles à connaître » (lignes « Proportion » et « Différence de deux proportions »); § 2.3, encadré « Taille d'échantillon ».

1. $f = \frac{k}{n}$.
2. Vérifier $n \geq 30$, $nf \geq 5$, $n(1-f) \geq 5$, puis $f \pm 1,96\sqrt{\frac{f(1-f)}{n}}$.
3. Comparer 0,70 aux bornes de l'intervalle.
4. Formule $n \geq \frac{z^2 p(1-p)}{e^2}$ avec $e = 0,03$, arrondie au-dessus. Pour expliquer la différence : $p(1-p)$ est maximal pour $p = 0,5$.
 - (a) Sans information : $p = 0,5$, d'où $n \geq \frac{z^2}{4e^2}$.
 - (b) Avec l'estimation de cette année : $p \approx f$.
5. Les deux enquêtes sont indépendantes : les variances s'additionnent sous la racine (ligne « Différence de deux proportions »). Puis regarder si l'intervalle contient 0.

Indication pour l'exercice 31 ▲

Fiche mémo : § 3.2, encadré « Les intervalles à connaître » (lignes « Différence de deux proportions » et « Différence de moyennes appariées »), puce « Appariement » et figure des différences.

1. $f = \frac{k}{n}$ dans chaque village.
2. $(f_A - f_B) \pm 1,96\sqrt{\frac{f_A(1-f_A)}{n_A} + \frac{f_B(1-f_B)}{n_B}}$.
3. L'intervalle contient-il 0 ? Si oui, on ne peut pas conclure à une différence (figure des différences).
4. Les deux variétés sont cultivées sur les *mêmes* exploitations : relire la puce « Appariement ».
5. Faire un tableau des $d_i = a_i - l_i$, puis calculer $\bar{d}$ et s'_D comme pour une seule série de données.
6. Ligne « Différence de moyennes appariées » : $\bar{d} \pm t_{7;0,975} \frac{s'_D}{\sqrt{n}}$.
7. L'intervalle du gain moyen est-il entièrement positif ?

Indication pour l'exercice 32 ▲

Fiche mémo : exercice de synthèse : § 2.1 (plans), § 2.2 (facteur d'exhaustivité), § 2.3 (taille d'échantillon), § 3.1 et § 3.2.

1. Ligne « Systématique » du tableau des plans : pas $k = N/n$, départ tiré au hasard entre 1 et k . Le piège : une liste qui a une structure régulière (périodique).
2. Tableau du § 3.1 : $\bar{x}$, s' et f .
3. $n = 50 \geq 30$: ligne « Moyenne, σ inconnu, $n \geq 30$ ». Pour le facteur d'exhaustivité, comparer le taux de sondage n/N à 10 %.
4. Revenu moyen = 1 500 μ : multiplier les deux bornes de l'intervalle de la question 3.

5. Total = $N\mu$: estimation ponctuelle $N\bar{x}$, et intervalle obtenu en multipliant les bornes par N .
 6. Vérifier les conditions, puis $f \pm 1,96\sqrt{\frac{f(1-f)}{n}}$. Pour juger la largeur, la comparer à la valeur de f elle-même.
 7. Sans information : $n_0 \geq \frac{z^2}{4e^2}$ avec $e = 0,05$. Si n_0 dépasse 10 % de N , corriger : $n = \frac{n_0}{1 + n_0/N}$. Toujours arrondir au-dessus.
-

Corrections

Correction de l'exercice 1 ▲

Fiche mémo : § 1.1, encadré « Calculer avec des événements » et diagramme ; § 1.2 (conditionnement) ; § 1.3 (indépendance).

1. On traduit symbole par symbole ($\cup$ = « ou », $\cap$ = « et », barre = « ne... pas ») :

- $M \cup C$: « le pied est atteint par la mosaïque *ou* par la cochenille (au moins l'un des deux) » ;
- $\overline{M \cap C}$: « le pied n'a ni la mosaïque, ni la cochenille » ;
- $M \cap \overline{C}$: « le pied a la mosaïque, mais pas la cochenille ».

2. Deux événements sont incompatibles s'ils ne peuvent pas se produire ensemble, c'est-à-dire si $P(M \cap C) = 0$. Ici $P(M \cap C) = 0,10 \neq 0$: certains pieds portent les deux bio-agresseurs. M et C ne sont donc **pas incompatibles**.

3. « Au moins un des deux » correspond à $M \cup C$. Dans $P(M) + P(C)$, les pieds atteints des deux maladies sont comptés deux fois : on retire une fois $P(M \cap C)$.

$$P(M \cup C) = P(M) + P(C) - P(M \cap C) = 0,30 + 0,25 - 0,10 = \mathbf{0,45}.$$

Un pied sur deux environ est touché par au moins un bio-agresseur.

4. D'après la loi de De Morgan, $\overline{M \cap C} = \overline{M} \cup \overline{C}$: « indemne des deux » est le contraire de « au moins un des deux ».

$$P(\overline{M \cap C}) = 1 - P(M \cap C) = 1 - 0,10 = \mathbf{0,90}.$$

5. « Un seul des deux » = $(M \cap \overline{C}) \cup (\overline{M} \cap C)$, réunion de deux événements incompatibles. Avec la formule de la fiche :

$$P(M \cap \overline{C}) = P(M) - P(M \cap C) = 0,30 - 0,10 = 0,20, \quad P(\overline{M} \cap C) = 0,25 - 0,10 = 0,15,$$

d'où $P(\text{un seul}) = 0,20 + 0,15 = \mathbf{0,35}$.

Contrôle : « un seul » = « au moins un » privé de « les deux », et $0,45 - 0,10 = 0,35$.

6. Par définition de la probabilité conditionnelle :

$$P(M | C) = \frac{P(M \cap C)}{P(C)} = \frac{0,10}{0,25} = \mathbf{0,40}, \quad P(C | M) = \frac{P(M \cap C)}{P(M)} = \frac{0,10}{0,30} \approx \mathbf{0,33}.$$

Parmi les pieds attaqués par la cochenille, 40 % ont aussi la mosaïque ; parmi les pieds atteints de mosaïque, un tiers environ portent aussi la cochenille. Les deux valeurs diffèrent car on ne divise pas par la même population de référence : le conditionnement n'est pas symétrique.

7. On compare $P(M \cap C)$ et $P(M)P(C)$:

$$P(M)P(C) = 0,30 \times 0,25 = 0,075 \neq 0,10 = P(M \cap C).$$

M et C **ne sont pas indépendants**. De façon équivalente, $P(M | C) = 0,40 > P(M) = 0,30$: savoir qu'un pied porte la cochenille augmente le risque qu'il ait la mosaïque. Agronomiquement, les deux problèmes se cumulent sur les mêmes pieds : boutures de mauvaise qualité, pieds affaiblis, parcelles moins bien entretenues. . .

À retenir. « Au moins un » se calcule par la formule de la réunion ou par le contraire « aucun » ; « incompatibles » ($P(A \cap B) = 0$) et « indépendants » ($P(A \cap B) = P(A)P(B)$) sont deux notions différentes.

Correction de l'exercice 2 ▲

Fiche mémo : § 1.1, tableau du dénombrement, principe multiplicatif et probabilité uniforme.

1. (a) On choisit un *groupe* de 3 variétés : l'ordre ne compte pas, c'est une combinaison.

$$\binom{8}{3} = \frac{8!}{3!5!} = \frac{8 \times 7 \times 6}{3 \times 2 \times 1} = 56 \text{ choix.}$$

- (b) Les parcelles 1, 2, 3 sont distinctes : échanger deux variétés donne une autre disposition, l'ordre compte. C'est un arrangement.

$$A_8^3 = \frac{8!}{5!} = 8 \times 7 \times 6 = 336 \text{ dispositions.}$$

Contrôle : chaque groupe de la question (a) peut être disposé de $3! = 6$ façons, et $56 \times 6 = 336$.

2. On range 5 opérations distinctes, toutes utilisées : $5! = 5 \times 4 \times 3 \times 2 \times 1 = 120$ ordres possibles.

3. Les $\binom{8}{3} = 56$ groupes sont équiprobables : $P = \frac{\text{nombre de cas favorables}}{56}$.

- (a) Un seul groupe est formé des 3 variétés améliorées : $P = \frac{1}{56} \approx 0,018$.

- (b) On choisit 2 améliorées parmi 3 et 1 locale parmi 5 ; par le principe multiplicatif :

$$P = \frac{\binom{3}{2} \times \binom{5}{1}}{\binom{8}{3}} = \frac{3 \times 5}{56} = \frac{15}{56} \approx 0,268.$$

- (c) Le contraire de « au moins une améliorée » est « aucune améliorée », soit 3 variétés choisies parmi les 5 locales :


$$P(\text{au moins une}) = 1 - \frac{\binom{5}{3}}{\binom{8}{3}} = 1 - \frac{10}{56} = \frac{46}{56} \approx 0,821.$$

À retenir. Toujours se demander si l'ordre compte (arrangement) ou non (combinaison). Quand on choisit dans plusieurs groupes à la fois, on multiplie les nombres de choix.

Correction de l'exercice 3 ▲

Fiche mémo : § 1.2, encadré « Conditionnement, probabilités totales, Bayes » et méthode de l'arbre pondéré.

1. Chaque parcelle est sur un et un seul type de sol : S_1, S_2, S_3 sont incompatibles deux à deux et leur réunion est l'ensemble des parcelles ($0,5 + 0,3 + 0,2 = 1$). C'est un **système complet**. Les pourcentages d'infestation sont des probabilités *conditionnelles* $P(I | S_i)$.



2. Probabilités totales : on multiplie le long de chaque branche qui mène à I , puis on additionne.

$$P(I) = 0,5 \times 0,40 + 0,3 \times 0,15 + 0,2 \times 0,10 = 0,200 + 0,045 + 0,020 = \mathbf{0,265}.$$

Un peu plus d'une parcelle sur quatre est infestée.

3. Formule de Bayes : on « remonte » l'arbre, $P(S_i | I) = \frac{P(I | S_i) P(S_i)}{P(I)}$.

$$P(S_1 | I) = \frac{0,200}{0,265} \approx \mathbf{0,755}, \quad P(S_2 | I) = \frac{0,045}{0,265} \approx \mathbf{0,170}, \quad P(S_3 | I) = \frac{0,020}{0,265} \approx \mathbf{0,075}.$$

Contrôle : $\frac{0,200 + 0,045 + 0,020}{0,265} = 1$: une parcelle infestée est forcément sur l'un des trois sols.

4. $P(\bar{I}) = 1 - 0,265 = 0,735$ et la branche « S_1 puis $\bar{I}$ » vaut $0,5 \times 0,60 = 0,30$, donc

$$P(S_1 | \bar{I}) = \frac{0,30}{0,735} \approx \mathbf{0,408}.$$


5. Les sols sableux ne représentent que la moitié des parcelles mais concentrent environ les trois quarts des parcelles infestées ($P(S_1 | I) \approx 0,755$), avec le plus fort taux d'infestation (40 %). Il faut donc **concentrer le traitement sur les sols sableux** : en traitant la moitié des parcelles, on touche 75 % de l'infestation. C'est cohérent avec l'agronomie : le striga prospère sur les sols sableux pauvres.

À retenir. Arbre pondéré : on multiplie le long d'une branche et on additionne les branches qui mènent au même événement. Bayes permet de « remonter » de l'effet (I) vers la cause (S_i).

Correction de l'exercice 4 ▲

Fiche mémo : § 1.2, encadré « Conditionnement, probabilités totales, Bayes » et paragraphe « Test de diagnostic ».

1. Premier niveau : l'état du porc ($P(M) = 0,04$, prévalence). Second niveau : le résultat du test, avec la sensibilité $P(+ | M) = 0,95$ et la spécificité $P(- | \bar{M}) = 0,98$, d'où les faux positifs $P(+ | \bar{M}) = 1 - 0,98 = 0,02$.



2. $\{M, \bar{M}\}$ est un système complet ; on additionne les deux branches qui mènent à + (vrais positifs et faux positifs) :

$$P(+) = 0,95 \times 0,04 + 0,02 \times 0,96 = 0,038 + 0,0192 = \mathbf{0,0572}.$$

3. Formule de Bayes :

$$\text{VPP} = P(M | +) = \frac{P(+ | M) P(M)}{P(+)} = \frac{0,038}{0,0572} \approx \mathbf{0,664}.$$

Le test est pourtant très performant (95 % de sensibilité, 98 % de spécificité), mais un porc positif n'est réellement infecté que dans deux cas sur trois environ. La maladie étant rare, les porcs sains sont très nombreux : même 2 % de faux positifs parmi eux (0,0192) pèsent lourd face aux vrais positifs (0,038). Un test positif doit donc être **confirmé** (analyse de laboratoire) avant d'abattre l'élevage.

4. $P(-) = 1 - P(+) = 0,9428$ et la branche « $\bar{M}$ puis - » vaut $0,98 \times 0,96 = 0,9408$, donc

$$\text{VPN} = P(\bar{M} | -) = \frac{0,9408}{0,9428} \approx \mathbf{0,998}.$$

Un test négatif est très rassurant : le porc est presque sûrement sain.

5. Avec $P(M) = 0,30$:

$$P(+) = 0,95 \times 0,30 + 0,02 \times 0,70 = 0,285 + 0,014 = 0,299, \quad VPP = \frac{0,285}{0,299} \approx \mathbf{0,953}.$$

Avec le même test, la VPP passe de 66 % à 95 % : les vrais positifs sont maintenant beaucoup plus nombreux que les faux positifs. **La valeur prédictive dépend fortement de la prévalence** : le test est bien plus fiable dans un foyer déclaré que pour un dépistage de masse en zone peu touchée.

À retenir. Ne pas confondre $P(+ | M)$ (sensibilité, qualité du test) et $P(M | +)$ (VPP, ce qui intéresse l'éleveur). On passe de l'une à l'autre par Bayes, et le résultat dépend de la prévalence.

Correction de l'exercice 5 ▲

Fiche mémo : § 1.3 « Indépendance » (« aucun succès », « au moins un succès », calcul du n minimal).

Notons L_i : « la graine i lève », avec $P(L_i) = 0,7$, $P(\bar{L}_i) = 0,3$, les L_i étant indépendants.

1. (a) Le poquet est vide si les deux graines échouent ; par indépendance, on multiplie :

$$P(\text{vide}) = P(\bar{L}_1 \cap \bar{L}_2) = 0,3 \times 0,3 = \mathbf{0,09}.$$

- (b) « Au moins une lève » est le contraire de « vide » : $1 - 0,09 = \mathbf{0,91}$.

2. (a) $P(\text{vide}) = 0,3^3 = \mathbf{0,027}$.

- (b) Il y a 3 façons de choisir la graine qui échoue, chacune de probabilité $0,7 \times 0,7 \times 0,3$:

$$P(\text{exactement 2}) = 3 \times 0,7^2 \times 0,3 = 3 \times 0,49 \times 0,3 = \mathbf{0,441}.$$

On reconnaît la loi binomiale $\mathcal{B}(3; 0,7)$ (§ 1.5).

- (c) Chaque poquet est vide avec la probabilité 0,027 : sur 100 poquets, on en attend en moyenne $100 \times 0,027 = \mathbf{2,7}$, soit environ 3 poquets à ressemer.

3. Avec k graines, le poquet est vide si les k graines échouent :

$$P(\text{au moins une levée}) = 1 - P(\text{vide}) = \mathbf{1 - 0,3^k}.$$

4. On résout l'inégalité en passant au logarithme :

$$1 - 0,3^k \geq 0,99 \iff 0,3^k \leq 0,01 \iff k \ln 0,3 \leq \ln 0,01 \iff k \geq \frac{\ln 0,01}{\ln 0,3} \approx 3,82.$$

On a divisé par $\ln 0,3 < 0$, ce qui *change le sens* de l'inégalité. Comme k est entier, il faut au minimum $\mathbf{k = 4}$ graines par poquet.

Contrôle : $1 - 0,3^3 = 0,973 < 0,99$ mais $1 - 0,3^4 = 0,9919 \geq 0,99$.

5. Les graines d'un même poquet partagent le même trou : même sol, même humidité, mêmes ravageurs (termites, oiseaux). Si le poquet est trop sec ou attaqué, toutes les graines risquent d'échouer *ensemble*. La probabilité réelle d'un poquet vide est alors supérieure à $0,3^k$: le calcul sous indépendance est optimiste.


À retenir. Pour n épreuves indépendantes : $P(\text{aucun succès}) = (1 - p)^n$ et $P(\text{au moins un}) = 1 - (1 - p)^n$. Pour trouver le n minimal, on passe au logarithme en surveillant le sens de l'inégalité.

Correction de l'exercice 6 ▲

Fiche mémo : § 1.4, encadré « Loi, espérance, variance ».

1. La somme des probabilités vaut 1 : $0,4 + 0,5 + a = 1$, donc $a = 0,1$ (on vérifie que $0 \leq a \leq 1$).
2. $F(x) = P(X \leq x)$ cumule les probabilités des valeurs inférieures ou égales à x :

$$F(x) = \begin{cases} 0 & \text{si } x < 1, \\ 0,4 & \text{si } 1 \leq x < 2, \\ 0,9 & \text{si } 2 \leq x < 3, \\ 1 & \text{si } x \geq 3. \end{cases}$$



C'est une fonction en escalier, croissante, qui saute de $P(X = k)$ en chaque valeur k (point plein : valeur prise en k).

3. Par définition de l'espérance :

$$E(X) = 1 \times 0,4 + 2 \times 0,5 + 3 \times 0,1 = 1,7.$$

Pour la variance, on calcule d'abord $E(X^2) = 1 \times 0,4 + 4 \times 0,5 + 9 \times 0,1 = 3,3$, puis

$$V(X) = E(X^2) - E(X)^2 = 3,3 - 1,7^2 = 0,41, \quad \sigma(X) = \sqrt{0,41} \approx 0,64.$$

Sur un grand nombre de mises-bas, une chèvre donne en moyenne 1,7 chevreau par mise-bas.

4. $R = 25\,000 X - 10\,000$ est de la forme $aX + b$:

$$E(R) = 25\,000 \times 1,7 - 10\,000 = 32\,500 \text{ FCFA}, \quad \sigma(R) = 25\,000 \times \sigma(X) \approx 16\,000 \text{ FCFA}.$$

La constante $-10\,000$ décale le revenu mais ne change pas sa dispersion.

5. $T = X_1 + \dots + X_{40}$, avec des X_i indépendants de même loi que X : les espérances et les variances s'additionnent.

$$E(T) = 40 \times 1,7 = 68, \quad V(T) = 40 \times 0,41 = 16,4, \quad \sigma(T) = \sqrt{16,4} \approx 4,05.$$

L'éleveur peut compter sur environ 68 chevreaux, à quelques unités près. Attention : $\sigma(T) \neq 40 \times \sigma(X)$, on n'additionne pas les écarts-types.

À retenir. $V(X) = E(X^2) - E(X)^2$; $V(aX + b) = a^2 V(X)$; pour une somme de variables indépendantes, ce sont les variances qui s'additionnent.

Correction de l'exercice 7 ▲

Fiche mémo : § 1.5 « Lois usuelles », tableau des lois discrètes, ligne « Binomiale ».

1. On vérifie les conditions de la binomiale : chaque graine est une épreuve à deux issues (germe, avec $p = 0,85$, ou non) ; les 10 épreuves sont identiques et indépendantes ; X compte le nombre de succès. Donc $X \sim \mathcal{B}(10; 0,85)$.

2. Toutes les graines germent :

$$P(X = 10) = 0,85^{10} \approx \mathbf{0,197}.$$

Même avec un bon lot, il n'y a qu'une chance sur cinq environ que les 10 graines germent.

3. Formule de la binomiale avec $k = 8$:

$$P(X = 8) = \binom{10}{8} 0,85^8 0,15^2 = 45 \times 0,2725 \times 0,0225 \approx \mathbf{0,276}.$$

$\binom{10}{8} = 45$ compte les façons de choisir les 8 graines qui germent.

4. « Au moins 8 » = $\{X = 8\} \cup \{X = 9\} \cup \{X = 10\}$. Avec $P(X = 9) = 10 \times 0,85^9 \times 0,15 \approx 0,347$:

$$P(X \geq 8) \approx 0,276 + 0,347 + 0,197 = \mathbf{0,820}.$$

5. Formules du tableau de la fiche :

$$E(X) = np = 10 \times 0,85 = \mathbf{8,5}, \quad V(X) = np(1 - p) = 10 \times 0,85 \times 0,15 = \mathbf{1,275}.$$

Si l'on sème un grand nombre de séries de 10 graines, on obtient en moyenne 8,5 graines germées par série.

6. On cherche n tel que $E(X) = 0,85n = 50$, soit $n = 50/0,85 \approx 58,8$: il faut semer **59** graines (arrondi au-dessus).

Attention : c'est une moyenne, pas une garantie. Avec 59 graines, la probabilité d'obtenir au moins 50 plants n'est que d'environ 0,61.

À retenir. On reconnaît la binomiale à « n épreuves indépendantes, deux issues, même p , on compte les succès ». « Au moins k » : additionner, ou passer par le contraire si c'est plus court.

Correction de l'exercice 8 ▲

Fiche mémo : § 1.5, ligne « Hypergéométrique » du tableau des lois discrètes et schéma des approximations.

Partie A – Petit lot

1. On tire $n = 5$ sacs *sans remise* dans un lot fini de $N = 50$ sacs, dont $K = 4$ « succès » (sacs non conformes), et l'on compte les succès tirés : $X \sim \mathcal{H}(50; 4; 5)$, à valeurs dans $\{0, 1, 2, 3, 4\}$.
2. $X = 0$: les 5 sacs sont choisis parmi les 46 conformes.

$$P(X = 0) = \frac{\binom{4}{0} \binom{46}{5}}{\binom{50}{5}} = \frac{1\,370\,754}{2\,118\,760} \approx \mathbf{0,647},$$

donc $P(\text{détecter au moins un sac non conforme}) = P(X \geq 1) = 1 - 0,647 \approx \mathbf{0,353}$.

3. $E(X) = n \frac{K}{N} = 5 \times \frac{4}{50} = \mathbf{0,4}$ sac. En moyenne, un contrôle de 5 sacs ne trouve que 0,4 sac non conforme, et dans près de deux cas sur trois il n'en trouve aucun alors que le lot en contient 4. Un contrôle sur 5 sacs est peu efficace.

Partie B – Grand lot

4. Le lot contient $K = 0,08 \times 2\,000 = 160$ sacs non conformes : la loi exacte est $Y \sim \mathcal{H}(2\,000; 160; 20)$. Comme $N = 2\,000 \geq 10n = 200$, retirer 20 sacs ne modifie presque pas la composition du lot : le tirage sans remise se comporte comme un tirage avec remise. D'après le schéma de la fiche, $Y \approx \mathcal{B}(20; 0,08)$, avec $p = K/N = 0,08$.

5. Avec la binomiale :

$$P(Y = 0) \approx 0,92^{20} \approx \mathbf{0,189}, \quad P(Y = 1) \approx 20 \times 0,08 \times 0,92^{19} \approx 0,328,$$

$$P(\text{lot accepté}) = P(Y \leq 1) \approx 0,189 + 0,328 = \mathbf{0,517}.$$

(Le calcul exact avec la loi hypergéométrique donne 0,516 : l'approximation est excellente.)

6. Un lot qui contient 8 % de sacs non conformes est accepté une fois sur deux : la règle est **trop permissive** pour protéger les producteurs. Il faudrait prélever davantage de sacs, ou n'accepter le lot qu'en l'absence de tout sac non conforme (il serait alors refusé dans 81 % des cas).

À retenir. Tirage sans remise dans un lot fini : loi hypergéométrique. Si le lot est grand devant l'échantillon ($N \geq 10n$), on l'approche par la binomiale de paramètre $p = K/N$.

Correction de l'exercice 9 ▲

Fiche mémo : § 1.5, ligne « Poisson » du tableau, remarque sur la somme de lois de Poisson, schéma des approximations.

Partie A – Chenilles légionnaires au Kenya

1. La loi de Poisson modélise le nombre d'événements *rare*s, indépendants, survenant à un taux moyen constant dans une unité de temps ou d'espace (ici, un plant). Son paramètre est le nombre moyen d'événements : $E(X) = V(X) = \lambda = \mathbf{1,5}$.

2. Plant indemne : $P(X = 0) = e^{-1,5} \approx \mathbf{0,223}$.

3. On passe par le contraire. Avec $P(X = 1) = 1,5 e^{-1,5} \approx 0,335$ et $P(X = 2) = \frac{1,5^2}{2} e^{-1,5} \approx 0,251$:

$$P(X \geq 3) = 1 - (P(X = 0) + P(X = 1) + P(X = 2)) \approx 1 - (0,223 + 0,335 + 0,251) = \mathbf{0,191}.$$

Environ un plant sur cinq atteint le seuil d'intervention.

4. Une somme de lois de Poisson indépendantes est une loi de Poisson dont le paramètre est la somme des paramètres : $Y \sim \mathcal{P}(4 \times 1,5) = \mathcal{P}(6)$.

$$P(Y \leq 2) = e^{-6} \left(1 + 6 + \frac{6^2}{2} \right) = 25 e^{-6} \approx \mathbf{0,062}.$$

Partie B – Mortalité des poussins en Côte d'Ivoire

5. Chaque poussin est une épreuve à deux issues (mort ou non), avec la même probabilité 0,02, indépendamment des autres ; Z compte les décès : $Z \sim \mathcal{B}(150; 0,02)$.

6. Schéma des approximations : $n = 150 \geq 30$ et $p = 0,02 \leq 0,1$. On approche donc $\mathcal{B}(150; 0,02)$ par $\mathcal{P}(\lambda)$ avec $\lambda = np = \mathbf{3}$.

7. Avec la loi $\mathcal{P}(3)$:

$$P(Z \leq 2) \approx e^{-3} \left(1 + 3 + \frac{3^2}{2} \right) = 8,5 e^{-3} \approx \mathbf{0,423}.$$

La valeur exacte est 0,421 : l'erreur est d'environ 0,002, négligeable. L'approximation évite le calcul de coefficients comme $\binom{150}{2}$ et de puissances comme $0,98^{148}$.

À retenir. Poisson : $E = V = \lambda$; « au moins k » se calcule par le contraire ; les paramètres de lois de Poisson indépendantes s'additionnent ; $\mathcal{B}(n, p) \approx \mathcal{P}(np)$ si $n \geq 30$ et $p \leq 0,1$.

Correction de l'exercice 10 ▲

Fiche mémo : § 1.5, encadré « Loi normale : tout ramener à $\mathcal{N}(0,1)$ » et sa figure.

1. Dans $\mathcal{N}(12; 2,5^2)$, le second paramètre est la variance : $E(X) = \mu = 12$ kg et $\sigma(X) = 2,5$ kg. La variable centrée réduite $Z = \frac{X - 12}{2,5}$ suit $\mathcal{N}(0,1)$.
2. On centre et on réduit, puis on utilise la symétrie $\Phi(-z) = 1 - \Phi(z)$:

$$P(X < 10) = P\left(Z < \frac{10 - 12}{2,5}\right) = \Phi(-0,8) = 1 - \Phi(0,8) = 1 - 0,7881 = \mathbf{0,2119}.$$

Environ un régime sur cinq pèse moins de 10 kg.

3. On centre et on réduit les deux bornes :

$$P(10 < X < 15) = P\left(\frac{10 - 12}{2,5} < Z < \frac{15 - 12}{2,5}\right) = \Phi(1,2) - \Phi(-0,8) = 0,8849 - 0,2119 = \mathbf{0,6730}.$$

4. D'après les repères de la fiche, environ 95 % des valeurs sont dans $[\mu - 2\sigma; \mu + 2\sigma] = [12 - 5; 12 + 5] = [7; 17]$ kg.
5. Les 10 % les plus lourds sont au-dessus du seuil x cherché : $P(X > x) = 0,10$, soit $P(X \leq x) = 0,90$.

$$\frac{x - 12}{2,5} = z_{0,90} = 1,2816 \iff x = 12 + 1,2816 \times 2,5 \approx \mathbf{15,2 \text{ kg}}.$$

Un régime est classé « premium » s'il pèse plus de 15,2 kg environ.

6. Cette fois l'inconnue est σ . On écrit $P(X < 8) = 0,05$ et on centre-réduit :

$$\frac{8 - 12}{\sigma} = z_{0,05} = -z_{0,95} = -1,645 \iff \sigma = \frac{4}{1,645} \approx \mathbf{2,43 \text{ kg}}.$$

(Par symétrie de la courbe, le quantile d'ordre 0,05 est l'opposé de celui d'ordre 0,95.)

À retenir. Toute question sur une loi normale se ramène à $\mathcal{N}(0,1)$ par $Z = (X - \mu)/\sigma$. Pour un seuil : $x = \mu + z_q \sigma$; si l'inconnue est μ ou σ , on écrit la même égalité et on la résout.

Correction de l'exercice 11 ▲

Fiche mémo : § 1.5, tableau des lois continues (ligne « Exponentielle ») et propriété « sans mémoire » ; § 1.6 (TCL) et § 2.2 (moyenne empirique) pour la question 5.

1. Pour une loi exponentielle, $E(T) = \frac{1}{\lambda}$. Ici $E(T) = 400$ h, donc $\lambda = \frac{1}{400} = \mathbf{0,0025}$ panne par heure. De plus $\sigma(T) = \frac{1}{\lambda} = \mathbf{400}$ h : l'écart-type est égal à la moyenne.
2. $P(T > t) = e^{-\lambda t}$, donc

$$P(T > 600) = e^{-600/400} = e^{-1,5} \approx \mathbf{0,223}.$$

Un peu plus d'une motopompe sur cinq dépasse 600 h sans panne.

3. $P(T \leq m) = 0,5 \iff e^{-\lambda m} = 0,5 \iff m = \frac{\ln 2}{\lambda} = 400 \ln 2 \approx \mathbf{277 \text{ h}}.$

La médiane est nettement inférieure à la moyenne : la moitié des motopompes tombent en panne avant 277 h, mais quelques machines très durables tirent la moyenne vers le haut (loi étalée vers la droite).

4. L'événement « $T > 500$ » est inclus dans « $T > 300$ », donc $P(T > 500 \cap T > 300) = P(T > 500)$:

$$P(T > 500 | T > 300) = \frac{P(T > 500)}{P(T > 300)} = \frac{e^{-500/400}}{e^{-300/400}} = e^{-200/400} = e^{-0,5} \approx \mathbf{0,607} = P(T > 200).$$

C'est la propriété « **sans mémoire** » : la probabilité de fonctionner encore 200 h ne dépend pas des heures déjà effectuées, comme si la machine ne vieillissait pas. (Hypothèse discutable pour une machine soumise à l'usure.)

5. (a) $\bar{T}$ est la moyenne de 50 durées indépendantes de même loi :

$$E(\bar{T}) = \mu = \mathbf{400 \text{ h}}, \quad \sigma(\bar{T}) = \frac{\sigma}{\sqrt{n}} = \frac{400}{\sqrt{50}} \approx \mathbf{56,6 \text{ h}}.$$

- (b) La loi exponentielle n'est pas normale, mais $n = 50 \geq 30$: d'après le TCL, $\bar{T} \approx \mathcal{N}(400; 56,6^2)$.

$$P(\bar{T} < 350) \approx \Phi\left(\frac{350 - 400}{56,6}\right) = \Phi(-0,88) = 1 - 0,8106 \approx \mathbf{0,19}.$$

À retenir. Exponentielle : $E(T) = \sigma(T) = 1/\lambda$ et $P(T > t) = e^{-\lambda t}$. Pour la *moyenne* de $n \geq 30$ durées, le TCL permet d'utiliser la loi normale même si chaque durée ne l'est pas.

Correction de l'exercice 12 ▲

Fiche mémo : § 2.1 « Plans d'échantillonnage et biais » (définitions, tableau des plans, figure des cibles).

- Population** : les 2 000 exploitations cotonnières de la commune. **Unité statistique** : une exploitation cotonnière. **Échantillon** : les 150 exploitations enquêtées. **Base de sondage** : la liste des membres de l'union communale, dans laquelle on tire l'échantillon.
- La base de sondage ne couvre pas toute la population : les non-membres (15%) n'ont aucune chance d'être tirés. On étudie en réalité les membres de l'union, qui ont sans doute des pratiques différentes (accès aux intrants à crédit, conseil technique...). C'est un **biais de couverture** (biais de sélection).
Enquêter 1 000 exploitations ne règle rien : l'estimation serait plus *précise* mais toujours *décalée*. Comme sur la figure des cibles, augmenter n resserre les points sans les ramener vers le centre. Il faut compléter la base de sondage (listes villageoises, par exemple).
- Un recensement de 2 000 exploitations serait **trop coûteux et trop long** (enquêtes, déplacements). De plus, un sondage permet une **collecte plus soignée** (enquêtes mieux formés et contrôlés) et une précision chiffrable, suffisante pour les besoins de l'ONG.
- Allocation proportionnelle : $n_h = n \frac{N_h}{N} = 150 \times \frac{N_h}{2\,000}$.

$$n_{\text{plateau}} = 150 \times \frac{1\,200}{2\,000} = \mathbf{90}, \quad n_{\text{bas-fond}} = 150 \times \frac{600}{2\,000} = \mathbf{45}, \quad n_{\text{berge}} = 150 \times \frac{200}{2\,000} = \mathbf{15}.$$

Contrôle : $90 + 45 + 15 = 150$. *Intérêt* : chaque zone est représentée selon son poids, y compris la petite zone de berge, qu'un tirage aléatoire simple pourrait sous-représenter. Si les pratiques sont homogènes à l'intérieur d'une zone et différentes d'une zone à l'autre, l'estimation gagne en précision.

- (a) Pas de sondage : $k = \frac{N}{n} = \frac{2\,000}{150} \approx 13,3$, arrondi à $k = \mathbf{13}$. (Avec ce pas, on parcourt la liste jusqu'au bout en obtenant 154 exploitations; on peut s'arrêter à 150.)
(b) Les rangs sont $d, d + k, d + 2k, d + 3k$ avec $d = 7$: **7, 20, 33, 46**.
(c) La liste a une structure périodique : un président tous les 20 rangs. Si le pas était 20 (ou un multiple de 20), on tomberait toujours sur des présidents, ou jamais : l'échantillon serait biaisé (les présidents ne sont pas des producteurs ordinaires). Ici le pas 13 n'est pas lié à 20 et le risque est faible, mais il faut toujours vérifier que l'ordre de la liste ne suit pas un cycle lié au pas.

6. On tire d'abord des villages, puis des exploitations dans chaque village : c'est un **échantillonnage à deux degrés** (ligne « Grappes / degrés » du tableau). Avantage : seulement 10 villages à visiter, d'où un coût logistique très réduit, et pas besoin de la liste complète des exploitations. Inconvénient : les exploitations d'un même village se ressemblent (mêmes sols, mêmes marchés, même encadrement) et apportent moins d'information que 150 exploitations dispersées : c'est l'**effet de grappe**, qui réduit la précision.

À retenir. Un défaut de la base de sondage crée un biais, qu'aucune augmentation de n ne corrige. La stratification gagne en précision, les grappes gagnent en coût.

Correction de l'exercice 13 ▲

Fiche mémo : § 2.1 (définitions, tableau des plans, figure des cibles) ; § 2.2, encadré « Moyenne empirique » (facteur d'exhaustivité) ; § 1.6 (TCL).

1. **Unité statistique** : l'éleveur (ou son exploitation). **Population** : tous les éleveurs de zébus du Menabe. **Base de sondage** : le registre communal des services vétérinaires.

Les éleveurs absents du registre ne peuvent jamais être tirés : c'est un **bias de couverture** (biais de sélection), une erreur systématique. Interroger plus d'éleveurs **ne la corrige pas** : on obtiendrait une estimation plus précise des éleveurs *déclarés* seulement. Il faut compléter la base (listes établies avec les chefs de fokontany, par exemple).

2. Allocation proportionnelle : $n_h = n \frac{N_h}{N} = 400 \times \frac{N_h}{2\,500}$, soit **240** petits, **120** moyens et **40** grands éleveurs.
Contrôle : $240 + 120 + 40 = 400$.

3. Les pratiques et la taille des troupeaux diffèrent beaucoup d'une strate à l'autre mais sont assez homogènes à l'intérieur de chacune : la stratification rend l'estimation **plus précise**. Elle garantit aussi que les grands éleveurs, peu nombreux (10 %) mais importants pour l'élevage de la région, soient bien représentés ; un tirage aléatoire simple pourrait, par hasard, en contenir très peu.

4. $E(\bar{X}) = \mu = 80$ têtes. Dans la strate des grands éleveurs, le taux de sondage vaut $n/N = 40/250 = 16\% > 10\%$: on interroge une part importante de la strate, et le tirage sans remise réduit nettement la variabilité. On applique le facteur d'exhaustivité :

$$\sigma(\bar{X}) = \frac{\sigma}{\sqrt{n}} \sqrt{\frac{N-n}{N-1}} = \frac{30}{\sqrt{40}} \sqrt{\frac{210}{249}} \approx 4,743 \times 0,918 \approx \mathbf{4,36} \text{ têtes.}$$

5. $n = 40 \geq 30$: d'après le TCL, $\bar{X} \approx \mathcal{N}(80; 4,36^2)$, même si la taille des troupeaux ne suit pas une loi normale. « S'écarter de μ de plus de 8 têtes » se traduit par $|\bar{X} - 80| > 8$, ce qui fait deux queues symétriques :

$$P(|\bar{X} - 80| > 8) = P\left(|Z| > \frac{8}{4,36}\right) \approx P(|Z| > 1,84) = 2(1 - \Phi(1,84)) = 2(1 - 0,9671) \approx \mathbf{0,066}.$$

Sans le facteur d'exhaustivité, on aurait trouvé $P(|Z| > 1,69) \approx 0,091$: on aurait surestimé le risque d'erreur.

6. On tire des villages entiers et on interroge tous leurs éleveurs : c'est un **sondage par grappes** (les grappes sont les fokontany). Avantage : beaucoup moins cher et plus simple (déplacements limités, il suffit de la liste des fokontany). Inconvénient : les éleveurs d'un même village se ressemblent (mêmes pâturages, mêmes pratiques), d'où une **précision plus faible** à effectif égal (effet de grappe).

À retenir. Le facteur d'exhaustivité se calcule avec le taux de sondage *de la population concernée* (ici la strate) ; il est nécessaire au-delà de 10 %.

Correction de l'exercice 14 ▲

Fiche mémo : § 2.1, définitions de l'erreur d'échantillonnage et du biais, figure des cibles.

Pour chaque situation, on se demande : l'écart changerait-il de sens au hasard d'un échantillon à l'autre (*fluctuation*), ou irait-il toujours dans le même sens (*biais*) ? Et pour un biais : vient-il de qui est tiré, de qui répond, ou de la façon de mesurer ?

1. **Biais de sélection (couverture).** Les parcelles proches de la route (meilleur accès aux intrants, au marché, à l'eau) ne représentent pas les autres : le rendement est sans doute surestimé. Augmenter n ne change rien, puisque toutes les parcelles visitées restent au bord de la route.

Amélioration : tirer les parcelles au hasard sur toute la zone (carte, image satellite, liste cadastrale), éventuellement en stratifiant selon la distance à la route.

2. **Biais de mesure (de déclaration).** La valeur relevée est systématiquement inférieure à la vraie valeur. Augmenter n ne corrige pas ce décalage.

Amélioration : garantir l'anonymat, mesurer directement (stocks, factures), recouper avec les ventes des distributeurs.

3. **Erreur d'échantillonnage.** Les deux tirages sont aléatoires et faits sur une liste complète : deux échantillons différents donnent naturellement deux moyennes différentes. Cet écart est aléatoire et diminue quand n augmente (erreur-type $\sigma/\sqrt{n}$).

Amélioration : augmenter n , ou stratifier pour gagner en précision.

4. **Biais de non-réponse.** Les répondants (plus jeunes, plus connectés) adoptent probablement davantage le service que les non-répondants. 800 réponses ne règlent pas le problème : un grand échantillon biaisé reste biaisé.

Amélioration : relances, enquête en face à face auprès d'un sous-échantillon de non-répondants, redressement selon l'âge.

5. **Biais de mesure (erreur instrumentale).** Chaque pesée est surestimée de 2 kg, quel que soit n .

Amélioration : tarer et étalonner la balance, ou retrancher 2 kg à chaque pesée.

6. **Biais de sélection.** Les éleveurs présents au marché du chef-lieu (plus intégrés, plus proches des services vétérinaires) ont sans doute un meilleur taux de vaccination ; les éleveurs transhumants ou isolés sont oubliés. La couverture vaccinale est surestimée.

Amélioration : tirer au hasard des villages ou des campements, puis des éleveurs dans chacun (échantillonnage à plusieurs degrés).

À retenir. Seule la situation 3 relève de la fluctuation : c'est la seule où l'échantillon est tiré au hasard dans une base complète, et mesuré correctement. Un biais ne disparaît jamais en augmentant n .

Correction de l'exercice 15 ▲

Fiche mémo : § 2.2, encadré « Moyenne empirique » et figure des courbes en cloche.

1. D'après l'encadré :

$$E(\bar{X}_n) = \mu = 30 \text{ g}, \quad V(\bar{X}_n) = \frac{\sigma^2}{n} = \frac{16}{n} \text{ g}^2.$$

$E(\bar{X}_n) = \mu$ signifie que la moyenne empirique est **sans biais** : en moyenne sur tous les échantillons possibles, elle tombe juste sur μ ; elle ne se trompe pas systématiquement dans un sens.

2. L'**erreur-type** est l'écart-type de $\bar{X}_n$, $\sigma(\bar{X}_n) = \sigma/\sqrt{n}$: elle mesure de combien la moyenne d'un échantillon s'écarte typiquement de μ , c'est-à-dire sa précision.

$$n = 16 : \frac{4}{4} = 1 \text{ g}, \quad n = 64 : \frac{4}{8} = 0,5 \text{ g}, \quad n = 256 : \frac{4}{16} = 0,25 \text{ g}.$$

À chaque fois que n est multiplié par 4, l'erreur-type est divisée par 2.

3. L'erreur-type varie en $1/\sqrt{n}$: pour la diviser par c , il faut multiplier $\sqrt{n}$ par c , donc n par c^2 . Diviser l'erreur-type par 2 demande 4 fois plus de lots ; la diviser par 10 en demande 100 fois plus. Les gains de précision deviennent très coûteux : au-delà d'un certain point, chaque lot supplémentaire n'améliore presque plus la précision.
4. (a) Taux de sondage : $n/N = 50/200 = 25\% > 10\%$. On mesure un quart du verger : la correction pour population finie est **nécessaire**.
- (b) Sans correction : $\frac{4}{\sqrt{50}} \approx 0,566$ g. Le facteur d'exhaustivité vaut $\frac{N-n}{N-1} = \frac{150}{199} \approx 0,754$, et l'on en prend la racine :

$$\sigma(\bar{X}_n) = \frac{4}{\sqrt{50}} \sqrt{0,754} \approx 0,566 \times 0,868 \approx 0,491 \text{ g.}$$

La correction réduit l'erreur-type d'environ 13 % : en mesurant une grande part de la population, on laisse moins de place au hasard (à la limite, pour $n = N$, l'erreur-type est nulle).

À retenir. $\bar{X}_n$ vise juste en moyenne ($E = \mu$) et sa précision s'améliore en $1/\sqrt{n}$. Au-delà de 10 % de la population, on multiplie l'erreur-type par $\sqrt{(N-n)/(N-1)}$.

Correction de l'exercice 16 ▲

Fiche mémo : § 2.2, encadré « Variance empirique et variance corrigée ».

1. $\bar{x} = \frac{2,4 + 2,8 + 3,4 + 2,5 + 3,0 + 2,7}{6} = \frac{16,8}{6} = 2,8$ t/ha.
2. On organise le calcul dans un tableau :

x_i	2,4	2,8	3,4	2,5	3,0	2,7	Somme
$x_i - \bar{x}$	-0,4	0	0,6	-0,3	0,2	-0,1	0
$(x_i - \bar{x})^2$	0,16	0	0,36	0,09	0,04	0,01	SCE = 0,66

Contrôle : la somme des écarts est nulle. On en déduit

$$s_n^2 = \frac{SCE}{n} = \frac{0,66}{6} = 0,110, \quad s_n'^2 = \frac{SCE}{n-1} = \frac{0,66}{5} = 0,132, \quad s'_n = \sqrt{0,132} \approx 0,363 \text{ t/ha.}$$

3. D'après l'encadré :

$$E(S_n^2) = \frac{n-1}{n} \sigma^2 = \frac{5}{6} \times 0,15 = 0,125, \quad E(S_n'^2) = \sigma^2 = 0,15.$$

Seule la variance corrigée $S_n'^2$ est **sans biais** : son espérance vaut exactement σ^2 . La variance empirique S_n^2 sous-estime σ^2 en moyenne de 0,025, soit σ^2/n .

4. Les écarts sont mesurés autour de la moyenne empirique $\bar{X}_n$, calculée sur les mêmes données, et non autour de la vraie moyenne μ . Or $\bar{X}_n$ est, par construction, la valeur la plus proche de l'ensemble des données (celle qui rend la somme des carrés des écarts la plus petite) : les données sont « au plus près » de leur propre moyenne, et la dispersion observée est trop petite. Diviser par $n-1$ au lieu de n compense exactement ce défaut.
5. $S_n'^2 = \frac{n}{n-1} S_n^2$, et le rapport $\frac{n}{n-1}$ tend vers 1 quand n grandit. Pour $n = 6$, il vaut 1,2 (écart de 20 %) ; pour $n = 100$, $\frac{100}{99} \approx 1,01$ (écart de 1 %). La correction compte surtout pour les **petits échantillons**.

À retenir. Pour estimer σ^2 , on divise la somme des carrés des écarts par $n-1$: c'est l'estimateur sans biais. La différence avec la division par n est importante pour les petits échantillons.

Correction de l'exercice 17 ▲

Fiche mémo : § 2.2, encadré « Moyenne empirique » et figure des courbes ; § 1.5, encadré « Loi normale » ; § 2.3, encadré « Taille d'échantillon ».

1. La loi mère est normale et les parcelles sont indépendantes, donc la moyenne est *exactement* normale, quel que soit n (pas besoin du TCL, et $n = 9 < 30$ ne pose donc aucun problème) :

$$\bar{X} \sim \mathcal{N}\left(2,4; \frac{0,6^2}{9}\right), \quad \sigma(\bar{X}) = \frac{0,6}{\sqrt{9}} = 0,2 \text{ t/ha.}$$

2. On centre et on réduit avec l'écart-type de $\bar{X}$ (et non celui d'une parcelle) :

$$P(\bar{X} > 2,7) = P\left(Z > \frac{2,7 - 2,4}{0,2}\right) = P(Z > 1,5) = 1 - \Phi(1,5) = 1 - 0,9332 = 0,0668.$$

3. Pour une seule parcelle, on utilise $\sigma = 0,6$:

$$P(X > 2,7) = P\left(Z > \frac{2,7 - 2,4}{0,6}\right) = 1 - \Phi(0,5) = 1 - 0,6915 = 0,3085.$$

Une parcelle isolée dépasse 2,7 t/ha environ une fois sur trois, mais la *moyenne* de 9 parcelles seulement une fois sur quinze. La moyenne fluctue beaucoup moins que les valeurs individuelles : son écart-type est divisé par $\sqrt{9} = 3$.

4. Intervalle de fluctuation à 95 % :

$$\mu \pm 1,96 \frac{\sigma}{\sqrt{n}} = 2,4 \pm 1,96 \times 0,2 = 2,4 \pm 0,392, \quad \text{soit } [2,01 ; 2,79] \text{ t/ha.}$$

5. $\bar{x} = 1,9$ t/ha est **en dehors** de l'intervalle de fluctuation : si les parcelles venaient d'une population de moyenne 2,4 t/ha, un tel résultat n'arriverait que dans moins de 5 % des échantillons. Ce n'est donc probablement pas une simple malchance. On peut suspecter que les parcelles du projet ne sont pas représentatives (biais de sélection : parcelles plus pauvres, zone plus sèche), ou que la moyenne régionale n'est plus valable cette année.

6. On veut que la marge soit au plus 0,1 t/ha :

$$1,96 \times \frac{0,6}{\sqrt{n}} \leq 0,1 \iff n \geq \left(\frac{1,96 \times 0,6}{0,1}\right)^2 = 11,76^2 \approx 138,3.$$

Il faut au moins **139** parcelles (on arrondit toujours au-dessus).

À retenir. Pour la moyenne, on utilise l'écart-type $\sigma/\sqrt{n}$, pas σ . Une valeur observée hors de l'intervalle de fluctuation fait douter de l'hypothèse de départ (ou de la représentativité de l'échantillon).

Correction de l'exercice 18 ▲

Fiche mémo : § 2.2, encadré « Moyenne empirique » ; § 2.3, encadrés « Fréquence » et « Taille d'échantillon » ; § 2.1 (deux grandes familles de plans).

1. (a) $\sigma(\bar{X}) = \frac{\sigma}{\sqrt{n}} = \frac{600}{\sqrt{76}} \approx 68,8$ kg/ha. Le rendement étant normal, $\bar{X} \sim \mathcal{N}(4800; 68,8^2)$ exactement.

- (b) On centre et on réduit avec $\sigma(\bar{X})$:

$$P(\bar{X} < 4600) = \Phi\left(\frac{4600 - 4800}{68,8}\right) = \Phi(-2,91) = 1 - \Phi(2,91) \approx 0,0018.$$

Une moyenne d'échantillon aussi basse est presque impossible si la moyenne de la vallée vaut bien 4800 kg/ha.

(c) L'intervalle est symétrique autour de μ :

$$P(4700 < \bar{X} < 4900) = P(-1,45 < Z < 1,45) = 2\Phi(1,45) - 1 \approx 2 \times 0,9265 - 1 = \mathbf{0,853}.$$

2. L'intervalle $[4750; 4850]$ est centré sur μ avec une marge $e = 50$ kg/ha. On veut $P(|\bar{X} - 4800| \leq 50) = 0,95$, c'est-à-dire $1,96 \frac{600}{\sqrt{n}} \leq 50$:

$$n \geq \left(\frac{1,96 \times 600}{50} \right)^2 = 23,52^2 \approx 553,2, \text{ soit } n = \mathbf{554} \text{ exploitations.}$$

3. La fréquence F d'exploitations utilisant des engrais vérifie $np = 49,4 \geq 5$ et $n(1-p) = 26,6 \geq 5$: $F \approx \mathcal{N}(0,65; 0,0547^2)$, car $\sigma(F) = \sqrt{\frac{0,65 \times 0,35}{76}} \approx 0,0547$.

$$P(F > 0,75) \approx 1 - \Phi\left(\frac{0,75 - 0,65}{0,0547}\right) = 1 - \Phi(1,83) \approx 1 - 0,9664 = \mathbf{0,034}.$$

4. Les deux grandes familles sont les plans **probabilistes** (chaque unité a une probabilité connue et non nulle d'être tirée : aléatoire simple, systématique, stratifié, grappes) et les plans **non probabilistes** (quotas, choix raisonné).

Pour les **périmètres irrigués**, bien délimités et répertoriés : un plan **stratifié** par périmètre (ou par taille d'exploitation), ou un tirage systématique sur la liste des attributaires. Pour les **villages dispersés** de la vallée : un plan **par grappes** ou **à deux degrés** (tirage de villages, puis d'exploitations dans chaque village), qui limite les déplacements.

À retenir. Même démarche pour une moyenne et pour une fréquence : identifier la loi (exacte ou approchée), son espérance et son écart-type, puis centrer et réduire.

Correction de l'exercice 19 ▲

Fiche mémo : § 1.6 « Théorème central limite » ; § 2.2, encadré « Moyenne empirique ».

Partie A – Revenus agricoles au Burkina Faso

- Non.** La distribution des revenus individuels est très asymétrique (quelques ménages ont des revenus très élevés) : elle n'est pas normale. Pour *un* ménage, on ne peut pas utiliser la loi normale, et l'on ne dispose pas de la vraie loi.
- TCL** : si $X_1, \dots, X_n$ sont indépendantes, de même loi, d'espérance μ et d'écart-type σ , alors, *quelle que soit cette loi*, la moyenne $\bar{X}_n$ suit approximativement $\mathcal{N}(\mu, \sigma^2/n)$ dès que n est assez grand ($n \geq 30$ en pratique).

Ici $n = 100$ ménages tirés au hasard :

$$\bar{X} \approx \mathcal{N}\left(350; \frac{200^2}{100}\right), \quad \sigma(\bar{X}) = \frac{200}{\sqrt{100}} = \mathbf{20} \text{ milliers de FCFA.}$$

3. On centre et on réduit avec $\sigma(\bar{X}) = 20$:

$$P(\bar{X} > 390) \approx P\left(Z > \frac{390 - 350}{20}\right) = 1 - \Phi(2) = 1 - 0,9772 = \mathbf{0,0228}.$$

Un revenu *moyen* supérieur à 390 est rare, alors qu'un ménage isolé dépasse souvent ce revenu.

4. L'intervalle est symétrique autour de μ :

$$P(330 < \bar{X} < 370) \approx P(-1 < Z < 1) = 2\Phi(1) - 1 = 2 \times 0,8413 - 1 = \mathbf{0,6826}.$$

Partie B – Chenilles sur le maïs au Kenya

5. Pour une loi de Poisson, $E(Y) = V(Y) = \lambda = 1,5$, donc $\sigma(Y) = \sqrt{1,5}$. Pour la moyenne de 60 plants :

$$E(\bar{Y}) = 1,5, \quad \sigma(\bar{Y}) = \frac{\sqrt{1,5}}{\sqrt{60}} = \sqrt{0,025} \approx 0,158.$$

6. $n = 60 \geq 30$: d'après le TCL, $\bar{Y} \approx \mathcal{N}(1,5; 0,158^2)$, bien que les comptages ne soient pas normaux.

$$P(\bar{Y} > 1,8) \approx P\left(Z > \frac{1,8 - 1,5}{0,158}\right) = 1 - \Phi(1,90) = 1 - 0,9713 \approx 0,029.$$

À retenir. Le TCL porte sur la *moyenne* (ou la somme) d'un grand nombre d'observations, jamais sur une observation isolée. Il marche quelle que soit la loi de départ.

Correction de l'exercice 20 ▲

Fiche mémo : § 2.3, encadré « Fréquence $F = K/n$ » et sa figure (qui reprend exactement cette situation).

1. $f = \frac{168}{200} = 0,84$.

2. On se place dans l'hypothèse où le semencier dit vrai : on utilise $p = 0,9$ (et non f).

$$E(F) = p = 0,9, \quad \sigma(F) = \sqrt{\frac{p(1-p)}{n}} = \sqrt{\frac{0,9 \times 0,1}{200}} = \sqrt{0,00045} \approx 0,0212.$$

3. Théorème de Moivre–Laplace : $np = 180 \geq 5$ et $n(1-p) = 20 \geq 5$. On peut donc approcher la loi de F par $\mathcal{N}(0,9; 0,0212^2)$.

4. Intervalle de fluctuation à 95 % :

$$p \pm 1,96 \sigma(F) = 0,9 \pm 1,96 \times 0,0212 = 0,9 \pm 0,042, \quad \text{soit } [0,858 ; 0,942].$$

Si l'annonce est vraie, la fréquence observée tombe dans cet intervalle 95 fois sur 100.

5. $f = 0,84$ est **en dehors** de l'intervalle de fluctuation : si le taux annoncé était exact, une fréquence aussi basse se produirait dans moins de 5 % des échantillons (en fait $P(F \leq 0,84) \approx \Phi(-2,83) \approx 0,002$). La coopérative peut **remettre en cause l'annonce** du semencier : réclamer un lot conforme, une baisse de prix ou augmenter la densité de semis. Le risque de se tromper (rejeter une annonce pourtant vraie) est de 5 % au plus.

6. La règle simplifiée $p \pm \frac{1}{\sqrt{n}}$ n'est valable que si $0,2 < p < 0,8$. Ici $p = 0,9$: la majoration $p(1-p) \leq 0,25$ est très grossière (0,09 en réalité). L'intervalle simplifié, $[0,829; 0,971]$, serait beaucoup trop large, et contiendrait 0,84 : il aurait conduit à accepter l'annonce à tort.

À retenir. Intervalle de fluctuation : on part de la valeur *annoncée* p ; si la fréquence observée en sort, on remet en cause l'annonce, avec un risque d'erreur de 5 %.

Correction de l'exercice 21 ▲

Fiche mémo : § 2.3, encadré « Taille d'échantillon » et exemple des chenilles légionnaires.

1. Aucune information sur p : on se place dans le cas le plus défavorable, $p = 0,5$, où $p(1-p)$ est maximal (0,25). Avec $e = 0,03$:

$$n \geq \frac{z^2}{4e^2} = \frac{1,96^2}{4 \times 0,03^2} = \frac{3,8416}{0,0036} \approx 1\,067,1, \quad \text{soit } n = 1\,068 \text{ exploitations.}$$

2. Avec $p \approx 0,2$:

$$n \geq \frac{1,96^2 \times 0,2 \times 0,8}{0,03^2} \approx 682,95, \text{ soit } n = \mathbf{683}.$$

La taille est plus faible car $p(1-p) = 0,16 < 0,25$: une proportion proche de 0,2 fluctue moins qu'une proportion proche de 0,5. Attention : si la vraie valeur de p est plus proche de 0,5, la précision visée ne sera pas tout à fait atteinte.

3. Même formule avec $e = 0,015$:

$$n \geq \frac{1,96^2}{4 \times 0,015^2} \approx 4\,268,4, \text{ soit } n = \mathbf{4\,269}.$$

Diviser la marge par 2 multiplie la taille par 4 (exactement comme sur la courbe de la marge dans la fiche) : la précision coûte cher.

4. Pour une moyenne, avec $e = 0,1$ t/ha :

$$n \geq \left(\frac{z\sigma}{e} \right)^2 = \left(\frac{1,96 \times 0,8}{0,1} \right)^2 = 15,68^2 \approx 245,9, \text{ soit } n = \mathbf{246} \text{ parcelles.}$$

5. Avec $z = 2,576$: $n \geq \left(\frac{2,576 \times 0,8}{0,1} \right)^2 \approx 424,7$, soit $n = \mathbf{425}$ parcelles. Plus de confiance exige plus de mesures.

6. $n_0 = 246$ représente 16 % des 1 500 exploitations, plus de 10 % : on corrige.

$$n = \frac{n_0}{1 + n_0/N} = \frac{246}{1 + 246/1\,500} = \frac{246}{1,164} \approx 211,3, \text{ soit } n = \mathbf{212} \text{ parcelles.}$$

Dans une petite population, on atteint la même précision avec moins de mesures.

À retenir. Toujours arrondir la taille à l'entier *supérieur*. Sans information sur p , prendre $p = 0,5$. Marge divisée par $c \Rightarrow$ taille multipliée par c^2 .

Correction de l'exercice 22 ▲

Fiche mémo : § 3.1 « Estimation ponctuelle » (définitions et tableau) ; § 2.2, encadré « Variance empirique et variance corrigée ».

- Population** : l'ensemble des cabosses mûres de la coopérative. **Paramètres** (inconnus, fixes) : le poids moyen μ , la variance σ^2 (ou l'écart-type σ) du poids, la proportion p de cabosses atteintes. **Estimateurs** : $\bar{X}_n$ pour μ , $S_n'^2$ (et S_n') pour σ^2 (et σ), $F = K/n$ pour p .
- Un **estimateur** est une *règle de calcul* appliquée à un échantillon aléatoire, par exemple $\bar{X}_n = \frac{1}{n} \sum X_i$: sa valeur change d'un échantillon à l'autre, c'est une **variable aléatoire**. Une **estimation** est le *nombre* obtenu en appliquant cette règle aux données observées, par exemple $\bar{x} = 540$ g : c'est un nombre fixe.
- $\sum x_i = 6\,480$, d'où $\hat{\mu} = \bar{x} = \frac{6\,480}{12} = \mathbf{540}$ g.
- Écarts à la moyenne : 0 ; -60 ; 70 ; 10 ; -45 ; -10 ; 35 ; -35 ; 20 ; 0 ; -25 ; 40 (leur somme est nulle). Somme des carrés :

$$SCE = 0 + 3\,600 + 4\,900 + 100 + 2\,025 + 100 + 1\,225 + 1\,225 + 400 + 0 + 625 + 1\,600 = 15\,800.$$

$$s_n'^2 = \frac{SCE}{n-1} = \frac{15\,800}{11} \approx \mathbf{1\,436} \text{ g}^2, \quad s_n' = \sqrt{1\,436,4} \approx \mathbf{37,9} \text{ g}.$$

On divise par $n-1 = 11$ car $S_n'^2$ est un estimateur **sans biais** de σ^2 . La variance empirique (division par n , ici $s_n^2 \approx 1\,317 \text{ g}^2$) sous-estime σ^2 en moyenne.

- $\hat{p} = f = \frac{3}{12} = \mathbf{0,25}$, soit 25 % de cabosses atteintes.

6. **Aucune erreur** : un autre échantillon donne une autre estimation, c'est la **fluctuation d'échantillonnage**. L'écart de 12 g entre les deux moyennes est d'ailleurs du même ordre que l'erreur-type $s'/\sqrt{n} \approx 37,9/\sqrt{12} \approx 10,9$ g. Ce qui manque à une estimation ponctuelle, c'est une mesure de sa **précision** : c'est le rôle de l'intervalle de confiance (§3.2).

À retenir. $\bar{x}$, s' (division par $n - 1$) et f sont les trois estimations de base. Une estimation ponctuelle seule ne dit rien de sa précision.

Correction de l'exercice 23 ▲

Fiche mémo : §3.1 « Estimation ponctuelle » ; §2.2, encadré « Variance empirique et variance corrigée ».

- $\sum x_i = 11,2$, donc $\hat{\mu} = \bar{x} = \frac{11,2}{10} = 1,12$ L/j.
- Écarts à la moyenne : 0,08 ; -0,22 ; 0,38 ; -0,02 ; -0,32 ; 0,18 ; -0,12 ; 0,28 ; -0,22 ; -0,02 (somme nulle), d'où $SCE = \sum (x_i - \bar{x})^2 = 0,476$.

$$s^2 = \frac{SCE}{n} = \frac{0,476}{10} = 0,0476, \quad s'^2 = \frac{SCE}{n-1} = \frac{0,476}{9} \approx 0,0529.$$

On estime σ^2 par s'^2 , **sans biais**. La variance empirique s^2 sous-estime σ^2 en moyenne, car les écarts sont calculés autour de $\bar{x}$, qui est « au milieu » des données, et non autour de la vraie moyenne μ . Avec $n = 10$, l'écart entre les deux est de 10 %.

- $\hat{\sigma} = s' = \sqrt{0,0529} \approx 0,230$ L/j. Six chèvres produisent *strictement* plus de 1 litre (1,2 ; 1,5 ; 1,1 ; 1,3 ; 1,4 ; 1,1 ; la valeur 1,0 n'est pas comptée), donc $\hat{p} = f = \frac{6}{10} = 0,6$.
- Non** : avec d'autres chèvres, il trouvera d'autres valeurs. L'**estimateur** est la règle de calcul (par exemple $\bar{X} = \frac{1}{n} \sum X_i$), une variable aléatoire qui varie d'un échantillon à l'autre ; l'**estimation** est le nombre obtenu sur un échantillon donné (1,12 L/j). La règle reste la même, le résultat change.
- Erreur-type estimée de la moyenne :

$$\frac{s'}{\sqrt{n}} = \frac{0,230}{\sqrt{10}} \approx 0,073 \text{ L/j.}$$

Elle mesure de combien $\bar{x}$ varie typiquement d'un échantillon de 10 chèvres à l'autre : c'est la précision de l'estimation de μ .

- Production journalière estimée : $120 \times \bar{x} = 120 \times 1,12 = 134,4$ litres. Chiffre d'affaires estimé : $134,4 \times 400 = 53\,760$ FCFA par jour.

Ce ne sont que des estimations ponctuelles : avec 10 chèvres seulement, leur précision est limitée, et seul un intervalle de confiance permettrait de la chiffrer.

À retenir. On estime σ par s' (division par $n - 1$) et la précision de $\bar{x}$ par l'erreur-type $s'/\sqrt{n}$.

Correction de l'exercice 24 ▲

Fiche mémo : §3.2 « Intervalles de confiance » (paragraphe « Interprétation », figure des dix intervalles, tableau des z , encadré « Les intervalles à connaître », ligne « Moyenne, σ connu ») ; §2.3 pour la taille.

- L'estimation ponctuelle de μ est la moyenne observée : $\hat{\mu} = \bar{x} = 78,6$ kg.
- La population est normale et σ est connu, donc

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0,1) \quad \text{exactement.}$$

C'est la **fonction pivot** : sa loi ne dépend pas du paramètre inconnu μ . De $P(-1,96 \leq Z \leq 1,96) = 0,95$, on isole μ pour obtenir l'intervalle.

3. Erreur-type : $\frac{\sigma}{\sqrt{n}} = \frac{6}{\sqrt{36}} = 1$ kg. Marge : $e = 1,96 \times 1 = 1,96$ kg.

$$IC_{95\%}(\mu) = [78,6 - 1,96 ; 78,6 + 1,96] = [76,64 ; 80,56] \text{ kg.}$$

4. Marge : $e = 2,576 \times 1 = 2,576$ kg.

$$IC_{99\%}(\mu) = [78,6 - 2,576 ; 78,6 + 2,576] \approx [76,02 ; 81,18] \text{ kg.}$$

L'intervalle à 99 % est plus large : pour être plus sûr de capturer μ , il faut accepter un encadrement moins précis.

5. **Non.** La valeur nominale 80 kg est dans l'intervalle à 95 % (et à 99 %) : les données sont compatibles avec un poids moyen de 80 kg, et l'écart observé (1,4 kg) peut s'expliquer par la fluctuation d'échantillonnage. L'acheteur ne peut pas conclure à une sous-pesée (sans pour autant prouver que le lot est conforme).

6. (a) **Incorrecte** au sens strict : une fois calculé, l'intervalle est fixe et μ aussi ; μ est dedans ou ne l'est pas, il n'y a plus de hasard.

(b) **Correcte** : c'est la bonne interprétation du niveau de confiance. C'est la *méthode* qui réussit 95 % du temps (figure des dix intervalles).

(c) **Incorrecte** : l'intervalle porte sur la *moyenne* μ , pas sur les sacs, dont les poids sont bien plus dispersés ($\sigma = 6$ kg).

7. On veut $e = 1,96 \frac{6}{\sqrt{n}} \leq 1,5$:

$$n \geq \left(\frac{1,96 \times 6}{1,5} \right)^2 = 7,84^2 \approx 61,5, \text{ soit } 62 \text{ sacs.}$$

À retenir. σ connu et population normale : $\bar{x} \pm z \sigma / \sqrt{n}$. L'intervalle porte sur la moyenne μ , et c'est la méthode qui a 95 % de chances de réussir, pas un intervalle déjà calculé.

Correction de l'exercice 25 ▲

Fiche mémo : § 3.2, encadré « Les intervalles à connaître » (lignes « σ connu » et « Student ») et tableau des z ; § 2.3, encadré « Taille d'échantillon ».

1. Le TB suit une loi normale, donc $\bar{X} \sim \mathcal{N}(\mu, \sigma^2/n)$ *exactement*, même pour $n = 16$. Comme σ est **connu**, $Z = \frac{\bar{X} - \mu}{\sigma / \sqrt{n}}$ suit exactement $\mathcal{N}(0, 1)$. La loi de Student ne sert que lorsqu'on remplace σ par son estimation s' , ce qui ajoute de l'incertitude ; ce n'est pas le cas ici.

2. Erreur-type : $\frac{0,5}{\sqrt{16}} = 0,125$ g/100 mL. Marge : $e = 1,96 \times 0,125 = 0,245$.

$$IC_{95\%}(\mu) = [3,8 - 0,245 ; 3,8 + 0,245] = [3,555 ; 4,045] \text{ g/100 mL.}$$

3. À 90 % ($z = 1,645$) : $e \approx 0,206$, d'où $IC_{90\%}(\mu) \approx [3,594 ; 4,006]$.

À 99 % ($z = 2,576$) : $e = 0,322$, d'où $IC_{99\%}(\mu) = [3,478 ; 4,122]$.

Plus le niveau de confiance est élevé, plus l'intervalle est **large** : on gagne en certitude ce que l'on perd en précision.

4. On peut affirmer que le seuil est atteint si 3,5 est *sous la borne inférieure* de l'intervalle. À 90 % et à 95 %, c'est le cas : le TB moyen atteint le seuil, la prime est justifiée. À 99 %, l'intervalle contient 3,5 (borne inférieure 3,478) : on ne peut plus l'affirmer.

La conclusion **dépend du niveau de confiance** : il doit être fixé *avant* l'analyse, par exemple dans le contrat entre la laiterie et les éleveurs.

5. On veut $e = 1,96 \frac{0,5}{\sqrt{n}} \leq 0,1$:

$$n \geq \left(\frac{1,96 \times 0,5}{0,1} \right)^2 = 9,8^2 = 96,04, \text{ soit } \mathbf{97} \text{ bidons.}$$

6. σ inconnu, petit échantillon, population normale : ligne « Student ». Erreur-type estimée $\frac{0,62}{\sqrt{16}} = 0,155$, marge $e = 2,131 \times 0,155 \approx 0,330$.

$$IC_{95\%}(\mu) \approx [3,470 ; 4,130] \text{ g/100 mL.}$$

Cet intervalle est nettement plus large (marge 0,330 au lieu de 0,245) et contient maintenant le seuil 3,5. Deux raisons : l'écart-type estimé sur ces 16 bidons (0,62) est plus grand que $\sigma = 0,5$, et le quantile de Student (2,131) est plus grand que 1,96 pour tenir compte de l'incertitude sur σ . Connaître σ grâce à un historique fiable fait gagner en précision.

À retenir. Le choix entre z et t ne dépend pas de la taille de l'échantillon mais de ce qu'on connaît : σ connu (et population normale) $\Rightarrow z$; σ estimé par s' sur un petit échantillon $\Rightarrow t$.

Correction de l'exercice 26 ▲

Fiche mémo : § 3.2, encadré « Les intervalles à connaître » (ligne « Moyenne, σ inconnu, $n \geq 30$ »), paragraphe « Interprétation » et règles de lecture ; § 1.6 (TCL).

1. σ est inconnu, mais $n = 64 \geq 30$: on le remplace par s' et on garde le quantile de la loi normale,

$$\bar{x} \pm z \frac{s'}{\sqrt{n}}.$$

Il n'est **pas nécessaire** de supposer les poids normaux : d'après le TCL, $\bar{X}$ suit approximativement une loi normale dès que $n \geq 30$, quelle que soit la loi des poids.

2. Erreur-type : $\frac{48}{\sqrt{64}} = 6$ kg. Marge : $e = 1,96 \times 6 = 11,76$ kg.

$$IC_{95\%}(\mu) = [312 - 11,76 ; 312 + 11,76] = [300,2 ; 323,8] \text{ kg.}$$

3. Marge : $e = 2,576 \times 6 \approx 15,46$ kg, d'où $IC_{99\%}(\mu) = [296,5 ; 327,5]$ kg. L'intervalle à 99 % est plus large : plus de confiance se paie par moins de précision.

4. **Non.** L'intervalle porte sur le poids *moyen* μ , pas sur les poids individuels, beaucoup plus dispersés ($s' = 48$ kg : de nombreux zébus pèsent moins de 300 kg ou plus de 324 kg). Interprétation correcte : la méthode utilisée produit, dans 95 % des échantillons possibles, un intervalle qui contient le vrai poids moyen ; on est donc confiant à 95 % que μ est compris entre 300,2 et 323,8 kg.

5. Le prix moyen vaut 1 500 μ : on multiplie les deux bornes par 1 500 (règle de la fiche).

$$IC_{95\%}(\text{prix moyen}) \approx [450\,360 ; 485\,640] \text{ FCFA.}$$

6. 330 kg est **en dehors** de l'intervalle à 95 % (et même de celui à 99 %) : ce chiffre n'est pas compatible avec les données actuelles. Le poids moyen des animaux vendus semble avoir baissé : pâturages dégradés, sécheresses, ou éleveurs qui vendent des animaux plus jeunes pour faire face à des besoins de trésorerie.

7. On veut $e = 1,96 \frac{48}{\sqrt{n}} \leq 5$:

$$n \geq \left(\frac{1,96 \times 48}{5} \right)^2 = 18,816^2 \approx 354,04, \text{ soit } \mathbf{355} \text{ zébus.}$$

À retenir. σ inconnu mais $n \geq 30$: $\bar{x} \pm z s' / \sqrt{n}$, sans hypothèse de normalité. Pour une grandeur proportionnelle à μ (prix, total), on multiplie les bornes.

Correction de l'exercice 27 ▲

Fiche mémo : § 3.2, encadré « Les intervalles à connaître » (ligne « Student »), figure Student / normale, puce sur la normalité et règles de lecture.

1. $\sum x_i = 8,80$, d'où $\bar{x} = 0,88$ t/ha. La somme des carrés des écarts vaut $SCE = 0,1808$, d'où

$$s'^2 = \frac{SCE}{n-1} = \frac{0,1808}{9} \approx 0,0201, \quad s' \approx 0,142 \text{ t/ha.}$$

(À la calculatrice : prendre l'écart-type *corrigé*, souvent noté s_x ou σ_{n-1} .)

2. σ est inconnu et estimé par s' sur un petit échantillon ($n = 10$) : cette estimation ajoute de l'incertitude, que la loi normale ignore. On utilise la loi de **Student** à $n - 1 = 9$ degrés de liberté, plus étalée que $\mathcal{N}(0, 1)$:

$$T = \frac{\bar{X} - \mu}{s'/\sqrt{n}} \sim t_9.$$

3. Erreur-type estimée : $\frac{0,142}{\sqrt{10}} \approx 0,0448$ t/ha. Marge : $2,262 \times 0,0448 \approx 0,101$ t/ha.

$$IC_{95\%}(\mu) = [0,88 - 0,101 ; 0,88 + 0,101] \approx [0,78 ; 0,98] \text{ t/ha.}$$

4. Avec 1,96 : marge $1,96 \times 0,0448 \approx 0,088$, soit $[0,79 ; 0,97]$. Cet intervalle est **trop étroit**, donc trop optimiste : il oublie l'incertitude due à l'estimation de σ , et son niveau de confiance réel est inférieur à 95 %.
5. 0,75 t/ha est **en dehors** de l'intervalle $[0,78 ; 0,98]$: au niveau 95 %, le rendement moyen des parcelles du projet semble **supérieur** à la moyenne régionale publiée. (Prudence : il peut aussi s'agir d'une année plus favorable que la précédente.)
6. Avec $n = 10$, le TCL ne s'applique pas : l'intervalle de Student suppose que les rendements suivent une **loi normale** (et que les parcelles sont tirées au hasard, indépendamment). On peut vérifier la normalité avec un histogramme ou une boîte à moustaches (symétrie, pas de valeur aberrante), une droite de Henry, ou un test de Shapiro-Wilk.

À retenir. Petit échantillon, σ inconnu, population normale : $\bar{x} \pm t_{n-1; 1-\alpha/2} s'/\sqrt{n}$. Utiliser 1,96 à la place de t donne un intervalle faussement précis.

Correction de l'exercice 28 ▲

Fiche mémo : § 3.2, encadré « Les intervalles à connaître » (ligne « Student »), puces sur la normalité et sur les grandeurs proportionnelles à μ .

1. $\sum x_i = 1204$, donc $\bar{x} = \frac{1204}{8} = 150,5$ g/j. Écarts : 1,5 ; -12,5 ; 14,5 ; -3,5 ; 20,5 ; -21,5 ; 7,5 ; -6,5 (somme nulle), d'où $SCE = 1362$.

$$s'^2 = \frac{1362}{7} \approx 194,57, \quad s' \approx 13,95 \text{ g/j.}$$

2. σ est inconnu et estimé par s' sur très peu de données ($n = 8$) : cette estimation ajoute de l'incertitude, que la loi de Student (plus étalée que la loi normale) prend en compte. Le TCL ne s'applique pas avec $n = 8$: c'est l'**hypothèse de normalité** des GMQ qui garantit que $T = \frac{\bar{X} - \mu}{s'/\sqrt{n}}$ suit une loi de Student à 7 degrés de liberté. On la vérifie avec un histogramme ou une boîte à moustaches (symétrie, pas de valeur aberrante), une droite de Henry ou un test de Shapiro-Wilk.

3. Erreur-type : $\frac{13,95}{\sqrt{8}} \approx 4,93$ g/j. Le quantile est d'ordre $1 - \alpha/2$: $t_{7; 0,975}$ à 95 %, $t_{7; 0,95}$ à 90 %.

$$IC_{95\%}(\mu) = 150,5 \pm 2,365 \times 4,93 = 150,5 \pm 11,66 = [138,8 ; 162,2] \text{ g/j,}$$

$$IC_{90\%}(\mu) = 150,5 \pm 1,895 \times 4,93 = 150,5 \pm 9,35 = [141,2 ; 159,8] \text{ g/j.}$$

- 165 g/j est **en dehors** de l'intervalle à 95 % : l'annonce n'est pas compatible avec les données. Elle paraît trop optimiste, au moins dans les conditions de ces élevages.
- Avec $1,96 : 150,5 \pm 1,96 \times 4,93 = 150,5 \pm 9,67$, soit $[140,8 ; 160,2]$. Cet intervalle est **trop étroit** : son niveau de confiance réel est inférieur à 95 %. L'étudiant croit son estimation plus précise qu'elle ne l'est.
- Sur 90 jours, le gain moyen vaut 90μ : on multiplie les bornes par 90, ce qui donne $[12\,495 ; 14\,595]$ g, soit environ $[12,5 ; 14,6]$ kg. À 2000 FCFA le kilogramme vif, le supplément de valeur moyen est compris entre 25 000 et 29 200 FCFA environ par bélière, avant déduction du coût de la ration.

À retenir. Avec Student, bien choisir le quantile : $n - 1$ degrés de liberté et ordre $1 - \alpha/2$. Les bornes d'un intervalle se transforment comme la grandeur elle-même (ici $\times 90$, puis $\times$ prix).

Correction de l'exercice 29 ▲

Fiche mémo : § 3.2, encadré « Les intervalles à connaître » (ligne « Proportion » et ses conditions), tableau des z , règles de lecture ; § 2.3, encadré « Taille d'échantillon ».

- $\hat{p} = f = \frac{60}{250} = 0,24$.
- Conditions de l'intervalle classique (de Wald) : $n = 250 \geq 30$, $nf = 60 \geq 5$ et $n(1 - f) = 190 \geq 5$. **Elles sont vérifiées.**
- Erreur-type estimée : $\sqrt{\frac{0,24 \times 0,76}{250}} \approx 0,0270$. Marge : $1,96 \times 0,0270 \approx 0,053$.
 $IC_{95\%}(p) \approx [0,24 - 0,053 ; 0,24 + 0,053] = [0,187 ; 0,293]$.
- Marge : $1,645 \times 0,0270 \approx 0,044$, d'où $IC_{90\%}(p) \approx [0,196 ; 0,284]$, plus étroit, puisque l'on exige moins de confiance.
- L'intervalle à 95 %, $[0,187 ; 0,293]$, **contient** 0,20 : on ne peut pas affirmer avec 95 % de confiance que la proportion dépasse 20 %, même si l'estimation ponctuelle (24 %) est au-dessus du seuil. La décision relève alors du principe de précaution, ou d'une enquête complémentaire pour gagner en précision.
- Avec $p \approx f = 0,24$ et $e = 0,03$:

$$n \geq \frac{1,96^2 \times 0,24 \times 0,76}{0,03^2} \approx 778,6, \text{ soit } 779 \text{ parcelles.}$$

- Avec $n = 20$ et $f = 0,10$: $nf = 2 < 5$ (et $n < 30$), les conditions **ne sont pas remplies** et l'approximation normale est mauvaise. L'intervalle classique serait $0,10 \pm 1,96\sqrt{0,10 \times 0,90/20} \approx 0,10 \pm 0,13$, avec une borne inférieure *négative*, absurde pour une proportion. Il faut un autre intervalle (de Wilson ou exact) ou un échantillon plus grand.

À retenir. Toujours vérifier $n \geq 30$, $nf \geq 5$, $n(1 - f) \geq 5$ avant d'utiliser $f \pm z\sqrt{f(1 - f)/n}$. Un seuil situé dans l'intervalle ne permet pas de conclure.

Correction de l'exercice 30 ▲

Fiche mémo : § 3.2, encadré « Les intervalles à connaître » (lignes « Proportion » et « Différence de deux proportions ») et règles de lecture ; § 2.3, encadré « Taille d'échantillon ».

- $\hat{p} = f = \frac{252}{400} = 0,63$.
- Conditions : $n = 400 \geq 30$, $nf = 252 \geq 5$, $n(1 - f) = 148 \geq 5$. Erreur-type estimée : $\sqrt{\frac{0,63 \times 0,37}{400}} \approx 0,0241$, marge $e = 1,96 \times 0,0241 \approx 0,047$.
 $IC_{95\%}(p) \approx [0,63 - 0,047 ; 0,63 + 0,047] = [0,583 ; 0,677]$.

3. 0,70 est **au-dessus** de la borne supérieure : avec 95 % de confiance, la couverture réelle est inférieure à 70 %. L'objectif **n'est pas atteint**.

4. On utilise $n \geq \frac{z^2 p(1-p)}{e^2}$ avec $e = 0,03$.

(a) Sans information, $p = 0,5$: $n \geq \frac{1,96^2}{4 \times 0,03^2} \approx 1067,1$, soit **1 068** ménages.

(b) Avec $p \approx 0,63$: $n \geq \frac{1,96^2 \times 0,63 \times 0,37}{0,03^2} \approx 994,97$, soit **995** ménages.

Le premier calcul se place dans le cas le plus défavorable : $p(1-p)$ est maximal pour $p = 0,5$ (0,25, contre 0,233 ici). La taille obtenue est toujours suffisante, mais un peu plus grande.

5. $f_2 = \frac{150}{300} = 0,50$, donc $f_1 - f_2 = 0,13$. Les deux enquêtes sont indépendantes : les variances s'additionnent sous la racine.

$$\sqrt{\frac{0,63 \times 0,37}{400} + \frac{0,50 \times 0,50}{300}} \approx \sqrt{0,000583 + 0,000833} \approx 0,0376, \quad e = 1,96 \times 0,0376 \approx 0,074.$$

$$IC_{95\%}(p_{\text{Kaolack}} - p_{\text{Kolda}}) \approx [0,13 - 0,074 ; 0,13 + 0,074] = [0,056 ; 0,204].$$

L'intervalle **ne contient pas** 0 et est entièrement positif : la couverture vaccinale est plus élevée à Kaolack qu'à Kolda, de 6 à 20 points environ.

À retenir. Pour une différence de proportions, on additionne les variances des deux fréquences ; si l'intervalle ne contient pas 0, la différence est établie.

Correction de l'exercice 31 ▲

Fiche mémo : § 3.2, encadré « Les intervalles à connaître » (lignes « Différence de deux proportions » et « Différence de moyennes appariées »), puce « Appariement » et figure des différences.

Partie A – Deux villages

1. $f_A = \frac{72}{180} = 0,40$, $f_B = \frac{45}{150} = 0,30$, d'où $f_A - f_B = 0,10$.

2. Les deux enquêtes sont indépendantes : les variances s'additionnent.

$$\sqrt{\frac{0,40 \times 0,60}{180} + \frac{0,30 \times 0,70}{150}} = \sqrt{0,001333 + 0,0014} \approx 0,0523, \quad e = 1,96 \times 0,0523 \approx 0,102,$$

$$IC_{95\%}(p_A - p_B) \approx [0,10 - 0,102 ; 0,10 + 0,102] = [-0,002 ; 0,202].$$

3. L'intervalle **contient** 0 (de justesse) : au niveau 95 %, on ne peut pas affirmer que les taux d'adoption diffèrent. L'écart observé de 10 points peut provenir de la fluctuation d'échantillonnage ; il faudrait des échantillons plus grands pour trancher.

Partie B – Parcelles appariées

4. Les deux variétés sont cultivées côte à côte sur la *même* exploitation : les deux mesures d'une même colonne partagent le même sol, le même climat, le même agriculteur. Les échantillons ne sont pas indépendants mais **appariés**. En travaillant sur les différences, on élimine la variabilité *entre* exploitations (ici très forte : de 2,4 à 3,8 t/ha), et l'on gagne beaucoup en précision.

5. Différences $d_i = a_i - l_i$: 0,5 ; 0,6 ; 0,1 ; 0,7 ; 0,5 ; 0,2 ; 0,6 ; 0,6.

$$\bar{d} = \frac{3,8}{8} = 0,475 \text{ t/ha}, \quad s'_D = \sqrt{\frac{\sum (d_i - \bar{d})^2}{n-1}} = \sqrt{\frac{0,315}{7}} \approx 0,212 \text{ t/ha}.$$

6. Intervalle de Student sur les différences, à $n - 1 = 7$ degrés de liberté : erreur-type $\frac{0,212}{\sqrt{8}} \approx 0,075$, marge $2,365 \times 0,075 \approx 0,177$.

$$IC_{95\%}(\mu_D) \approx [0,475 - 0,177 ; 0,475 + 0,177] = [0,30 ; 0,65] \text{ t/ha.}$$

7. L'intervalle **ne contient pas** 0 et est entièrement positif : au niveau 95 %, la variété améliorée apporte un gain de rendement moyen compris entre 0,3 et 0,65 t/ha environ. Il reste à vérifier que ce gain compense le surcoût éventuel des semences.

À retenir. Intervalle d'une différence : s'il contient 0, on ne peut pas conclure à une différence. Données appariées : on calcule les différences et on applique l'intervalle de Student à leur moyenne.

Correction de l'exercice 32 ▲

Fiche mémo : exercice de synthèse : § 2.1 (plans), § 2.2 (facteur d'exhaustivité), § 2.3 (taille d'échantillon), § 3.1 et § 3.2.

1. Ligne « Systématique » du tableau des plans. Le pas vaut $k = \frac{N}{n} = \frac{1200}{50} = 24$. On tire au hasard un numéro de départ d entre 1 et 24, puis on retient les productrices de rangs $d, d + 24, d + 48, \dots, d + 49 \times 24$.

Risque : si chaque village occupe un nombre régulier de lignes avec la présidente en tête, le pas peut tomber régulièrement sur les présidentes, ou les éviter toujours. Les présidentes ne sont pas typiques (plus d'accès au crédit, plus gros volumes) : l'échantillon serait **biaisé**. Il faut mélanger la liste, ou vérifier qu'elle n'a pas de structure périodique liée au pas.

2. Tableau du § 3.1 : $\hat{\mu} = \bar{x} = 42$ kg/mois, $\hat{\sigma} = s' = 15$ kg/mois et $\hat{p} = f = \frac{18}{50} = 0,36$.

3. σ inconnu mais $n = 50 \geq 30$: $\bar{x} \pm 1,96 \frac{s'}{\sqrt{n}}$, avec une marge $e = 1,96 \times \frac{15}{\sqrt{50}} \approx 1,96 \times 2,121 \approx 4,16$ kg.

$$IC_{95\%}(\mu) \approx [37,84 ; 46,16] \text{ kg/mois.}$$

Le taux de sondage vaut $50/1200 \approx 4\% < 10\%$: le facteur d'exhaustivité ($\sqrt{1150/1199} \approx 0,98$) est négligeable.

4. Revenu moyen = 1500μ : on multiplie les bornes par 1500.

$$IC_{95\%}(\text{revenu moyen}) \approx [56\,760 ; 69\,240] \text{ FCFA par mois.}$$

5. Total = 1200μ : estimation ponctuelle $1200 \times 42 = 50\,400$ kg par mois, et intervalle obtenu en multipliant les bornes par 1200 :

$$IC_{95\%}(\text{total}) \approx [45\,410 ; 55\,390] \text{ kg par mois.}$$

6. Conditions : $n = 50 \geq 30$, $nf = 18 \geq 5$, $n(1 - f) = 32 \geq 5$. Marge : $1,96 \sqrt{\frac{0,36 \times 0,64}{50}} \approx 1,96 \times 0,0679 \approx 0,133$.

$$IC_{95\%}(p) \approx [0,227 ; 0,493].$$

L'intervalle est **très large** : sa demi-largeur (0,133) représente plus d'un tiers de f . 50 productrices suffisent pour estimer la moyenne correctement, mais pas une proportion.

7. Sans information, $p = 0,5$ et $e = 0,05$:

$$n_0 \geq \frac{1,96^2}{4 \times 0,05^2} = 384,16, \text{ soit } n_0 = 385.$$

n_0 représente 32 % des 1200 productrices, bien plus de 10 % : on corrige pour la population finie.

$$n = \frac{n_0}{1 + n_0/N} = \frac{385}{1 + 385/1200} \approx 291,5, \text{ soit } 292 \text{ productrices.}$$

Comme on interroge une grande part de l'union, le tirage sans remise apporte un gain de précision appréciable.

À retenir. La démarche complète : un plan de sondage sans biais, des estimations ponctuelles, des intervalles de confiance (moyenne, proportion, grandeurs dérivées), puis le dimensionnement de la prochaine enquête.



Étudiant(e) (Nom, Prénom) :

Promotion, groupe :

Email :