Ecole supérieure d'agro-développement international
istom

TD : CAH avec R

Promotion 115

Table des matières

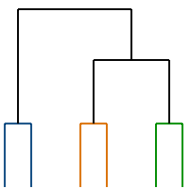
1 Synthèse : la classification ascendante hiérarchique **2**
1.1 Position du problème et vocabulaire . . . 2
1.2 Mesurer la dissimilarité entre individus . . . 2
1.3 L'algorithme général . . . 3
1.4 Les critères d'agrégation (*linkage*) . . . 3
1.5 La formule de récurrence de Lance–Williams . . . 5
1.6 Le dendrogramme : lecture et propriétés . . . 5
1.7 Le critère de Ward en détail . . . 6
1.8 Choisir le nombre de classes . . . 6

2 Faire une CAH sous R avec RStudio **7**
Exercice 1 : CAH sous R, guidée : typologie d'exploitations d'un bassin cotonnier . . . 7
Exercice 2 : CAH sous R, en autonomie : systèmes maraîchers péri-urbains . . . 9

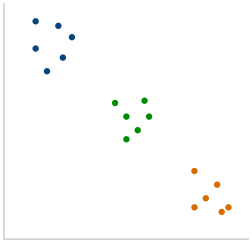
Corrections **11**

Ce TD comporte **deux exercices pour faire une CAH avec R sous RStudio** (section 2) : un premier très guidé, où le code est fourni, puis un second à mener en autonomie. Les jeux de données sont fournis dans les fichiers Excel `data_stat-0113.xlsx` et `data_stat-0114.xlsx`.

Ces exercices couvrent l'essentiel de ce qu'un étudiant d'une école d'ingénieurs comme l'ISTOM doit savoir maîtriser sur la classification ascendante hiérarchique **en pratique** : mener une CAH sur des questions agronomiques réalistes avec R, centrer-réduire les données, choisir et justifier le nombre de classes, lire le dendrogramme avec esprit critique, caractériser les classes et rédiger une synthèse. Le cadre théorique correspondant est rassemblé dans la synthèse qui précède les exercices.



Exercice 1 – sous R, guidé
typologie de 15 exploitations



Exercice 2 – sous R, en autonomie
typologie de 18 exploitations

1 Synthèse : la classification ascendante hiérarchique

La **classification** (en anglais *clustering*) cherche à organiser un ensemble d'individus en *classes* homogènes, sans qu'aucune étiquette ne soit donnée au départ : c'est une méthode d'*apprentissage non supervisé*. La **classification ascendante hiérarchique** (CAH ; en anglais *Hierarchical Agglomerative Clustering*, HAC) en est la famille la plus répandue. Plutôt qu'une partition unique, elle produit une *hiérarchie* de partitions emboîtées, résumée par un arbre, le **dendrogramme**, que l'on coupe à la hauteur voulue pour obtenir le nombre de classes souhaité.

Cette synthèse rassemble le cadre théorique. Les **travaux dirigés** qui suivent (page 7) en sont la mise en pratique sous R.

1.1 Position du problème et vocabulaire

On part d'un tableau de n **individus** décrits par p **variables** ($x_i \in \mathbb{R}^p$). Deux grandes familles de méthodes de classification coexistent :

- les méthodes de **partitionnement** (par ex. les k-means), qui cherchent directement une partition en un nombre k de classes *fixé à l'avance* ;
- les méthodes **hiérarchiques**, qui construisent un *emboîtement* de classes et ne fixent pas k a priori.

Les méthodes hiérarchiques se déclinent elles-mêmes en deux approches :

- **ascendante** (agglomérative) : on part des n individus isolés et on fusionne, de proche en proche, jusqu'à une classe unique ($n-1$ fusions) ;
- **descendante** (divisive, par ex. DIANA) : on part de la classe totale et on la scinde récursivement. Cette approche beaucoup moins utilisée que l'approche ascendante, seule traitée ici.

> **Idée directrice.** La CAH ne demande qu'une chose : savoir mesurer à quel point deux individus, puis deux *groupes* d'individus, se ressemblent. Tout le reste (l'arbre, les classes) en découle mécaniquement.

1.2 Mesurer la dissimilarité entre individus

La ressemblance entre deux individus se mesure par une **dissimilarité** $d(x_i, x_j) \geq 0$, symétrique, nulle lorsque $i = j$. Pour des variables quantitatives, on emploie le plus souvent une distance.

Distance	Définition entre x et y de $\mathbb{R}^p$
Euclidienne	$d_2(x,y) = \sqrt{\sum_{k=1}^{p} (x_k - y_k)^2}$
Manhattan	$d_1(x,y) = \sum_{k=1}^{p} \lvert x_k - y_k \rvert$
Minkowski ($m \geq 1$)	$d_m(x,y) = \left(\sum_{k=1}^{p} \lvert x_k - y_k \rvert^m \right)^{1/m}$
Mahalanobis	$d_\Sigma(x,y) = \sqrt{(x-y)^\top \Sigma^{-1} (x-y)}$
Cosinus	$d_{\cos}(x,y) = 1 - \dfrac{x \cdot y}{\lVert x \rVert \, \lVert y \rVert}$

Pour des variables qualitatives ou mixtes, on utilise des indices adaptés (distance de Hamming, dissimilarité de **Gower**, cette dernière accessible sous R par `daisy()` du package `cluster`).

À retenir : standardiser. La distance euclidienne additionne des écarts variable par variable : une variable à forte amplitude (une surface en hectares) écrase une variable à faible amplitude (un taux en %). On **centre et on réduit** donc chaque variable avant de classer, sauf si toutes sont déjà exprimées dans la même unité comparable.

Centrer et réduire : la méthode

Pour une variable X mesurée sur les n individus (valeurs $x_1, \dots, x_n$) :

1. calculer la moyenne $\overline{X} = \dfrac{1}{n}\sum_{i=1}^{n} x_i$;
2. calculer l'écart-type $\sigma_X = \sqrt{\dfrac{1}{n}\sum_{i=1}^{n}\left(x_i - \overline{X}\right)^2}$;
3. remplacer chaque valeur par sa version *centrée réduite*

$$z_i = \frac{x_i - \overline{X}}{\sigma_X}.$$

La nouvelle variable Z a alors une moyenne nulle et un écart-type égal à 1 ; elle est sans unité. On répète l'opération pour chacune des p variables, de sorte qu'elles pèsent toutes autant dans le calcul de la distance. (Sous R : la fonction `scale()`.)

1.3 L'algorithme général

Schéma de la CAH

Entrée : les n individus et une dissimilarité d.

1. **Initialisation.** Chaque individu forme sa propre classe ; on calcule la matrice des dissimilarités.
2. **Répéter** jusqu'à n'avoir qu'une classe : trouver les deux classes C_i et C_j les plus proches au sens d'un *critère d'agrégation* $D(C_i, C_j)$, les fusionner, enregistrer la fusion et sa hauteur, puis mettre à jour les dissimilarités entre la nouvelle classe et les autres.

Sortie : l'arbre des $n-1$ fusions (le dendrogramme).

Pourquoi « glouton » ? À chaque étape, la CAH fait le choix qui semble le meilleur *sur le moment* , réunir les deux classes les plus proches, sans jamais revenir en arrière : on dit qu'elle est **gloutonne**.

C'est simple et rapide, mais une fusion décidée tôt est *définitive*. Deux individus regroupés au début resteront dans la même classe jusqu'au bout, même si, au vu de l'ensemble des données, il aurait finalement mieux valu les séparer. La partition obtenue est donc une *bonne* solution construite pas à pas, pas nécessairement la meilleure possible.

1.4 Les critères d'agrégation (*linkage*)

Tout l'enjeu est de définir la distance $D(C_i, C_j)$ *entre deux groupes* à partir de la distance d entre individus. Les principaux critères :

Définition 1 (Critères d'agrégation).
Pour deux classes C_i et C_j d'effectifs n_i, n_j et de centres de gravité g_i, g_j :

$$\text{lien simple (min)} : \quad D(C_i, C_j) = \min_{x \in C_i, y \in C_j} d(x, y),$$

$$\text{lien complet (max)} : \quad D(C_i, C_j) = \max_{x \in C_i, y \in C_j} d(x, y),$$

$$\text{lien moyen (UPGMA)} : \quad D(C_i, C_j) = \frac{1}{n_i n_j} \sum_{x \in C_i} \sum_{y \in C_j} d(x, y),$$

$$\text{lien du centroïde} : \quad D(C_i, C_j) = \|g_i - g_j\|^2,$$

$$\text{critère de Ward} : \quad D(C_i, C_j) = \frac{n_i\, n_j}{n_i + n_j} \|g_i - g_j\|^2.$$

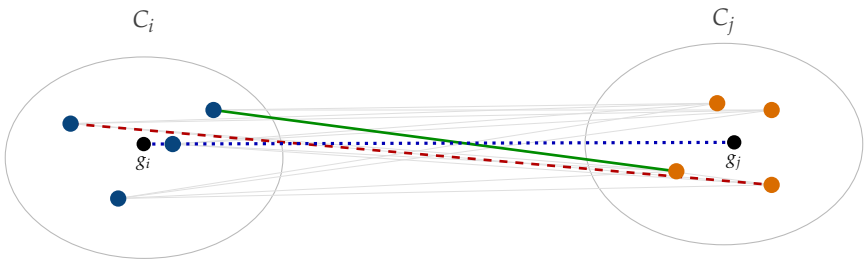
Pour les deux derniers critères, g_i et g_j sont les **centres de gravité** des classes et $\|g_i - g_j\|^2$ est le **carré de la distance euclidienne** entre ces deux centres.

- Le *lien du centroïde* prend directement cette quantité. Il mesure l'éloignement des deux «individus moyens».
- Le *critère de Ward* la pondère par le coefficient $\frac{n_i\, n_j}{n_i + n_j}$, qui dépend des effectifs n_i, n_j des deux classes.

  Par exemple à distance égale entre centres, fusionner deux *petites* classes coûte moins cher que fusionner deux grosses, de sorte que les petits groupes proches se réunissent en premier. Ce coût $D(C_i, C_j)$ est exactement l'**augmentation de l'inertie intra-classe** provoquée par la fusion : c'est la « hauteur » reportée sur le dendrogramme.

On rencontre aussi le *lien moyen pondéré* (WPGMA, dit de McQuitty) et le *lien médian* (WPGMC). Chaque critère imprime une « forme » aux classes :

Critère	Tendance	Remarque
Lien simple	classes allongées, filaments	équivaut à l'arbre couvrant minimal ; sujet à l'*effet de chaîne*
Lien complet	classes compactes, sphériques	sensible aux points aberrants
Lien moyen	compromis des deux précédents	robuste au bruit
Centroïde / médian	fondés sur les centres	peuvent créer des *inversions*
Ward	classes compactes, de tailles proches	le plus utilisé en pratique



lien simple : la paire la plus proche (min)

lien complet : la paire la plus éloignée (max)

lien centroïde : entre les centres g_i et g_j

lien moyen : moyenne de toutes les paires (en gris)

Remarque (Le critère de Ward et l'inertie)**.**
Le critère de Ward mesure l'**augmentation d'inertie intra-classe** provoquée par la fusion : il regroupe les classes dont la réunion « coûte » le moins de dispersion.

1.5 La formule de récurrence de Lance–Williams

Recalculer les distances de groupe à partir des individus à chaque étape serait coûteux. La **formule de Lance–Williams** (1967) exprime la distance entre une classe fusionnée $C_i \cup C_j$ et une autre classe C_k *uniquement* à partir des distances déjà connues :

Proposition 1 (Récurrence de Lance–Williams)**.**

$$D(C_i \cup C_j,\, C_k) = \alpha_i\, D(C_i, C_k) + \alpha_j\, D(C_j, C_k) + \beta\, D(C_i, C_j) + \gamma\, |D(C_i, C_k) - D(C_j, C_k)|.$$

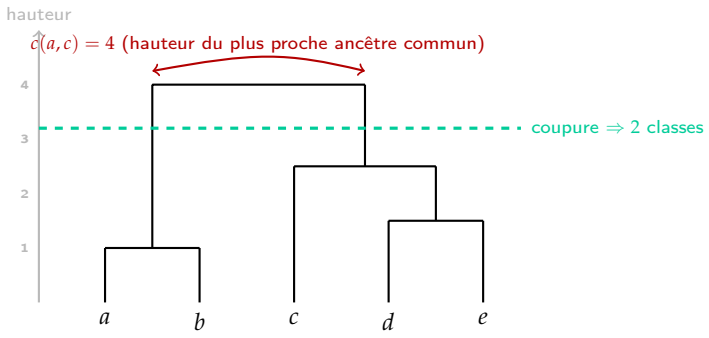
Les coefficients $(\alpha_i, \alpha_j, \beta, \gamma)$ caractérisent le critère d'agrégation.

Critère	α_i	α_j	β	γ
Lien simple	$\frac{1}{2}$	$\frac{1}{2}$	0	$-\frac{1}{2}$
Lien complet	$\frac{1}{2}$	$\frac{1}{2}$	0	$+\frac{1}{2}$
Lien moyen (UPGMA)	$\frac{n_i}{n_i+n_j}$	$\frac{n_j}{n_i+n_j}$	0	0
Moyen pondéré (McQuitty)	$\frac{1}{2}$	$\frac{1}{2}$	0	0
Centroïde	$\frac{n_i}{n_i+n_j}$	$\frac{n_j}{n_i+n_j}$	$-\frac{n_i n_j}{(n_i+n_j)^2}$	0
Médian	$\frac{1}{2}$	$\frac{1}{2}$	$-\frac{1}{4}$	0
Ward	$\frac{n_i+n_k}{n_i+n_j+n_k}$	$\frac{n_j+n_k}{n_i+n_j+n_k}$	$-\frac{n_k}{n_i+n_j+n_k}$	0

Remarque (Portée)**.**
Le centroïde, le médian et Ward s'appliquent sur des distances *euclidiennes au carré*. La récurrence met à jour chaque distance en temps constant : elle est le moteur des implémentations efficaces et unifie tous les critères sous une même écriture.

1.6 Le dendrogramme : lecture et propriétés

Le **dendrogramme** représente les fusions successives ; la *hauteur* d'un nœud est la valeur du critère D au moment de la fusion. Couper l'arbre par une ligne horizontale fournit une partition : le nombre de branches coupées est le nombre de classes.



Définition 2 (Distance cophénétique)**.**
La **distance cophénétique** $c(i,i')$ entre deux individus est la hauteur du plus petit nœud de l'arbre qui les contient tous les deux. Les $c(i,i')$ forment une *ultramétrique* : $c(i,i') \leq \max\big(c(i,k), c(k,i')\big)$ pour tout k. Un dendrogramme équivaut exactement à une ultramétrique.

Qualité de l'arbre : la corrélation cophénétique. On mesure la fidélité du dendrogramme aux données par le **coefficient de corrélation cophénétique** : la corrélation de Pearson entre les dissimilarités d'origine $d(i,i')$ et les distances cophénétiques $c(i,i')$. Proche de 1, l'arbre résume bien les distances ; faible, il les déforme.

Proposition 2 (Monotonie et inversions)**.**
Avec les liens simple, complet, moyen et Ward, les hauteurs de fusion sont ***croissantes*** *le long de l'arbre : il n'y a jamais d'*inversion*. Les liens du* ***centroïde*** *et* ***médian*** *ne garantissent pas cette monotonie : une fusion peut se produire à une hauteur* inférieure *à une fusion antérieure, ce qui rend le dendrogramme difficile à lire.*

1.7 Le critère de Ward en détail

Le critère de Ward (1963) choisit, à chaque étape, la fusion qui augmente le moins l'**inertie intra-classe**, autrement dit qui fait perdre le moins d'inertie inter-classe.

Proposition 3 (Coût de fusion de Ward)**.**
Fusionner C_i et C_j augmente l'inertie intra de

$$\Delta(C_i, C_j) = \frac{n_i\, n_j}{n_i + n_j} \, \|g_i - g_j\|^2.$$

*La somme des $n-1$ coûts de fusion de tout l'arbre est égale à l'****inertie totale*** *du nuage.*

Remarque (Lien avec Huygens)**.**
La décomposition de Huygens $\mathcal{I}_{\text{tot}} = \mathcal{I}_{\text{intra}} + \mathcal{I}_{\text{inter}}$ étant fixe, minimiser la perte d'inertie inter à chaque fusion revient à garder les classes aussi séparées que possible. Pour une coupure en deux classes, l'inertie inter est exactement la hauteur de la dernière fusion.

1.8 Choisir le nombre de classes

Aucun critère n'est universel ; on croise plusieurs lectures :

- **saut de hauteur** (règle du coude) : on coupe juste en dessous du plus grand écart entre deux fusions successives ;
- **part d'inertie expliquée** $\mathcal{I}_{\text{inter}}/\mathcal{I}_{\text{tot}}$, à mettre en regard du nombre de classes (critère de Ward) ;
- **silhouette** moyenne, **statistique de l'écart** (*gap statistic*) ;
- **interprétabilité** : des classes que l'on sait nommer et utiliser.

Remarque (Séparation forte)**.**
Si les données vérifient la *séparation forte*, tout individu est plus proche des individus de sa classe que de tout individu d'une autre classe — alors le lien simple retrouve exactement la vraie partition, qui est une coupe de son arbre. En pratique cette condition est rarement satisfaite, d'où l'intérêt des liens moyen et de Ward.

Recette pratique

1. Centrer-réduire les variables (ou choisir une dissimilarité adaptée).
2. En grande dimension, réduire d'abord par une ACP, puis classer sur les premières composantes (sous R : `HCPC` de `FactoMineR`).
3. Préférer **Ward** (ou le lien moyen) pour des classes compactes ; le lien simple pour des formes allongées.
4. Lire le dendrogramme *et* le diagramme des sauts d'inertie pour choisir k.
5. **Consolider** la partition par quelques itérations de k-means.
6. Caractériser chaque classe (moyennes, valeurs-tests) et la nommer.

Remarque (Sources)**.**
Cette synthèse s'appuie sur F. Nielsen, *Hierarchical Clustering* (chap. 8, 2016) ; le cours *stats306b* de L. Mackey (Stanford) ; les notes de D. Sontag (MIT, ML 2013) et de Princeton (COS 324) ; E. García-Portugués, *Notes for Predictive Modeling* (UC3M) ; ainsi que les supports de TU Dortmund, UCL, UBC et Al-Mustansiriyah cités en référence du TD.

2 Faire une CAH sous R avec RStudio

Exercice 1 CAH sous R, guidée : typologie d'exploitations d'un bassin cotonnier

Dans une zone soudano-sahélienne, un service d'appui-conseil a enquêté auprès de 15 **exploitations** ($I = 15$). Chacune est décrite par cinq variables ($K = 5$) :

- **SAU_ha** : surface agricole utile (ha) ;
- **Cheptel_UBT** : taille du cheptel (unités de bétail tropical) ;
- **Actifs** : nombre d'actifs familiaux ;
- **Autoconso_pct** : part de la production autoconsommée (%) ;
- **Rdt_cereales** : rendement céréalier (kg/ha).

Les données sont dans le fichier `data_stat-0113.xlsx` (exploitations en lignes, variables en colonnes).

Exploitation	SAU_ha	Cheptel_UBT	Actifs	Autoconso_pct	Rdt_cereales
Exp01	7,8	24	9	65	845
Exp02	7,9	19	8	59	884
Exp03	2,4	2	5	75	741
Exp04	3,1	3	3	80	858
Exp05	1,9	2	4	74	834
Exp06	10,5	6	8	32	1094
Exp07	2,9	0	4	79	759
Exp08	1,9	3	5	75	910
Exp09	9,2	5	5	36	1164
Exp10	12,0	6	6	29	1109
Exp11	7,2	22	8	46	853
Exp12	12,7	6	7	29	1147
Exp13	6,8	29	10	45	836
Exp14	7,8	15	7	54	1000
Exp15	13,0	3	6	23	1033

Sous R : préparez votre session

Ouvrez RStudio, placez `data_stat-0113.xlsx` dans votre dossier de travail puis indiquez-le à R (menu *Session* → *Set Working Directory*, ou `setwd()`). Les packages utiles s'installent une seule fois :

```
install.packages(c("readxl", "FactoMineR", "factoextra"))  # une seule fois
```

Le code ci-dessous est fourni **pas à pas** : exécutez chaque bloc, observez la sortie, et répondez aux questions. L'objectif est de construire une **typologie** des exploitations par CAH, puis de la lire avec esprit critique.

1. Importer et explorer les données

```
library(readxl)
exploit <- as.data.frame(read_excel("data_stat-0113.xlsx"))
rownames(exploit) <- exploit$Exploitation   # noms de lignes = exploitations
exploit$Exploitation <- NULL                # on retire la colonne de noms
summary(exploit)                            # ordres de grandeur tres differents
```

a) Comparez les ordres de grandeur des cinq variables (lignes `Min.` et `Max.` de `summary`). Pourquoi serait-il dangereux de calculer des distances directement sur ces données brutes ?

2. Centrer et réduire

```
exploit.cr <- scale(exploit)   # chaque variable : moyenne 0, ecart-type 1
round(head(exploit.cr), 2)
```

Lecture. `scale()` remplace chaque valeur par son écart à la moyenne divisé par l'écart-type. Toutes les variables pèsent alors autant, quelle que soit leur unité : une différence de cheptel et une différence de rendement deviennent comparables.

3. Construire l'arbre (CAH de Ward)

```
d <- dist(exploit.cr)                    # distances euclidiennes entre exploitations
arbre <- hclust(d, method = "ward.D2")   # CAH, critere de Ward
plot(arbre, hang = -1, main = "Dendrogramme", xlab = "", sub = "")
```

Lecture. `dist()` calcule les distances entre individus, `hclust(..., "ward.D2")` construit l'arbre en minimisant à chaque étape la perte d'inertie inter-classe. La hauteur d'un branchement est le coût de la fusion.

a) Combien de grands groupes se dessinent « à l'œil » sur le dendrogramme ?

4. Choisir le nombre de classes

```
barplot(rev(arbre$height),
        names.arg = seq_along(arbre$height),
        xlab = "fusions (de la derniere a la premiere)",
        ylab = "hauteur (perte d'inertie)")
classe <- cutree(arbre, k = 3)           # on decoupe en 3 classes
table(classe)                            # effectif de chaque classe
plot(arbre, hang = -1, main = "", xlab = "", sub = "")
rect.hclust(arbre, k = 3, border = 2:4)  # encadre les 3 classes
```

Où couper l'arbre ?

Le diagramme en barres montre les hauteurs de fusion, de la dernière (la plus coûteuse) à la première. On coupe *juste avant* un grand saut : le nombre de classes correspond au nombre de branches coupées par la ligne horizontale.

a) Le découpage en 3 classes est-il cohérent avec le plus grand saut du diagramme ? Donner l'effectif de chaque classe.

5. Caractériser les classes

```
aggregate(exploit, by = list(classe = classe), FUN = mean)  # moyennes par classe
```

Lecture. `aggregate` donne, pour chaque classe, la moyenne de chaque variable. On compare ces moyennes entre classes (et à la moyenne générale) pour décrire chaque groupe et lui donner un nom.

a) Pour chaque classe, repérer les deux ou trois variables les plus caractéristiques (nettement au-dessus ou en dessous des autres classes).

b) Proposer un nom agronomique pour chacune des trois classes.

6. Pour aller plus loin : classification sur composantes et valeurs-tests

```
library(FactoMineR)
res.pca  <- PCA(exploit, scale.unit = TRUE, graph = FALSE)
res.hcpc <- HCPC(res.pca, nb.clust = 3, graph = FALSE)
plot(res.hcpc, choice = "map")        # les classes sur le plan de l'ACP
res.hcpc$desc.var$quanti              # valeurs-tests : variables qui caracterisent
```

> **La valeur-test**
> Pour chaque classe, `HCPC` trie les variables par **valeur-test** : une valeur-test positive (resp. négative) et de module $\geq 1{,}96$ signale une variable significativement *plus forte* (resp. *plus faible*) dans la classe que dans l'ensemble. C'est la version automatique de la lecture faite à la question 5.

a) Les valeurs-tests confirment-elles les noms de classes proposés à la question 5 ? Rédiger, en trois ou quatre phrases, une synthèse de la typologie obtenue.

Correction ▼ [stat-0113]

Exercice 2 CAH sous R, en autonomie : systèmes maraîchers péri-urbains

Autour d'une grande ville, une enquête a porté sur 18 **exploitations maraîchères** ($I = 18$), décrites par six variables ($K = 6$) :

- **Surface_ha** : surface en maraîchage (ha) ;
- **Part_irriguee_pct** : part de la surface irriguée (%) ;
- **Nb_cultures_an** : nombre de cultures dans l'année (diversité) ;
- **Charges_intrants_kFCFA_ha** : charges en intrants (milliers de FCFA/ha) ;
- **Marge_nette_kFCFA_ha** : marge nette (milliers de FCFA/ha) ;
- **Actifs** : nombre d'actifs sur l'exploitation.

Les données sont dans `data_stat-0114.xlsx` (exploitations en lignes, variables en colonnes).

Exploitation	Surface_ha	Part_irr._%	Nb_cult._an	Charges_kFCFA	Marge_kFCFA	Actifs
Mar01	2,82	4	3	240	386	3
Mar02	3,10	7	3	217	295	2
Mar03	2,02	40	6	463	488	4
Mar04	1,27	42	8	474	735	3
Mar05	2,78	12	2	250	266	2
Mar06	0,81	83	5	797	1474	6
Mar07	0,54	92	3	655	1245	5
Mar08	1,19	46	8	459	573	4
Mar09	0,76	88	5	962	1113	5
Mar10	3,28	2	3	336	294	2
Mar11	0,76	83	4	846	1509	6
Mar12	1,59	55	6	560	635	3
Mar13	1,47	49	7	492	681	4
Mar14	1,92	21	2	295	223	3
Mar15	0,83	100	4	825	1336	6
Mar16	3,25	10	2	130	198	3
Mar17	1,95	61	7	469	534	4
Mar18	0,80	94	4	1026	1299	6

Votre mission

Construire, **sous R et de façon autonome**, une typologie de ces 18 exploitations par une CAH de Ward, puis l'interpréter. Vous vous inspirerez de la démarche de l'exercice précédent, mais cette fois **sans code fourni** : à vous d'écrire le script, de justifier vos choix et de rédiger une courte synthèse.

1. **Préparer les données.** Importer le fichier, mettre les noms d'exploitations en noms de lignes, puis *centrer-réduire* les six variables. Justifier en une phrase pourquoi cette étape est indispensable ici.
2. **Construire l'arbre.** Calculer les distances euclidiennes et réaliser la CAH de Ward. Tracer le dendrogramme.
3. **Choisir le nombre de classes.** À l'aide des hauteurs de fusion (ou du diagramme des sauts d'inertie), proposer un nombre de classes et le justifier. Découper l'arbre et donner l'effectif de chaque classe.
4. **Caractériser.** Calculer les moyennes par classe (ou utiliser les valeurs-tests de `HCPC`). Décrire chaque classe par ses variables les plus marquantes.

5. **Interpréter.** Donner un nom à chaque classe et rédiger une synthèse de quatre ou cinq lignes : quels grands types de maraîchage péri-urbain votre classification met-elle en évidence ? Quel intérêt pour orienter un conseil technique ?

Indications. Fonctions utiles : `read_excel` (package `readxl`), `scale`, `dist`, `hclust(..., method = "ward.D2")`, `plot`, `cutree`, `rect.hclust`, `aggregate` ; et, pour aller plus loin, `PCA` et `HCPC` du package `FactoMineR`.

Contrôle. Un découpage en **trois classes** de six exploitations chacune se dégage nettement. Elles opposent, pour l'essentiel, un maraîchage *intensif très irrigué et à forte marge*, un maraîchage *extensif peu irrigué et à faible marge*, et un type *intermédiaire diversifié*.

Correction ▼ [stat-0114]

Corrections

Correction de l'exercice 1 ▲

Comment lire cette correction

Les valeurs données sont celles que R affiche avec ce code. La numérotation des classes (1, 2, 3) et l'ordre des feuilles du dendrogramme peuvent différer d'une version de R à l'autre : c'est la *composition* des classes qui compte.

1. Importer et explorer les données.

	SAU_ha	Cheptel_UBT	Actifs	Autoconso_pct	Rdt_cereales
Min.	1,9	0	3	23	741
Mean	7,14	9,67	6,33	53,4	937,8
Max.	13,0	29	10	80	1 164
Écart-type	3,94	9,46	2,02	20,51	141,2

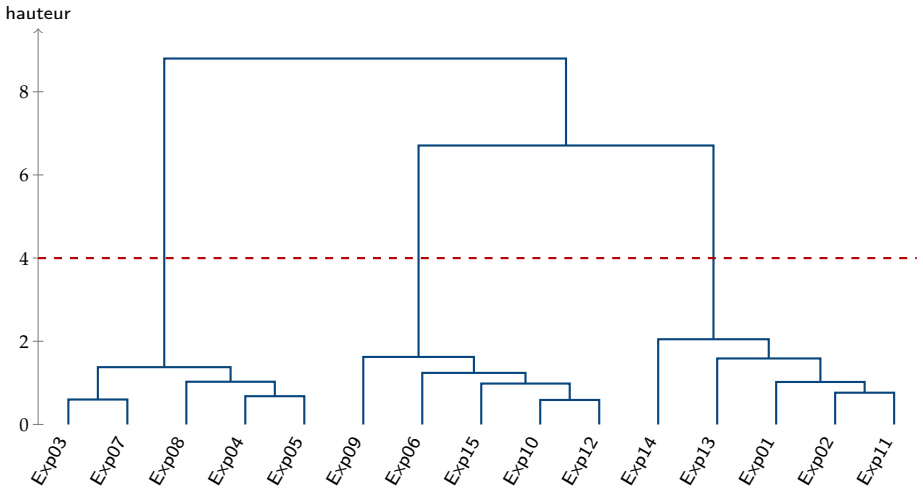
a) Les ordres de grandeur sont très différents : quelques actifs ou quelques hectares, mais des centaines de kg/ha pour le rendement. Une distance euclidienne additionne des carrés d'écarts : sur données brutes, un écart de 100 kg/ha pèserait 10 000, contre 1 pour un écart d'un actif. Le rendement (écart-type 141) dicterait à lui seul la classification, simplement parce qu'il s'exprime dans une unité « grande ». Les autres variables seraient pratiquement ignorées.

2. Centrer et réduire. `round(head(exploit.cr), 2)` affiche :

	SAU_ha	Cheptel_UBT	Actifs	Autoconso_pct	Rdt_cereales
Exp01	0,17	1,51	1,32	0,57	−0,66
Exp02	0,19	0,99	0,82	0,27	−0,38
Exp03	−1,20	−0,81	−0,66	1,05	−1,39
Exp04	−1,02	−0,70	−1,65	1,30	−0,57
Exp05	−1,33	−0,81	−1,15	1,00	−0,73
Exp06	0,85	−0,39	0,82	−1,04	1,11

Par exemple, Exp01 a un cheptel supérieur de 1,51 écart-type à la moyenne : $(24 - 9{,}67)/9{,}46 \approx 1{,}51$. Toutes les colonnes ont maintenant une moyenne nulle et un écart-type égal à 1 : chaque variable pèse autant dans les distances.

3. Construire l'arbre.



a) Deux branchements dominent nettement tous les autres (hauteurs 8,80 et 6,71, contre 2,05 au plus pour les suivants). On voit donc **trois grands groupes** de cinq exploitations : {Exp03, 04, 05, 07, 08}, {Exp06, 09, 10, 12, 15} et {Exp01, 02, 11, 13, 14}.

4. **Choisir le nombre de classes.** Les premières barres du diagramme (hauteurs de la dernière fusion à la première) valent :

Fusion	14e	13e	12e	11e	10e	…
Hauteur	8,80	6,71	2,05	1,62	1,59	…

a) Le plus grand saut entre deux barres successives est entre la 2e (6,71) et la 3e (2,05) : on garde les deux dernières fusions « au-dessus » de la coupure, ce qui laisse **trois classes**. Le découpage en 3 est donc cohérent. `table(classe)` donne trois classes de 5 **exploitations** chacune.

Pour aller plus loin. Avec `ward.D2`, la perte d'inertie d'une fusion vaut $h^2/2$. L'inertie totale (somme des carrés des données centrées-réduites) vaut $(15-1)\times 5 = 70$; les deux dernières fusions coûtent $8{,}80^2/2 + 6{,}71^2/2 \approx 38{,}7 + 22{,}5 = 61{,}2$, soit $\approx 87\,\%$ de l'inertie expliquée par la partition en trois classes (contre 55 % pour deux classes).

5. **Caractériser les classes.**

Classe	Exploitations	SAU_ha	Cheptel	Actifs	Autoconso	Rdt
1	01, 02, 11, 13, 14	7,5	**21,8**	**8,4**	53,8	884
2	03, 04, 05, 07, 08	**2,4**	**2,0**	**4,2**	**76,6**	**820**
3	06, 09, 10, 12, 15	**11,5**	5,2	6,4	**29,8**	**1 109**
Ensemble		7,1	9,7	6,3	53,4	938

a)
- *Classe 1* : très gros cheptel (plus du double de la moyenne) et familles nombreuses ; surface et autoconsommation proches de la moyenne.
- *Classe 2* : très petite surface, presque pas de bétail, peu d'actifs, forte autoconsommation et rendements les plus faibles.
- *Classe 3* : grande surface, rendements élevés, faible autoconsommation (la production est surtout vendue).

b) Noms possibles :
- classe 1 : **agro-éleveurs** (exploitations familiales associant cultures et grand troupeau) ;
- classe 2 : **petites exploitations vivrières** (production surtout destinée à la famille) ;
- classe 3 : **grandes exploitations céréalières orientées vers le marché**.

6. **Classification sur composantes et valeurs-tests.** Avec toutes les composantes de l'ACP, les distances sont les mêmes qu'à la question 3 : `HCPC` retrouve les mêmes trois classes (la consolidation par k-means ne déplace aucune exploitation). Valeurs-tests des variables significatives :

Classe	Valeurs-tests positives	Valeurs-tests négatives
Vivrières	Autoconso (+3,10)	SAU (−3,26), Actifs (−2,89), Rdt (−2,28), Cheptel (−2,22)
Céréalières	Rdt (+3,33), SAU (+3,01)	Autoconso (−3,15)
Agro-éleveurs	Cheptel (+3,51), Actifs (+2,80)	*aucune*

a) Oui : les valeurs-tests confirment exactement la lecture des moyennes, et indiquent en plus quelles différences sont significatives. Par exemple, le cheptel des exploitations céréalières est inférieur à la moyenne (5,2 contre 9,7) mais pas significativement (valeur-test −1,29).

Synthèse. Les 15 exploitations se répartissent en trois types de taille égale. Les **petites exploitations vivrières** cultivent peu de terres, avec peu de main-d'œuvre et presque pas de bétail, et consomment l'essentiel de leur production. Les **grandes exploitations céréalières** ont les plus grandes surfaces et les

meilleurs rendements, et vendent l'essentiel de leur récolte. Les **agro-éleveurs**, familles nombreuses, se distinguent avant tout par leur troupeau. Cette typologie, qui explique 87 % de l'inertie, peut orienter des conseils différenciés (sécurité alimentaire, commercialisation, intégration agriculture–élevage) ; elle repose cependant sur 15 exploitations seulement.

Correction de l'exercice 2 ▲

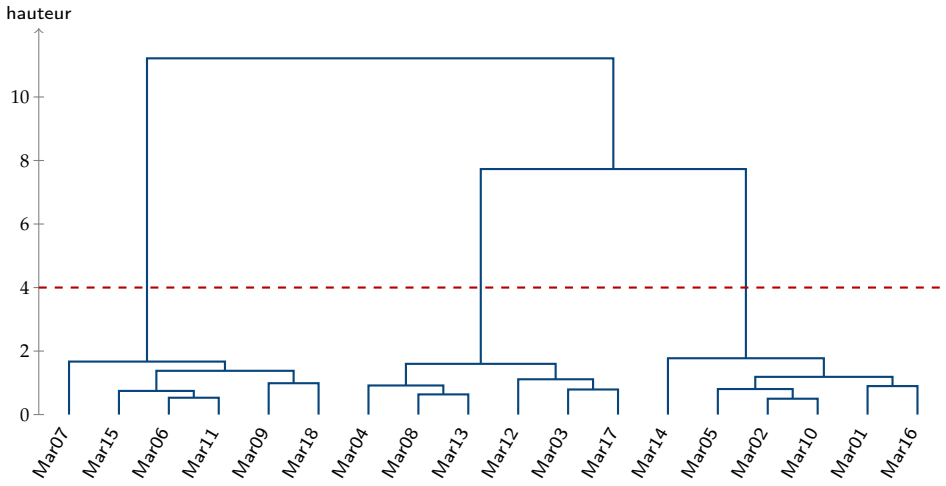
Comment lire cette correction

Voici *un* script possible et les résultats qu'il donne. La numérotation des classes et l'ordre des feuilles du dendrogramme peuvent différer selon la version de R : c'est la composition des classes qui compte.

```
library(readxl); library(FactoMineR)
mar <- as.data.frame(read_excel("data_stat-0114.xlsx"))
rownames(mar) <- mar$Exploitation
mar$Exploitation <- NULL
mar.cr <- scale(mar)                                # centrer-reduire
arbre <- hclust(dist(mar.cr), method = "ward.D2") # CAH de Ward
plot(arbre, hang = -1, main = "", xlab = "", sub = "")
round(rev(arbre$height), 2)                         # hauteurs, de la derniere fusion a la premiere
classe <- cutree(arbre, k = 3); table(classe)
rect.hclust(arbre, k = 3, border = 2:4)
aggregate(mar, by = list(classe = classe), FUN = mean)
res.hcpc <- HCPC(PCA(mar, graph = FALSE), nb.clust = 3, graph = FALSE)
res.hcpc$desc.var$quanti                            # valeurs-tests
```

1. **Préparer les données.** Les variables ont des unités et des ordres de grandeur très différents : la surface varie de 0,5 à 3,3 ha, les charges et la marge de 130 à plus de 1 500 milliers de FCFA/ha. Sans réduction, les distances seraient presque entièrement déterminées par les variables monétaires ; **centrer-réduire** donne à chacune des six variables le même poids.

2. **Construire l'arbre.**



3. **Choisir le nombre de classes.** Hauteurs de fusion, de la dernière à la première : 11,22 ; 7,73 ; 1,78 ; 1,67 ; 1,60 ; … Le plus grand saut se situe entre 7,73 et 1,78 : on coupe l'arbre entre ces deux hauteurs et on retient **trois classes** de 6 **exploitations** chacune. Elles expliquent environ 91 % de l'inertie (deux classes n'en expliqueraient que 62 %), et toutes les fusions internes aux classes sont basses : les classes sont homogènes et bien séparées.

4. **Caractériser.**

Classe	Exploitations	Surface	Irrig. (%)	Nb cult.	Charges	Marge	Actifs
1	01, 02, 05, 10, 14, 16	**2,86**	**9**	**2,5**	**245**	**277**	**2,5**
2	03, 04, 08, 12, 13, 17	1,58	49	**7,0**	486	608	3,7
3	06, 07, 09, 11, 15, 18	**0,75**	**90**	4,2	**852**	**1 329**	**5,7**
Ensemble		1,73	49	4,6	528	738	3,9

Valeurs-tests de `HCPC` (mêmes classes ; seules les variables significatives sont listées) :

- *classe 3* : Marge ($+3{,}83$), Charges ($+3{,}60$), Actifs ($+3{,}60$), Irrigation ($+3{,}53$) ; Surface ($-3{,}08$) ;
- *classe 2* : Nb de cultures ($+3{,}60$), et aucune autre variable ;
- *classe 1* : Surface ($+3{,}55$) ; Irrigation ($-3{,}48$), Charges ($-3{,}14$), Nb de cultures ($-3{,}03$), Actifs ($-3{,}02$), Marge ($-2{,}99$).

5. Interpréter.

- Classe 3 : **maraîchage intensif irrigué** – petites surfaces (moins d'un hectare) presque entièrement irriguées, beaucoup d'intrants et de main-d'œuvre par hectare, et des marges de loin les plus élevées.
- Classe 2 : **maraîchage diversifié intermédiaire** – surfaces, irrigation, charges et marges moyennes ; ce qui le distingue est le grand nombre de cultures dans l'année.
- Classe 1 : **maraîchage extensif pluvial** – les plus grandes surfaces, presque pas d'irrigation, peu d'intrants, peu de cultures et peu d'actifs, et des marges faibles.

Synthèse. Autour de la ville coexistent trois façons de produire des légumes : un maraîchage *intensif* sur de petites parcelles irriguées, très rémunérateur à l'hectare mais exigeant en eau, en intrants et en travail ; un maraîchage *diversifié* intermédiaire ; et un maraîchage *extensif* sur des surfaces plus grandes, sans irrigation, à faible marge. Pour le conseil technique, ces types n'ont pas les mêmes priorités : gestion raisonnée des intrants et de l'eau pour le premier, organisation des successions de cultures pour le deuxième, accès à l'eau (puits, petite irrigation) pour le troisième. Attention : une marge *par hectare* élevée ne dit rien du revenu total, qui dépend aussi de la surface ; et 18 exploitations ne suffisent pas à généraliser.

Étudiant(e) (Nom, Prénom) : .....

Promotion, groupe : .....

Email : .....