Ecole supérieure d'agro-développement international
istom

TD : Clustering avec R

Promotion 115

Table des matières

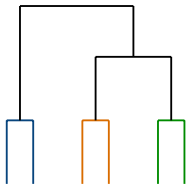
1 Synthèse : la classification ascendante hiérarchique **2**
- 1.1 Position du problème et vocabulaire . . . 2
- 1.2 Mesurer la dissimilarité entre individus . . . 2
- 1.3 L'algorithme général . . . 3
- 1.4 Les critères d'agrégation (*linkage*) . . . 3
- 1.5 La formule de récurrence de Lance–Williams . . . 5
- 1.6 Le dendrogramme : lecture et propriétés . . . 5
- 1.7 Le critère de Ward en détail . . . 6
- 1.8 Les k-means : partitionner directement . . . 6
- 1.9 Choisir le nombre de classes . . . 7

2 Clustering sous R **8**
- Exercice 1 : TD guidé : analyse de clustering complète sous R (typologie agro-alimentaire de pays du Sud) 8
- Exercice 2 : TD en autonomie : typologie de variétés (clustering complet sous R) . . . 10

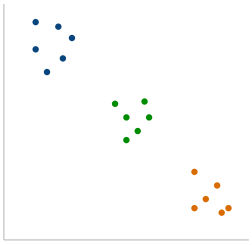
Corrections **12**

Ce TD comporte **deux exercices pour mener une analyse de clustering complète sous R** (section 2) : un premier très guidé, où le code est fourni, puis un second à mener en autonomie. Les jeux de données sont fournis dans les fichiers Excel `data_stat-0123.xlsx` et `data_stat-0124.xlsx`.

Ces exercices couvrent l'essentiel de ce qu'un étudiant d'une école d'ingénieurs comme l'ISTOM doit savoir maîtriser sur le clustering **en pratique** : préparer les données (centrer-réduire), choisir le nombre de classes par plusieurs méthodes (coude, silhouette, *gap*, `NbClust`), construire une partition par **k-means** et par **CAH de Ward**, les comparer, valider par la silhouette, puis caractériser et nommer les classes. Le cadre théorique de la CAH est rassemblé dans la synthèse qui précède les exercices.



Exercice 1 – guidé, sous R
typologie de 21 pays



Exercice 2 – en autonomie, sous R
typologie de 18 variétés

1 Synthèse : la classification ascendante hiérarchique

La **classification** (en anglais *clustering*) cherche à organiser un ensemble d'individus en *classes* homogènes, sans qu'aucune étiquette ne soit donnée au départ : c'est une méthode d'*apprentissage non supervisé*. La **classification ascendante hiérarchique** (CAH ; en anglais *Hierarchical Agglomerative Clustering*, HAC) en est la famille la plus répandue. Plutôt qu'une partition unique, elle produit une *hiérarchie* de partitions emboîtées, résumée par un arbre, le **dendrogramme**, que l'on coupe à la hauteur voulue pour obtenir le nombre de classes souhaité.

Cette synthèse rassemble le cadre théorique. Les **travaux dirigés** qui suivent (page 8) en sont la mise en pratique, par une analyse de clustering complète sous R.

1.1 Position du problème et vocabulaire

On part d'un tableau de n **individus** décrits par p **variables** ($x_i \in \mathbb{R}^p$). Deux grandes familles de méthodes de classification coexistent :

- les méthodes de **partitionnement** (par ex. les k-means), qui cherchent directement une partition en un nombre k de classes *fixé à l'avance* ;
- les méthodes **hiérarchiques**, qui construisent un *emboîtement* de classes et ne fixent pas k a priori.

Les méthodes hiérarchiques se déclinent elles-mêmes en deux approches :

- **ascendante** (agglomérative) : on part des n individus isolés et on fusionne, de proche en proche, jusqu'à une classe unique ($n-1$ fusions) ;
- **descendante** (divisive, par ex. DIANA) : on part de la classe totale et on la scinde récursivement. Cette approche beaucoup moins utilisée que l'approche ascendante, seule traitée ici.

> **Idée directrice.** La CAH ne demande qu'une chose : savoir mesurer à quel point deux individus, puis deux *groupes* d'individus, se ressemblent. Tout le reste (l'arbre, les classes) en découle mécaniquement.

1.2 Mesurer la dissimilarité entre individus

La ressemblance entre deux individus se mesure par une **dissimilarité** $d(x_i, x_j) \geq 0$, symétrique, nulle lorsque $i = j$. Pour des variables quantitatives, on emploie le plus souvent une distance.

Distance	Définition entre x et y de $\mathbb{R}^p$
Euclidienne	$d_2(x,y) = \sqrt{\sum_{k=1}^{p} (x_k - y_k)^2}$
Manhattan	$d_1(x,y) = \sum_{k=1}^{p} \lvert x_k - y_k \rvert$
Minkowski ($m \geq 1$)	$d_m(x,y) = \left(\sum_{k=1}^{p} \lvert x_k - y_k \rvert^m \right)^{1/m}$
Mahalanobis	$d_\Sigma(x,y) = \sqrt{(x-y)^\top \Sigma^{-1} (x-y)}$
Cosinus	$d_{\cos}(x,y) = 1 - \dfrac{x \cdot y}{\lVert x \rVert \, \lVert y \rVert}$

Pour des variables qualitatives ou mixtes, on utilise des indices adaptés (distance de Hamming, dissimilarité de **Gower**, cette dernière accessible sous R par `daisy()` du package `cluster`).

À retenir : standardiser. La distance euclidienne additionne des écarts variable par variable : une variable à forte amplitude (une surface en hectares) écrase une variable à faible amplitude (un taux en %). On **centre et on réduit** donc chaque variable avant de classer, sauf si toutes sont déjà exprimées dans la même unité comparable.

Centrer et réduire : la méthode

Pour une variable X mesurée sur les n individus (valeurs $x_1, \dots, x_n$) :

1. calculer la moyenne $\overline{X} = \dfrac{1}{n}\sum_{i=1}^{n} x_i$;
2. calculer l'écart-type $\sigma_X = \sqrt{\dfrac{1}{n}\sum_{i=1}^{n}\left(x_i - \overline{X}\right)^2}$;
3. remplacer chaque valeur par sa version *centrée réduite*

$$z_i = \frac{x_i - \overline{X}}{\sigma_X}.$$

La nouvelle variable Z a alors une moyenne nulle et un écart-type égal à 1 ; elle est sans unité. On répète l'opération pour chacune des p variables, de sorte qu'elles pèsent toutes autant dans le calcul de la distance. (Sous R : la fonction `scale()`.)

1.3 L'algorithme général

Schéma de la CAH

Entrée : les n individus et une dissimilarité d.

1. **Initialisation.** Chaque individu forme sa propre classe ; on calcule la matrice des dissimilarités.
2. **Répéter** jusqu'à n'avoir qu'une classe : trouver les deux classes C_i et C_j les plus proches au sens d'un *critère d'agrégation* $D(C_i, C_j)$, les fusionner, enregistrer la fusion et sa hauteur, puis mettre à jour les dissimilarités entre la nouvelle classe et les autres.

Sortie : l'arbre des $n-1$ fusions (le dendrogramme).

Pourquoi « glouton » ? À chaque étape, la CAH fait le choix qui semble le meilleur *sur le moment* , réunir les deux classes les plus proches, sans jamais revenir en arrière : on dit qu'elle est **gloutonne**.

C'est simple et rapide, mais une fusion décidée tôt est *définitive*. Deux individus regroupés au début resteront dans la même classe jusqu'au bout, même si, au vu de l'ensemble des données, il aurait finalement mieux valu les séparer. La partition obtenue est donc une *bonne* solution construite pas à pas, pas nécessairement la meilleure possible.

1.4 Les critères d'agrégation (*linkage*)

Tout l'enjeu est de définir la distance $D(C_i, C_j)$ *entre deux groupes* à partir de la distance d entre individus. Les principaux critères :

Définition 1 (Critères d'agrégation).
Pour deux classes C_i et C_j d'effectifs n_i, n_j et de centres de gravité g_i, g_j :

$$\text{lien simple (min)} : \quad D(C_i, C_j) = \min_{x \in C_i, y \in C_j} d(x, y),$$

$$\text{lien complet (max)} : \quad D(C_i, C_j) = \max_{x \in C_i, y \in C_j} d(x, y),$$

$$\text{lien moyen (UPGMA)} : \quad D(C_i, C_j) = \frac{1}{n_i n_j} \sum_{x \in C_i} \sum_{y \in C_j} d(x, y),$$

$$\text{lien du centroïde} : \quad D(C_i, C_j) = \|g_i - g_j\|^2,$$

$$\text{critère de Ward} : \quad D(C_i, C_j) = \frac{n_i\, n_j}{n_i + n_j} \|g_i - g_j\|^2.$$

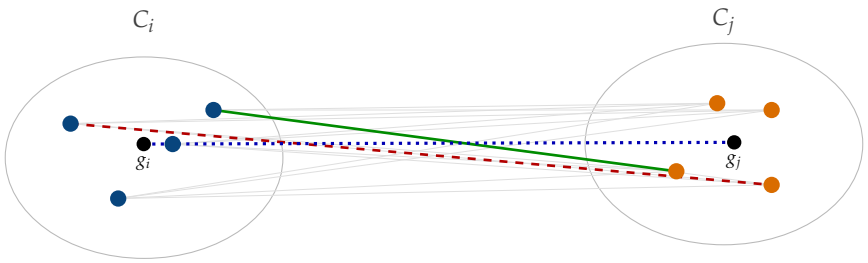
Pour les deux derniers critères, g_i et g_j sont les **centres de gravité** des classes et $\|g_i - g_j\|^2$ est le **carré de la distance euclidienne** entre ces deux centres.

- Le *lien du centroïde* prend directement cette quantité. Il mesure l'éloignement des deux «individus moyens».
- Le *critère de Ward* la pondère par le coefficient $\frac{n_i\, n_j}{n_i + n_j}$, qui dépend des effectifs n_i, n_j des deux classes.

  Par exemple à distance égale entre centres, fusionner deux *petites* classes coûte moins cher que fusionner deux grosses, de sorte que les petits groupes proches se réunissent en premier. Ce coût $D(C_i, C_j)$ est exactement l'**augmentation de l'inertie intra-classe** provoquée par la fusion : c'est la « hauteur » reportée sur le dendrogramme.

On rencontre aussi le *lien moyen pondéré* (WPGMA, dit de McQuitty) et le *lien médian* (WPGMC). Chaque critère imprime une « forme » aux classes :

Critère	Tendance	Remarque
Lien simple	classes allongées, filaments	équivaut à l'arbre couvrant minimal ; sujet à l'*effet de chaîne*
Lien complet	classes compactes, sphériques	sensible aux points aberrants
Lien moyen	compromis des deux précédents	robuste au bruit
Centroïde / médian	fondés sur les centres	peuvent créer des *inversions*
Ward	classes compactes, de tailles proches	le plus utilisé en pratique



lien simple : la paire la plus proche (min)

lien complet : la paire la plus éloignée (max)

lien centroïde : entre les centres g_i et g_j

lien moyen : moyenne de toutes les paires (en gris)

Remarque (Le critère de Ward et l'inertie)**.**
Le critère de Ward mesure l'**augmentation d'inertie intra-classe** provoquée par la fusion : il regroupe les classes dont la réunion « coûte » le moins de dispersion.

1.5 La formule de récurrence de Lance–Williams

Recalculer les distances de groupe à partir des individus à chaque étape serait coûteux. La **formule de Lance–Williams** (1967) exprime la distance entre une classe fusionnée $C_i \cup C_j$ et une autre classe C_k *uniquement* à partir des distances déjà connues :

Proposition 1 (Récurrence de Lance–Williams)**.**

$$D(C_i \cup C_j,\, C_k) = \alpha_i\, D(C_i, C_k) + \alpha_j\, D(C_j, C_k) + \beta\, D(C_i, C_j) + \gamma\, |D(C_i, C_k) - D(C_j, C_k)|.$$

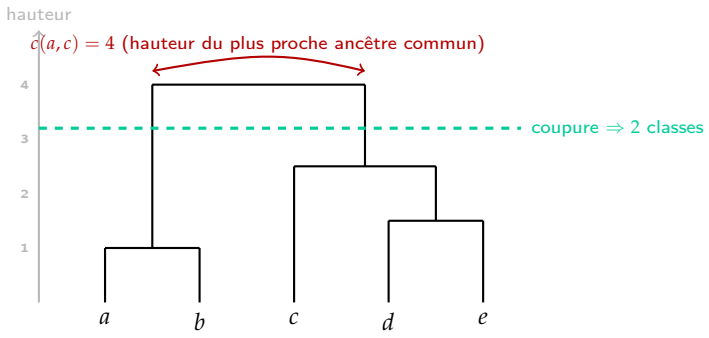
Les coefficients $(\alpha_i, \alpha_j, \beta, \gamma)$ caractérisent le critère d'agrégation.

Critère	α_i	α_j	β	γ
Lien simple	$\frac{1}{2}$	$\frac{1}{2}$	0	$-\frac{1}{2}$
Lien complet	$\frac{1}{2}$	$\frac{1}{2}$	0	$+\frac{1}{2}$
Lien moyen (UPGMA)	$\frac{n_i}{n_i+n_j}$	$\frac{n_j}{n_i+n_j}$	0	0
Moyen pondéré (McQuitty)	$\frac{1}{2}$	$\frac{1}{2}$	0	0
Centroïde	$\frac{n_i}{n_i+n_j}$	$\frac{n_j}{n_i+n_j}$	$-\frac{n_i n_j}{(n_i+n_j)^2}$	0
Médian	$\frac{1}{2}$	$\frac{1}{2}$	$-\frac{1}{4}$	0
Ward	$\frac{n_i+n_k}{n_i+n_j+n_k}$	$\frac{n_j+n_k}{n_i+n_j+n_k}$	$-\frac{n_k}{n_i+n_j+n_k}$	0

Remarque (Portée)**.**
Le centroïde, le médian et Ward s'appliquent sur des distances *euclidiennes au carré*. La récurrence met à jour chaque distance en temps constant : elle est le moteur des implémentations efficaces et unifie tous les critères sous une même écriture.

1.6 Le dendrogramme : lecture et propriétés

Le **dendrogramme** représente les fusions successives ; la *hauteur* d'un nœud est la valeur du critère D au moment de la fusion. Couper l'arbre par une ligne horizontale fournit une partition : le nombre de branches coupées est le nombre de classes.



Définition 2 (Distance cophénétique)**.**
La **distance cophénétique** $c(i,i')$ entre deux individus est la hauteur du plus petit nœud de l'arbre qui les contient tous les deux. Les $c(i,i')$ forment une *ultramétrique* : $c(i,i') \leq \max\big(c(i,k), c(k,i')\big)$ pour tout k. Un dendrogramme équivaut exactement à une ultramétrique.

Qualité de l'arbre : la corrélation cophénétique. On mesure la fidélité du dendrogramme aux données par le **coefficient de corrélation cophénétique** : la corrélation de Pearson entre les dissimilarités d'origine $d(i,i')$ et les distances cophénétiques $c(i,i')$. Proche de 1, l'arbre résume bien les distances ; faible, il les déforme.

Proposition 2 (Monotonie et inversions)**.**
Avec les liens simple, complet, moyen et Ward, les hauteurs de fusion sont ***croissantes*** *le long de l'arbre : il n'y a jamais d'*inversion*. Les liens du* ***centroïde*** *et* ***médian*** *ne garantissent pas cette monotonie : une fusion peut se produire à une hauteur* inférieure *à une fusion antérieure, ce qui rend le dendrogramme difficile à lire.*

1.7 Le critère de Ward en détail

Le critère de Ward (1963) choisit, à chaque étape, la fusion qui augmente le moins l'**inertie intra-classe**, autrement dit qui fait perdre le moins d'inertie inter-classe.

Proposition 3 (Coût de fusion de Ward)**.**
Fusionner C_i et C_j augmente l'inertie intra de

$$\Delta(C_i, C_j) = \frac{n_i\, n_j}{n_i + n_j} \|g_i - g_j\|^2.$$

*La somme des $n-1$ coûts de fusion de tout l'arbre est égale à l'****inertie totale*** *du nuage.*

Remarque (Lien avec Huygens)**.**
La décomposition de Huygens $\mathcal{I}_{\text{tot}} = \mathcal{I}_{\text{intra}} + \mathcal{I}_{\text{inter}}$ étant fixe, minimiser la perte d'inertie inter à chaque fusion revient à garder les classes aussi séparées que possible. Pour une coupure en deux classes, l'inertie inter est exactement la hauteur de la dernière fusion. C'est la propriété vérifiée « à la main » dans l'exemple entièrement traité (section **??**).

1.8 Les k-means : partitionner directement

À côté des méthodes hiérarchiques, les **k-means** (MacQueen, 1967) cherchent *directement* une partition en un nombre k de classes **fixé à l'avance**, sans construire d'arbre.

L'algorithme des k-means

Entrée : les n individus (centrés-réduits) et un nombre de classes k.

1. **Initialisation.** Choisir k centres, en général k individus tirés au hasard.
2. **Affectation.** Affecter chaque individu à la classe du centre le plus proche (distance euclidienne).
3. **Recalcul.** Remplacer chaque centre par la *moyenne* des individus de sa classe.
4. **Répéter** les étapes 2 et 3 jusqu'à ce que les classes ne changent plus.

Sortie : une partition en k classes et leurs centres.

À chaque tour, l'**inertie intra-classe** (la somme des carrés des distances des individus à leur centre) diminue : l'algorithme converge donc, mais vers un *minimum local* seulement, qui dépend des centres de départ.

Pourquoi `nstart` ? Comme le résultat dépend du tirage initial, on relance les k-means depuis plusieurs jeux de centres et on conserve la partition d'inertie intra la plus faible. Sous R, l'argument `nstart = 25` de `kmeans()` fait exactement cela : 25 départs, meilleure solution retenue. Il faut par ailleurs **fixer** k **à l'avance**, d'où l'étape suivante.

Remarque (k-means et CAH de Ward : deux chemins, la même idée)**.**
Les deux méthodes minimisent l'inertie intra-classe : Ward par fusions successives et irréversibles, les k-means par réaffectations itératives à k fixé. En pratique on les combine (la CAH suggère un nombre de classes et une partition de départ), que l'on **consolide** par quelques k-means, et l'on **compare** les deux partitions (table de confusion) pour tester la *robustesse* de la typologie : si elles concordent, le découpage est solide.

1.9 Choisir le nombre de classes

Aucun critère n'est universel ; on croise plusieurs lectures :

- **saut de hauteur** (règle du coude) : on coupe juste en dessous du plus grand écart entre deux fusions successives ;
- **part d'inertie expliquée** $\mathcal{I}_{\text{inter}}/\mathcal{I}_{\text{tot}}$, à mettre en regard du nombre de classes (critère de Ward) ;
- **silhouette** moyenne, **statistique de l'écart** (*gap statistic*), ou le **vote de nombreux indices** (fonction `NbClust` sous R, qui en combine 26 et retient le k majoritaire) ;
- **interprétabilité** : des classes que l'on sait nommer et utiliser.

Remarque (Séparation forte)**.**
Si les données vérifient la *séparation forte*, tout individu est plus proche des individus de sa classe que de tout individu d'une autre classe — alors le lien simple retrouve exactement la vraie partition, qui est une coupe de son arbre. En pratique cette condition est rarement satisfaite, d'où l'intérêt des liens moyen et de Ward.

Recette pratique

1. Centrer-réduire les variables (ou choisir une dissimilarité adaptée).
2. En grande dimension, réduire d'abord par une ACP, puis classer sur les premières composantes (sous R : `HCPC` de `FactoMineR`).
3. Préférer **Ward** (ou le lien moyen) pour des classes compactes ; le lien simple pour des formes allongées.
4. Lire le dendrogramme *et* le diagramme des sauts d'inertie pour choisir k.
5. **Consolider** la partition par quelques itérations de k-means.
6. Caractériser chaque classe (moyennes, valeurs-tests) et la nommer.

Remarque (Sources)**.**
Cette synthèse s'appuie sur F. Nielsen, *Hierarchical Clustering* (chap. 8, 2016) ; le cours *stats306b* de L. Mackey (Stanford) ; les notes de D. Sontag (MIT, ML 2013) et de Princeton (COS 324) ; E. García-Portugués, *Notes for Predictive Modeling* (UC3M) ; ainsi que les supports de TU Dortmund, UCL, UBC et Al-Mustansiriyah cités en référence du TD.

2 Clustering sous R

Ces deux travaux dirigés déroulent une *analyse de clustering complète* (k-means et CAH, choix du nombre de classes, validation, caractérisation) : le premier est guidé, le second est à mener en autonomie. Les jeux de données (`data_stat-0123.xlsx` et `data_stat-0124.xlsx`) et les sources sont indiqués dans chaque énoncé.

Exercice 1 TD guidé : analyse de clustering complète sous R (typologie agro-alimentaire de pays du Sud)

On dispose d'un jeu de données (fictif, inspiré d'indicateurs de type FAO) décrivant 21 **pays** ($I = 21$) par **sept variables** agro-économiques ($K = 7$) :

- **Agri_PIB_pct** : part de l'agriculture dans le PIB (%) ;
- **Pop_rurale_pct** : part de la population rurale (%) ;
- **Terres_arables_hab** : terres arables par habitant (ha/hab) ;
- **Rdt_cereales** : rendement céréalier (kg/ha) ;
- **Sousalim_pct** : prévalence de la sous-alimentation (%) ;
- **Engrais_ha** : engrais minéraux (kg/ha) ;
- **PIB_hab** : PIB par habitant (USD).

Les données sont dans `data_stat-0123.xlsx` (pays en lignes, variables en colonnes).

Pays	Agri_PIB	Pop_rur.	Terres_hab	Rdt_cér.	Sousalim	Engrais	PIB_hab
P01	31	72	0,31	979	22	13	635
P02	22	58	0,67	1996	11	77	2309
P03	21	38	0,16	3630	5	195	2739
P04	26	69	0,27	882	22	8	919
P05	12	32	0,26	4424	8	204	4726
P06	42	74	0,34	977	35	13	944
P07	26	63	0,39	2512	7	96	1726
P08	14	59	0,50	2062	14	102	2245
P09	38	73	0,29	1119	32	14	1237
P10	15	32	0,27	5060	5	146	6330
P11	34	70	0,19	814	34	11	637
P12	36	68	0,25	872	29	7	1089
P13	18	55	0,44	2536	21	51	1492
P14	17	42	0,20	4151	11	131	2875
P15	11	32	0,18	4728	7	207	4156
P16	14	50	0,33	5627	6	153	3347
P17	33	69	0,26	1062	24	7	1312
P18	18	56	0,51	2338	16	31	2958
P19	21	49	0,58	2416	11	40	2976
P20	28	39	0,59	2617	18	11	2975
P21	10	36	0,21	4209	12	172	4606

Objectif et préparation

Mener, **pas à pas et sous R**, une *analyse de clustering complète* : préparer les données, déterminer le bon nombre de classes par plusieurs méthodes, construire une partition par **k-means** *et* par **CAH**, les comparer, valider la partition, puis caractériser et nommer les types de pays. Le code est fourni ; exécutez chaque bloc, observez la sortie et répondez aux questions. Installez une fois :

```
install.packages(c("readxl", "factoextra", "cluster", "NbClust", "FactoMineR"))
```

1. Importer et explorer

```
library(readxl)
pays <- as.data.frame(read_excel("data_stat-0123.xlsx"))
rownames(pays) <- pays$id ; pays$id <- NULL
summary(pays)        # des unites et des ordres de grandeur tres differents
```

a) Comparez les ordres de grandeur (PIB/hab en milliers, part de l'agriculture en dizaines). Pourquoi faut-il centrer-réduire avant de calculer des distances ?

2. Centrer-réduire

```
pays.cr <- scale(pays)      # moyenne 0, ecart-type 1 pour chaque variable
round(head(pays.cr), 2)
```

3. Choisir le nombre de classes : trois méthodes

```
library(factoextra)
set.seed(123)
fviz_nbclust(pays.cr, kmeans, method = "wss")        # methode du coude
fviz_nbclust(pays.cr, kmeans, method = "silhouette") # silhouette moyenne
fviz_nbclust(pays.cr, kmeans, method = "gap_stat", nstart = 25, nboot = 100)  # gap

library(NbClust)
nb <- NbClust(pays.cr, distance = "euclidean",
              min.nc = 2, max.nc = 8, method = "kmeans", index = "all")
fviz_nbclust(nb)     # regle de la majorite sur 26 indices
```

Trois regards sur le « bon » nombre de classes

La **méthode du coude** cherche le k à partir duquel l'inertie intra ne diminue plus beaucoup ; la **silhouette** retient le k qui maximise la silhouette moyenne ; la **statistique de l'écart** (gap) compare l'inertie observée à celle de données sans structure ; `NbClust` fait voter 26 indices. On retient le k sur lequel ces méthodes convergent.

a) Quel nombre de classes ces méthodes suggèrent-elles ? Concordent-elles ?

4. Partition par k-means

```
set.seed(123)
km <- kmeans(pays.cr, centers = 3, nstart = 25)   # 25 initialisations, on garde la
    meilleure
km$size                                            # effectif de chaque classe
fviz_cluster(km, data = pays.cr, repel = TRUE,
             ellipse.type = "convex")              # classes sur le plan de l'ACP
```

Lecture. `nstart = 25` relance les k-means depuis 25 tirages de centres et conserve la meilleure solution : cela neutralise la sensibilité aux centres initiaux. `fviz_cluster` projette les classes sur les deux premiers axes d'une ACP.

5. Partition par CAH (Ward)

```
d    <- dist(pays.cr)                        # distances euclidiennes
arbre <- hclust(d, method = "ward.D2")       # CAH, critere de Ward
fviz_dend(arbre, k = 3, rect = TRUE, cex = 0.6)   # dendrogramme colore
cah <- cutree(arbre, k = 3)                  # on decoupe en 3 classes
```

a) Le dendrogramme confirme-t-il le découpage en 3 classes (grand saut) ?

6. Comparer les deux partitions

```
table(kmeans = km$cluster, cah = cah)   # table de confusion entre les deux partitions
```

a) Les deux méthodes donnent-elles (à l'étiquette près) les mêmes groupes ? Qu'en concluez-vous sur la robustesse de la typologie ?

7. Valider : la silhouette

```
library(cluster)
sil <- silhouette(km$cluster, dist(pays.cr))
fviz_silhouette(sil)         # largeur de silhouette par pays et moyenne
```

> **La silhouette**
> Pour chaque individu, la **silhouette** compare sa distance moyenne aux membres de sa classe à sa distance à la classe voisine la plus proche. Elle varie de -1 à 1 : proche de 1, l'individu est bien classé ; négative, il serait mieux ailleurs. La *silhouette moyenne* mesure la qualité globale de la partition.

a) La silhouette moyenne est-elle élevée ? Des pays ont-ils une silhouette négative (classement douteux) ?

8. Caractériser et nommer les types

```
aggregate(pays, by = list(classe = km$cluster), FUN = mean)  # moyennes par classe

library(FactoMineR)
res.pca  <- PCA(pays, scale.unit = TRUE, graph = FALSE)
res.hcpc <- HCPC(res.pca, nb.clust = 3, graph = FALSE)
res.hcpc$desc.var$quanti      # valeurs-tests : variables caracteristiques de chaque classe
```

a) Pour chaque classe, repérez les variables les plus caractéristiques (valeurs-tests de module $\geq 1{,}96$).

b) Proposez un nom parlant pour chacun des trois types (par exemple selon le niveau d'intensification, de sous-alimentation et de revenu).

c) En trois ou quatre phrases, rédigez une synthèse : quels grands profils agro-alimentaires se dégagent, et en quoi une telle typologie peut-elle orienter des politiques de développement agricole ?

Sources. Démarche adaptée (thématique ISTOM) à partir de : A. Kassambara, *Cluster Analysis in R*, Datanovia, `datanovia.com` ; DU-Bii, *TP Clustering* (module 3, Stat-R), `du-bii.github.io` ; J. Jacques, *TD Clustering* (Fouille de données, Univ. Lyon 2), `eric.univ-lyon2.fr` ; M. Chica & J. Torres, *TD Clustering* (INSA Centre-Val de Loire), `github.com/milleracero` ; B. Ndiaye, *Clustering TD*, RPubs, `rpubs.com/ben_ndiaye`.

Correction ▼ [stat-0123]

Exercice 2 TD en autonomie : typologie de variétés (clustering complet sous R)

Un programme de sélection variétale a évalué 18 **variétés** d'une céréale de zone sèche ($I = 18$) sur **six traits agronomiques** ($K = 6$) :

- **Cycle_j** : durée du cycle (jours) ;
- **Hauteur_cm** : hauteur à maturité (cm) ;
- **Rdt_t_ha** : rendement en grain (t/ha) ;
- **Proteines_pct** : teneur en protéines du grain (%) ;
- **Tol_secheresse** : tolérance à la sécheresse (note de 1 à 10) ;
- **P1000_g** : poids de mille grains (g).

Les données sont dans `data_stat-0124.xlsx` (variétés en lignes, traits en colonnes).

Variété	Cycle_j	Hauteur_cm	Rdt_t_ha	Protéines_%	Tol_sécher.	P1000_g
V01	107	208	3,7	13,3	4	26
V02	112	273	3,6	12,4	8	28
V03	90	137	1,7	12,1	9	24
V04	80	171	1,3	11,6	8	23
V05	131	307	5,0	7,4	4	29
V06	130	326	4,2	8,3	3	27
V07	132	324	4,6	9,1	3	28
V08	99	250	2,5	12,5	5	24
V09	89	140	2,0	11,8	8	18
V10	109	208	3,4	11,3	4	22
V11	100	161	2,5	12,9	9	21
V12	80	159	1,8	10,3	9	18
V13	115	281	3,2	12,2	7	26
V14	130	336	4,5	7,5	3	35
V15	131	343	4,7	8,4	3	29
V16	108	243	3,1	12,7	6	20
V17	98	155	2,6	12,1	4	23
V18	132	340	3,9	7,9	4	35

Votre mission

Mener **seul(e) et sous R** une analyse de clustering complète de ces variétés, puis l'interpréter. Vous vous inspirerez de la démarche du TD précédent, mais **sans code fourni** : à vous d'écrire le script, de justifier chaque choix et de rédiger une synthèse.

1. **Préparer.** Importer le fichier, mettre les noms de variétés en noms de lignes, puis *centrer-réduire* les six traits. Justifier en une phrase.
2. **Choisir le nombre de classes.** Le déterminer par *au moins deux* méthodes (coude, silhouette, gap, ou `NbClust`) et conclure sur le k retenu.
3. **Deux partitions.** Construire une partition par **k-means** (penser à `nstart`) *et* une par **CAH de Ward** (dendrogramme). Visualiser les classes sur le plan de l'ACP.
4. **Comparer** les deux partitions (table de confusion) et commenter leur accord.
5. **Valider** la partition retenue par la **silhouette** (moyenne et silhouettes individuelles).
6. **Caractériser et nommer.** Calculer les moyennes par classe (ou les valeurs-tests de `HCPC`), décrire chaque groupe par ses traits marquants, nommer les types variétaux et rédiger une synthèse de cinq lignes : quel intérêt pour orienter le choix variétal selon les contextes (zones sèches, recherche de rendement, qualité du grain) ?

Indications. Fonctions utiles : `read_excel` (`readxl`), `scale`, `dist`, `hclust(..., method = "ward.D2")`, `cutree`, `kmeans` ; du package `factoextra` : `fviz_nbclust`, `fviz_cluster`, `fviz_dend`, `fviz_silhouette` ; `silhouette` (`cluster`) ; `NbClust` ; `PCA` et `HCPC` (`FactoMineR`).

Contrôle. Un découpage en **trois types** se dégage : des variétés *précoces, courtes et très tolérantes à la sécheresse* mais peu productives ; des variétés *tardives, hautes et productives* mais pauvres en protéines et sensibles à la sécheresse ; et un type *intermédiaire, riche en protéines*. Une ou deux variétés « frontière » peuvent hésiter entre deux types : discutez-les à l'aide de leur silhouette.

Sources. Démarche adaptée (thématique ISTOM) à partir de : A. Kassambara, *Cluster Analysis in R*, Datanovia, `datanovia.com` ; DU-Bii, *TP Clustering* (module 3, Stat-R), `du-bii.github.io` ; J. Jacques, *TD Clustering* (Univ. Lyon 2), `eric.univ-lyon2.fr` ; M. Chica & J. Torres, *TD Clustering* (INSA CVL), `github.com/milleracero` ; B. Ndiaye, *Clustering TD*, RPubs, `rpubs.com/ben_ndiaye`.

Correction ▼ [stat-0124]

Corrections

Correction de l'exercice 1 ▲

Comment lire cette correction

Les valeurs sont celles que R affiche avec le code de l'énoncé. La numérotation des classes (1, 2, 3) et l'ordre des feuilles du dendrogramme peuvent varier d'une version de R à l'autre : c'est la *composition* des classes qui compte, pas leur numéro.

1. **Importer et explorer.** `summary(pays)` donne des ordres de grandeur très hétérogènes :

	Agri_PIB	Pop_rur.	Terres	Rdt_cér.	Sousalim	Engrais	PIB_hab
Min.	10	32	0,16	814	5	7	635
Moy.	23,2	54,1	0,34	2 620	16,7	80,4	2 487
Max.	42	74	0,67	5 627	35	207	6 330
Éc.-type	9,6	15,1	0,15	1 563	9,8	74,1	1 532

   a) Les variables ne sont pas comparables : le PIB/hab et le rendement se comptent en milliers, la part de l'agriculture ou la sous-alimentation en dizaines, les terres par habitant en fractions d'hectare. Or une distance euclidienne additionne des carrés d'écarts : sur données brutes, un écart de rendement ($\sigma \approx 1\,563$) pèserait des millions, un écart de terres par habitant ($\sigma \approx 0{,}15$) pratiquement rien. Le rendement et le PIB décideraient à eux seuls de la classification. Il faut donc **centrer-réduire** pour que chaque variable pèse autant.

2. **Centrer-réduire.** `round(head(pays.cr), 2)` affiche (six premiers pays) :

	Agri_PIB	Pop_rur.	Terres	Rdt_cér.	Sousalim	Engrais	PIB_hab
P01	0,81	1,19	−0,22	−1,05	0,54	−0,91	−1,21
P02	−0,12	0,26	2,19	−0,40	−0,58	−0,05	−0,12
P03	−0,23	−1,07	−1,22	0,65	−1,19	1,55	0,16
P04	0,29	0,99	−0,49	−1,11	0,54	−0,98	−1,02
P05	−1,17	−1,46	−0,55	1,15	−0,88	1,67	1,46
P06	1,96	1,32	−0,02	−1,05	1,87	−0,91	−1,01

   Chaque colonne a désormais une moyenne nulle et un écart-type égal à 1 : les sept variables pèsent autant dans les distances.

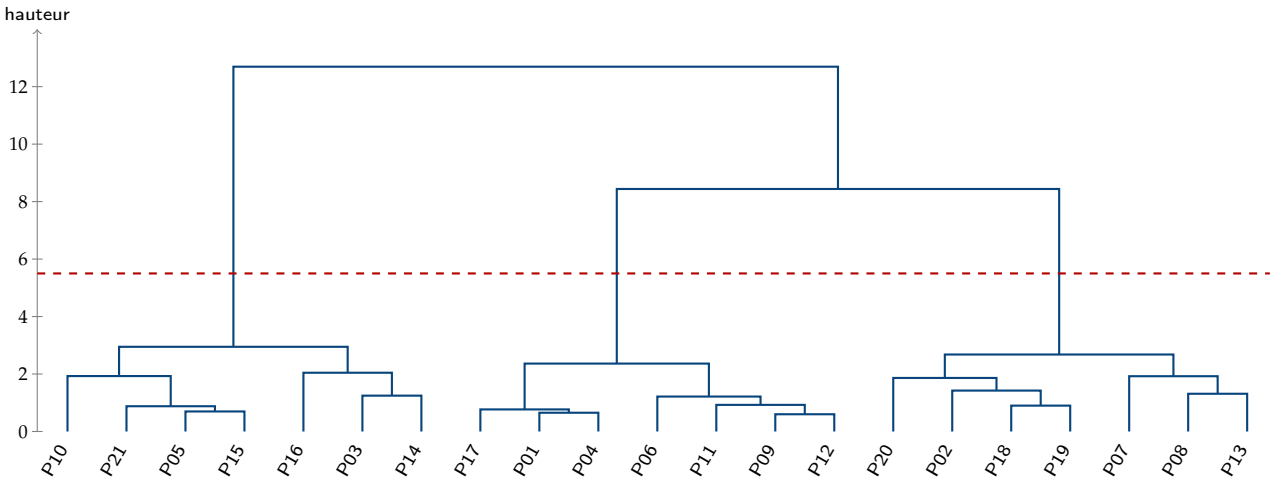
3. **Choisir le nombre de classes.** Les trois méthodes convergent vers $k = 3$:

   - *méthode du coude* (`wss`) : l'inertie intra chute fortement jusqu'à $k = 3$ puis décroît lentement — le « coude » est à 3 ;
   - *silhouette moyenne* : maximale pour $k = 3$ (0,56, contre 0,49 pour $k = 2$ et 0,47 pour $k = 4$) ;
   - *statistique de l'écart* (`gap`) et vote de `NbClust` (majorité des 26 indices) : 3 également.

   a) Oui, les méthodes concordent : on retient **trois classes**.

4. **Partition par k-means.** Avec `centers = 3, nstart = 25`, `km$size` donne trois classes de **sept pays** chacune. `fviz_cluster` les projette sur les deux premiers axes de l'ACP (qui résument ici ≈ 80 % de l'inertie) : les trois groupes y sont nettement séparés, sans recouvrement.

5. **Partition par CAH (Ward).**



a) Oui. Les deux dernières fusions se font à des hauteurs très élevées (12,7 et 8,4), alors que toutes les suivantes coûtent moins de 3. Le **grand saut** se situe donc juste en dessous de l'avant-dernière fusion : on coupe à **trois classes**, de sept pays chacune, en accord avec la question 3.

6. Comparer les deux partitions. `table(kmeans, cah)` (après avoir aligné les étiquettes) :

	CAH int.	CAH vivr.	CAH interm.
k-means int.	7	0	0
k-means vivr.	0	7	0
k-means interm.	0	0	7

a) Les deux méthodes donnent, à l'étiquette près, **exactement les mêmes groupes** : aucun pays n'est classé différemment. Cet accord parfait entre deux méthodes de logiques distinctes (réaffectation itérative pour les k-means, fusions hiérarchiques pour Ward) indique une typologie **robuste** : les trois types sont réellement présents dans les données, ils ne sont pas un artefact de méthode.

7. Valider : la silhouette. `fviz_silhouette(sil)` donne une silhouette moyenne de 0,56 (par classe : 0,53 ; 0,66 ; 0,49).

a) La silhouette moyenne (0,56) est élevée : une valeur $> 0{,}5$ signale une structure forte et bien séparée. **Aucun pays n'a de silhouette négative** : tous sont mieux dans leur classe que dans la plus proche voisine. La partition est de bonne qualité.

8. Caractériser et nommer. Moyennes par classe (variables d'origine) :

Classe	Agri_PIB	Pop_rur.	Terres	Rdt_cér.	Sousalim	Engrais	PIB_hab
Intensive	14,3	37,4	0,23	**4 547**	7,7	**173**	**4 111**
Vivrière	**34,3**	**70,7**	0,27	958	**28,3**	10	968
Intermédiaire	21,0	54,1	**0,53**	2 354	14,0	58	2 383
Ensemble	23,2	54,1	0,34	2 620	16,7	80	2 487

Valeurs-tests `HCPC` (variables significatives, $|v| \geq 1{,}96$) :

Classe	Valeurs-tests positives	Valeurs-tests négatives
Intensive	Engrais (+4,0), Rdt (+4,0), PIB_hab (+3,4)	Pop_rur. (−3,6), Agri_PIB (−3,0), Sousalim (−3,0), Terr
Vivrière	Agri_PIB (+3,8), Sousalim (+3,8), Pop_rur. (+3,6)	Rdt (−3,5), PIB_hab (−3,2), Engrais (−3,1)
Intermédiaire	Terres (+4,0)	*aucune*

a) Les variables caractéristiques (valeurs-tests $\geq 1{,}96$ en module) sont : pour la classe *intensive*, de forts rendements, engrais et PIB/hab et, à l'inverse, une faible part agricole, une population peu rurale et peu de sous-alimentation ; pour la classe *vivrière*, une forte part agricole, une population très rurale et beaucoup de sous-alimentation, avec de faibles rendements, engrais et revenus ; la classe *intermédiaire* ne se distingue que par des terres arables par habitant élevées.

b) Noms possibles :

- **Agricultures intensives à hauts revenus** : rendements élevés, forte fertilisation, PIB/hab élevé, faible sous-alimentation (pays agro-exportateurs ou à agriculture modernisée) ;
- **Agricultures vivrières à forte insécurité alimentaire** : économies très agricoles et rurales, faibles intrants et rendements, sous-alimentation marquée ;
- **Type intermédiaire** : situations de transition, sans trait extrême, avec de relativement grandes surfaces arables par habitant.

c) *Synthèse.* Les 21 pays se répartissent en trois profils de taille égale (sept chacun), que les k-means et la CAH retrouvent à l'identique et que la silhouette valide (0,56). Un pôle d'**agricultures intensives** (forts intrants, hauts rendements et revenus, peu de sous-alimentation) s'oppose à un pôle d'**agricultures vivrières** (très rurales, pauvres, en insécurité alimentaire), un troisième groupe occupant une position **intermédiaire**. Une telle typologie aide à cibler les politiques agricoles : sécurité alimentaire et accès aux intrants pour le second groupe, durabilité et diversification pour le premier, accompagnement de la transition pour le troisième. Elle repose toutefois sur un jeu réduit de 21 pays et sur des indicateurs agrégés, à confirmer sur données réelles.

Correction de l'exercice 2 ▲

Comment lire cette correction

Comme l'exercice est à mener en autonomie, on donne ici une rédaction possible et les valeurs que R affiche. La numérotation des classes et l'ordre des feuilles du dendrogramme peuvent varier selon les versions : c'est la *composition* des groupes qui compte.

1. **Préparer.** Après import et mise des variétés en noms de lignes, on centre-réduit les six traits (`scale`). C'est indispensable car ils ne sont pas comparables : la hauteur se compte en centaines de cm, le cycle en dizaines de jours, le rendement en quelques t/ha, la tolérance sur une note de 1 à 10. Sans réduction, la hauteur ($\sigma \approx 76$) écraserait toutes les autres variables dans les distances. `round(head(don.cr), 2)` donne par exemple :

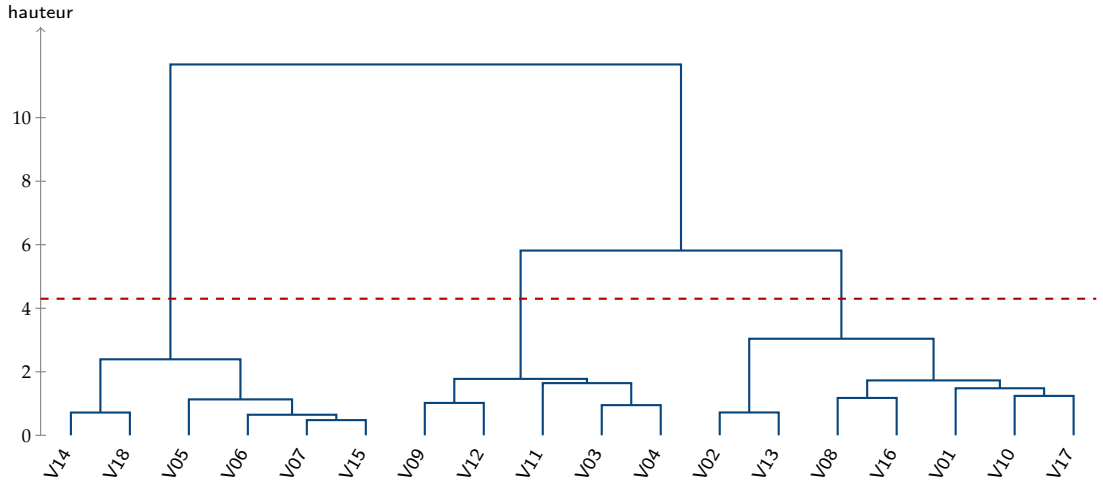
	Cycle	Hauteur	Rdt	Protéines	Tol_séch.	P1000
V01	−0,14	−0,45	0,41	1,22	−0,68	0,14
V02	0,13	0,40	0,32	0,79	1,01	0,54
V03	−1,07	−1,38	−1,36	0,64	1,44	−0,27
V04	−1,62	−0,93	−1,72	0,40	1,01	−0,47
V05	1,17	0,85	1,56	−1,63	−0,68	0,74
V06	1,11	1,10	0,85	−1,19	−1,11	0,34

2. **Choisir le nombre de classes.** Les diagnostics ne sont pas tout à fait unanimes :

- *silhouette moyenne* : légèrement meilleure pour $k = 2$ (0,56) que pour $k = 3$ (0,51) ;
- *dendrogramme / coude* : le plus grand saut de hauteur sépare les deux dernières fusions (11,7 puis 5,8), ce qui pointe aussi vers 2 ; mais la fusion suivante reste coûteuse (3,0 contre $< 2{,}4$ ensuite), ce qui rend $k = 3$ légitime.

On retient **trois classes** : le troisième groupe est agronomiquement informatif (un type intermédiaire riche en protéines), et les k-means comme la caractérisation le confirment. C'est un bon exemple où l'*interprétabilité* tranche entre deux découpages statistiquement proches.

3. **Deux partitions.** `kmeans(centers = 3, nstart = 25)` donne des classes de 7, 6 et 5 variétés ; la CAH de Ward (`ward.D2`, puis `cutree(k = 3)`) donne les trois mêmes groupes.



Sur le plan de l'ACP (`fviz_cluster`), les trois groupes sont bien distincts, le type intermédiaire se plaçant entre les deux autres.

4. **Comparer.** `table(kmeans, cah)` montre, à l'étiquette près, un **accord parfait** : chaque variété tombe dans le même groupe par les deux méthodes.

	CAH tardives	CAH précoces	CAH interm.
k-means tardives	6	0	0
k-means précoces	0	5	0
k-means interm.	0	0	7

Cet accord entre deux méthodes de logiques différentes confirme la robustesse de la typologie.

5. **Valider.** La silhouette moyenne vaut 0,51 (par classe : tardives 0,39, précoces 0,67, intermédiaires 0,50) ; aucune variété n'a de silhouette négative. La partition est satisfaisante. Le groupe des *tardives* est le moins homogène, et une ou deux variétés « frontière » (p. ex. V17, de silhouette faible) hésitent entre le type intermédiaire et un autre : c'est à discuter au cas par cas.

6. **Caractériser et nommer.** Moyennes par classe (traits d'origine) :

Classe	Cycle_j	Hauteur	Rdt_t/ha	Protéines	Tol_séch.	P1000
Tardives	**131**	**329**	**4,5**	**8,1**	**3,3**	**30,5**
Précoces	**88**	**154**	**1,9**	11,7	**8,6**	20,8
Intermédiaires	107	231	3,2	**12,4**	5,4	24,1
Ensemble	110	242	3,2	10,8	5,6	25,3

Valeurs-tests `HCPC` (significatives, $|v| \geq 1{,}96$) :

Classe	Valeurs-tests positives	Valeurs-tests négatives
Tardives	Cycle (+3,5), Hauteur (+3,4), Rdt (+3,3), P1000 (+3,2)	Protéines (−3,9), Tol_séch. (−2,9)
Précoces	Tol_séch. (+3,3)	Rdt (−3,2), Cycle (−3,1), Hauteur (−3,1), P1000 (−2,4)
Intermédiaires	Protéines (+2,6)	*aucune*

Noms possibles : **variétés tardives, hautes et productives** (gros grain, mais pauvres en protéines et sensibles à la sécheresse) ; **variétés précoces, courtes et très tolérantes à la sécheresse** (peu productives, petit grain) ; **variétés intermédiaires, riches en protéines**.

Synthèse. Les 18 variétés se répartissent en trois types, retrouvés à l'identique par k-means et par CAH et validés par la silhouette (0,51). Un premier type réunit les variétés **tardives, hautes et très productives**, au gros grain mais pauvres en protéines et sensibles à la sécheresse ; un deuxième, à l'opposé, des variétés **précoces, courtes et rustiques**, très tolérantes à la sécheresse mais peu productives ; un troisième, **intermédiaire**, se distingue surtout par sa richesse en protéines. Cette typologie oriente le choix variétal selon le contexte : les rustiques pour les zones sèches à risque, les productives pour les milieux favorables en recherche de rendement, les intermédiaires lorsque la qualité du grain prime. Quelques variétés frontière (faible silhouette) méritent une évaluation complémentaire avant conseil.

Étudiant(e) (Nom, Prénom) : .....

Promotion, groupe : .....

Email : .....