Exercice complet

Promotion 115

Exercice 1 Projet complet sous R : cacaoculture agroforestière du Centre Cameroun

Dans la région du Centre (Cameroun), le cacao est cultivé dans des systèmes très variés : vieilles *agroforêts* où les cacaoyers poussent sous un couvert dense d'arbres fruitiers et forestiers, et plantations plus récentes, plus denses et plus ensoleillées, conduites avec davantage d'intrants. Une union de coopératives de producteurs, en lien avec un programme de recherche agronomique, a suivi 600 **parcelles cacaoyères** ($I = 600$) pendant la campagne 2025-2026, réparties dans trois départements : la *Lekié* (bassin cacaoyer ancien, autour d'Obala), le *Mbam-et-Inoubou* et le *Mbam-et-Kim* (front pionnier plus récent). La question posée est double : **quels sont les grands types de cacaoyères** de la zone, et **quels compromis** observe-t-on entre production, revenu et services environnementaux (biodiversité, carbone) ?
Les données sont dans `data_stat-0125.xlsx` (feuille `parcelles` ; parcelles en lignes, variables en colonnes).

☞ Récupérer les données

Scanner le QR code avec un téléphone, ou cliquer sur le lien `data_stat-0125.xlsx`, puis télécharger le fichier avec le bouton Download raw file de la page GitHub. L'enregistrer dans le dossier `data_raw` de votre projet RStudio.

https://github.com/ant0in3g/ant0in3g.github.io/blob/main/sTa7/td-R-lab/R-lab/data_raw/data_stat-0125.xlsx

Variable	Description	Type / unité
`Parcelle`	identifiant de la parcelle	P001 à P600
`Zone`	département	Lekie, Mbam-et-Inoubou, Mbam-et-Kim
`Cooperative`	le producteur est membre d'une coopérative	Oui / Non
`Certification`	cacao vendu sous un label de certification	Oui / Non
`Surface_ha`	surface de la cacaoyère	ha
`Age_ans`	âge du verger	années
`Densite_pieds_ha`	densité de cacaoyers	pieds/ha
`Ombrage_pct`	couverture de la canopée d'ombrage	%
`Nb_especes_arbres`	nombre d'espèces d'arbres associés	espèces
`Fongicide_trait_an`	traitements fongicides par an	nombre
`MO_hj_ha`	main-d'œuvre	hommes-jours/ha/an
`Pourriture_pct`	cabosses atteintes de pourriture brune	%
`Rdt_kg_ha`	rendement en fèves sèches	kg/ha
`Prix_FCFA_kg`	prix moyen de vente bord-champ sur la campagne	FCFA/kg
`Carbone_t_ha`	stock de carbone aérien (cacaoyers + arbres)	t/ha

Extrait (six premières parcelles) :

Parc.	Zone	Coop.	Certif.	Surf.	Âge	Dens.	Omb.	Esp.	Fong.	MO	Pourr.	Rdt	Prix	Carb.
P001	Lekie	Oui	Oui	2,5	46	750	39	12	2	62	19	477	2720	46,2
P002	Mbam-et-Inoubou	Oui	Non	1,7	41	750	48	21	0	24	32	350	2340	55,2
P003	Mbam-et-Inoubou	Non	Non	1,6	44	1150	49	19	0	49	24	169	2315	79,5
P004	Lekie	Oui	Non	2,5	42	1020	33	21	3	34	29	370	2535	87,6
P005	Mbam-et-Inoubou	Oui	Non	2,2	30	1000	46	16	3	68	23	472	2670	63,4
P006	Lekie	Non	Non	2,2	23	1060	42	19	3	52	5	386	2250	68,0
						...								

Votre mission

Mener **seul(e) et sous R** l'analyse complète de ce jeu de données, depuis l'importation jusqu'à une note de synthèse. **Aucun code n'est fourni** : écrivez un script commenté et reproductible, justifiez chaque choix de méthode et interprétez chaque résultat en langage agronomique. **Durée indicative : 3 heures pour les parties A à E** ; la synthèse (partie F) se rédige *en dehors* de ce temps. À rendre : le script `.R` (ou un rapport R Markdown / Quarto) et la note de synthèse.

Partie A – Importation et qualité des données. (≈ 25 min)

A1. Importer le fichier, mettre les identifiants de parcelles en noms de lignes et vérifier la structure de l'objet obtenu (type de chaque colonne, effectifs).

A2. Le fichier brut n'est *pas* propre. Repérer et corriger les problèmes de saisie : modalités mal orthographiées des variables qualitatives, valeurs impossibles, données manquantes. Pour chaque problème, indiquer la ou les parcelles concernées et le traitement retenu, en le justifiant. Avec 600 lignes, pas question de parcourir le tableau à l'œil : tous les contrôles se font *par le code*. Distinguez aussi une valeur *impossible* d'une valeur *extrême mais plausible*.

A3. Transformer les variables qualitatives en facteurs, puis créer une nouvelle variable `Revenu_brut` (en milliers de FCFA/ha) à partir du rendement et du prix de vente.

Partie B – Statistique descriptive. (≈ 30 min)

B1. Univarié. Produire un tableau de synthèse des variables quantitatives (moyenne, écart-type, médiane, quartiles, coefficient de variation) et les tableaux d'effectifs et de fréquences des variables qualitatives. Quelles variables sont les plus dispersées ? Lesquelles présentent une distribution nettement asymétrique (histogrammes, boîtes à moustaches) ?

B2. Quanti × quali. Représenter le rendement, l'ombrage et le stock de carbone selon la zone (boîtes à moustaches juxtaposées) et calculer les moyennes par zone. Commenter.

B3. Quanti × quanti. Calculer la matrice des corrélations des variables quantitatives et la représenter graphiquement (`corrplot` ou équivalent). Repérer les groupes de variables fortement liées entre elles. Tracer le nuage rendement / ombrage.

B4. Quali × quali. Construire le tableau croisé `Cooperative` × `Certification` (effectifs et profils-lignes) et le représenter par un diagramme en barres.

Partie C – Tests statistiques classiques. (≈ 50 min)

Pour chaque question : formuler H_0 et H_1, vérifier les conditions d'application (normalité, homogénéité des variances, effectifs théoriques…), choisir le test *en le justifiant*, conclure au risque $\alpha = 5\,\%$ puis traduire la conclusion en une phrase compréhensible par un responsable de coopérative. Avec 600 parcelles, demandez-vous aussi si un écart *significatif* est pour autant *important* : donnez l'intervalle de confiance des écarts, et une **taille d'effet** en C2 (η^2) et en C4 (V de Cramér). Que valent les tests de normalité sur de si grands échantillons ? Enfin, combien de tests réalisez-vous dans cette partie, et qu'est-ce que cela implique pour le risque global de conclure à tort ?

C1. Le rendement moyen des membres de coopérative diffère-t-il de celui des non-membres ? Même question pour le prix de vente.

C2. Le rendement moyen diffère-t-il entre les trois zones ? Si oui, quelles zones diffèrent deux à deux ? Proposer aussi une alternative non paramétrique et comparer les conclusions.

C3. Le taux de pourriture brune suit-il une loi normale ? Comparer le taux de pourriture entre zones avec le test approprié.

C4. L'adhésion à une coopérative et la certification sont-elles indépendantes ? Même question pour la zone et l'adhésion à une coopérative. Discuter la validité du test du χ^2 et proposer une alternative si nécessaire.

C5. Tester la significativité de la corrélation entre l'ombrage et le rendement, puis entre l'ombrage et la pourriture brune (Pearson *et* Spearman). Une corrélation significative permet-elle de conclure que l'ombrage *cause* une baisse de rendement ? Argumenter.

Partie D – Analyse en composantes principales. (≈ 40 min)

D1. Réaliser une ACP sur les variables quantitatives décrivant les parcelles. Justifier : le choix d'une ACP *normée*, le choix des variables actives et des variables supplémentaires (quantitatives *et* qualitatives), le traitement des données manquantes.

D2. Combien d'axes retenir ? Argumenter à partir des valeurs propres (éboulis, critère de Kaiser, pourcentages d'inertie).

D3. Interpréter le ou les axes retenus en D2 : cercle des corrélations, variables les mieux représentées ($\cos^2$) et contributions. Donner un nom à chaque axe retenu.

D4. Représenter les parcelles sur le premier plan, colorées selon la zone, puis selon l'adhésion à une coopérative. Les modalités des variables supplémentaires sont-elles bien séparées (valeurs-tests) ? Repérer les parcelles atypiques.

Partie E – Classification ascendante hiérarchique. (≈ 35 min)

E1. Réaliser une CAH (critère de Ward) sur les coordonnées des parcelles issues de l'ACP. Justifier le nombre d'axes conservés pour la classification, et expliquer pourquoi il peut différer du nombre d'axes *interprétés* en D2.

E2. Choisir le nombre de classes à l'aide du dendrogramme et du diagramme des gains d'inertie ; confirmer par une autre méthode (silhouette, consolidation par k-means…). Si les critères ne concordent pas, trancher et justifier le choix.

E3. Caractériser chaque classe : variables quantitatives (moyennes par classe, valeurs-tests) et modalités qualitatives surreprésentées. Nommer les types de cacaoyères obtenus et identifier la parcelle la plus représentative (parangon) de chaque classe. Les valeurs-tests des variables actives ont-elles la même portée qu'un test de la partie C ?

E4. Serait-il légitime de *tester* si le rendement ou le revenu brut diffèrent entre les classes ? Testez en revanche la liaison entre la classe et les variables qui n'ont pas servi à la construire : zone, adhésion, certification et prix de vente (avec taille d'effet). Commenter.

Partie F – Synthèse. (hors temps, travail personnel)

F1. Rédiger une **note d'une page** à destination de l'union de coopératives : principaux types de cacaoyères, compromis observés entre rendement, revenu, pression sanitaire et services environnementaux (diversité d'arbres, carbone), et pistes d'accompagnement adaptées à chaque type.

F2. Indiquer les **limites** de l'étude : taille et mode de constitution de l'échantillon, indépendance des observations, nature observationnelle des données, variables manquantes pour juger de la durabilité des systèmes (revenus des autres produits de l'agroforêt, coûts des intrants, fertilité du sol…).

Indications. Fonctions utiles : `read_excel` (`readxl`), `str`, `summary`, `table`, `is.na`, `factor`, `tapply`, `aggregate`, `boxplot`, `cor`, `corrplot` ; `shapiro.test`, `var.test`, `bartlett.test`, `leveneTest` (`car`), `t.test`, `wilcox.test`, `aov`, `oneway.test`, `TukeyHSD`, `pairwise.t.test`, `kruskal.test`, `chisq.test`, `fisher.test`, `cor.test` ; `PCA`, `dimdesc`, `HCPC` (`FactoMineR`), `imputePCA` (`missMDA`) ; `fviz_eig`, `fviz_pca_var`, `fviz_pca_ind`, `fviz_dend`, `fviz_cluster` (`factoextra`) ; `silhouette` (`cluster`).

Contrôle. Après nettoyage : 3 zones (220, 200 et 180 parcelles), 292 membres de coopérative, 595 rendements exploitables et un ombrage moyen de 36 % environ. Le premier axe de l'ACP résume un peu plus de la moitié de l'inertie ; les axes suivants sont beaucoup plus faibles.

Sources. La démarche de cet exercice n'est pas originale. Elle reprend de nombreux exercices rencontrés, traités ou proposés dans de nombreux manuels, polycopiés et TD de statistique et d'analyse de données sous R. Le travail a surtout consisté ici à les **remettre en contexte** autour d'une thématique propre à l'ISTOM : la cacaoculture agroforestière du Centre Cameroun, et à les enchaîner sur un même jeu de données. Ce jeu de données est *simulé* à des fins pédagogiques.

[stat-0125]

Étudiant(e) (Nom, Prénom) : .....

Promotion, groupe : .....

Email : .....