Ecole supérieure d'agro-développement international
istom

# TD : Classification ascendante hiérarchique

*Promotion 115*

---

## Table des matières


**1 Synthèse : la classification ascendante hiérarchique** **2**
- 1.1 Position du problème et vocabulaire . . . 2
- 1.2 Mesurer la dissimilarité entre individus . . . 2
- 1.3 L'algorithme général . . . 3
- 1.4 Les critères d'agrégation (*linkage*) . . . 3
- 1.5 La formule de récurrence de Lance–Williams . . . 5
- 1.6 Le dendrogramme : lecture et propriétés . . . 5
- 1.7 Le critère de Ward en détail . . . 6
- 1.8 Choisir le nombre de classes . . . 6

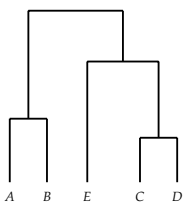
**2 Un exemple entièrement traité au critère de Ward** **7**

**3 Faire une CAH à la main** **11**
- Exercice 1 : CAH guidée à la main : typologie de cinq exploitations . . . 11
- Exercice 2 : CAH à la main : entraînement sur cinq exploitations . . . 13

**Corrections** **15**


Ce TD comporte **deux exercices pour faire une CAH à la main** (section 3) : une classification complète guidée pas à pas, puis un exercice d'entraînement à mener en autonomie.

Ces exercices couvrent l'essentiel de ce qu'un étudiant d'une école d'ingénieurs comme l'ISTOM doit savoir maîtriser sur la classification ascendante hiérarchique : comprendre d'où viennent les résultats en refaisant les calculs à la main (distances, critère de Ward, coûts de fusion, dendrogramme, choix du nombre de classes, décomposition de l'inertie), lire le dendrogramme avec esprit critique, caractériser les classes et nommer les groupes obtenus.




**Exercice 1** – à la main, guidé
dendrogramme de cinq exploitations



**Exercice 2** – à la main, entraînement
deux groupes à retrouver

# 1 Synthèse : la classification ascendante hiérarchique

La **classification** (en anglais *clustering*) cherche à organiser un ensemble d'individus en *classes* homogènes, sans qu'aucune étiquette ne soit donnée au départ : c'est une méthode d'*apprentissage non supervisé*. La **classification ascendante hiérarchique** (CAH ; en anglais *Hierarchical Agglomerative Clustering*, HAC) en est la famille la plus répandue. Plutôt qu'une partition unique, elle produit une *hiérarchie* de partitions emboîtées, résumée par un arbre, le **dendrogramme**, que l'on coupe à la hauteur voulue pour obtenir le nombre de classes souhaité.

Cette synthèse rassemble le cadre théorique. Les **travaux dirigés** qui suivent (page 11) en sont la mise en pratique, à la main.

## 1.1 Position du problème et vocabulaire

On part d'un tableau de $n$ **individus** décrits par $p$ **variables** ($x_i \in \mathbb{R}^p$). Deux grandes familles de méthodes de classification coexistent :

- les méthodes de **partitionnement** (par ex. les $k$-means), qui cherchent directement une partition en un nombre $k$ de classes *fixé à l'avance* ;
- les méthodes **hiérarchiques**, qui construisent un *emboîtement* de classes et ne fixent pas $k$ a priori.

Les méthodes hiérarchiques se déclinent elles-mêmes en deux approches :

- **ascendante** (agglomérative) : on part des $n$ individus isolés et on fusionne, de proche en proche, jusqu'à une classe unique ($n-1$ fusions) ;
- **descendante** (divisive, par ex. DIANA) : on part de la classe totale et on la scinde récursivement. Cette approche beaucoup moins utilisée que l'approche ascendante, seule traitée ici.

> **Idée directrice.** La CAH ne demande qu'une chose : savoir mesurer à quel point deux individus, puis deux *groupes* d'individus, se ressemblent. Tout le reste (l'arbre, les classes) en découle mécaniquement.

## 1.2 Mesurer la dissimilarité entre individus

La ressemblance entre deux individus se mesure par une **dissimilarité** $d(x_i, x_j) \geq 0$, symétrique, nulle lorsque $i = j$. Pour des variables quantitatives, on emploie le plus souvent une distance.

| Distance | Définition entre $x$ et $y$ de $\mathbb{R}^p$ |
|---|---|
| Euclidienne | $d_2(x,y) = \sqrt{\sum_{k=1}^{p} (x_k - y_k)^2}$ |
| Manhattan | $d_1(x,y) = \sum_{k=1}^{p} \lvert x_k - y_k \rvert$ |
| Minkowski ($m \geq 1$) | $d_m(x,y) = \left( \sum_{k=1}^{p} \lvert x_k - y_k \rvert^m \right)^{1/m}$ |
| Mahalanobis | $d_\Sigma(x,y) = \sqrt{(x-y)^\top \Sigma^{-1} (x-y)}$ |
| Cosinus | $d_{\cos}(x,y) = 1 - \dfrac{x \cdot y}{\lVert x \rVert \, \lVert y \rVert}$ |

Pour des variables qualitatives ou mixtes, on utilise des indices adaptés (distance de Hamming, dissimilarité de **Gower**, cette dernière accessible sous R par `daisy()` du package `cluster`).

**À retenir : standardiser.** La distance euclidienne additionne des écarts variable par variable : une variable à forte amplitude (une surface en hectares) écrase une variable à faible amplitude (un taux en %). On **centre et on réduit** donc chaque variable avant de classer, sauf si toutes sont déjà exprimées dans la même unité comparable.

**Centrer et réduire : la méthode**

Pour une variable $X$ mesurée sur les $n$ individus (valeurs $x_1, \dots, x_n$) :

1. calculer la moyenne $\overline{X} = \dfrac{1}{n}\sum_{i=1}^{n} x_i$ ;
2. calculer l'écart-type $\sigma_X = \sqrt{\dfrac{1}{n}\sum_{i=1}^{n}\left(x_i - \overline{X}\right)^2}$ ;
3. remplacer chaque valeur par sa version *centrée réduite*

$$z_i = \frac{x_i - \overline{X}}{\sigma_X}.$$

La nouvelle variable $Z$ a alors une moyenne nulle et un écart-type égal à $1$ ; elle est sans unité. On répète l'opération pour chacune des $p$ variables, de sorte qu'elles pèsent toutes autant dans le calcul de la distance. (Sous R : la fonction `scale()`.)

## 1.3 L'algorithme général

**Schéma de la CAH**

**Entrée :** les $n$ individus et une dissimilarité $d$.

1. **Initialisation.** Chaque individu forme sa propre classe ; on calcule la matrice des dissimilarités.
2. **Répéter** jusqu'à n'avoir qu'une classe : trouver les deux classes $C_i$ et $C_j$ les plus proches au sens d'un *critère d'agrégation* $D(C_i, C_j)$, les fusionner, enregistrer la fusion et sa hauteur, puis mettre à jour les dissimilarités entre la nouvelle classe et les autres.

**Sortie :** l'arbre des $n-1$ fusions (le dendrogramme).

**Pourquoi « glouton » ?** À chaque étape, la CAH fait le choix qui semble le meilleur *sur le moment* , réunir les deux classes les plus proches, sans jamais revenir en arrière : on dit qu'elle est **gloutonne**.

C'est simple et rapide, mais une fusion décidée tôt est *définitive*. Deux individus regroupés au début resteront dans la même classe jusqu'au bout, même si, au vu de l'ensemble des données, il aurait finalement mieux valu les séparer. La partition obtenue est donc une *bonne* solution construite pas à pas, pas nécessairement la meilleure possible.

## 1.4 Les critères d'agrégation (*linkage*)

Tout l'enjeu est de définir la distance $D(C_i, C_j)$ *entre deux groupes* à partir de la distance $d$ entre individus. Les principaux critères :

**Définition 1** (Critères d'agrégation).
Pour deux classes $C_i$ et $C_j$ d'effectifs $n_i, n_j$ et de centres de gravité $g_i, g_j$ :

$$\text{lien simple (min)} : \quad D(C_i, C_j) = \min_{x \in C_i, y \in C_j} d(x, y),$$

$$\text{lien complet (max)} : \quad D(C_i, C_j) = \max_{x \in C_i, y \in C_j} d(x, y),$$

$$\text{lien moyen (UPGMA)} : \quad D(C_i, C_j) = \frac{1}{n_i n_j} \sum_{x \in C_i} \sum_{y \in C_j} d(x, y),$$

$$\text{lien du centroïde} : \quad D(C_i, C_j) = \|g_i - g_j\|^2,$$

$$\text{critère de Ward} : \quad D(C_i, C_j) = \frac{n_i\, n_j}{n_i + n_j} \|g_i - g_j\|^2.$$

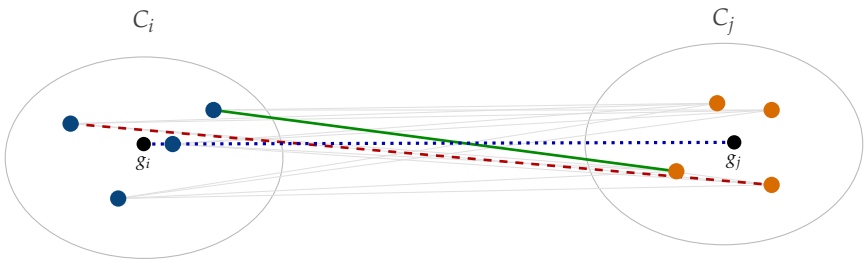
Pour les deux derniers critères, $g_i$ et $g_j$ sont les **centres de gravité** des classes et $\|g_i - g_j\|^2$ est le **carré de la distance euclidienne** entre ces deux centres.

- Le *lien du centroïde* prend directement cette quantité. Il mesure l'éloignement des deux «individus moyens».
- Le *critère de Ward* la pondère par le coefficient $\frac{n_i\, n_j}{n_i + n_j}$, qui dépend des effectifs $n_i, n_j$ des deux classes.

  Par exemple à distance égale entre centres, fusionner deux *petites* classes coûte moins cher que fusionner deux grosses, de sorte que les petits groupes proches se réunissent en premier. Ce coût $D(C_i, C_j)$ est exactement l'**augmentation de l'inertie intra-classe** provoquée par la fusion : c'est la « hauteur » reportée sur le dendrogramme.

On rencontre aussi le *lien moyen pondéré* (WPGMA, dit de McQuitty) et le *lien médian* (WPGMC). Chaque critère imprime une « forme » aux classes :

| Critère | Tendance | Remarque |
|---|---|---|
| Lien simple | classes allongées, filaments | équivaut à l'arbre couvrant minimal ; sujet à l'*effet de chaîne* |
| Lien complet | classes compactes, sphériques | sensible aux points aberrants |
| Lien moyen | compromis des deux précédents | robuste au bruit |
| Centroïde / médian | fondés sur les centres | peuvent créer des *inversions* |
| Ward | classes compactes, de tailles proches | le plus utilisé en pratique |




**lien simple** : la paire la plus proche (min)

**lien complet** : la paire la plus éloignée (max)

**lien centroïde** : entre les centres $g_i$ et $g_j$

**lien moyen** : moyenne de toutes les paires (en gris)

**Remarque** (Le critère de Ward et l'inertie)**.**
Le critère de Ward mesure l'**augmentation d'inertie intra-classe** provoquée par la fusion : il regroupe les classes dont la réunion « coûte » le moins de dispersion.

## 1.5 La formule de récurrence de Lance–Williams

Recalculer les distances de groupe à partir des individus à chaque étape serait coûteux. La **formule de Lance–Williams** (1967) exprime la distance entre une classe fusionnée $C_i \cup C_j$ et une autre classe $C_k$ *uniquement* à partir des distances déjà connues :

**Proposition 1** (Récurrence de Lance–Williams)**.**

$$D(C_i \cup C_j,\, C_k) = \alpha_i\, D(C_i, C_k) + \alpha_j\, D(C_j, C_k) + \beta\, D(C_i, C_j) + \gamma\, |D(C_i, C_k) - D(C_j, C_k)|.$$

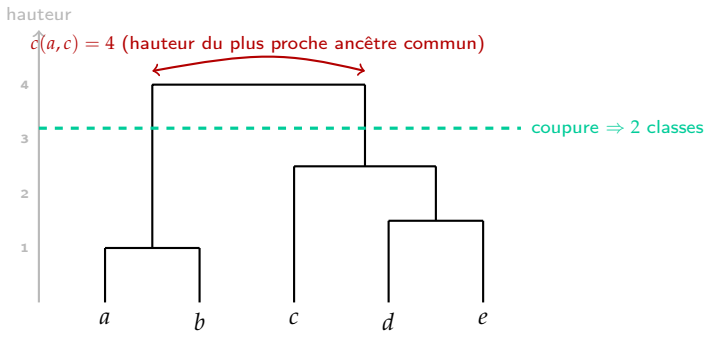
*Les coefficients $(\alpha_i, \alpha_j, \beta, \gamma)$ caractérisent le critère d'agrégation.*

| **Critère** | $\alpha_i$ | $\alpha_j$ | $\beta$ | $\gamma$ |
|---|---|---|---|---|
| Lien simple | $\frac{1}{2}$ | $\frac{1}{2}$ | $0$ | $-\frac{1}{2}$ |
| Lien complet | $\frac{1}{2}$ | $\frac{1}{2}$ | $0$ | $+\frac{1}{2}$ |
| Lien moyen (UPGMA) | $\frac{n_i}{n_i+n_j}$ | $\frac{n_j}{n_i+n_j}$ | $0$ | $0$ |
| Moyen pondéré (McQuitty) | $\frac{1}{2}$ | $\frac{1}{2}$ | $0$ | $0$ |
| Centroïde | $\frac{n_i}{n_i+n_j}$ | $\frac{n_j}{n_i+n_j}$ | $-\frac{n_i n_j}{(n_i+n_j)^2}$ | $0$ |
| Médian | $\frac{1}{2}$ | $\frac{1}{2}$ | $-\frac{1}{4}$ | $0$ |
| Ward | $\frac{n_i+n_k}{n_i+n_j+n_k}$ | $\frac{n_j+n_k}{n_i+n_j+n_k}$ | $-\frac{n_k}{n_i+n_j+n_k}$ | $0$ |

**Remarque** (Portée)**.**
Le centroïde, le médian et Ward s'appliquent sur des distances *euclidiennes au carré*. La récurrence met à jour chaque distance en temps constant : elle est le moteur des implémentations efficaces et unifie tous les critères sous une même écriture.

## 1.6 Le dendrogramme : lecture et propriétés

Le **dendrogramme** représente les fusions successives ; la *hauteur* d'un nœud est la valeur du critère $D$ au moment de la fusion. Couper l'arbre par une ligne horizontale fournit une partition : le nombre de branches coupées est le nombre de classes.




**Définition 2** (Distance cophénétique)**.**
La **distance cophénétique** $c(i,i')$ entre deux individus est la hauteur du plus petit nœud de l'arbre qui les contient tous les deux. Les $c(i,i')$ forment une *ultramétrique* : $c(i,i') \leq \max\big(c(i,k), c(k,i')\big)$ pour tout $k$. Un dendrogramme équivaut exactement à une ultramétrique.

**Qualité de l'arbre : la corrélation cophénétique.** On mesure la fidélité du dendrogramme aux données par le **coefficient de corrélation cophénétique** : la corrélation de Pearson entre les dissimilarités d'origine $d(i,i')$ et les distances cophénétiques $c(i,i')$. Proche de 1, l'arbre résume bien les distances ; faible, il les déforme.

**Proposition 2** (Monotonie et inversions)**.**
*Avec les liens simple, complet, moyen et Ward, les hauteurs de fusion sont* ***croissantes*** *le long de l'arbre : il n'y a jamais d'*inversion*. Les liens du* ***centroïde*** *et* ***médian*** *ne garantissent pas cette monotonie : une fusion peut se produire à une hauteur* inférieure *à une fusion antérieure, ce qui rend le dendrogramme difficile à lire.*

## 1.7 Le critère de Ward en détail

Le critère de Ward (1963) choisit, à chaque étape, la fusion qui augmente le moins l'**inertie intra-classe**, autrement dit qui fait perdre le moins d'inertie inter-classe.

**Proposition 3** (Coût de fusion de Ward)**.**
*Fusionner $C_i$ et $C_j$ augmente l'inertie intra de*

$$\Delta(C_i, C_j) = \frac{n_i\, n_j}{n_i + n_j} \|g_i - g_j\|^2.$$

*La somme des $n-1$ coûts de fusion de tout l'arbre est égale à l'****inertie totale*** *du nuage.*

**Remarque** (Lien avec Huygens)**.**
La décomposition de Huygens $\mathcal{I}_{\text{tot}} = \mathcal{I}_{\text{intra}} + \mathcal{I}_{\text{inter}}$ étant fixe, minimiser la perte d'inertie inter à chaque fusion revient à garder les classes aussi séparées que possible. Pour une coupure en deux classes, l'inertie inter est exactement la hauteur de la dernière fusion. C'est la propriété vérifiée « à la main » dans l'exercice 1.

## 1.8 Choisir le nombre de classes

Aucun critère n'est universel ; on croise plusieurs lectures :

- **saut de hauteur** (règle du coude) : on coupe juste en dessous du plus grand écart entre deux fusions successives ;
- **part d'inertie expliquée** $\mathcal{I}_{\text{inter}}/\mathcal{I}_{\text{tot}}$, à mettre en regard du nombre de classes (critère de Ward) ;
- **silhouette** moyenne, **statistique de l'écart** (*gap statistic*) ;
- **interprétabilité** : des classes que l'on sait nommer et utiliser.

**Remarque** (Séparation forte)**.**
Si les données vérifient la *séparation forte*, tout individu est plus proche des individus de sa classe que de tout individu d'une autre classe — alors le lien simple retrouve exactement la vraie partition, qui est une coupe de son arbre. En pratique cette condition est rarement satisfaite, d'où l'intérêt des liens moyen et de Ward.

**Recette pratique**

1. Centrer-réduire les variables (ou choisir une dissimilarité adaptée).
2. En grande dimension, réduire d'abord par une ACP, puis classer sur les premières composantes (sous R : `HCPC` de `FactoMineR`).
3. Préférer **Ward** (ou le lien moyen) pour des classes compactes ; le lien simple pour des formes allongées.
4. Lire le dendrogramme *et* le diagramme des sauts d'inertie pour choisir $k$.
5. **Consolider** la partition par quelques itérations de $k$-means.
6. Caractériser chaque classe (moyennes, valeurs-tests) et la nommer.

**Remarque** (Sources)**.**
Cette synthèse s'appuie sur F. Nielsen, *Hierarchical Clustering* (chap. 8, 2016) ; le cours *stats306b* de L. Mackey (Stanford) ; les notes de D. Sontag (MIT, ML 2013) et de Princeton (COS 324) ; E. García-Portugués, *Notes for Predictive Modeling* (UC3M) ; ainsi que les supports de TU Dortmund, UCL, UBC et Al-Mustansiriyah cités en référence du TD.

# 2 Un exemple entièrement traité au critère de Ward

Pour relier toute la théorie qui précède, déroulons une CAH de Ward *complète*, du tableau de données jusqu'au nom des classes, sur un petit cas réaliste : six exploitations de la zone cacaoyère d'**Obala** (Cameroun). Tous les calculs sont détaillés, et les nombres ont été choisis pour « tomber juste ».

## Les données

Six exploitations sont décrites par trois variables **actives** — la surface, le cheptel bovin et la part de cacao —, qui servent à *construire* les classes, et une variable **supplémentaire** — l'accès à la route —, qui servira seulement à *décrire* les classes ensuite. Question : quels types d'exploitations se dégagent, et sont-ils liés à l'accès au marché ?

| **Exploitation** | Surface (ha) | Bovins (têtes) | Cacao (% surf.) | Accès route |
|---|---|---|---|---|
| $E_1$ | 3 | 4 | 30 | piste |
| $E_2$ | 1 | 2 | 20 | piste |
| $E_3$ | 4 | 10 | 30 | piste |
| $E_4$ | 4 | 12 | 30 | bitumée |
| $E_5$ | 5 | 4 | 60 | bitumée |
| $E_6$ | 7 | 4 | 70 | bitumée |
| **Moyenne** | 4 | 6 | 40 | — |
| **Écart-type** (div. 5) | 2 | 4 | 20 | — |

**Variable active ou supplémentaire ?** Une variable **active** entre dans le calcul des distances : elle façonne les classes. Une variable **supplémentaire** est mise de côté pendant la classification, puis projetée a posteriori pour aider à interpréter (jamais pour fabriquer) les classes.

## Étape 1 — Centrer et réduire

Les unités n'ont rien à voir : le cacao (jusqu'à 70) écraserait la surface (jusqu'à 7) et les bovins. On remplace donc chaque valeur par $z = \dfrac{x - \overline{X}}{\sigma}$.

| | Surface | Bovins | Cacao |
|---|---|---|---|
| $E_1$ | $-0{,}5$ | $-0{,}5$ | $-0{,}5$ |
| $E_2$ | $-1{,}5$ | $-1$ | $-1$ |
| $E_3$ | 0 | 1 | $-0{,}5$ |
| $E_4$ | 0 | 1,5 | $-0{,}5$ |
| $E_5$ | 0,5 | $-0{,}5$ | 1 |
| $E_6$ | 1,5 | $-0{,}5$ | 1,5 |

**Remarque** (Deux détails utiles)**.**
On a pris ici l'écart-type « corrigé » (diviseur $n-1=5$) uniquement pour que les écarts-types tombent sur des entiers (2, 4, 20) ; la méthode est identique avec le diviseur $n$. Avec ce choix, la somme des carrés de *chaque* colonne vaut 5 : l'inertie totale du nuage vaut donc $\mathcal{I}_{\text{tot}} = 3 \times 5 = \mathbf{15}$.

## Étape 2 — La matrice des distances au carré

On calcule, sur les données centrées-réduites, $d^2(E_i, E_j) = \sum_{k=1}^{3} (z_{ik} - z_{jk})^2$. Par exemple $d^2(E_3, E_4) = (0-0)^2 + (1-1{,}5)^2 + (-0{,}5+0{,}5)^2 = 0{,}25$.

| $d^2$ | $E_2$ | $E_3$ | $E_4$ | $E_5$ | $E_6$ |
|---|---|---|---|---|---|
| $E_1$ | 1,5 | 2,5 | 4,25 | 3,25 | 8 |
| $E_2$ | | 6,5 | 8,75 | 8,25 | 15,5 |
| $E_3$ | | | **0,25** | 4,75 | 8,5 |
| $E_4$ | | | | 6,5 | 10,25 |
| $E_5$ | | | | | 1,25 |

La plus petite distance est $d^2(E_3, E_4) = 0{,}25$ : ce sera la première fusion.

## Étape 3 — Les fusions de Ward

On construit, à chaque étape, le tableau des **coûts de Ward** $\Delta$ entre les classes du moment :

$$\Delta(a,b) = \frac{m_a\, m_b}{m_a + m_b}\, d^2(g_a, g_b), \qquad \Delta = \tfrac{1}{2}\, d^2 \text{ pour deux individus seuls.}$$

On repère le **minimum** (il donne la fusion suivante *et* sa hauteur sur le dendrogramme), on fusionne, puis on **recalcule** les coûts vers la nouvelle classe — à partir de son centre de gravité, ou par la récurrence de Lance–Williams vue dans la synthèse. On recommence jusqu'à une seule classe.

**Départ — 6 classes.** Les coûts valent $\Delta = \frac{1}{2}d^2$ (la moitié du tableau de l'étape 2) :

| $\Delta$ | $E_2$ | $E_3$ | $E_4$ | $E_5$ | $E_6$ |
|---|---|---|---|---|---|
| $E_1$ | 0,75 | 1,25 | 2,125 | 1,625 | 4 |
| $E_2$ | | 3,25 | 4,375 | 4,125 | 7,75 |
| $E_3$ | | | **0,125** | 2,375 | 4,25 |
| $E_4$ | | | | 3,25 | 5,125 |
| $E_5$ | | | | | 0,625 |

Minimum **0,125** : on réunit $E_3$ et $E_4$, de centre $g_{34} = (0\,;1{,}25\,;-0{,}5)$.

**Après la fusion 1 — 5 classes.** On recalcule les coûts vers $\{E_3E_4\}$, par exemple $\Delta(E_1, \{E_3E_4\}) = \frac{1\cdot 2}{3}\, d^2(E_1, g_{34}) = \frac{2}{3} \times 3{,}31 = 2{,}21$ :

| $\Delta$ | $E_2$ | $\{E_3E_4\}$ | $E_5$ | $E_6$ |
|---|---|---|---|---|
| $E_1$ | 0,75 | 2,21 | 1,625 | 4 |
| $E_2$ | | 5,04 | 4,125 | 7,75 |
| $\{E_3E_4\}$ | | | 3,71 | 6,21 |
| $E_5$ | | | | **0,625** |

Minimum **0,625** : on réunit $E_5$ et $E_6$, de centre $g_{56} = (1\,;-0{,}5\,;1{,}25)$.

**Après la fusion 2 — 4 classes.**

| $\Delta$ | $E_2$ | $\{E_3E_4\}$ | $\{E_5E_6\}$ |
|---|---|---|---|
| $E_1$ | **0,75** | 2,21 | 3,54 |
| $E_2$ | | 5,04 | 7,71 |
| $\{E_3E_4\}$ | | | 7,13 |

Minimum **0,75** : on réunit $E_1$ et $E_2$, de centre $g_{12} = (-1\,;-0{,}75\,;-0{,}75)$.

**Après la fusion 3 — 3 classes.**

| $\Delta$ | $\{E_3E_4\}$ | $\{E_5E_6\}$ |
|---|---|---|
| $\{E_1E_2\}$ | **5,06** | 8,06 |
| $\{E_3E_4\}$ | | 7,13 |

Minimum **5,06** : on réunit $\{E_1, E_2\}$ et $\{E_3, E_4\}$.

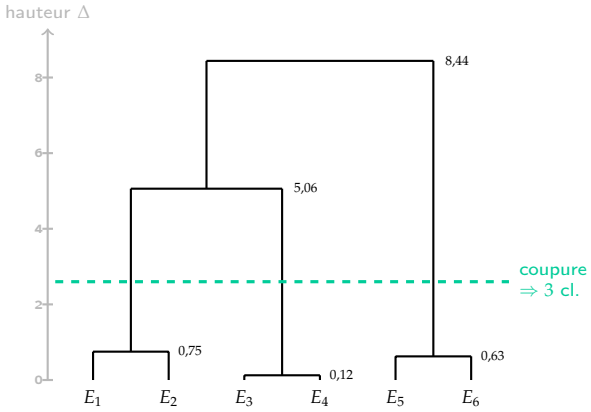
**Après la fusion 4 — 2 classes.** Il ne reste que $\{E_1, E_2, E_3, E_4\}$ (masse 4, centre $(-0{,}5\,;0{,}25\,;-0{,}625)$) et $\{E_5, E_6\}$ : leur coût vaut $\Delta = \frac{4\cdot 2}{6}\, d^2 = \frac{8}{6} \times 6{,}33 = \mathbf{8{,}44}$. C'est la dernière fusion, la racine de l'arbre.

En récapitulant, les cinq minimums successifs sont les hauteurs du dendrogramme :

| Fusion | Groupes réunis | Hauteur $\Delta$ |
|---|---|---|
| 1 | $E_3$ et $E_4$ | 0,125 |
| 2 | $E_5$ et $E_6$ | 0,625 |
| 3 | $E_1$ et $E_2$ | 0,75 |
| 4 | $\{E_1, E_2\}$ et $\{E_3, E_4\}$ | 5,06 |
| 5 | tout | 8,44 |

✓ **Contrôle** la somme des hauteurs vaut $0{,}125 + 0{,}625 + 0{,}75 + 5{,}06 + 8{,}44 = 15$, soit l'inertie totale.

## Le dendrogramme



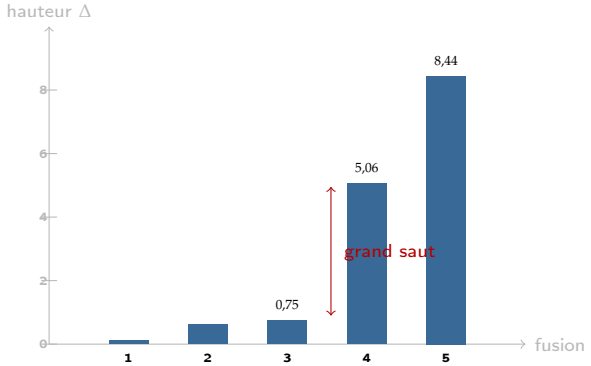

## Étape 4 — Choisir le nombre de classes

Couper le dendrogramme à une hauteur donnée, c'est tracer une ligne horizontale : le nombre de branches qu'elle traverse est le nombre de classes. Reste à décider *où* couper. On s'appuie sur deux lectures complémentaires qui, ici, concordent.

**1) Le saut d'inertie (règle du coude).** On range les hauteurs de fusion dans l'ordre et on regarde l'écart entre deux fusions successives.

| Fusion | 1 | 2 | 3 | 4 | 5 |
|---|---|---|---|---|---|
| Hauteur $\Delta$ | 0,12 | 0,63 | 0,75 | 5,06 | 8,44 |
| Saut depuis la précédente | — | 0,51 | 0,12 | **4,31** | 3,38 |

Les trois premières fusions coûtent très peu (0,12 à 0,75) : elles réunissent des exploitations déjà semblables. La quatrième coûte d'un coup 5,06 : pour descendre de 3 à 2 classes, il faudrait réunir deux groupes très différents. Cet écart, le plus grand de tous (4,31), est le **grand saut** : on coupe juste en dessous, donc à **3 classes**.



**2) La part d'inertie conservée.** Pour chaque nombre de classes, l'inertie inter (ce que les classes « expliquent ») vaut $\mathcal{I}_{\text{tot}} = 15$ moins la somme des hauteurs déjà « consommées » par les fusions.

| Nombre de classes | 6 | 5 | 4 | 3 | 2 | 1 |
|---|---|---|---|---|---|---|
| Inertie intra cumulée | 0 | 0,12 | 0,75 | 1,5 | 6,56 | 15 |
| % d'inertie conservée | 100 | 99,2 | 95,0 | **90,0** | 56,3 | 0 |

Même message : passer de 3 à 2 classes fait chuter le résumé de 90 % à 56 % — une seule fusion détruit 34 points d'un coup, c'est elle qu'il faut refuser. En deçà (de 6 à 3 classes), chaque fusion ne coûte presque rien.

**La décision.** Les deux critères pointent vers **3 classes** :

$$C_1 = \{E_1, E_2\}, \qquad C_2 = \{E_3, E_4\}, \qquad C_3 = \{E_5, E_6\},$$

qui conservent $\dfrac{15 - 1{,}5}{15} = \mathbf{90}\,\%$ de l'information. En pratique, on confirme ce choix par l'*interprétabilité* des classes (étapes 5–6) et, sur de vraies données, par la consolidation et des indices comme la silhouette (cf. synthèse).

> **Pourquoi couper *en dessous* du saut ?** Couper en dessous du grand saut revient à *refuser* la fusion coûteuse : on garde séparés deux groupes très différents. Couper au-dessus reviendrait à les avoir réunis, donc à fabriquer une classe artificiellement hétérogène, exactement ce que la hauteur du saut déconseille.

## Étape 5 — Décrire les classes

On revient aux *variables d'origine* et on calcule les moyennes par classe.

| | Surface (ha) | Bovins | Cacao (%) |
|---|---|---|---|
| $C_1$ | **2** | 3 | 25 |
| $C_2$ | 4 | **11** | 30 |
| $C_3$ | 6 | 4 | **65** |
| Ensemble | 4 | 6 | 40 |

La **valeur-test** confirme : $C_2$ se distingue par ses bovins et $C_3$ par son cacao (valeur-test $\approx +2{,}17$ pour chacun, donc $\geq 1{,}96$) ; toutes les autres valeurs-tests sont comprises entre $-2$ et 2, non significatives.

**La variable supplémentaire (accès à la route).** Les deux exploitations de $C_3$ sont sur route bitumée — mais c'est aussi le cas de la moitié de l'échantillon. La probabilité de tirer « par hasard » deux exploitations bitumées parmi les deux de $C_3$ vaut $\binom{3}{2}/\binom{6}{2} = 3/15 = 0{,}20$ : ce n'est pas assez rare pour conclure à un lien. Prudence, donc : l'accès à la route ne caractérise pas les classes ici.

## Étape 6 — Nommer les classes

| Classe | Nom | Conseil adapté |
|---|---|---|
| $C_1$ | Petites exploitations vivrières | sécurité alimentaire, cultures vivrières |
| $C_2$ | Agro-éleveurs | santé animale, alimentation du bétail |
| $C_3$ | Cacaoculteurs | itinéraire technique du cacao, commercialisation |

> **Le piège à éviter.** Sans centrer-réduire, la même CAH donnerait les classes $\{E_1, E_3, E_4\}$, $\{E_2\}$ et $\{E_5, E_6\}$ : le cacao, de grande amplitude, écrase tout et le nombre de bovins est presque ignoré. L'étape 1 n'est donc pas une formalité, elle change le résultat.

# 3 Faire une CAH à la main

## Exercice 1 CAH guidée à la main : typologie de cinq exploitations

Une coopérative agricole d'une zone soudano-sahélienne veut y voir clair dans la diversité de ses membres. Pour cinq exploitations $A, B, C, D, E$, elle résume chaque système par **deux indicateurs** notés sur une même échelle de 0 à 10 ($K = 2$) :

- $X_1$ **(intensification) :** recours aux intrants et à la mécanisation ;
- $X_2$ **(intégration de l'élevage) :** place de l'élevage dans le système.

| Exploitation | $X_1$ : intensification | $X_2$ : élevage |
|---|---|---|
| $A$ | 1 | 2 |
| $B$ | 2 | 1 |
| $C$ | 6 | 5 |
| $D$ | 7 | 5 |
| $E$ | 4 | 4 |

**À la main**

On mène **entièrement à la main** une classification ascendante hiérarchique (CAH) de ces $I = 5$ exploitations selon le **critère de Ward**, puis on interprète l'arbre obtenu. Des lignes ✓ **Contrôle** permettent de vérifier chaque étape avant de continuer ; les encadrés bleus rappellent le cours. Ici les deux indicateurs sont déjà sur la même échelle : inutile de les centrer-réduire.

**Convention.** Dans tout l'exercice, l'inertie d'un nuage est la **somme** des carrés des distances à son centre de gravité (chaque individu compte pour 1). Avec cette convention, la somme des hauteurs de fusion de l'arbre est exactement l'inertie totale du nuage.

### 1. Le nuage et son inertie

**Centre de gravité et inertie**

Chaque exploitation est un point du plan $(X_1, X_2)$. Le **centre de gravité** $G$ est le point moyen, de coordonnées $(\overline{X}_1 ; \overline{X}_2)$ : c'est l'« exploitation moyenne ». Le carré de la distance d'un point $i$ à $G$ se calcule par Pythagore :

$$d^2(i, G) = (x_{i1} - \overline{X}_1)^2 + (x_{i2} - \overline{X}_2)^2.$$

L'**inertie totale** $\mathcal{I}_{\text{tot}} = \sum_{i=1}^{I} d^2(i, G)$ mesure la dispersion globale du nuage : plus elle est grande, plus les exploitations sont hétérogènes.

a) Placer les cinq exploitations dans le plan $(X_1, X_2)$.

b) Calculer les coordonnées du centre de gravité $G = (\overline{X}_1 ; \overline{X}_2)$.

c) Calculer l'inertie totale $\mathcal{I}_{\text{tot}} = \sum_i d^2(i, G)$.

✓ **Contrôle** $\overline{X}_1 = 4$, $\overline{X}_2 = 3{,}4$ et $\mathcal{I}_{\text{tot}} = 39{,}2$.

**2. La matrice des distances** Pour regrouper des points, il faut d'abord savoir lesquels sont proches. Compléter le tableau des **carrés des distances** $d^2(i, j) = (x_{i1} - x_{j1})^2 + (x_{i2} - x_{j2})^2$ entre exploitations (la matrice est symétrique, on ne remplit que le triangle inférieur).

| $d^2$ | $A$ | $B$ | $C$ | $D$ |
|---|---|---|---|---|
| $B$ | | | | |
| $C$ | | | | |
| $D$ | | | | |
| $E$ | | | | |

✓ **Contrôle** la plus petite distance est $d^2(C,D) = 1$, la plus grande $d^2(A,D) = 45$.

### 3. La première fusion

**Le critère de Ward.** À chaque étape, la CAH réunit les deux classes $a$ et $b$ dont le regroupement coûte le moins d'inertie. Ce coût est

$$\Delta(a,b) = \frac{m_a\, m_b}{m_a + m_b}\, d^2(g_a, g_b),$$

où $m_a, m_b$ sont les effectifs des deux classes et $g_a, g_b$ leurs centres de gravité. **Pour deux individus seuls** ($m_a = m_b = 1$), ce coût se réduit à $\Delta = \frac{1}{2}\, d^2(a,b)$.

a) Au départ, chaque exploitation forme sa propre classe. En déduire, à partir de la matrice de la question 2, le coût $\Delta$ de chaque fusion possible (c'est la moitié de chaque distance).

b) Quelle paire fusionne-t-on en premier ? Donner le coût de cette fusion.

✓ **Contrôle** on réunit $C$ et $D$, pour un coût $\Delta = 0{,}5$.

### 4. Mettre à jour, puis fusionner encore

**Comment continuer après une fusion ?**

La classe $\{C,D\}$ est maintenant représentée par son centre de gravité $g_{CD}$ et sa masse $m = 2$. Pour la fusionner avec une autre exploitation $x$ (masse 1), on applique la formule de Ward :

$$\Delta(x, \{C,D\}) = \frac{1 \times 2}{1+2}\, d^2(x, g_{CD}) = \tfrac{2}{3}\, d^2(x, g_{CD}).$$

Les fusions entre exploitations encore seules gardent, elles, le coût $\frac{1}{2}d^2$.

a) Calculer $g_{CD}$, puis $\Delta(A,\{C,D\})$, $\Delta(B,\{C,D\})$ et $\Delta(E,\{C,D\})$.

b) Comparer avec le coût de la meilleure fusion entre exploitations seules restantes. Quelle est la deuxième fusion ?

✓ **Contrôle** on réunit $A$ et $B$ ($\Delta = 1$), moins coûteux que de rattacher $E$ à $\{C,D\}$.

### 5. Les dernières fusions

Il reste trois classes : $\{A,B\}$, $\{C,D\}$ et $\{E\}$.

a) Calculer les coûts $\Delta$ des trois regroupements possibles et en déduire la troisième fusion.

✓ **Contrôle** $E$ rejoint $\{C,D\}$ pour $\Delta = \frac{2}{3} \times 7{,}25 \approx 4{,}83$.

b) Il ne reste que deux classes, $\{A,B\}$ et $\{C,D,E\}$. Calculer le coût de la dernière fusion.

✓ **Contrôle** $\Delta = \frac{2\times 3}{5}\, d^2(g_{AB}, g_{CDE}) \approx 32{,}87$.

### 6. Le dendrogramme

**Lecture.** Le **dendrogramme** représente l'histoire des fusions : en bas les exploitations, et chaque regroupement est tracé à une *hauteur* égale à son coût $\Delta$. Plus une fusion est haute, plus elle réunit des classes différentes.

a) Reporter les quatre hauteurs de fusion dans le tableau.

| Fusion | $C$–$D$ | $A$–$B$ | $E$–$\{C,D\}$ | $\{A,B\}$–$\{C,D,E\}$ |
|---|---|---|---|---|
| Hauteur $\Delta$ | | | | |

b) **Contrôle par le théorème de Huygens.** Vérifier que la somme des quatre hauteurs est égale à l'inertie totale de la question 1.

✓ **Contrôle** $0{,}5 + 1 + 4{,}83 + 32{,}87 = 39{,}2 = \mathcal{I}_{\text{tot}}$.

c) Tracer le dendrogramme (axe vertical = hauteur de fusion) en respectant l'ordre des feuilles $A, B, E, C, D$.

### 7. Combien de classes ?

> **Le saut d'inertie**
> On coupe l'arbre *juste en dessous* d'un grand saut de hauteur : les fusions situées au-dessus réunissent des classes trop différentes pour être mélangées. La part d'inertie expliquée par une partition est le rapport $\mathcal{I}_B/\mathcal{I}_{\text{tot}}$, et pour une coupure en deux classes, $\mathcal{I}_B$ est exactement la hauteur de la dernière fusion.

a) Entre quelles fusions se situe le plus grand saut de hauteur ? Combien de classes retient-on ?

b) Donner la composition des classes et la part d'inertie qu'elles expliquent.

✓ **Contrôle** deux classes, $\{A, B\}$ et $\{C, D, E\}$, qui expliquent $32{,}87/39{,}2 \approx 83{,}8\,\%$ de l'inertie.

8. **Caractériser et nommer les classes** Pour interpréter une classe, on compare ses moyennes à celles de l'ensemble.

a) Calculer, pour chacune des deux classes, la moyenne de $X_1$ et de $X_2$, et les comparer aux moyennes générales $\overline{X}_1 = 4$ et $\overline{X}_2 = 3{,}4$.

b) Proposer un nom parlant pour chaque classe. Que dire de l'exploitation $E$ : est-elle très typique de sa classe ?

Correction ▼ [stat-0111]

## Exercice 2 CAH à la main : entraînement sur cinq exploitations

On reprend la même démarche qu'à l'exercice précédent, cette fois **en autonomie**. Cinq exploitations $V_1, \ldots, V_5$ d'un même terroir sont décrites par deux indicateurs notés de 0 à 10 :

- $X_1$ **(diversification) :** nombre et variété des cultures ;
- $X_2$ **(accès à l'eau) :** équipement d'irrigation et accès à la ressource.

| **Exploitation** | $X_1$ : diversification | $X_2$ : accès à l'eau |
|---|---|---|
| $V_1$ | 2 | 2 |
| $V_2$ | 3 | 2 |
| $V_3$ | 8 | 6 |
| $V_4$ | 9 | 7 |
| $V_5$ | 9 | 5 |

**À la main**

Mener **entièrement à la main** la CAH de Ward de ces cinq exploitations, en réutilisant les formules de l'exercice précédent. On rappelle que, pour deux individus seuls, $\Delta = \frac{1}{2}d^2$, et que pour une classe de masse $m$ et un individu seul, $\Delta = \frac{m}{m+1}\,d^2(\text{individu}, \text{centre de la classe})$. L'inertie est la somme des carrés des distances au centre de gravité.

1. **Nuage et inertie.** Placer les cinq exploitations, calculer le centre de gravité $G$ et l'inertie totale.

✓ **Contrôle** $G = (6{,}2\,;4{,}4)$ et $\mathcal{I}_{\text{tot}} = 68$.

2. **Matrice des distances.** Compléter le tableau des carrés des distances $d^2(i, j)$.

| $d^2$ | $V_1$ | $V_2$ | $V_3$ | $V_4$ |
|---|---|---|---|---|
| $V_2$ | | | | |
| $V_3$ | | | | |
| $V_4$ | | | | |
| $V_5$ | | | | |

✓ **Contrôle** la plus petite distance est $d^2(V_1, V_2) = 1$.

3. **La classification.** Mener la CAH de Ward jusqu'à la racine : donner, à chaque étape, la fusion retenue et sa hauteur $\Delta$. Les reporter dans le tableau.

| Étape | 1 | 2 | 3 | 4 |
|---|---|---|---|---|
| Fusion | | | | |
| Hauteur $\Delta$ | | | | |

✓ **Contrôle** les quatre hauteurs sont $0{,}5$ ; $1$ ; $\approx 1{,}67$ et $\approx 64{,}83$, et leur somme vaut $68 = \mathcal{I}_{\text{tot}}$.

> **Attention.** À l'une des étapes, deux fusions ont exactement le même coût. Repérer cette égalité, choisir l'une des deux fusions, puis vérifier que l'autre choix aurait donné les mêmes hauteurs de fusion. L'arbre obtenu est-il pour autant le même ?

4. **Dendrogramme.** Tracer l'arbre (hauteur = coût de fusion).

5. **Interprétation.** À l'aide du plus grand saut d'inertie, proposer un découpage en classes. Donner leur composition, la part d'inertie expliquée, et nommer les classes.

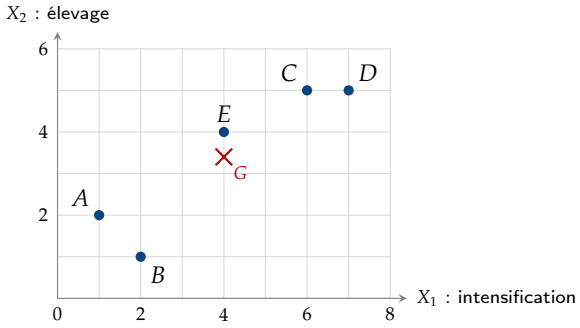
✓ **Contrôle** deux classes, $\{V_1, V_2\}$ et $\{V_3, V_4, V_5\}$, expliquant $\approx 95\,\%$ de l'inertie.

Correction ▼ [stat-0112]

# Corrections

## Correction de l'exercice 1 ▲

**1. Le nuage et son inertie.**




$G = (\overline{X}_1 ; \overline{X}_2) = (\frac{20}{5} ; \frac{17}{5}) = (\mathbf{4} ; \mathbf{3{,}4})$.

| | $A$ | $B$ | $C$ | $D$ | $E$ |
|---|---|---|---|---|---|
| $x_{i1} - \overline{X}_1$ | $-3$ | $-2$ | 2 | 3 | 0 |
| $x_{i2} - \overline{X}_2$ | $-1{,}4$ | $-2{,}4$ | 1,6 | 1,6 | 0,6 |
| $d^2(i, G)$ | 10,96 | 9,76 | 6,56 | 11,56 | 0,36 |

$\mathcal{I}_{\text{tot}} = 10{,}96 + 9{,}76 + 6{,}56 + 11{,}56 + 0{,}36 = \mathbf{39{,}2}$. L'exploitation $E$ est presque confondue avec l'exploitation moyenne.

**2. La matrice des distances.**

| $d^2$ | $A$ | $B$ | $C$ | $D$ |
|---|---|---|---|---|
| $B$ | 2 | | | |
| $C$ | 34 | 32 | | |
| $D$ | 45 | 41 | **1** | |
| $E$ | 13 | 13 | 5 | 10 |

Par exemple $d^2(A, D) = (1-7)^2 + (2-5)^2 = 36 + 9 = 45$ et $d^2(C, E) = (6-4)^2 + (5-4)^2 = 4 + 1 = 5$.

**3. La première fusion.**

a) Coûts $\Delta = \frac{1}{2} d^2$ :

| $\Delta$ | $A$ | $B$ | $C$ | $D$ |
|---|---|---|---|---|
| $B$ | 1 | | | |
| $C$ | 17 | 16 | | |
| $D$ | 22,5 | 20,5 | **0,5** | |
| $E$ | 6,5 | 6,5 | 2,5 | 5 |

b) Le plus petit coût est $\Delta(C, D) = 0{,}5$ : on réunit $C$ **et** $D$, les deux exploitations les plus proches.

**4. Mettre à jour, puis fusionner encore.**

a) $g_{CD} = (\frac{6+7}{2} ; \frac{5+5}{2}) = (6{,}5 ; 5)$, puis

$$\Delta(A, \{C, D\}) = \tfrac{2}{3}\left[(1-6{,}5)^2 + (2-5)^2\right] = \tfrac{2}{3} \times 39{,}25 \approx 26{,}17,$$
$$\Delta(B, \{C, D\}) = \tfrac{2}{3}\left[(2-6{,}5)^2 + (1-5)^2\right] = \tfrac{2}{3} \times 36{,}25 \approx 24{,}17,$$
$$\Delta(E, \{C, D\}) = \tfrac{2}{3}\left[(4-6{,}5)^2 + (4-5)^2\right] = \tfrac{2}{3} \times 7{,}25 \approx 4{,}83.$$

b) Entre exploitations encore seules ($A$, $B$, $E$), les coûts sont $\Delta(A,B) = 1$, $\Delta(A,E) = \Delta(B,E) = 6{,}5$. Le minimum de tous les coûts est $\Delta(A,B) = 1 < 4{,}83$ : la deuxième fusion réunit $A$ **et** $B$.

**5. Les dernières fusions.** $g_{AB} = (1{,}5\,;1{,}5)$.

a)

$$\Delta(E,\{C,D\}) \approx 4{,}83 \quad \text{(inchangé)},$$
$$\Delta(E,\{A,B\}) = \tfrac{2}{3}\left[(4-1{,}5)^2 + (4-1{,}5)^2\right] = \tfrac{2}{3} \times 12{,}5 \approx 8{,}33,$$
$$\Delta(\{A,B\},\{C,D\}) = \tfrac{2\times 2}{4}\left[(1{,}5-6{,}5)^2 + (1{,}5-5)^2\right] = 37{,}25.$$

La troisième fusion rattache $E$ **à** $\{C,D\}$, pour $\Delta \approx 4{,}83$.

b) $g_{CDE} = \left(\frac{6+7+4}{3}\,;\frac{5+5+4}{3}\right) \approx (5{,}67\,;4{,}67)$, d'où $d^2(g_{AB},g_{CDE}) = \left(\frac{25}{6}\right)^2 + \left(\frac{19}{6}\right)^2 = \frac{986}{36} \approx 27{,}39$ et

$$\Delta(\{A,B\},\{C,D,E\}) = \frac{2\times 3}{5} \times \frac{986}{36} \approx \mathbf{32{,}87}.$$

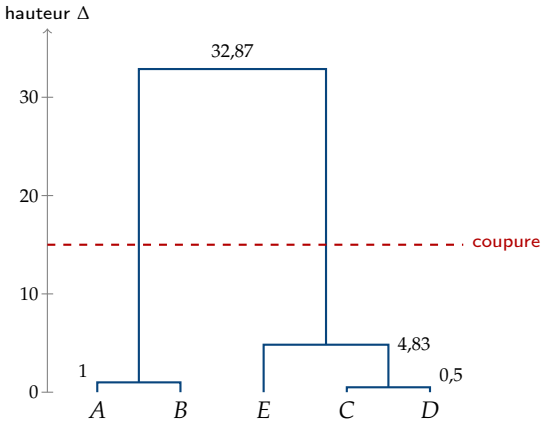
**6. Le dendrogramme.**

a)

| Fusion | $C$–$D$ | $A$–$B$ | $E$–$\{C,D\}$ | $\{A,B\}$–$\{C,D,E\}$ |
|---|---|---|---|---|
| Hauteur $\Delta$ | 0,5 | 1 | 4,83 | 32,87 |

b) $0{,}5 + 1 + 4{,}83 + 32{,}87 = 39{,}2 = \mathcal{I}_{\text{tot}}$ : le théorème de Huygens est vérifié. Au départ (cinq classes d'un seul individu), toute l'inertie est *inter*-classes ; chaque fusion en fait passer une part $\Delta$ en *intra*-classe ; à la fin (une seule classe), toute l'inertie est intra-classe.

c)




**7. Combien de classes ?**

a) Les hauteurs successives sont 0,5 ; 1 ; 4,83 ; 32,87. Le plus grand saut se situe entre la troisième fusion (4,83) et la dernière (32,87) : on coupe l'arbre entre ces deux hauteurs et on retient **deux classes**.

b) Classes $\{A,B\}$ et $\{C,D,E\}$. Elles expliquent $\mathcal{I}_B/\mathcal{I}_{\text{tot}} = 32{,}87/39{,}2 \approx \mathbf{83{,}8}\,\%$ de l'inertie : en résumant cinq exploitations par deux types, on ne perd que 16 % de l'information.

**8. Caractériser et nommer les classes.**

a)

| | $X_1$ : intensification | $X_2$ : élevage |
|---|---|---|
| Classe $\{A,B\}$ | 1,5 | 1,5 |
| Classe $\{C,D,E\}$ | 5,67 | 4,67 |
| Ensemble | 4 | 3,4 |

La classe $\{A,B\}$ est nettement *en dessous* de la moyenne sur les deux indicateurs ; la classe $\{C,D,E\}$ est *au-dessus* sur les deux.

b)

- $\{A,B\}$ : **exploitations peu intensifiées, à faible intégration de l'élevage** (systèmes manuels, peu d'intrants, peu d'animaux).

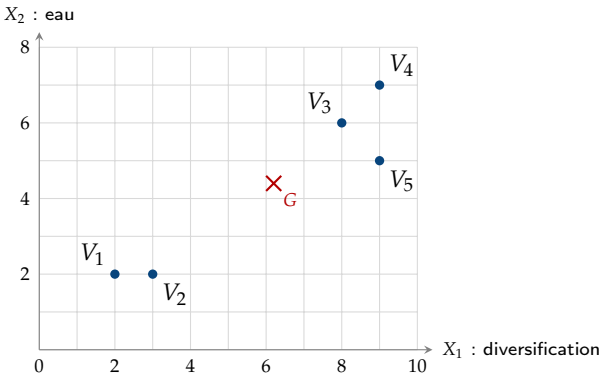
- $\{C, D, E\}$ : **exploitations intensifiées associant agriculture et élevage** (intrants, mécanisation et troupeau).

$E$ n'est pas très typique de sa classe : $d^2(E, g_{CDE}) \approx 2{,}78 + 0{,}44 = 3{,}22$, contre 0,22 pour $C$ et 1,89 pour $D$. C'est une exploitation *intermédiaire*, presque confondue avec l'exploitation moyenne $G$ ($d^2(E, G) = 0{,}36$) ; elle rejoint $\{C, D\}$ tardivement, et c'est elle qui changerait de classe en premier si les données bougeaient un peu. Sur le dendrogramme, sa fusion à 4,83, bien plus haute que 0,5 et 1, le signale.

---

## Correction de l'exercice 2 ▲

**1. Nuage et inertie.**




$G = (\frac{31}{5} ; \frac{22}{5}) = (\mathbf{6{,}2 ; 4{,}4})$.

| | $V_1$ | $V_2$ | $V_3$ | $V_4$ | $V_5$ |
|---|---|---|---|---|---|
| $x_{i1} - \overline{X}_1$ | $-4{,}2$ | $-3{,}2$ | 1,8 | 2,8 | 2,8 |
| $x_{i2} - \overline{X}_2$ | $-2{,}4$ | $-2{,}4$ | 1,6 | 2,6 | 0,6 |
| $d^2(i, G)$ | 23,4 | 16 | 5,8 | 14,6 | 8,2 |

$\mathcal{I}_{\text{tot}} = 23{,}4 + 16 + 5{,}8 + 14{,}6 + 8{,}2 = \mathbf{68}$.

**2. Matrice des distances.**

| $d^2$ | $V_1$ | $V_2$ | $V_3$ | $V_4$ |
|---|---|---|---|---|
| $V_2$ | **1** | | | |
| $V_3$ | 52 | 41 | | |
| $V_4$ | 74 | 61 | 2 | |
| $V_5$ | 58 | 45 | 2 | 4 |

**3. La classification.**

- *Étape 1.* Le plus petit coût est $\Delta(V_1, V_2) = \frac{1}{2} \times 1 = 0{,}5$ : on réunit $V_1$ et $V_2$, de centre $g_{12} = (2{,}5 ; 2)$.
- *Étape 2.* Coûts possibles : $\Delta(V_3, V_4) = \Delta(V_3, V_5) = \frac{1}{2} \times 2 = 1$, $\Delta(V_4, V_5) = 2$, et pour un point rattaché à $\{V_1, V_2\}$, $\Delta(V_3, \{V_1, V_2\}) = \frac{2}{3} \times 46{,}25 \approx 30{,}83$ (encore plus pour $V_4$ et $V_5$). **Égalité** : $V_3$ peut être réuni à $V_4$ ou à $V_5$ pour le même coût 1. Choisissons $\{V_3, V_4\}$, de centre $g_{34} = (8{,}5 ; 6{,}5)$.
- *Étape 3.*

$$\Delta(V_5, \{V_3, V_4\}) = \tfrac{2}{3}\left[(9 - 8{,}5)^2 + (5 - 6{,}5)^2\right] = \tfrac{2}{3} \times 2{,}5 \approx 1{,}67,$$

bien moins que $\Delta(V_5, \{V_1, V_2\}) = \frac{2}{3} \times 51{,}25 \approx 34{,}17$ ou $\Delta(\{V_1, V_2\}, \{V_3, V_4\}) = \frac{2\times 2}{4} \times 56{,}25 = 56{,}25$. $V_5$ rejoint $\{V_3, V_4\}$. Avec l'autre choix à l'étape 2 ($\{V_3, V_5\}$, centre $(8{,}5 ; 5{,}5)$), on trouve $\Delta(V_4, \{V_3, V_5\}) = \frac{2}{3} \times 2{,}5 \approx 1{,}67$ : **même hauteur**, même classe $\{V_3, V_4, V_5\}$.

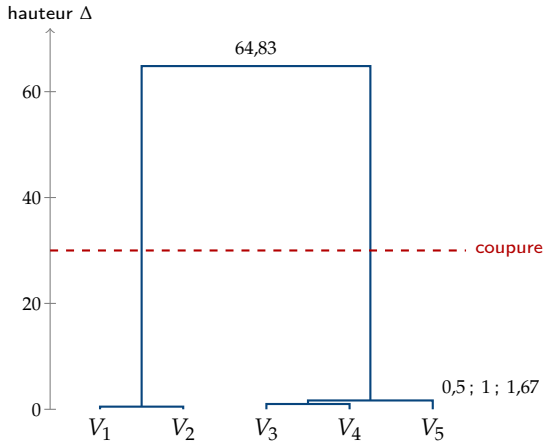
- *Étape 4.* $g_{345} = \left(\frac{26}{3}\,;6\right) \approx (8{,}67\,;6)$ et $d^2(g_{12}, g_{345}) = \left(\frac{37}{6}\right)^2 + 4^2 \approx 54{,}03$, d'où $\Delta = \frac{2\times 3}{5} \times 54{,}03 \approx 64{,}83$.

| Étape | 1 | 2 | 3 | 4 |
|---|---|---|---|---|
| Fusion | $V_1$–$V_2$ | $V_3$–$V_4$ | $V_5$–$\{V_3, V_4\}$ | $\{V_1, V_2\}$–$\{V_3, V_4, V_5\}$ |
| Hauteur $\Delta$ | 0,5 | 1 | 1,67 | 64,83 |

Contrôle : $0{,}5 + 1 + 1{,}67 + 64{,}83 = 68 = \mathcal{I}_{\text{tot}}$.

*L'égalité.* Les hauteurs ne dépendent pas du choix fait à l'étape 2, mais *l'arbre*, lui, en dépend : selon le choix, $V_3$ est d'abord réuni à $V_4$ ou à $V_5$. Une CAH n'est pas toujours unique ; en pratique, un logiciel tranche selon l'ordre des données. Ici cela ne change rien à la partition en deux classes.

4. **Dendrogramme.**




Les trois premières fusions sont presque invisibles à cette échelle : les exploitations de chaque groupe sont très proches les unes des autres.

5. **Interprétation.** Le saut de 1,67 à 64,83 écrase tous les autres : on coupe en **deux classes**, $\{V_1, V_2\}$ et $\{V_3, V_4, V_5\}$, qui expliquent $64{,}83/68 \approx$ **95,3** % de l'inertie.

| | $X_1$ : diversification | $X_2$ : accès à l'eau |
|---|---|---|
| Classe $\{V_1, V_2\}$ | 2,5 | 2 |
| Classe $\{V_3, V_4, V_5\}$ | 8,67 | 6 |
| Ensemble | 6,2 | 4,4 |

- $\{V_1, V_2\}$ : **exploitations peu diversifiées et mal équipées en eau** (cultures pluviales, peu de spéculations).
- $\{V_3, V_4, V_5\}$ : **exploitations diversifiées ayant un bon accès à l'eau**, ce qui leur permet de multiplier les cultures (contre-saison, maraîchage).

Les deux indicateurs vont de pair : l'accès à l'eau est sans doute une condition de la diversification. Avec cinq exploitations seulement, ce n'est qu'une piste à confirmer.

Étudiant(e) (Nom, Prénom) : .....

Promotion, groupe : .....

Email : .....